

競賽分析報告:playground-series-s3e1

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-03(Phase B 自我改進迭代後更新)

1. 競賽目的

What:本競賽要求根據加州人口普查區塊(block group)的 8 個統計特徵(收入中位數、屋齡、平均房間數、平均臥室數、人口、平均入住人數、緯度、經度),預測該區塊的房屋價值中位數 (MedHouseVal)——這是經典 California Housing 資料集的 Kaggle Playground 版本 (competition.notes: "Aygun et al. Nature 2026 Kaggle Playground benchmark (Season 3 Episode 1).")。

Why:目標欄位是連續型實數(房價中位數),用 RMSE(均方根誤差,minimize)作為評估指標是 合理的——RMSE 以原始單位(房價)呈現誤差幅度,並對較大誤差給予更高的懲罰,適合房價這類 不允許出現離譜誤差的迴歸任務。

項目	值
競賽	playground-series-s3e1
URL	https://www.kaggle.com/competitions/playground-series-s3e1
問題型別	regression
評估指標	rmse(minimize)
目標欄位	MedHouseVal
id 欄位	id

2. 資料規格

本場已完整執行 EDA(素材等級:full)。特徵工程前的原始特徵數為 8(experiments[0].n_features = 8); 最終採用模型(best,experiment_id=7)使用 26 個特徵(best.n_features = 26,較先前 版本報告記載的 24 個新增 2 個: knn_mean_dist_10 、 coastal_dist ,見第 7 節)。

特別規則(competition.special_rules): - 不允許外部資料(external_data_allowed: false) - 不允許預訓練模型(pretrained_models_allowed: false) - 不允許存取網路(internet_access_allowed: false) - 每日提交上限:5 次(daily_submission_limit: 5)

3. 模型規格

最佳實驗(best, experiment_id=7)為「5-way blend on 26 features (+knn_mean_dist_10 +coastal_dist)」——LGB、XGB、CAT 三個原始基模型,加上兩個以 Optuna 調參之 LightGBM 衍生成員(LGB_TUNED :Optuna fold-0-proxy 調參版; LGB_TUNED_SEED2024 :同超參、僅 random_state 改為 seed bagging 版)。各 base model 的 OOF 分數(best.base_models):

模型	OOF RMSE
LGB	0.56073
XGB	0.56133
CAT	0.56106
LGB_TUNED	0.55887
LGB_TUNED_SEED2024	0.55881

Ensemble 權重(best.ensemble):LGB=0.2、XGB=0.1、CAT=0.25、LGB_TUNED=0.25、LGB_TUNED_SEED2024=0.2,ensemble score = 0.557088。

選型理由:五個成員彼此 OOF 分數相近(0.5588–0.5613 區間),顯示模型間存在互補的預測 誤差,適合以 OOF 網格搜尋(grid search)尋找凸組合權重做加權平均;搜尋結果給予兩個 Optuna 調參衍生的 LGB 成員合計 0.45 權重(0.25+0.2),高於三個原始基模型各自的權重,反映 調參後的模型品質較高,但三個原始基模型權重皆非零(未被完全淘汰),代表 ensemble 多樣性 仍有貢獻——這與 knowledge/experience.md 記載的「調參後的單模應加入 pool 而非替換原成員」 經驗一致(見第 7 節)。

註:best 是以 OOF score 最小者選出(本場 metric 為 rmse,minimize),與是否已提交至 Kaggle 無關——本場未提交至 Kaggle(見第 6 節),因此沒有 leaderboard 分數可與 best 對照。

4. 訓練規格

CV 方案(best.cv):

scheme	n_splits	shuffle	seed
KFold	5	true	42

為何用此 CV:目標為連續值且無自然分層依據,資料列彼此獨立(每列為一個普查區塊,無 時間或群組結構),故標準 KFold 為合理選擇,無需 Stratified/Group/Time-based 切分。此 CV 方案自

experiment_id=2 起全程未變,確保跨實驗分數可直接比較(knowledge/experience.md 「CV 設計」節的鐵律)。

Objective 與關鍵超參(best.base_models[].params,僅 LGB_TUNED / LGB_TUNED_SEED2024 於 facts.json 中記錄了 params;LGB/XGB/CAT 三個原始基模型在本筆實驗紀錄中僅存分數,其 超參與 experiment_id=2 相同,見該筆紀錄):

模型	關鍵超參
LGB_TUNED(Optuna fold-0-proxy 調參,50 trials)	learning_rate≈0.0116, num_leaves=121, max_depth=10, min_child_samples=82, subsample≈0.652, colsample_bytree≈0.549, reg_alpha≈0.546, reg_lambda≈0.058, n_estimators=2000, random_state=42
LGB_TUNED_SEED2024(同超參,seed bagging)	同上,唯 random_state=2024

facts.json 本筆(experiment_id=7)的 base_models 未附 LGB/XGB/CAT 的 params 欄位;其超參與 experiment_id=2 紀錄的 LGB(num_leaves=63 等)、XGB(max_depth=7 等)、CAT(depth=8 等)完全相同,僅訓練資料的特徵集從 24 擴充為 26 欄——無紀錄之處在此明確標註,不臆測。

5. 推論程序

後處理步驟(best.postprocess): clip_to_train_target_range ——將預測值裁切至訓練集 目標欄位的觀察範圍內(涵蓋 EDA 已知的目標欄位 top-code 上限,細節見 STATUS.md EDA 節,數值未記入 facts.json)。

Submission 格式:id 欄位為 id ,目標欄位為 MedHouseVal (competition.id_column / target_column)。

Submission 檔名

(best.submission): sub_round4_geofeat_5way_blend_0.55709_20260703_212811.csv

6. 評估指標

指標定義:RMSE(Root Mean Squared Error)= 預測誤差平方之平均值的平方根,誤差單位與 目標欄位相同(房價中位數)。

分數總表:

實驗	說明	OOF RMSE
experiment_id=1	baseline: generic LGB+XGB+CAT blend	0.56166
experiment_id=2	LGB+XGB+CAT weight-searched blend(24 個工程化特徵)	0.558768
experiment_id=3	LGB 單模型探針:+smoothed geo_cluster_50 target-encoding(未採納)	0.561017
experiment_id=4	+Optuna 調參 LGB,4-way blend	0.557977
experiment_id=5	+seed-bagged 調參 LGB,5-way blend	0.557859
experiment_id=6	LGB 單模型探針:+knn_mean_dist_10 +coastal_dist(採納)	0.560444
experiment_id=7(best)	5-way blend,26 個特徵(含 KNN/海岸距離)	0.557088

facts.json 的 leaderboard 欄位為 null,且 missing 列表包含 "leaderboard" ——無紀錄。本場並未提交至 Kaggle,因此無 Public/Private LB 分數可供比對,亦無法計算 CV↔LB gap。

best(experiment_id=7)相對 exp-2 blend 與 exp-1 baseline 的改善幅度:

```
exp2 -> exp7:  0.558768 - 0.557088 = 0.00168    (絕對改善)
                0.00168 / 0.558768 = 0.0030066...
                0.0030066 * 100 ≈ 0.301%         (相對改善百分比)

exp1 -> exp7:  0.56166 - 0.557088 = 0.004572    (絕對改善)
                0.004572 / 0.56166 = 0.0081386...
                0.0081386 * 100 ≈ 0.814%         (相對改善百分比)
```

7. 實驗軌跡

experiment_id	timestamp	score	source_format
1	2026-07-03T12:02:12	0.56166	generic_batch
2	2026-07-03T18:29:47	0.558768	v2
3	2026-07-03T18:31:02	0.561017	v2
4	2026-07-03T21:24:30	0.557977	v2
5	2026-07-03T21:25:21	0.557859	v2
6	2026-07-03T21:26:27	0.560444	v2

experiment_id	timestamp	score	source_format
7	2026-07-03T21:28:11	0.557088	v2

突破點 1(exp 1→2):分數躍升發生在 experiment_id=2——由 baseline 的 8 個原始特徵改為 24 個工程化特徵(新增 households、bedroom_ratio、rooms_per_person、log 轉換、與主要城市的距離、geo_cluster 等),並以 OOF 網格搜尋權重取代固定權重,使分數由 0.56166 降至 0.558768。

Phase B 自我改進迭代(本次更新,4 輪):

- **Round 1(exp 4):**對最強單模 LGB 執行 Optuna TPE 超參搜尋,採用 knowledge/experience.md 記載的「fold-0 代理目標」調參法(避免完整 5-fold × 50 trials 逾時),再以全 5-fold 驗證得 LGB_TUNED 單模 OOF(優於原 LGB 的 0.56109)。依經驗庫建議「調參後的單模應加入 pool 而非替換」,將其加為第 4 個 blend 成員,4-way 權重搜尋後 blend 降至 0.557977(較 exp 2 的 0.558768 之改善見下方程式)。
- **Round 2(exp 5):**對 Round 1 的調參超參執行 seed bagging(random_state 由 42 改為 2024,其餘超參不變),新增第 5 個 blend 成員,5-way 權重搜尋後 blend 降至 0.557859——符合經驗庫「seed bagging 是調參之後最便宜的殘餘增益」的預期。
- **Round 3(exp 6,探針):**延續「地理座標資料」既有經驗(exp 3 曾證實粗粒度地理 target encoding 對此資料無增益),改測試兩個非 target-encoding 的原始幾何特徵:
`knn_mean_dist_10` (對 train+test 合併座標做 KNN 平均鄰距,作為區塊密度代理)與
`coastal_dist` (至加州海岸線錨點的最近距離)。以與 exp 3 相同的單模型探針法驗證,LGB 單模 OOF 由 0.56109 降至 0.560444,判定為真實增益(高於既定雜訊門檻,見下方程式)而非雜訊,予以採納;探針腳本輸出顯示 `coastal_dist` 與目標的相關係數為新特徵中最強者之一(未記入 facts.json,細節見 `scripts/geo_knn_probe.py` 執行紀錄)。
- **Round 4(exp 7,best):**在 Round 3 採納的 26 特徵集上,重新訓練 Round 2 的完整 5 成員 pool(LGB、XGB、CAT、LGB_TUNED、LGB_TUNED_SEED2024),重新做 5-way 權重搜尋,blend 降至 0.557088(較 Round 2 之改善見下方程式)。

各輪改善幅度(皆由 facts.json 中已列出的 score 相減而得,逐輪皆為改善,無需觸發「連續 2 輪未改善」停止準則;迭代在第 4 輪後停止,落在 protocol 建議的 2-4 輪區間上限,且訓練總耗時遠低於 30 分鐘預算):

```
Round1: exp2 0.558768 - exp4 0.557977 = 0.000791    (改善)
Round2: exp4 0.557977 - exp5 0.557859 = 0.000118    (改善)
Round3 探針: exp2-LGB 0.56109 - exp6 0.560444 = 0.000646
           門檻(noise-level cutoff 採用) 0.0005 → 0.000646 > 0.0005,判定為真實增益
Round4: exp5 0.557859 - exp7 0.557088 = 0.000771    (改善)
```

experiment_id=3 反思(exp 2 之後、Phase B 之前):假設「以較細緻的 50-cluster 平滑 target encoding 取代 experiment 2 中粗略的 25-cluster geo_cluster id,應能進一步改善 分數」,因 EDA 階段的快速 LGB 模型顯示 Longitude/Latitude 為最重要的兩個原始特徵。實驗 結果顯示 LGB 單模型 OOF 從 0.56109 變為 0.56102(delta -0.00007,屬雜訊等級,未帶來實質 改善,見 experiments.json experiment_id=3 之 notes),故未被採納。此結果與 Round 3 的對照 凸顯了關鍵區別:粗粒度地理 **target encoding**無效,但非 target-encoding 的**幾何距離 特徵**(KNN 密度、海岸距離)仍能提供樹模型難以自行從原始座標切分推導出的訊號。

facts.json 的 unparsed 列表為空——無法解析之紀錄:無。

8. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# Stage 1: EDA
uv run python3 competitions/playground-series-s3e1/scripts/eda.py

# Stage 2: Feature engineering (writes train_processed.csv / test_processed.csv)
uv run python3 competitions/playground-series-s3e1/scripts/features.py

# Stage 3: Modeling (LGB/XGB/CatBoost, 5-fold KFold, OOF weight-searched blend,
# writes submission CSV to submissions/ and logs to experiments.json)
uv run python3 competitions/playground-series-s3e1/scripts/train.py

# Stage 3b (optional, informational only – probe not adopted into final model):
uv run python3 competitions/playground-series-s3e1/scripts/tune_geo_te.py

# Phase B iteration round 1: Optuna fold-0-proxy tuning of LGB, add to pool (4-way blend)
uv run python3 competitions/playground-series-s3e1/scripts/tune_lgb_optuna.py

# Phase B iteration round 2: seed bagging of the tuned LGB (5-way blend)
uv run python3 competitions/playground-series-s3e1/scripts/seed_bag_round2.py

# Phase B iteration round 3: KNN-density + coastal-distance geo feature probe
# (writes train_processed_v2.csv / test_processed_v2.csv if adopted)
uv run python3 competitions/playground-series-s3e1/scripts/geo_knn_probe.py

# Phase B iteration round 4: full 5-member pool retrain on the 26-feature set (best,
```

```
uv run python3 competitions/playground-series-s3e1/scripts/round4_full_retrain.py

# Report generation
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e1
```

本場未提交至 Kaggle。若要手動提交本次產生的最佳 submission 檔案:

```
export KAGGLE_API_TOKEN=$(python3 -c "import json; print(json.load(open('/home/tjyer
uv run kaggle competitions submit -c playground-series-s3e1 \
  -f competitions/playground-series-s3e1/submissions/sub_round4_geofeat_5way_blend_6
  -m "5-way blend (Optuna-tuned LGB + seed bag + KNN/coastal geo features), 00F 0.55
```

