

競賽分析報告:playground-series-s3e1

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

目錄

1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格表	4
3.4 推論表	5
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	5
5. 效能對照(逐階段)	6
6. 總結	7
7. 重現指令	8

1. 競賽目的

What:依加州人口普查區塊(block group)的 8 個統計特徵(收入中位數、屋齡、平均房間數、平均臥室數、人口、平均入住人數、緯度、經度)預測該區塊的房屋價值中位數(`MedHouseVal`), 為連續數值輸出的迴歸問題,即經典 California Housing 資料集的 Kaggle Playground 版本。

Why:評估指標為 **RMSE(minimize)**。房價中位數為連續實數,RMSE 以原始單位呈現誤差 幅度並對大誤差施以平方懲罰,能引導模型優先壓制嚴重錯估,適合房價這類不允許離譜誤差的 迴歸任務。

項目	值
競賽	playground-series-s3e1
問題型別	regression
評估指標	rmse(minimize)
目標欄位	MedHouseVal

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第2版。交叉驗證採標準 KFold(shuffle)5 折(設計理由見第3.3節)。

2.2 本場專業術語

專業術語	定義
clip(裁切)	將預測值限制在訓練集目標值的範圍內,避免離譜的外插預測
top-code	資料集把高於某上限的目標值一律記為該上限值,形成分數的天花板

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段1 | 無 skill 基線

- 1.1 單模型基線 — 使用
- 1.2 三模型 blend — 使用

階段2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(併入第2次實驗,無獨立分數)
- 2.2 EDA 驅動特徵工程 — 使用(併入第2次實驗,無獨立分數)
- 2.3 指標感知後處理 — 使用(clip 裁切,併入第2次實驗)
- 2.4 場內反思回退 — 使用(第3次實驗 先以單模快速試地理目標編碼,判定屬雜訊未採納)

階段3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 使用
- 3.3 調參入池 — 使用(含於3.2之作法)
- 3.4 seed bagging — 使用
- 3.5 結構化去噪 — 本場未使用

階段4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 使用

- 4.3 先驗注入+去重 — 使用(v2 內建)
- 4.4 邊界推進 mutation — 本場未使用
- 4.5 預算相位機 — 本場未使用

階段 5 | +外部想法注入

- 5.1 外部想法庫先驗 — 使用(快評注入 stacking meta 模型,在階段4收斂點以快取 OOF 評估;未勝過階段4 → 階段5=階段4)
- 5.2 重組 mutation — 本場未使用(機制已建置[harness_v4 機械版 + LLM 版];跨場 pilot 實測與 mega-blend 搜尋冗餘、無增益,見 docs/recombine_findings)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	37,137
test 列數	24,759
原始欄位數	8
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

8 個原始特徵皆為數值型、無類別欄位;train/test 皆無缺失值、train 無重複列,亦無 高共線特徵對。目標 MedHouseVal 右偏(skew 0.97,mean 2.08、median 1.808),且在 5.00001 處被 top-code(佔 train 4.92%)——此為資料本身的誤差天花板,非建模可修復。

MedInc 為最強線性預測子(Pearson 0.70);緯度/經度單看相關性弱,但 EDA 快速 LGB 的重要度 排名將其列為前二,顯示地理訊號為非線性,此觀察驅動了後續的地理特徵工程。train/test 分佈 幾乎一致(平均值差異最大者為 Population 的 1.12%),無 covariate shift 疑慮。

3.2 實驗總表

語意澄清(本報告全文適用):本場指標為連續 RMSE,無取整議題,「決策分數」即(原始) OOF RMSE,兩欄恆相等。第 3、6 次實驗 為 **LGB 單模快速試驗**(新想法先只訓練單一 LGB 看分數,過門檻才納入完整流程),其分數與 第 2 次實驗之 LGB 成員 (0.56109)相比,不與 blend 分數相比;其餘各列為 blend 分數。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	1.2	LGB/XGB/CAT(.2/.2/.6)	8	0.56166	0.56166	是,後由 第 2 次實驗 取代
2	2	LGB/XGB/CAT(.45/.15/.40)	24	0.558768	0.558768	是,階段 2 最佳
3	2.4	LGB 單模(+geo_te)	25	0.561017	0.561017	否,雜訊等級
4	3.2	+LGB_TUNED(4-way)	24	0.557977	0.557977	是

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
5	3.4	+LGB_TUNED_SEED2024(5-way)	24	0.557859	0.557859	是
6	3	LGB 單模(+2 個 geo 特徵)	26	0.560444	0.560444	是,特徵獲採納
7	3	5-way blend(26 特徵)	26	0.557088	0.557088	是,線性迭代最佳
8	4.2	7-way blend(node #14)	26	0.556329	0.556329	是,本場最佳(僅 OOF 分數)
9	5	外部注入快評候選(EXT-09(stacking);沿用階段4成員 OOF)	26	0.556369	0.556369	否(未勝過階段4,見 § 5)

補充說明:第 8 次實驗 為樹搜尋結果,只算出 OOF 分數——未產生 test 預測、未提交 Kaggle, 該筆實驗紀錄無 submission 欄位;其特徵數 26 出自紀錄的文字備註(與 第 7 次實驗 同一特徵集), 非正式數值欄位。

最佳解成員表(第 8 次實驗,7-way blend)

成員	權重	solo 分數	備註
LGBORIG	0.150	0.560732	—
XGBORIG	0.036	0.561331	—
CATORIG	0.249	0.561063	—
SEEDBAG	0.186	0.558812	即 LGB_TUNED_SEED2024,root 之 seed-bag 同胞
REGNUDGE	0.050	0.558208	正則化微調之 tuned-LGB;全樹最佳 solo
XGB_deep	0.041	無紀錄	刻意多樣性成員
CEILING	0.289	0.561227	top-code 感知的兩階段組合成員;solo 最弱但權重最大,單筆最大增益

選型理由:三樹模型 solo 分數相近、誤差互補,適合 OOF 權重搜尋的凸組合;階段 3 的線性 迭代依「調參後單模加入池而非替換」原則逐步擴充成員。第 8 次實驗 由樹搜尋工具(第 2 版)的 權重搜尋找到(評分時先做 clip 裁切再計分;22 個評估節點,耗時 190.3 秒),CEILING 成員 印證「blend 貢獻 ≠ solo 分數」。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1	5fold	5	無紀錄
2	KFold(shuffle)	5	42
3	KFold(shuffle)	5	42
4	KFold(shuffle)	5	42
5	KFold(shuffle)	5	42
6	KFold(shuffle)	5	42
7	KFold(shuffle)	5	42
8	KFold(shuffle)	5	42

目標為連續值、各列為獨立普查區塊(無群組/時間結構),且 train/test 分佈近乎一致,標準 KFold 即為教科書式正解;自 第 2 次實驗 起 CV 全程固定,確保跨實驗分數可直接比較。

Objective 一律為 RMSE。第 4 次實驗 之 LGB_TUNED 以 Optuna(TPE)調參——每組參數先只在第 0 折 評分以省時,勝出者再以完整 5 折復驗(50 trials,搜尋耗時 74.3 秒、全 CV 復驗 13.2 秒),關鍵超參:learning_rate≈0.0116、num_leaves=121、max_depth=10、min_child_samples=82;seed-bag 成員僅將 random_state 由 42 改為 2024。第 8 次實驗 新增成員(REGNUDGE、XGB_deep、CEILING)之超參無紀錄。

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無後處理紀錄	sub_generic_0.56166_20260703_120212.csv	否
2	clip_to_train_target_range	sub_lgb_xgb_cat_blend_0.55877_20260703_182947.csv	否
3	無後處理紀錄	無紀錄(單模快速試驗)	否
4	clip_to_train_target_range	sub_lgb_xgb_cat_lgbtuned_blend_0.55798_20260703_212430.csv	否
5	clip_to_train_target_range	sub_5way_seedbag_blend_0.55786_20260703_212521.csv	否
6	無後處理紀錄	無紀錄(單模快速試驗)	否
7	clip_to_train_target_range	sub_round4_geofeat_5way_blend_0.55709_20260703_212811.csv	否
8	clip(於評分函式內對 OOF 裁切評分)	無紀錄(僅 OOF 分數,未產生 test 預測)	否

id_column = id、target_column = MedHouseVal。第 8 次實驗 與 第 2-7 次實驗 的差異在裁切時點:線性 各輪僅於 submission 階段裁切,第 8 次實驗 於權重搜尋的評分函式內部即以裁切後 OOF 評分。本場為 無人值守 批次執行,所有 submission 檔皆未上傳 Kaggle。

3.5 評估指標 / 排行榜

指標定義:RMSE = 預測誤差平方平均之平方根,單位與 MedHouseVal 相同。

本場未提交 Kaggle,無排行榜紀錄,故無排行榜表,亦無 CV↔LB gap 可計。全場分數的唯一比較 基準為同一固定 CV 下的 OOF RMSE,最佳為 第 8 次實驗 之 **0.556329**(各實驗與各成員分數見第 3.2 節)。

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	2026-07-03T12:02:12	0.56166	1.2	8 原始特徵三模型 blend,固定權重基線
2	2026-07-03T18:29:47	0.558768	2	24 工程化特徵+OOF 權重搜尋,全場最大單筆躍升
3	2026-07-03T18:31:02	0.561017	2.4	單模快速試 geo target-encoding,增益屬雜訊未採納
4	2026-07-03T21:24:30	0.557977	3.2	Optuna 調參 LGB 加入池,4-way blend 改善

實驗編號	時間	決策分數	階段	摘要
5	2026-07-03T21:25:21	0.557859	3.4	seed-bag 調參 LGB 為第 5 成員,續改善
6	2026-07-03T21:26:27	0.560444	3	KNN 鄰距+海岸距離特徵,LGB 單模快速試驗過門檻採納
7	2026-07-03T21:28:11	0.557088	3	5 成員池於 26 特徵全量重訓,線性迭代最佳
8	2026-07-04T11:59:43	0.556329	4.2	7-way blend(先裁切再評分,node #14),本場最佳
9	2026-07-08T11:46:18	0.556369	5	外部注入快評:EXT-09(stacking) 候選 OOF 未勝過階段4,不採納

- 轉折 1(第 1 次實驗→第 2 次實驗):特徵工程(比例、log 轉換、城市距離、geo_cluster)加上 OOF 權重搜尋,0.56166→0.558768,為全場最大單筆增益。
- 轉折 2(第 3 次實驗 vs 第 6 次實驗):粗粒度地理 target-encoding 無效(第 3 次實驗,雜訊等級),但非 target-encoding 的幾何特徵(KNN 密度、海岸距離)帶來真實增益(第 6 次實驗)——同一「地理」槓桿、不同機制,結局相反。
- 轉折 3(第 7 次實驗→第 8 次實驗):樹搜尋以「先裁切再評分」與 top-code 感知的 CEILING 成員把分數推至 0.556329;CEILING solo 最弱卻拿最大權重,是全樹單筆最大增益來源。

5. 效能對照(逐階段)

階段	配置	分數	相對改善
1	基線(Claude Code 直接執行,未引入 skill;第 1 次實驗 通用批次 blend)	0.56166	—(基線)
2	+ kaggle-agent skill 六階段流程(第 2 次實驗 手刻管線)	0.558768	0.51%
3	+ self-improvement 線性迭代(第 7 次實驗 四輪終點)	0.557088	0.30%
4	+ 樹搜尋(第 8 次實驗,node #14 7-way blend)	0.556329	0.14%
5	+ 外部想法注入(第 9 次實驗,快評)	0.556329	0.00%(未勝過)

相對改善計算式(每階段對前一階段)

階段1→2: $0.56166 - 0.558768 = 0.002892$,相對改善 $0.002892 / 0.56166 = 0.5149\%$
階段2→3: $0.558768 - 0.557088 = 0.001680$,相對改善 $0.001680 / 0.558768 = 0.3007\%$
階段3→4: $0.557088 - 0.556329 = 0.000759$,相對改善 $0.000759 / 0.557088 = 0.1362\%$
階段4→5: 注入候選 0.556369 未勝過階段4 0.556329,搜尋保留階段4 → 相對改善 0.00%(外部注入無增益)

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:CAT)	0.56391	第 1 次實驗
1.2(三模權重 blend)	0.56166	第 1 次實驗
2.4(場內反思:單模快速試 geo_cluster_50 平滑目標編碼,判定雜訊未採納)	0.561017	第 3 次實驗

子階段	分數	出處
3.2(Optuna 入池)	0.557977	第 4 次實驗
3.4(seed bagging)	0.557859	第 5 次實驗
4.2(樹搜尋 7-way,先裁切再評分)	0.556329	第 8 次實驗

階段 5 | + 外部想法注入

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-09:stacking**——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic),以 nested-CV 避免洩漏。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們**已算好的 OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

```
階段5 注入候選(stacking)OOF RMSE = 0.556369
階段4 冠軍          OOF RMSE = 0.556329
差距 = -0.000040 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4
```

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場資料乾淨(無缺失、無重複列)且全為數值特徵,建模的兩個結構性事實在 EDA 即已確立:目標在 5.00001 處被 top-code(佔 train 4.92%),構成誤差天花板;地理訊號強但非線性,單變量相關性看不出來。這兩點分別決定了後段的裁切後處理與前段的地理特徵工程方向。

關鍵決策有二。其一是自第 2 次實驗起固定 KFold(5 折、shuffle、seed 42)不再變動,使全場八個實驗的 OOF 分數可直接比較;其二是先試後納的紀律——新想法一律先只訓練單一 LGB 快速驗證,過雜訊門檻才併入池(第 6 次實驗 採納、第 3 次實驗 否決),避免把雜訊當進步。

增益來源逐階遞減且各有歸屬:階段1→2 靠特徵工程與權重搜尋(0.56166→0.558768),是最大單筆增益;階段2→3 靠線性迭代四輪(調參、seed bagging、幾何特徵)推進至 0.557088;階段3→4 靠樹搜尋的兩個本場專屬作法——「先裁切再評分」與 top-code 感知的 CEILING 成員——收於 0.556329。

結果的可信度建立在同一固定 CV 的 OOF 之上,且逐階皆為正向改善;但須如實註記:本場全程未提交 Kaggle,無 LB 外部驗證,且第 8 次實驗為只算出 OOF 分數的搜尋產物、未產生 test 預測,目前可直接提交的最佳檔案仍是第 7 次實驗的 submission。

重現本實驗的最短路徑:見第 7 節。

階段 5(外部想法注入) 經快評未勝過階段4:注入機制可運作、也產生了候選(stackings),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 階段 2:EDA
uv run python3 competitions/playground-series-s3e1/scripts/eda.py

# 階段 2:特徵工程(輸出 train_processed.csv / test_processed.csv)
uv run python3 competitions/playground-series-s3e1/scripts/features.py

# 階段 2 / 第 2 次實驗:建模(LGB/XGB/CatBoost,5-fold KFold,00F 權重搜尋 blend)
uv run python3 competitions/playground-series-s3e1/scripts/train.py

# 第 3 次實驗(2.4,僅供參考——單模快速試驗未採納):
uv run python3 competitions/playground-series-s3e1/scripts/tune_geo_te.py

# 3.2 / 第 4 次實驗:Optuna 調參 LGB(僅以第 0 折評分挑參),加入池(4-way blend)
uv run python3 competitions/playground-series-s3e1/scripts/tune_lgb_optuna.py

# 3.4 / 第 5 次實驗:調參 LGB 的 seed bagging(5-way blend)
uv run python3 competitions/playground-series-s3e1/scripts/seed_bag_round2.py

# 階段 3 / 第 6 次實驗:KNN 密度 + 海岸距離地理特徵(單模快速試驗)
# (若採納會輸出 train_processed_v2.csv / test_processed_v2.csv)
uv run python3 competitions/playground-series-s3e1/scripts/geo_knn_probe.py

# 階段 3 / 第 7 次實驗:5 成員池於 26 特徵全量重訓
uv run python3 competitions/playground-series-s3e1/scripts/round4_full_retrain.py

# 4.2 / 第 8 次實驗:樹搜尋(可中斷續跑;只算 00F 分數、不產生 submission)
uv run python3 tree_search/run_s3e1.py

# 報告產生(本檔)
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e1

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 00F、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s3e1
```

本場未提交至 Kaggle。若要手動提交目前可提交的最佳 submission 檔(第 7 次實驗):

```
export KAGGLE_API_TOKEN=$(python3 -c "import json; print(json.load(open('/home/tjyen/.kaggle/kaggle.json'))['key'])"
uv run kaggle competitions submit -c playground-series-s3e1 \
    -f competitions/playground-series-s3e1/submissions/sub_round4_geofeat_5way_blend_0.55709_20260703_21281 \
    -m "5-way blend (Optuna-tuned LGB + seed bag + KNN/coastal geo features), 00F 0.557088"
```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 uv run 。