

競賽分析報告:playground-series-s3e3

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

目錄	
1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格表	4
3.4 推論表	4
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	5
5. 效能對照(逐階段)	6
6. 總結	7
7. 重現指令	7

1. 競賽目的

What:依員工人事資料(年齡、職級、月薪、任職年資、各項滿意度評分、是否加班等 33 個 原始欄位)預測其是否離職(Attrition),為二元分類問題。

Why:評估指標為 **ROC-AUC(maximize)**。離職樣本僅 200 筆、留任 1477 筆,類別嚴重 不平衡;ROC-AUC 衡量「將實際離職者排在較高風險分數」的排序能力,不受分類門檻與類別比例 影響,較準確率等門檻敏感指標更適合此類不平衡二元分類問題。

項目	值
競賽	playground-series-s3e3
問題型別	classification
評估指標	roc_auc(maximize)
目標欄位	Attrition

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第2版。交叉驗證採依 Attrition 分層的 StratifiedKFold(設計理由見第3.3節)。

2.2 本場專業術語

專業術語	定義
KITCHENBLEND	本場樹搜尋中「把當時已評估的全部 solo 節點都納入混合」的節點名稱(即《前言》§5 的 mega-blend 作法)

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段1 | 無 skill 基線

- 1.1 單模型基線 — 使用
- 1.2 三模型 blend — 使用

階段2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(併入第2、3次實驗,無獨立分數)
- 2.2 EDA 驅動特徵工程 — 使用(併入第2、3次實驗,無獨立分數)
- 2.3 指標感知後處理 — 本場未使用(ROC-AUC 無需後處理)
- 2.4 場內反思回退 — 使用(第2次實驗→第3次實驗,移除不平衡加權並加強正則化)

階段3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 使用
- 3.3 調參入池 — 使用(含於3.2之作法)
- 3.4 seed bagging — 使用
- 3.5 結構化去噪 — 本場未使用

階段4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 使用

- 4.3 先驗注入+去重 — 使用(v2 內建)
- 4.4 邊界推進 mutation — 本場未使用
- 4.5 預算相位機 — 本場未使用

階段 5 | +外部想法注入

- 5.1 外部想法庫先驗 — 使用(快評注入 rank averaging,在階段4收斂點以快取 OOF 評估;未勝過階段4 → 階段5=階段4)
- 5.2 重組 mutation — 本場未使用(機制已建置[harness_v4 機械版 + LLM 版];跨場 pilot 實測與 mega-blend 搜尋冗餘、無增益,見 docs/recombine_findings)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	1677
test 列數	1119
原始欄位數	33(25 個數值 + 8 個類別)
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

目標 Attrition 為 0/1 整數標籤:離職(1)200 筆、留任(0)1477 筆,平均值 0.119261、偏度 2.351659,類別嚴重不平衡。EDA 已執行:train/test 皆無缺失值、無重複列、無 test 未見類別; EmployeeCount、StandardHours 標準差為 0、Over18 僅單一取值,三欄為常數,特徵工程時剔除。

高共線特徵對清單為空(未達自動門檻),但另一份進度筆記記錄年資類特徵彼此相關 0.75-0.79、JobLevel ↔ MonthlyIncome $r=0.91$,屬中高度冗餘。特徵數上,第 1 次實驗使用 33 個原始欄位,第 2-5、7 次實驗經特徵工程展開為 48 個,第 6 次實驗改用 40 個(類別欄保留原始字串供 CatBoost 原生處理)。

3.2 實驗總表

語意澄清(本報告全文適用):本場指標 ROC-AUC 為連續排序指標,無取整等後處理,故各實驗的「原始 OOF」即「決策分數」。另,最佳解紀錄以 OOF 分數最大者選出:最佳解為第 8 次實驗之樹搜尋結果,只算出 OOF 分數、未產生 test 預測;本場所有實驗皆未提交 Kaggle 排行榜,下文不再重複解釋。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	1.2	LGB+XGB+CAT blend	33	0.81624	0.81624	基線
2	2	LGB+XGB+CAT blend	48	0.819008	0.819008	否,旋被第 3 次實驗取代
3	2.4	LGB+XGB+CAT blend	48	0.832925	0.832925	是,階段 2 冠軍
4	3.2	LGB_tuned(Optuna,solo)	48	0.837305	0.837305	是,入池

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
5	3.4	5-way blend(+seed bag)	48	0.837776	0.837776	是
6	3	CAT_native(solo,診斷)	40	0.814259	0.814259	否,診斷用
7	3	6-way rank-average blend	48	0.83814	0.83814	是,線性迭代冠軍
8	4.2	KITCHENBLEND(全 solo 池混合)	無紀錄	0.845051	0.845051	是,本場最佳
9	5	外部注入快評候選(EXT-12(rank);沿用階段4 成員 OOF)	無紀錄	0.839770	0.839770	否(未勝過階段4,見 § 5)

最佳解成員表:第 8 次實驗 之 KITCHENBLEND 為「當時已評估之所有 solo 節點」的全池混合 (權重由演算法在 OOF 上搜尋而得),成員隨搜尋進度變動,該筆實驗紀錄未附結構化 的成員清單——成員/權重/solo 分數無紀錄,依規範不逐一列出。線性迭代冠軍 第 7 次實驗 之權重搜尋 結果為 LGB_orig 0.3、LGB_tuned 0.7,其餘成員(XGB/CAT_orig/LGB_tuned_seed2024/ CAT_native)權重皆為 0,以 rank-average 合併。

選型理由:三個梯度提升樹在表格資料上穩健,以權重搜尋決定集成比例;各輪權重搜尋一致將 CatBoost 權重收斂為 0(第 6 次實驗 原生類別處理將其 solo 由 0.762684 拉升至 0.814259,仍為最弱 成員),確認其在此小樣本資料上結構性偏弱。階段 3 的線性迭代聚焦 LightGBM:Optuna 直接以 完整 5-fold CV AUC 為目標(第 4 次實驗)、調參版入池加 seed bagging(第 5 次實驗)、終以 rank-average 收尾(第 7 次實驗)。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1	5fold	5	無紀錄
2	StratifiedKFold	5	42
3	StratifiedKFold	5	42
4	StratifiedKFold	5	42
5	StratifiedKFold	5	42
6	StratifiedKFold	5	42
7	StratifiedKFold	5	42
8	StratifiedKFold	5	42

類別不平衡下,一般隨機 K-fold 會使各折正負比例不穩、驗證 AUC 波動;第 2 次實驗 起改用依 Attrition 分層的 StratifiedKFold(seed=42),且 第 2–8 次實驗(含樹搜尋)沿用同一組固定折,跨實驗分數可直接比較。第 4 次實驗 之 Optuna 設定(TPE、50 trials、實際耗時 111.3 秒)與最佳 超參(num_leaves=3、max_depth=4 等)僅記於實驗紀錄的文字備註;其餘模型之損失函數/超參 無結構化紀錄。

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無後處理紀錄	sub_generic_0.81624_20260703_120255.csv	否
2	無後處理紀錄	sub_blend_0.81901_20260703_183757.csv	否

實驗編號	後處理	submission 檔	是否已提交
3	無後處理紀錄	sub_blend_0.83292_20260703_183913.csv	否
4	無後處理紀錄	無紀錄	否
5	無後處理紀錄	sub_blend_0.83778_20260703_233044.csv	否
6	無後處理紀錄	無紀錄	否
7	無後處理紀錄	sub_blend_0.83814_20260703_233303.csv	否
8	無後處理紀錄	無紀錄(僅 OOF 分數,未產生 test 預測)	否

`id_column = id`、`target_column = Attrition`。本場為無人值守批次執行,僅產生 submission 檔案、未觸碰 Kaggle 憑證;第 8 次實驗 為樹搜尋結果,只算出 OOF 分數、未產生 test 預測。

3.5 評估指標 / 排行榜

指標定義:ROC-AUC = 模型將正樣本(離職)排序高於負樣本(留任)之機率,愈高愈好,不受決策 門檻影響。各實驗決策分數已列於第 3.2 節,本場最佳為 第 8 次實驗 之 **0.845051**(OOF)。

本場未提交 Kaggle,無排行榜紀錄:Public/Private LB 皆無紀錄,故本場無排行榜表,亦無法 計算 CV↔LB gap。

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	2026-07-03T12:02:55	0.81624	1.2	33 原始特徵三模型 blend 基線
2	2026-07-03T18:37:57	0.819008	2	48 特徵 + 不平衡加權,XGB/CAT 反而退步
3	2026-07-03T18:39:13	0.832925	2.4	移除加權 + 加強正則化,階段 2 冠軍
4	2026-07-03T23:29:51	0.837305	3.2	Optuna 直接優化 5-fold CV AUC,LGB solo 新高
5	2026-07-03T23:30:44	0.837776	3.4	調參版入池 + seed bag,5-way blend
6	2026-07-03T23:31:25	0.814259	3	CatBoost 原生類別重試,大幅回升仍最弱
7	2026-07-03T23:33:03	0.83814	3	6-way rank-average,線性迭代冠軍
8	2026-07-04T11:59:43	0.845051	4.2	KITCHENBLEND node #55,本場最佳(僅 OOF 分數)
9	2026-07-08T11:46:18	0.839770	5	外部注入快評:EXT-12(rank) 候選 OOF 未勝過階段4,不採納

- **轉折 1(第 2 次實驗→第 3 次實驗)**:診斷出 `scale_pos_weight/class_weights` 對排序指標無益反害 (AUC 非門檻敏感),移除加權並加強 LGB 正則化,0.819008 → 0.832925,為單筆最大躍升。
- **轉折 2(第 3 次實驗→第 7 次實驗)**:階段 3 的線性迭代四輪各改一事(Optuna 直接 CV-AUC 調參、入池 + seed bag、CatBoost 原生類別診斷、rank-average),0.832925 → 0.83814,增益遞減後依 協定停止。
- **轉折 3(第 7 次實驗→第 8 次實驗)**:樹搜尋規模實驗(80-節點預算)之 KITCHENBLEND lineage 於 node #55 混合當時全部 solo 節點(含個別已被淘汰的 CatBoost 變體),0.83814 → 0.845051。

5. 效能對照(逐階段)

階段	配置	分數	相對改善
1	基線(Claude Code 直接執行,未引入 skill;第 1 次實驗 通用批次 3 模型 blend)	0.81624	—(基線)
2	+ kaggle-agent skill 六階段流程(第 3 次實驗,階段 2 冠軍)	0.832925	2.04%
3	+ self-improvement 線性迭代(第 7 次實驗,6-way rank-average blend)	0.83814	0.63%
4	+ 樹搜尋(第 8 次實驗,KITCHENBLEND node #55)	0.845051	0.82%
5	+ 外部想法注入(第 9 次實驗,快評)	0.845051	0.00%(未勝過)

相對改善計算式(每階段對前一階段)

階段1→2: $0.832925 - 0.81624 = 0.016685$, 相對改善 $0.016685 / 0.81624 = 2.0441\%$
階段2→3: $0.83814 - 0.832925 = 0.005215$, 相對改善 $0.005215 / 0.832925 = 0.6261\%$
階段3→4: $0.845051 - 0.83814 = 0.006911$, 相對改善 $0.006911 / 0.83814 = 0.8246\%$
階段4→5: 注入候選 0.839770 未勝過階段4 0.845051, 搜尋保留階段4 → 相對改善 0.00%(外部注入無增益)

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:LGB)	0.81362	第 1 次實驗
1.2(三模權重 blend)	0.81624	第 1 次實驗
2.4(場內反思前:48 特徵 + 類別不平衡加權,XGB/CAT 反而退步)	0.819008	第 2 次實驗
2.4(場內反思後:移除加權 + 加強 LGB 正則化)	0.832925	第 3 次實驗
3.2(Optuna 直接優化完整 5-fold CV AUC)	0.837305	第 4 次實驗
3.4(調參版入池 + seed bagging)	0.837776	第 5 次實驗
4.2(樹搜尋,較早 22-節點掃描之最佳)	0.841442	第 8 次實驗 紀錄的文字備註引用
4.2(樹搜尋擴大規模版,80-節點,KITCHENBLEND node #55,本場最佳)	0.845051	第 8 次實驗

階段 5 | + 外部想法注入

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-12:rank averaging**——把各成員預測先轉成排名再加權平均,對只看排序的指標(如 ROC-AUC)特別自然。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們已算好的 **OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

```
階段5 注入候選(rank averaging) OOF ROC-AUC = 0.839770
階段4 冠軍 OOF ROC-AUC = 0.845051
差距 = -0.005281 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4
```

(本場註:s3e3 的快評成員池取自 base 樹的 3-way blend(node#7),而非 _scale 樹的 36-way 真冠軍 (node#55)——stage5_sweep 未讀 _scale 樹。比較基準仍為真冠軍 0.845051、注入候選 0.839770 未勝過,結論不受影響。)

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場資料小(1677 列)且嚴重不平衡(離職 200 筆對留任 1477 筆),無缺失、無重複,品質乾淨。小樣本決定了兩個貫穿全程的原則:自第 2 次實驗起固定 StratifiedKFold(seed=42)的同一組折以確保跨實驗可比,以及對模型施加較強正則化,避免在 48 個部分相關的工程特徵上過擬合。

關鍵決策是第 3 次實驗的場內反思迭代:辨識出不平衡加權對 ROC-AUC 這種排序指標是壞交易,移除加權並收緊 LGB 正則化後,分數由 0.819008 躍升至 0.832925,為全場最大單筆增益。其後階段 3 的線性迭代每輪只改一件事——Optuna 直接以完整 CV AUC 為目標、調參版入池加 seed bag、CatBoost 原生類別診斷、rank-average 合併——使線性迭代收在 0.83814。

各階段增益來源分佈不均:階段1→2(skill 流程之特徵工程 + 場內反思)貢獻最大;階段2→3 (線性迭代四輪)增益遞減,依協定如實停止;階段3→4 之樹搜尋以 KITCHENBLEND 混合當時全部 solo 節點突破線性天花板,收在 0.845051。CatBoost 個別結構性偏弱、但其變體在大池混合中仍可能貢獻多樣性,是本場最有趣的一組正反證據。

可信度方面,第 2-8 次實驗全部使用同一組固定 CV 折,分數排序可直接比較;但本場無任何 Kaggle 提交,所有分數皆為 OOF,缺乏排行榜外部驗證是本報告最大的補充說明。第 8 次實驗更是只算出 OOF 分數、未產生 test 預測,若要採用需先重建預測並提交驗證。

重現本實驗的最短路徑:見第 7 節。

階段 5(外部想法注入)經快評未勝過階段4:注入機制可運作、也產生了候選(rank averaging),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 資料下載(需先設定 KAGGLE_API_TOKEN;data/ 已存在者可略過)
uv run kaggle competitions download -c playground-series-s3e3 \
```

```

-p competitions/playground-series-s3e3/data

# 階段 2:EDA
uv run python3 competitions/playground-series-s3e3/scripts/eda.py

# 第 1 次實驗(對照組):通用批次管線
uv run python3 competitions/run_competition.py playground-series-s3e3

# 第 2 次實驗:特徵工程 + 不平衡加權(v1)
uv run python3 competitions/playground-series-s3e3/scripts/train.py

# 第 3 次實驗(2.4):場內反思迭代,移除加權(階段 2 冠軍)
uv run python3 competitions/playground-series-s3e3/scripts/train_v2.py

# 第 4 次實驗(3.2):Optuna 直接優化 5-fold CV AUC
uv run python3 competitions/playground-series-s3e3/scripts/iterate_round1_optuna_lgb.py

# 第 5 次實驗(3.4):調參版入池 + seed bagging
uv run python3 competitions/playground-series-s3e3/scripts/iterate_round2_pool_seedbag.py

# 第 6 次實驗(階段 3,診斷):CatBoost 原生類別診斷
uv run python3 competitions/playground-series-s3e3/scripts/iterate_round3_catboost_native.py

# 第 7 次實驗(階段 3):6-way rank-average(線性迭代冠軍,產出 submission)
uv run python3 competitions/playground-series-s3e3/scripts/iterate_round4_add_catnative_blend.py

# 第 8 次實驗(4.2):樹搜尋規模實驗(best;只算 00F 分數、不產生 submission;可中斷/續跑,
# 樹狀態存 experiments_tree_scale.json)
uv run python3 tree_search/run_s3e3_scale.py

# (選用)提交至 Kaggle—本場實際未執行此步,列出僅供後續採用
# uv run kaggle competitions submit -c playground-series-s3e3 \
#   -f competitions/playground-series-s3e3/submissions/<submission.csv> -m "<msg>"

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 00F、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s3e3

```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 uv run 以確保套件環境一致。本場為無人值守批次執行,未提交至 Kaggle 排行榜、未觸碰 Kaggle 憑證。