

競賽分析報告:playground-series-s3e3

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-06 本報告所有數字皆出自 facts.json,經 verify_report.py 驗證。

1. 競賽目的

What:依員工人事資料(年齡、職級、月薪、任職年資、各項滿意度評分、是否加班等 33 個 原始欄位)預測其是否離職(Attrition),為二元分類問題。

Why:評估指標為 **ROC-AUC(maximize)**。離職樣本僅 200 筆、留任 1477 筆,類別嚴重 不平衡;ROC-AUC 衡量「將實際離職者排在較高風險分數」的排序能力,不受分類門檻與類別比例 影響,較準確率等門檻敏感指標更適合此類不平衡二元分類問題。

項目	值
競賽	playground-series-s3e3
問題型別	classification
評估指標	roc_auc(maximize)
目標欄位	Attrition
素材等級	full

2. 使用工具與環境

工具	用途
LightGBM / XGBoost / CatBoost	梯度提升樹基礎模型:exp1/2/3/5/7 之 blend 成員,exp4(LGB 調參)與 exp6(CatBoost 原生類別)之 solo 模型
Optuna	exp4 對 LGB 做超參搜尋,目標函式為完整 5-fold CV 之 OOF ROC-AUC
自建樹搜尋 harness	exp8 規模實驗:結構化搜尋特徵/模型/超參與 blend 組合空間
5-fold CV 框架(scikit-learn)	依 Attrition 分層抽樣的 StratifiedKFold,5 折交叉驗證
uv	Python 套件與虛擬環境管理,所有腳本皆以 uv run 執行

本場工具鏈組合邏輯:Claude Code(LLM)負責決策——選型、特徵工程、診斷不平衡加權為何傷害 排序指標、判斷何時停損(Phase B 增益趨緩後停止線性迭代);Auto-ML 工具(Optuna、樹搜尋 harness)負責系統化執行超參搜尋與組合空間探索,兩者分工互補。

3. 流程(how):五大元件

3.1 資料規格

項目	值
train 列數	1677
test 列數	1119
原始欄位數	33(25 個數值 + 8 個類別)
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

目標 Attrition 為 0/1 整數標籤:離職(1)200 筆、留任(0)1477 筆,平均值 0.119261、偏度 2.351659,類別嚴重不平衡。EDA 已執行(eda_summary.py):train/test 皆無缺失值、無重複列、無 test 未見類別;EmployeeCount、StandardHours 標準差為 0、Over18 僅單一取值,三欄為常數,特徵工程時剔除。

eda 的高共線特徵對清單為空(未達自動門檻),但 STATUS.md 記錄年資類特徵彼此相關 0.75–0.79、JobLevel ↔ MonthlyIncome $r=0.91$,屬中高度冗餘。特徵數上,exp1 使用 33 個原始欄位,exp2–5/7 經特徵工程展開為 48 個,exp6 改用 40 個(類別欄保留原始字串供 CatBoost 原生處理)。

3.2 實驗總表

語意澄清(本報告全文適用):本場指標 ROC-AUC 為連續排序指標,無取整等後處理,故各實驗的「原始 OOF」即「決策分數」。另, facts.best 以 OOF 分數最大者選出:best 為 exp8 之樹搜尋結果,屬 **OOF-only**——未產生 test 預測;本場所有實驗皆未提交 Kaggle 排行榜,下文不再重複解釋。

exp	階段	模型/成員	特徵數	原始 OOF	決策分數	採納
1	Baseline(通用批次)	LGB+XGB+CAT blend	33	0.81624	0.81624	基線
2	Phase A(特徵工程+不平衡加權)	LGB+XGB+CAT blend	48	0.819008	0.819008	否,旋被 exp3 取代
3	Phase A(Reflexion:移除加權)	LGB+XGB+CAT blend	48	0.832925	0.832925	是,Phase A 冠軍
4	Phase B round1	LGB_tuned(Optuna,solo)	48	0.837305	0.837305	是,入池
5	Phase B round2	5-way blend(+seed bag)	48	0.837776	0.837776	是
6	Phase B round3(診斷)	CAT_native(solo)	40	0.814259	0.814259	否,診斷用
7	Phase B round4	6-way rank-average blend	48	0.83814	0.83814	是,線性迭代冠軍
8	Phase E-5 樹搜尋(best)	KITCHENBLEND(全 solo 池混合)	無紀錄	0.845051	0.845051	是,本場最佳

best 成員表:exp8 之 KITCHENBLEND 為「當時已評估之所有 solo 節點」的 kitchen-sink 混合 (dirichlet(k=800)+coordinate-ascent),成員隨搜尋進度變動,facts.json 未附結構化 base_models 清單——成員/ 權重/solo 分數無紀錄,依規範不逐一列出。線性迭代冠軍 exp7 之 權重搜尋結果為 LGB_orig 0.3、LGB_tuned 0.7,其餘成員(XGB/CAT_orig/LGB_tuned_seed2024/ CAT_native)權重皆為 0,以 rank-average 合併。

選型理由:三個梯度提升樹在表格資料上穩健,以權重搜尋決定集成比例;各輪權重搜尋一致將 CatBoost 權重收斂為 0(exp6 原生類別處理將其 solo 由 0.762684 拉升至 0.814259,仍為最弱 成員),確認其在此小樣本資料上結構性偏 弱。Phase B 聚焦 LightGBM:Optuna 直接以完整 5-fold CV AUC 為目標(exp4)、調參版入池加 seed bagging(exp5)、終以 rank-average 收尾(exp7)。

3.3 訓練規格表

exp	CV 方案	folds	seed
1	5fold	5	無紀錄
2	StratifiedKFold	5	42
3	StratifiedKFold	5	42
4	StratifiedKFold	5	42
5	StratifiedKFold	5	42
6	StratifiedKFold	5	42
7	StratifiedKFold	5	42
8	StratifiedKFold	5	42

類別不平衡下,一般隨機 K-fold 會使各折正負比例不穩、驗證 AUC 波動;exp2 起改用依 Attrition 分層的 StratifiedKFold(seed=42),且 exp2-8(含樹搜尋)沿用同一組固定折,跨實驗分數可直接比較。exp4 之 Optuna 設定(TPE、50 trials、實際 111.3s)與最佳超參 (num_leaves=3、max_depth=4 等)僅記於 notes 文字;其餘 base model 之 objective/超參無結構化紀錄。

3.4 推論表

exp	後處理	submission 檔	已提交
1	無後處理紀錄	sub_generic_0.81624_20260703_120255.csv	否
2	無後處理紀錄	sub_blend_0.81901_20260703_183757.csv	否
3	無後處理紀錄	sub_blend_0.83292_20260703_183913.csv	否
4	無後處理紀錄	無紀錄	否
5	無後處理紀錄	sub_blend_0.83778_20260703_233044.csv	否
6	無後處理紀錄	無紀錄	否
7	無後處理紀錄	sub_blend_0.83814_20260703_233303.csv	否

exp	後處理	submission 檔	已提交
8	無後處理紀錄	無紀錄(OOF-only)	否

`id_column = id`、`target_column = Attrition`。本場為無人值守批次執行,僅產生 submission 檔案、未觸碰 Kaggle 憑證;exp8 為樹搜尋 OOF-only 結果,未產生 test 預測。

3.5 評估指標 / 排行榜

指標定義:ROC-AUC = 模型將正樣本(離職)排序高於負樣本(留任)之機率,愈高愈好,不受決策 門檻影響。各實驗決策分數已列於實驗總表,本場最佳為 exp8 之 **0.845051**(OOF)。

`facts.leaderboard` 為 `null`(`missing` 列出 `leaderboard`):Public/Private LB 皆無紀錄,故本場無排行榜表,亦無法計算 CV↔LB gap。

4. 實驗軌跡

exp	時間	決策分數	階段	一句話摘要
1	2026-07-03T12:02:55	0.81624	Baseline(通用批次)	33 原始特徵三模型 blend 基線
2	2026-07-03T18:37:57	0.819008	Phase A	48 特徵 + 不平衡加權,XGB/CAT 反而退步
3	2026-07-03T18:39:13	0.832925	Phase A(Reflexion)	移除加權 + 加強正則化,Phase A 冠軍
4	2026-07-03T23:29:51	0.837305	Phase B round1	Optuna 直接優化 5-fold CV AUC,LGB solo 新高
5	2026-07-03T23:30:44	0.837776	Phase B round2	調參版入池 + seed bag,5-way blend
6	2026-07-03T23:31:25	0.814259	Phase B round3(診斷)	CatBoost 原生類別重試,大幅回升仍最弱
7	2026-07-03T23:33:03	0.83814	Phase B round4	6-way rank-average,線性迭代冠軍
8	2026-07-04T11:59:43	0.845051	Phase E-5 樹搜尋(best)	KITCHENBLEND node #55,本場最佳(OOF-only)

- **突破點 1(exp2→exp3)**:診斷出 `scale_pos_weight/class_weights` 對排序指標無益反害 (AUC 非門檻敏感),移除加權並加強 LGB 正則化,0.819008 → 0.832925,為單筆最大躍升。
- **突破點 2(exp3→exp7)**:Phase B 四輪各改一事(Optuna 直接 CV-AUC 調參、入池 + seed bag、CatBoost 原生類別診斷、rank-average),0.832925 → 0.83814,增益遞減後依協定停止。
- **突破點 3(exp7→exp8)**:樹搜尋規模實驗(80-節點預算)之 KITCHENBLEND lineage 於 node #55 混合當時全部 solo 節點(含個別已被淘汰的 CatBoost 變體),0.83814 → 0.845051。

`facts.unparsed` 為空陣列,無法解析之紀錄:無。

5. 效能對照:四層消融

層級	配置	分數	相對改善
tier1	基線(Claude Code 直接執行,未引入 skill;exp1 通用批次 3 模型 blend)	0.81624	—(基線)
tier2	+ kaggle-agent skill 六階段流程(exp3,Phase A 冠軍)	0.832925	見下方算式
tier3	+ self-improvement 線性迭代(exp7,6-way rank-average blend)	0.83814	見下方算式
tier4	+ 樹搜尋(exp8,KITCHENBLEND node #55)	0.845051	見下方算式

tier1→tier2: $0.832925 - 0.81624 = 0.016685$, 相對改善 $0.016685 / 0.81624 = 2.0441\%$
 tier2→tier3: $0.83814 - 0.832925 = 0.005215$, 相對改善 $0.005215 / 0.832925 = 0.6261\%$
 tier3→tier4: $0.845051 - 0.83814 = 0.006911$, 相對改善 $0.006911 / 0.83814 = 0.8246\%$

本場由導入報告功能後之版本執行,分數自 tier2 起未低於前一層——符合計畫書目標三(效能不退步)。

6. 總結

本場資料小(1677 列)且嚴重不平衡(離職 200 筆對留任 1477 筆),無缺失、無重複,品質乾淨。小樣本決定了兩個貫穿全程的原則:自 exp2 起固定 StratifiedKFold(seed=42)的同一組折以確保 跨實驗可比,以及對模型施加較強正則化,避免在 48 個部分相關的工程特徵上過擬合。

關鍵決策是 exp3 的 Reflexion 迭代:辨識出不平衡加權對 ROC-AUC 這種排序指標是壞交易,移除 加權並收緊 LGB 正則化後,分數由 0.819008 躍升至 0.832925,為全場最大單筆增益。其後 Phase B 每輪只改一件事——Optuna 直接以完整 CV AUC 為目標、調參版入池加 seed bag、CatBoost 原生 類別診斷、rank-average 合併——使線性迭代收在 0.83814。

各層增益來源分佈不均:tier1→tier2(skill 流程之特徵工程 + Reflexion)貢獻最大; tier2→tier3(Phase B 四輪)增益遞減,依協定誠實停止;tier3→tier4 之樹搜尋以 KITCHENBLEND 混合當時全部 solo 節點突破線性天花板,收在 0.845051。CatBoost 個別結構性偏弱、但其變體在大池混合中仍可能貢獻多樣性,是本場最有趣的一組正反證據。

可信度方面,exp2-8 全部使用同一組固定 CV 折,分數排序可直接比較;但本場無任何 Kaggle 提交,所有分數皆為 OOF,缺乏排行榜外部驗證是本報告最大的誠實但書。exp8 更是 OOF-only, 未產生 test 預測,若要採用需先重建預測並提交驗證。

重現本實驗的最短路徑:見第 7 節。

7. 重現指令

```

cd /home/tjyen/ai_agents/kaggle

# 資料下載(需先設定 KAGGLE_API_TOKEN;data/ 已存在者可略過)
uv run kaggle competitions download -c playground-series-s3e3 \
    -p competitions/playground-series-s3e3/data

```

```
# Stage 1: EDA
uv run python3 competitions/playground-series-s3e3/scripts/eda.py

# exp1(對照組):通用批次管線
uv run python3 competitions/run_competition.py playground-series-s3e3

# exp2:特徵工程 + 不平衡加權(v1)
uv run python3 competitions/playground-series-s3e3/scripts/train.py

# exp3:Reflexion 迭代,移除加權(Phase A 冠軍)
uv run python3 competitions/playground-series-s3e3/scripts/train_v2.py

# exp4:Phase B round1,Optuna 直接優化 5-fold CV AUC
uv run python3 competitions/playground-series-s3e3/scripts/iterate_round1_optuna_lgb.py

# exp5:Phase B round2,調參版入池 + seed bagging
uv run python3 competitions/playground-series-s3e3/scripts/iterate_round2_pool_seedbag.py

# exp6:Phase B round3,CatBoost 原生類別診斷
uv run python3 competitions/playground-series-s3e3/scripts/iterate_round3_catboost_native.py

# exp7:Phase B round4,6-way rank-average(線性迭代冠軍,產出 submission)
uv run python3 competitions/playground-series-s3e3/scripts/iterate_round4_add_catnative_blend.py

# exp8:Phase E-5 樹搜尋規模實驗(best;00F-only;可中斷/續跑,
# 樹狀態存 experiments_tree_scale.json)
uv run python3 tree_search/run_s3e3_scale.py

# (選用)提交至 Kaggle—本場實際未執行此步,列出僅供後續採用
# uv run kaggle competitions submit -c playground-series-s3e3 \
# -f competitions/playground-series-s3e3/submissions/<submission.csv> -m "<msg>"
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle` ;所有 Python 執行皆透過 `uv run` 以確保套件環境一致。本場為無人值守批次執行,未提交至 Kaggle 排行榜、未觸碰 Kaggle 憑證。