

競賽分析報告:playground-series-s3e5

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-03(Phase B 自我改進迭代更新)

1. 競賽目的

What:本場競賽要求依葡萄酒的物理化學量測值(固定酸度、揮發性酸度、檸檬酸、殘糖、氯化物、游離/總二氧化硫、密度、pH、硫酸鹽、酒精濃度)預測其品質評分 `quality`,分數為 3 至 8 的序數(ordinal)整數等級。

Why:評估指標為 `quadratic_weighted_kappa(QWK,maximize)`。品質等級雖以整數表示,但等級之間存在順序關係(5 分與 6 分的差距遠小於 3 分與 8 分),QWK 會依「預測與真實等級距離的平方」懲罰誤差,比單純的準確率或無序的多分類損失更能反映序數目標「越接近真實等級越好」的評分邏輯,因此是此類序數評分資料的合理指標選擇。

項目	值
競賽	playground-series-s3e5
問題型別	classification
評估指標	quadratic_weighted_kappa(maximize)
目標欄位	quality

2. 資料規格

- 依 `competition.notes` 記載,本場為 Aygun et al. Nature 2026 論文所評測之 Kaggle Playground benchmark(Season 3 Episode 5)。
- 特別規則:不可使用外部資料、不可使用預訓練模型、不可存取網路;每日提交上限 5 次(來源: `competition.special_rules`)。
- 實驗 1(`generic_batch` 通用批次管線)使用 11 個原始欄位(來源: `experiments[0].n_features`)。
- 實驗 2、3(`v2` 手刻管線)在原始欄位基礎上,經特徵工程展開為 21 個特徵(來源: `experiments[1].n_features`、`experiments[2].n_features`),欄位清單詳 `facts.json` 之 `experiments[1].features` / `experiments[2].features`,包含游離/總二氧化硫比值、酸度比值、酒精濃度與硫酸鹽/密度的交互作用等衍生特徵。

- 實驗 4-11(Phase B 自我改進迭代)沿用與實驗 2、3 完全相同的 21 個特徵(來源: `experiments[3..10].features` ,逐筆核對欄位清單一致),本輪迭代未新增特徵工程。

3. 模型規格

本場共 11 筆實驗紀錄, `facts.best` 為實驗 8:

實驗 1(`generic_batch` ,通用批次管線,11 特徵)— base models:

Model	OOF QWK
LGB	0.45223
XGB	0.46995
CAT	0.46768

Ensemble 權重(來源: `experiments[0].ensemble.weights`):LGB 0.1 / XGB 0.4 / CAT 0.5, Ensemble 分數(來源: `experiments[0].ensemble.score`):**0.47871**。

實驗 2(`v2` ,21 特徵,同一集成權重但採「四捨五入」後處理)— base models:

Model	OOF QWK
LGB	0.4522
XGB	0.46218
CAT	0.47094

Ensemble 權重(來源: `experiments[1].ensemble.weights`):LGB 0.2 / XGB 0.2 / CAT 0.6, Ensemble 分數(來源: `experiments[1].ensemble.score`):**0.47191**。

實驗 3(`v2` ,21 特徵,採「最佳化分割閾值」後處理)— base models:

同實驗 2 之 base models 分數。Ensemble 權重(來源: `experiments[2].ensemble.weights`): LGB 0.2 / XGB 0.2 / CAT 0.6,Ensemble 分數(來源: `experiments[2].ensemble.score`):**0.52687**。此為 Phase B 迭代前的既有最佳分數。

實驗 4(方法論調整:更細緻的權重搜尋,同 3 個原始成員)— base models:

Model	OOF QWK(post-rounder)
LGB	0.50547
XGB	0.50847

Model	OOF QWK(post-rounder)
CAT	0.52517

Ensemble 權重(來源: `experiments[3].ensemble.weights`):LGB 0.028 / XGB 0.023 / CAT 0.949, Ensemble 分數(來源: `experiments[3].ensemble.score`):**0.52986**。(註:此處 base model 分數與實驗 2/3 表列數字不同,因改用 post-rounder QWK 而非 naive-round QWK 呈現各成員分數;來源皆為 `experiments[].base_models[].score`,逐實驗各自的計算基準已於 `experiments[].notes` 註明。)

實驗 5(4-way:加入 Optuna 全 CV 直接優化 post-rounder QWK 調校之 LGB_tuned)— base models:

Model	OOF QWK(post-rounder)
LGB	0.50547
XGB	0.50847
CAT	0.52517
LGB_tuned	0.56244

Ensemble 權重(來源: `experiments[4].ensemble.weights`):LGB 0.02 / XGB 0.0 / CAT 0.0 / LGB_tuned 0.98,Ensemble 分數:**0.56293**。

實驗 6(5-way:LGB_tuned 加碼一組 seed=2024 版本):權重全數指向 LGB_tuned(來源: `experiments[5].ensemble.weights`),分數與實驗 5 相同:**0.56293**(來源: `experiments[5].ensemble.score`)——seed-bagging 未帶來額外增益。

實驗 7(巢狀切點診斷,非模型變更):分數 **0.54649**(來源: `experiments[6].score`), 為 leave-fold-out 巢狀切點擬合下的誠實 QWK 估計,對照實驗 5/6 之全 OOF 切點擬合分數 0.56293。

實驗 8(6-way:再加入 Optuna 全 CV 直接優化調校之 CAT_tuned, facts.best)— base models:

Model	OOF QWK(post-rounder)
LGB	0.50547
XGB	0.50847
CAT	0.52517
LGB_tuned	0.56244
LGB_tuned_seed2024	0.55765
CAT_tuned	0.56466

Ensemble 權重(來源: `experiments[7].ensemble.weights`):LGB 0.05 / XGB 0.0 / CAT 0.0 / LGB_tuned 0.0 / LGB_tuned_seed2024 0.0 / CAT_tuned 0.95, Ensemble 分數(來源: `experiments[7].ensemble.score`):**0.56769**。此為 `facts.best`。

實驗 9(7-way:CAT_tuned 加碼一組 seed=2024 版本):分數 **0.56716**(來源: `experiments[8].ensemble.score`),低於實驗 8 的 0.56769,未取代 running best。

實驗 10(巢狀切點診斷,基於實驗 8 之 6-way blend,非模型變更):分數 **0.56393**(來源: `experiments[9].score`),對照實驗 8 全 OOF 切點擬合分數 0.56769,差距 0.00377。

實驗 11(7-way:加入 LGB multiclass + class_weight=balanced + expected-value decode 作為序數/分類頭的多樣性成員):分數 **0.56769**(來源: `experiments[10].ensemble.score`),與實驗 8 相同——權重搜尋將新成員權重歸零(來源: `experiments[10].ensemble.weights`),未帶來增益。

選型理由:延續既有的三個梯度提升樹迴歸模型(LightGBM、XGBoost、CatBoost)為基礎,Phase B 迭代依序嘗試:(a) 以 Dirichlet 隨機搜尋取代粗網格權重搜尋(實驗 4)、(b) 對 LightGBM 以 Optuna 在完整 5-fold CV 上直接優化「後處理後的 QWK」(而非原始 RMSE)進行 40 組超參數搜尋,並將調校後版本加入(而非取代)集成池(實驗 5)、(c) 同法調校 CatBoost 並加入集成池(實驗 8,最終最佳)。每一步的加入/捨棄決策皆僅依「後處理(OptimizedRounder)後的 QWK」判斷,不依原始 OOF 分數判斷——此為避免序數/離散化指標特有的「原始分數進步但離散化後不進步」陷阱。另嘗試 seed-bagging (實驗 6、9)與多分類期望值解碼頭(實驗 11)兩種候選改動,皆未通過此判準,故未採用。

4. 訓練規格

實驗	CV scheme	n_splits	seed
1	5fold	5	無紀錄
2-11	5fold	5	42

(來源: `experiments[].cv`;實驗 1 之 seed 未記錄,故寫「無紀錄」;實驗 2-11 皆為 StratifiedKFold on quality,標籤分層抽樣,folds/seed 全程保持一致以利跨實驗比較。)

各 base model 之 objective/超參數在 `experiments[].base_models[]` 中未記錄對應欄位,故此項為「無紀錄」;LGB_tuned / CAT_tuned 之 Optuna 最佳超參數本身未寫入 `experiments.json` (僅分數與決策記錄於此),故亦標「無紀錄」。

為何用此 CV: quality 為小基數(3-8 共 6 級)且嚴重不平衡的序數目標(依 STATUS.md 記載,最稀有等級與最常見等級之比例懸殊),若採用一般隨機 K-fold 切分,稀有等級可能在某些 fold 中樣本過少甚至掛零,使該 fold 的 QWK 計算不穩定。全部 11 筆實驗皆改用「依 quality 標籤分層抽樣」的 StratifiedKFold,且 folds/seed 固定不變,使各實驗分數可直接比較。

5. 推論程序

`facts.best` (實驗 8)之 `postprocess` 欄位記錄: `OptimizedRounder(cutpoints=[3.574, 4.586, 5.609, 6.174, 7.628])` 與 `clip[3,8]` (來源: `experiments[7].postprocess`)。即先以最佳化搜尋得到的 5 個分割閾值,將迴歸模型輸出的連續值 轉換為離散等級,再限制於 3 至 8 的合法範圍內。

實驗 7、10 額外記錄了巢狀切點擬合的後處理描述: `OptimizedRounder(nested: fit on 4 folds, applied to held-out fold)` (來源: `experiments[6].postprocess`、`experiments[9].postprocess`)—— 此為診斷用途,用以檢驗全 OOF 切點擬合是否過度貼合本次 OOF 樣本,並非用於正式提交之後處理。

`facts.best` (實驗 8)之 `submission` 欄位在 `facts.json` 中無紀錄(v2 schema 之 `submission` 為 選填欄位, `log_experiment_v2` 呼叫時未填入,依 Hard Rule 4 標記「無紀錄」)。對應之提交檔由 獨立的 `scripts/iterate.py submit` 步驟產生於 `submissions/` 目錄下(id 欄 `Id`、目標欄 `quality`),其 確切檔名/時間戳記未記入 `experiments.json`,故不在此覆誦。實驗 1 之 `submission` 有記 錄: `sub_generic_0.47871_20260703_120341.csv` (來源: `experiments[0].submission`)。

本場所有實驗均未提交至 **Kaggle 排行榜**(此執行環境未設定 Kaggle 憑證, `facts.json` 中 `leaderboard` 欄位為 `null`,且列於 `facts.missing`)。

6. 評估指標

指標定義:`quadratic_weighted_kappa(QWK)`= 觀察一致性與隨機期望一致性之差,並以「預測與 真實等級距離的平方」作為誤差權重,數值愈接近 1 表示模型排序與真實等級愈一致。

項目	分數
實驗 1 Ensemble(generic_batch,11 特徵)	0.47871
實驗 2 Ensemble(四捨五入後處理)	0.47191
實驗 3 Ensemble(最佳化閾值後處理,Phase B 迭代前基準)	0.52687
實驗 4 Ensemble(更細緻權重搜尋)	0.52986
實驗 5 Ensemble(+Optuna 調校 LGB)	0.56293
實驗 6 Ensemble(+seed-bag LGB_tuned)	0.56293
實驗 7(巢狀切點診斷)	0.54649
實驗 8 Ensemble(+Optuna 調校 CAT,facts.best)	0.56769
實驗 9 Ensemble(+seed-bag CAT_tuned)	0.56716
實驗 10(巢狀切點診斷)	0.56393

項目	分數
實驗 11 Ensemble(+多分類期望值解碼頭)	0.56769
Public LB	無紀錄
Private LB	無紀錄

(來源: `experiments[].ensemble.score / experiments[].score`; `facts.leaderboard` 為 null, `facts.missing` 列出 `leaderboard`, 故 Public/Private LB 皆寫「無紀錄」。)

CV↔LB gap: 因本場所有實驗皆未提交排行榜, `facts.leaderboard` 不存在, 故無法計算 CV↔LB 差值, 亦不進行任何推測性比較。

`facts.best` (實驗 8) 相對於 Phase B 迭代前既有最佳(實驗 3)之增益, 以內嵌算式呈現:

$$\text{實驗 8 OOF QWK} - \text{實驗 3 OOF QWK} = 0.56769 - 0.52687 = 0.04082$$

實驗 8 相對於實驗 1(最初基準)之增益:

$$\text{實驗 8 OOF QWK} - \text{實驗 1 OOF QWK} = 0.56769 - 0.47871 = 0.08898$$

巢狀切點診斷(實驗 10)顯示全 OOF 切點擬合與誠實巢狀估計之差距:

$$\text{實驗 8 全 OOF 切點 QWK} - \text{實驗 10 巢狀切點 QWK} = 0.56769 - 0.56393 = 0.00376$$

7. 實驗軌跡

experiment_id	timestamp	score	source_format
1	2026-07-03T12:03:41	0.47871	generic_batch
2	2026-07-03T18:48:21	0.47191	v2
3	2026-07-03T18:48:21	0.52687	v2
4	2026-07-03T23:08:22	0.52986	v2
5	2026-07-03T23:09:50	0.56293	v2
6	2026-07-03T23:10:42	0.56293	v2
7	2026-07-03T23:11:20	0.54649	v2
8	2026-07-03T23:13:44	0.56769	v2

experiment_id	timestamp	score	source_format
9	2026-07-03T23:15:20	0.56716	v2
10	2026-07-03T23:15:32	0.56393	v2
11	2026-07-03T23:16:51	0.56769	v2

(來源: `facts.trajectory`)

突破點:分數最大的單一躍升發生在實驗 3(0.47191 → 0.52687,後處理由四捨五入改為最佳化切點,Phase B 迭代前既有結論)。本輪 Phase B 迭代中,最大躍升發生在實驗 5(0.52986 → 0.56293, `experiments[4].notes` 記載:以 Optuna 在完整 5-fold CV 上直接優化 post-rounder QWK 調校 LightGBM,並將調校版本加入而非取代原集成池),其次是實驗 8(0.56293 → 0.56769,同法調校 CatBoost 加入集成池, `experiments[7].notes`)。實驗 4(更細緻權重搜尋,0.52687 → 0.52986) 為方法論層面的小幅穩定增益。實驗 6、9(seed-bagging)與實驗 11(多分類期望值解碼頭)三次嘗試 權重搜尋皆將新成員權重歸零或分數持平/下降(`experiments[5,8,10].notes`),故未被採用為 `facts.best`。實驗 7、10 為診斷性巢狀切點檢驗,非模型改動,用以評估 STATUS.md 中「切點於全 OOF 擬合可能過擬」的風險,結果顯示差距分別為 0.01644(5-way blend)與 0.00377(`facts.best` 之 6-way blend),差距隨集成池成熟而縮小。

`facts.unparsed` 為空陣列,無法解析之紀錄:無。

8. 重現指令

```
cd /home/tjyen/ai_agents/kaggle
```

```
# 實驗 1:通用批次管線(11 特徵,四捨五入後處理)
```

```
uv run python3 competitions/run_competition.py playground-series-s3e5
```

```
# 實驗 2、3:手刻管線(EDA → 特徵工程 → 訓練/CV/集成 → 兩種後處理比較 → 提交檔產出)
```

```
uv run python3 competitions/playground-series-s3e5/scripts/eda.py
```

```
uv run python3 competitions/playground-series-s3e5/scripts/features.py
```

```
uv run python3 competitions/playground-series-s3e5/scripts/train.py
```

```
# 實驗 4–11(Phase B 自我改進迭代,依序執行,每步驟皆會寫入 experiments.json 並快取
```

```
# scripts/cache/*.npz 供後續步驟重用):
```

```
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py base #
```

```
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py tune_lgb #
```

```
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py rl_pool #
```

```
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py seed_bag #
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py nested_cut #
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py tune_cat #
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py r2_pool #
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py seed_bag #
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py nested_cut #
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py r3_multiclass #
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py submit #

# 提交至 Kaggle(本次執行環境未設定憑證,以下指令供後續有憑證時使用)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e5 -f <submission.csv> -m "
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle` ;所有 Python 執行皆透過 `uv run` 以確保套件環境一致。

