

競賽分析報告:playground-series-s3e5

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-06 本報告所有數字皆出自 facts.json,經 verify_report.py 驗證。

1. 競賽目的

What:依葡萄酒的 11 項理化量測值(酸度結構、殘糖、氯化物、游離/總二氧化硫、密度、pH、硫酸鹽、酒精濃度)預測品質評分 `quality`,標籤為 3 至 8 的**序數(ordinal)整數等級**。

Why:評估指標為 **quadratic_weighted_kappa(QWK,maximize)**。品質等級之間有順序關係——把 5 分誤判為 6 分遠輕於誤判為 8 分;QWK 以「預測與真實等級距離的平方」加權懲罰誤差,比準確率或無序多分類損失更貼合「越接近真實等級越好」的評分邏輯,是序數目標的合理指標。指標特性也直接決定了本場的建模路線:迴歸頭+指標特化的切點後處理。

項目	值
競賽	playground-series-s3e5
問題型別	classification
評估指標	quadratic_weighted_kappa(maximize)
目標欄位	quality
素材等級	full

2. 使用工具與環境

工具	用途
LightGBM / XGBoost / CatBoost	三個梯度提升樹迴歸模型,構成全部 12 筆實驗的集成成員主體
Optuna 超參搜尋	TPE 全 5-fold CV 調參,目標函數直接設為 post-rounder QWK,產出 LGB_tuned 與 CAT_tuned
OptimizedRounder 指標特化後處理	以最佳化切點將迴歸連續輸出離散化為 3-8 等級,本場決定性槓桿
自建樹搜尋 harness	Phase E-2 結構化搜尋成員/超參/blend 權重組合空間,於 node #17 找到 exp12
5-fold CV 框架(scikit-learn)	StratifiedKFold on quality,全程固定折以利跨實驗比較
uv	Python 套件與虛擬環境管理,所有腳本皆以 <code>uv run</code> 執行

本場工具鏈組合邏輯:Claude Code(LLM)負責決策——選擇迴歸頭而非多分類頭、把 Optuna 目標 函數改成 post-rounder QWK、依「連兩輪無改善即停」協定停損;Auto-ML 工具(Optuna、樹搜尋 harness、權重搜尋)負責系統化執行,兩者分工互補。

3. 流程(how):五大元件

3.1 資料規格

項目	值
train 列數	2,056
test 列數	1,372
原始欄位數	11
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

11 個原始欄位皆為數值型,無類別欄位。目標 `quality` 為整數(mean 5.720817、median 6.0、skew 0.266307),共 6 個等級且嚴重不平衡:quality 3 僅 12 列、quality 8 僅 39 列,quality 5 (839 列)與 quality 6(778 列)為絕對大宗;非 log 轉換候選。

資料品質乾淨:train/test 皆無缺失值、無重複列、無高共線特徵對(`citric acid` 有 211 個零值,屬合理的理化量測)。train/test 特徵分佈幾乎一致(最大平均差 2.078843%,`citric acid`),無 共變數偏移。EDA 對單一特徵的訊號排序: `alcohol` (Spearman 0.504246)與 `sulphates` (0.456985)最強。EDA 之驗證建議即為「整數目標 → 分層 K-fold」,見 3.3 節。

exp1(通用批次)直接用 11 個原始欄位;exp2-11 經特徵工程展開為 21 個特徵(SO2 比值、酸度比值、酒精×硫酸鹽/密度交互作用、糖/酒精比等),線性迭代(Phase B)期間特徵集固定不變。

3.2 實驗總表

語意澄清(本報告全文適用):本場為離散化指標,所有實驗的「決策分數」一律為**後處理後的 QWK**(exp2 為四捨五入,其餘為 OptimizedRounder 切點);原始迴歸 OOF 分數未被記錄、也從未作為決策依據(避免「原始分數進步但離散化後不進步」的陷阱),故下表「原始 OOF」欄一律標「—」。

ex p	階段	模型/成員	特徵數	原始 OOF	決策分數	採納
1	Baseline(通用批次)	LGB/XGB/CAT(.1/.4/.5)	11	—	0.47871	是,初始基線
2	手刻管線(四捨五入)	LGB/XGB/CAT(.2/.2/.6)	21	—	0.47191	否,rounder 對照組
3	手刻管線(OptimizedRounder)	同 exp2 成員與權重	21	—	0.52687	是,Phase A 最佳

ex p	階段	模型/成員	特徵數	原始 OOF	決策分數	採納
4	Phase B round0(權重搜尋方法論)	3-way(Dirichlet+座標上升)	21	—	0.52986	是
5	Phase B round1(+LGB_tuned)	4-way blend	21	—	0.56293	是
6	Phase B round2(seed-bag LGB_tuned)	5-way blend	21	—	0.56293	否,無增益
7	診斷(巢狀切點,非模型變更)	exp5/6 之 5-way blend	21	—	0.54649	—(診斷)
8	Phase B round3(+CAT_tuned)	6-way blend	21	—	0.56769	是,線性迭代最佳
9	Phase B round4(seed-bag CAT_tuned)	7-way blend	21	—	0.56716	否,退步
10	診斷(巢狀切點,非模型變更)	exp8 之 6-way blend	21	—	0.56393	—(診斷)
11	Phase B round5(多分類 EV 解碼頭)	7-way blend	21	—	0.56769	否,新成員權重歸零
12	Phase E-2 樹搜尋(best)	3-way blend(node #17)	無紀錄	—	0.57066	是,OOF-only

線性迭代選型邏輯:以三個梯度提升樹迴歸模型為基礎,依序做(a)更細的 Dirichlet 權重搜尋 (exp4)、(b)Optuna 直接以 post-rounder QWK 為目標調校 LGB 與 CAT,調校版**加入而非取代**集成池(exp5、exp8);seed-bagging(exp6、exp9)與多分類期望值解碼頭(exp11)皆未通過 決策判準。exp9、exp11 連兩輪無改善後依協定停止線性迭代。

best 成員表(exp12,3-way blend,node #17)

成員	權重	solo 分數	備註
LGB_tuned(root)	0.151	無紀錄	即線性迭代之 Optuna 調校 LGB 成員
CAT_tuned	0.551	無紀錄	即線性迭代之 Optuna 調校 CAT 成員,權重最高
LGBBOUND	0.297	0.55784	邊界推進 LGB(max_depth 3→2):solo 比 root 差 0.005,blend 貢獻 +0.0026

exp12 由 harness v2 樹搜尋(22 個評估節點、1 次 backtrack、wall 793.7s)找到,勝出的兩個 槓桿:(1)LGBBOUND——線性迭代的 Optuna 搜尋盒有超參飽和在盒邊界,推過邊界的成員 solo 較弱 但異質性高;(2)足額 k=800 權重搜尋預算——k=200 粗搜在同一組成員上僅找到 0.56601,離散 指標上縮減 blend 搜尋預算會讓勝場悄悄變回平手。

誠實但書:exp12 為 **OOF-only 搜尋結果**——未產生 test 預測、無 submission 檔、未提交 Kaggle;facts.best 依 OOF 分數選出,與是否提交無關。其權重與切點皆直接對全 OOF 搜尋,未對此結果重跑巢狀切點診斷(exp7、exp10 的診斷模式)。

3.3 訓練規格表

exp	CV 方案	folds	seed
1	5fold	5	無紀錄
2-12	5fold(StratifiedKFold on quality)	5	42

quality 為 6 級且嚴重不平衡的序數目標(quality 3 僅 12 列),一般隨機 K-fold 會使稀有 等級在部分折中掛零、QWK 不穩定,故 exp2 起依標籤分層抽樣,且 folds/seed 全程固定(含 exp12 樹搜尋),各實驗分數可直接比較;此亦與 EDA 的驗證建議一致。

各成員之 objective 與最終超參數未寫入結構化欄位,標「無紀錄」;調參設定僅見於 notes (Optuna TPE、40 trials、600s timeout、完整 5-fold CV,目標函數為該 trial 自身 OOF 的 post-rounder QWK)。

3.4 推論表

exp	後處理	submission 檔	已提交
1	無後處理紀錄	sub_generic_0.47871_20260703_120341.csv	否
2	round_to_nearest_int + clip[3,8]	無紀錄	否
3	OptimizedRounder(cutpoints=[3.642, 4.594, 5.657, 6.196, 7.386]) + clip[3,8]	無紀錄	否
4-6, 8, 9, 11	OptimizedRounder(各實驗切點各異,詳 facts.json) + clip[3,8]	無紀錄	否
7, 10	OptimizedRounder(nested:4 折擬合、留出折套用) + clip[3,8], 診斷用	—(診斷)	否
12	OptimizedRounder 切點與 blend 權重在每個節點的 metric_fn 內聯合搜尋	—(OOF-only,未產生)	否

id_column = Id、target_column = quality。線性迭代最佳 exp8 之切點為 [3.574, 4.586, 5.609, 6.174, 7.628];exp12 之具體切點未入 facts.json,標「無紀錄」。本場執行環境未設定 Kaggle 憑證,所有實驗皆未提交排行榜。

3.5 評估指標 / 排行榜

指標定義:QWK = 觀察一致性對隨機期望一致性之修正,以「預測與真實等級距離的平方」加權,越接近 1 代表預測排序與真實等級越一致。

項目	分數
exp1(通用批次基線)	0.47871
exp3(Phase A 最佳)	0.52687
exp8(線性迭代最佳)	0.56769

項目	分數
exp12(樹搜尋,facts.best)	0.57066
Public LB / Private LB	無紀錄

facts.leaderboard 為 null(列於 facts.missing),無法計算 CV↔LB gap,不作推測性比較。各階段增益與切點過擬診斷之衍生算式:

線性迭代增益(exp8 - exp3):0.56769 - 0.52687 = 0.04082
樹搜尋增益(exp12 - exp8):0.57066 - 0.56769 = 0.00297
巢狀切點診斷 gap(全 OOF 切點 - 巢狀切點):
5-way(exp7):0.56293 - 0.54649 = 0.01644
6-way(exp10):0.56769 - 0.56393 = 0.00376(notes 記為 +0.00377,四捨五入口徑差)

巢狀切點診斷顯示全 OOF 切點擬合的過擬風險隨集成池成熟而縮小(0.01644 → 0.00377),全 OOF 切點在本場屬可接受的標準做法;但 exp12 未重跑此診斷,見 3.2 節誠實但書。

4. 實驗軌跡

實驗階段對照表(內部代號使用前先定義,R-W8)

代號	白話名稱	對應層級
Phase A	kaggle-agent skill 六階段首跑	tier2
Phase B	self-improvement 線性迭代	tier3
Phase E-2	樹搜尋執行(harness v2)	tier4

exp	時間	決策分數	階段	一句話摘要
1	2026-07-03T12:03:41	0.47871	Baseline(通用批次)	11 特徵三模型 blend,初始基線
2	2026-07-03T18:48:21	0.47191	手刻管線	21 特徵,四捨五入後處理(rounder 對照組)
3	2026-07-03T18:48:21	0.52687	手刻管線	同一 blend 改用 OptimizedRounder,Phase A 最佳
4	2026-07-03T23:08:22	0.52986	Phase B round0	權重搜尋改 Dirichlet+座標上升
5	2026-07-03T23:09:50	0.56293	Phase B round1	加入 Optuna 直接 QWK 調校之 LGB_tuned
6	2026-07-03T23:10:42	0.56293	Phase B round2	seed-bag LGB_tuned,無增益
7	2026-07-03T23:11:20	0.54649	診斷	巢狀切點檢驗(5-way),非模型變更
8	2026-07-03T23:13:44	0.56769	Phase B round3	加入 CAT_tuned,線性迭代最佳
9	2026-07-03T23:15:20	0.56716	Phase B round4	seed-bag CAT_tuned,退步
10	2026-07-03T23:15:32	0.56393	診斷	巢狀切點檢驗(6-way),非模型變更
11	2026-07-03T23:16:51	0.56769	Phase B round5	多分類 EV 解碼頭權重歸零,連兩輪無改善停止

exp	時間	決策分數	階段	一句話摘要
12	2026-07-04T11:59:43	0.57066	Phase E-2 樹搜尋(best)	node #17 3-way blend,本場最佳

- **突破點 1(exp2→3)**:同一組成員與權重,後處理由四捨五入改為 OptimizedRounder 切點, 0.47191 → 0.52687(同 blend 上 rounder 增益 +0.05496)——本場單一最大槓桿。
- **突破點 2(exp4→5、exp5→8)**:把 Optuna 目標函數直接設為 post-rounder QWK 調校 LGB (0.52986 → 0.56293)、再同法調校 CAT(0.56293 → 0.56769),兩次調參佔線性迭代大部分增益。
- **突破點 3(exp11→12)**:harness v2 樹搜尋以邊界推進成員 LGBBOUND + 足額權重搜尋預算, 0.56769 → 0.57066(勝線性迭代 +0.00297、勝樹搜尋 v1 之 0.56766 達 +0.00300,屬結構性 勝出而非切點噪音量級)。

facts.unparsed 為空陣列,無法解析之紀錄:無。

5. 效能對照:四層消融

層級	配置	分數	相對改善
tier1	基線(Claude Code 直接執行,未引入 skill;exp1 通用批次)	0.47871	—(基線)
tier2	+ kaggle-agent skill 六階段流程(exp3,Phase A 最佳,OptimizedRounder)	0.52687	見下方算式
tier3	+ self-improvement 線性迭代(exp8,6-way blend + Optuna 直接 QWK 調參)	0.56769	見下方算式
tier4	+ 樹搜尋(exp12,node #17,3-way blend)	0.57066	見下方算式

tier1→tier2: $0.52687 - 0.47871 = 0.04816$, 相對改善 $0.04816 / 0.47871 = 10.0604\%$
 tier2→tier3: $0.56769 - 0.52687 = 0.04082$, 相對改善 $0.04082 / 0.52687 = 7.7476\%$
 tier3→tier4: $0.57066 - 0.56769 = 0.00297$, 相對改善 $0.00297 / 0.56769 = 0.5232\%$

本場由導入報告功能後之版本執行,分數自 tier2 起未低於前一層——符合計畫書目標三(效能不退步)。

6. 總結

本場資料乾淨(無缺失、無重複、無共線問題),真正的難點在目標本身: quality 是 6 級、嚴重不平衡的序數標籤,而 QWK 是離散化指標。第一個關鍵決策是採迴歸頭而非多分類頭——讓大宗等級的連續訊號幫助定位資料稀少的極端等級;exp11 的多分類 EV 解碼頭成員權重被搜尋歸零,反向印證了這個選擇。

第二個關鍵決策是把「後處理」當一級公民:同一組模型與權重,後處理由四捨五入換成 OptimizedRounder 切點即帶來本場單一最大增益(exp2→exp3);其後所有加入/捨棄決策一律只看 post-rounder QWK,並把同一原則貫徹到 Optuna 的目標函數(直接優化 post-rounder QWK)與樹搜尋評估器(rounder 內建於每個節點)。

各階段增益來源清楚分層:tier1→tier2 來自 skill 管線的特徵工程與切點後處理(0.47871 → 0.52687),tier2→tier3 來自 Optuna 直接 QWK 調參的成員 LGB_tuned、CAT_tuned(→ 0.56769), tier3→tier4 來自樹搜尋挖出的邊界

推進成員 LGBBOUND($\rightarrow 0.57066$)。本場為此批競賽中前兩層 增幅最大的一場,顯示離散化指標下「指標特化後處理 + 直接優化最終指標」的複利效果。

結果可信度:CV 全程固定同一組 StratifiedKFold 折,分數跨實驗可直接比較;巢狀切點診斷 (exp7、exp10)顯示切點過擬風險隨集成池成熟而縮小。但須誠實標注:本場所有實驗皆未提交 Kaggle(無憑證),最終 0.57066 為 OOF-only 結果且未重跑巢狀診斷,缺乏排行榜錨點驗證。

重現本實驗的最短路徑:見第 7 節。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# exp1:通用批次管線(11 特徵)
uv run python3 competitions/run_competition.py playground-series-s3e5

# exp2、3:手刻管線(EDA → 特徵工程 → 訓練/CV/集成 → naive-round vs OptimizedRounder)
uv run python3 competitions/playground-series-s3e5/scripts/eda.py
uv run python3 competitions/playground-series-s3e5/scripts/features.py
uv run python3 competitions/playground-series-s3e5/scripts/train.py

# exp4-11(Phase B 自我改進迭代,依序執行;每步寫入 experiments.json,
# 並快取 scripts/cache/*.npz 供後續步驟重用)
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py base # exp4
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py tune_lgb # Optuna 調校 LG
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py r1_pool # exp5
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py seed_bag # exp6
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py nested_cut # exp7
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py tune_cat # Optuna 調校 CA
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py r2_pool # exp8
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py seed_bag # exp9
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py nested_cut # exp10
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py r3_multiclass # exp11
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py submit # 產出提交檔

# exp12:Phase E-2 樹搜尋 v2(best;可中斷/續跑;樹狀態存 experiments_tree_v2.json,
# 與 v1 的 experiments_tree.json 各自獨立;OOF-only,不產生提交檔)
uv run python3 tree_search/run_s3e5_v2.py

# 提交至 Kaggle(本場執行環境未設定憑證,以下指令供後續有憑證時使用)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e5 -f <submission.csv> -m "<msg>"
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle`;所有 Python 執行皆透過 `uv run` 以確保 套件環境一致。