

競賽分析報告:playground-series-s3e5

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

目錄	
1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格表	5
3.4 推論表	5
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	6
5. 效能對照(逐階段)	7
6. 總結	8
7. 重現指令	8

1. 競賽目的

What:依葡萄酒的 11 項理化量測值(酸度結構、殘糖、氯化物、游離/總二氧化硫、密度、pH、硫酸鹽、酒精濃度)預測品質評分 `quality`,標籤為 3 至 8 的**序數(ordinal)整數等級**。

Why:評估指標為 **`quadratic_weighted_kappa(QWK,maximize)`**。品質等級之間有順序關係 —— 把 5 分誤判為 6 分遠輕於誤判為 8 分;QWK 以「預測與真實等級距離的平方」加權懲罰誤差,比準確率或無序多分類損失更貼合「越接近真實等級越好」的評分邏輯,是序數目標的合理指標。指標特性也直接決定了本場的建模路線:迴歸頭 + 指標特化的切點後處理。

項目	值
競賽	playground-series-s3e5
問題型別	classification
評估指標	quadratic_weighted_kappa(maximize)
目標欄位	quality

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

本場特有工具:**OptimizedRounder** 切點後處理(定義見第 2.2 節),為本場決定性的一步。其餘全數為共同工具鏈(見《前言》第 3 節);樹搜尋工具本場第 1 版與第 2 版皆有使用。交叉驗證採依 `quality` 分層的 StratifiedKFold(設計理由見第 3.3 節)。

2.2 本場專業術語

專業術語	定義
OptimizedRounder	在 OOF 上搜尋最佳切點,把連續預測值離散化為等級的後處理方法
迴歸頭 / 多分類頭	模型的輸出形式:迴歸頭輸出連續數值,多分類頭輸出各等級的機率

2.3 採用策略

各階段與子階段的定義見《前言》第 6 節(編號跨場同義);主階段 1-4 本場皆有執行,各子階段採用情形如下。

階段 1 | 無 skill 基線

- 1.1 單模型基線 — 使用
- 1.2 三模型 blend — 使用

階段 2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(併入 第 2、3 次實驗,無獨立分數)
- 2.2 EDA 驅動特徵工程 — 使用(併入 第 2、3 次實驗,無獨立分數)
- 2.3 指標感知後處理 — 使用(第 2 次實驗→第 3 次實驗,四捨五入改 OptimizedRounder)
- 2.4 場內反思回退 — 本場未使用

階段 3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 使用
- 3.3 調參入池 — 使用(含於 3.2 之作法)
- 3.4 seed bagging — 使用
- 3.5 結構化去噪 — 本場未使用

階段 4 | +樹搜尋

- 4.1 單模型節點樹 — 使用(工具第 1 版之最佳節點)

- 4.2 ensemble 節點樹 — 使用
- 4.3 先驗注入+去重 — 使用(v2 內建)
- 4.4 邊界推進 mutation — 使用(LGBBOUND 成員)
- 4.5 預算相位機 — 本場未使用

階段 5 | +外部想法注入 — 全案已實測:注入機制建置完成,但注入候選未勝過階段4(階段5=階段4,見總結報告第 7 節)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	2,056
test 列數	1,372
原始欄位數	11
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

11 個原始欄位皆為數值型,無類別欄位。目標 `quality` 為整數(mean 5.720817、median 6.0、skew 0.266307),共 6 個等級且嚴重不平衡:quality 3 僅 12 列、quality 8 僅 39 列,quality 5 (839 列)與 quality 6(778 列)為絕對大宗;非 log 轉換候選。

資料品質乾淨:train/test 皆無缺失值、無重複列、無高共線特徵對(`citric acid` 有 211 個零值,屬合理的理化量測)。train/test 特徵分佈幾乎一致(最大平均差 2.078843%,`citric acid`),無 共變數偏移。EDA 對單一特徵的訊號排序: `alcohol` (Spearman 0.504246)與 `sulphates` (0.456985)最強。EDA 之驗證建議即為「整數目標 → 分層 K-fold」,見第 3.3 節。

第 1 次實驗(通用批次)直接用 11 個原始欄位;第 2–11 次實驗 經特徵工程展開為 21 個特徵(SO2 比值、酸度比值、酒精×硫酸鹽/密度交互作用、糖/酒精比等),階段 3 的線性迭代期間特徵集固定不變。

3.2 實驗總表

語意澄清(本報告全文適用):本場為離散化指標,所有實驗的「決策分數」一律為**後處理後的 QWK**(第 2 次實驗 為四捨五入,其餘為 OptimizedRounder 切點);原始迴歸 OOF 分數未被記錄、也從未作為決策依據(避免「原始分數進步但離散化後不進步」的陷阱),故下表「原始 OOF」欄 一律標「—」。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	1.2	LGB/XGB/CAT(.1/.4/.5)	11	—	0.47871	是,初始基線
2	2.3	LGB/XGB/CAT(.2/.2/.6)	21	—	0.47191	否,取整方式對照組
3	2.3	同 第 2 次實驗 成員與權重	21	—	0.52687	是,階段 2 最佳

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
4	3	3-way(更細的權重搜尋)	21	—	0.52986	是
5	3.2	4-way blend(+LGB_tuned)	21	—	0.56293	是
6	3.4	5-way blend(seed-bag LGB_tuned)	21	—	0.56293	否,無增益
7	3	第 5、6 次實驗 之 5-way blend(巢狀驗證檢驗切點)	21	—	0.54649	—(診斷)
8	3.2	6-way blend(+CAT_tuned)	21	—	0.56769	是,線性迭代最佳
9	3.4	7-way blend(seed-bag CAT_tuned)	21	—	0.56716	否,退步
10	3	第 8 次實驗 之 6-way blend(巢狀驗證檢驗切點)	21	—	0.56393	—(診斷)
11	3	7-way blend(多分類期望值解碼頭)	21	—	0.56769	否,新成員權重歸零
12	4.2	3-way blend(node #17)	無紀錄	—	0.57066	是(僅 OOF 分數)
13	5	外部注入快評候選(EXT-09(stacking);沿用階段4成員 OOF)	無紀錄	—	0.477239	否(未勝過階段4,見 § 5)

線性迭代選型邏輯:以三個梯度提升樹迴歸模型為基礎,依序做(a)更細粒度的權重搜尋(第 4 次實驗)、(b)Optuna 直接以切點離散化後的 QWK 為目標調校 LGB 與 CAT,調校版**加入而非取代**集成池(第 5、8 次實驗);seed-bagging(第 6、9 次實驗)與多分類期望值解碼頭(第 11 次實驗)皆未通過 決策判準。第 9、11 次實驗連兩輪無改善後依協定停止線性迭代。

最佳解成員表(第 12 次實驗,3-way blend,node #17)

成員	權重	solo 分數	備註
LGB_tuned(root)	0.151	無紀錄	即線性迭代之 Optuna 調校 LGB 成員
CAT_tuned	0.551	無紀錄	即線性迭代之 Optuna 調校 CAT 成員,權重最高
LGBBOUND	0.297	0.55784	邊界推進 LGB(max_depth 3→2):solo 比 root 差 0.005,blend 貢獻 +0.0026

第 12 次實驗 由樹搜尋工具(第 2 版,22 個評估節點、1 次回溯、耗時 793.7 秒)找到,勝出的兩個 原因:
(1)LGBBOUND——線性迭代的 Optuna 調參有超參數停在搜尋範圍的邊緣,把範圍再往外推 一步的成員 solo 較弱但夠不一樣;(2)足額的權重搜尋預算(每節點 800 次權重抽樣)——僅 200 次的粗搜在同一組成員上只找到 0.56601,離散指標上縮減權重搜尋預算會讓勝場悄悄變回平手。

補充說明:第 12 次實驗 為**只算出 OOF 分數的搜尋結果**——未產生 test 預測、無 submission 檔、未提交 Kaggle;最佳解紀錄依 OOF 分數選出,與是否提交無關。其權重與切點皆直接對全 OOF 搜尋,未以巢狀驗證對此結果重跑切點檢驗(第 7、10 次實驗 的診斷模式)。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1	5fold	5	無紀錄
2-12	5fold(StratifiedKFold on quality)	5	42

quality 為 6 級且嚴重不平衡的序數目標(quality 3 僅 12 列),一般隨機 K-fold 會使稀有等級在部分折中掛零、QWK 不穩定,故第 2 次實驗起依標籤分層抽樣,且 folds/seed 全程固定(含第 12 次實驗 樹搜尋),各實驗分數可直接比較;此亦與 EDA 的驗證建議一致。

各成員之損失函數與最終超參數未完整記錄,標「無紀錄」;調參設定僅見於實驗紀錄的文字備註 (Optuna TPE、40 trials、600 秒逾時、完整 5-fold CV,目標函數為該 trial 自身 OOF 經切點 離散化後的 QWK)。

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無後處理紀錄	sub_generic_0.47871_20260703_120341.csv	否
2	round_to_nearest_int + clip[3,8]	無紀錄	否
3	OptimizedRounder(cutpoints=[3.642, 4.594, 5.657, 6.196, 7.386])+ clip[3,8]	無紀錄	否
4-6, 8, 9, 11	OptimizedRounder(各實驗切點各異)+ clip[3,8]	無紀錄	否
7, 10	OptimizedRounder(nested:4 折擬合、留出折套用)+ clip[3,8],診斷用	—(診斷)	否
12	OptimizedRounder 切點與 blend 權重在每個節點的評分函式內聯合搜尋	—(僅 OOF 分數,未產生)	否

id_column = Id、target_column = quality。線性迭代最佳第 8 次實驗之切點為 [3.574, 4.586, 5.609, 6.174, 7.628];第 12 次實驗之具體切點無正式數值紀錄,標「無紀錄」。本場執行環境未設定 Kaggle 憑證,所有實驗皆未提交排行榜。

3.5 評估指標 / 排行榜

指標定義:QWK = 觀察一致性對隨機期望一致性之修正,以「預測與真實等級距離的平方」加權,越接近 1 代表預測排序與真實等級越一致。

項目	分數
第 1 次實驗(通用批次基線)	0.47871
第 3 次實驗(階段 2 最佳)	0.52687
第 8 次實驗(線性迭代最佳)	0.56769
第 12 次實驗(樹搜尋,本場最佳解紀錄)	0.57066
Public LB / Private LB	無紀錄

本場未提交 Kaggle,無排行榜紀錄,無法計算 CV↔LB gap,不作推測性比較。各階段增益與切點 過擬診斷之衍生算式:

線性迭代增益(第 8 次實驗 - 第 3 次實驗): $0.56769 - 0.52687 = 0.04082$
樹搜尋增益(第 12 次實驗 - 第 8 次實驗): $0.57066 - 0.56769 = 0.00297$
巢狀驗證切點檢驗 gap(全 OOF 切點 - 巢狀切點):
5-way(第 7 次實驗): $0.56293 - 0.54649 = 0.01644$
6-way(第 10 次實驗): $0.56769 - 0.56393 = 0.00376$ (實驗紀錄的文字備註記為 $+0.00377$,四捨五入位數差異)

以巢狀驗證檢驗切點的結果顯示,全 OOF 切點擬合的過擬風險隨集成池成熟而縮小($0.01644 \rightarrow 0.00377$),全 OOF 切點在本場屬可接受的標準做法;但第 12 次實驗 未重跑此診斷,見第 3.2 節補充說明。

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	2026-07-03T12:03:41	0.47871	1.2	11 特徵三模型 blend,初始基線
2	2026-07-03T18:48:21	0.47191	2.3	21 特徵,四捨五入後處理(取整方式對照組)
3	2026-07-03T18:48:21	0.52687	2.3	同一 blend 改用 OptimizedRounder,階段 2 最佳
4	2026-07-03T23:08:22	0.52986	3	改用更細粒度的權重搜尋
5	2026-07-03T23:09:50	0.56293	3.2	加入 Optuna 直接 QWK 調校之 LGB_tuned
6	2026-07-03T23:10:42	0.56293	3.4	seed-bag LGB_tuned,無增益
7	2026-07-03T23:11:20	0.54649	3	巢狀切點檢驗(5-way),非模型變更
8	2026-07-03T23:13:44	0.56769	3.2	加入 CAT_tuned,線性迭代最佳
9	2026-07-03T23:15:20	0.56716	3.4	seed-bag CAT_tuned,退步
10	2026-07-03T23:15:32	0.56393	3	巢狀切點檢驗(6-way),非模型變更
11	2026-07-03T23:16:51	0.56769	3	多分類期望值解碼頭權重歸零,連兩輪無改善停止
12	2026-07-04T11:59:43	0.57066	4.2	node #17 3-way blend,本場最佳
13	2026-07-08T11:46:18	0.477239	5	外部注入快評:EXT-09(stacking) 候選 OOF 未勝過階段4,不採納

- **轉折 1(第 2→3 次實驗):**同一組成員與權重,後處理由四捨五入改為 OptimizedRounder 切點, $0.47191 \rightarrow 0.52687$ (同一 blend 上取整方式帶來 $+0.05496$ 增益)——本場單一最大增益來源。
- **轉折 2(第 4→5 次實驗、第 5→8 次實驗):**把 Optuna 目標函數直接設為切點離散化後的 QWK 調校 LGB ($0.52986 \rightarrow 0.56293$)、再同法調校 CAT($0.56293 \rightarrow 0.56769$),兩次調參佔線性迭代大部分增益。
- **轉折 3(第 11→12 次實驗):**樹搜尋工具(第 2 版)以邊界推進成員 LGBBOUND + 足額權重搜尋預算, $0.56769 \rightarrow 0.57066$ (勝線性迭代 $+0.00297$ 、勝第 1 版樹搜尋之 0.56766 達 $+0.00300$,屬結構性 勝出而非切點噪音量級)。

5. 效能對照(逐階段)

階段	配置	分數	相對改善
1	基線(Claude Code 直接執行,未引入 skill;第 1 次實驗 通用批次)	0.47871	—(基線)
2	+ kaggle-agent skill 六階段流程(第 3 次實驗,OptimizedRounder)	0.52687	10.06%
3	+ self-improvement 線性迭代(第 8 次實驗,6-way blend + Optuna 直接 QWK 調參)	0.56769	7.75%
4	+ 樹搜尋(第 12 次實驗,node #17,3-way blend)	0.57066	0.52%
5	+ 外部想法注入(第 13 次實驗,快評)	0.57066	0.00%(未勝過)

相對改善計算式(每階段對前一階段)

階段1→2: $0.52687 - 0.47871 = 0.04816$, 相對改善 $0.04816 / 0.47871 = 10.0604\%$
階段2→3: $0.56769 - 0.52687 = 0.04082$, 相對改善 $0.04082 / 0.52687 = 7.7476\%$
階段3→4: $0.57066 - 0.56769 = 0.00297$, 相對改善 $0.00297 / 0.56769 = 0.5232\%$
階段4→5: 注入候選 0.477239 未勝過階段4 0.57066, 搜尋保留階段4 → 相對改善 0.00%(外部注入無增益)

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:XGB)	0.46995	第 1 次實驗
1.2(三模權重 blend)	0.47871	第 1 次實驗
2.3(指標感知後處理前:naive round,對照組)	0.47191	第 2 次實驗
2.3(指標感知後處理後:OptimizedRounder)	0.52687	第 3 次實驗
3.2(Optuna 直接優化切點後 QWK 調參 LGB,加入池)	0.56293	第 5 次實驗
3.4(seed bagging,LGB_tuned seed 2024,無增益)	0.56293	第 6 次實驗
3.2(Optuna 直接優化切點後 QWK 調參 CatBoost,加入池,線性迭代最佳)	0.56769	第 8 次實驗
3.4(seed bagging,CAT_tuned seed 2024,退步未採用)	0.56716	第 9 次實驗
4.1(樹搜尋工具第 1 版,node #11,首版樹搜尋最佳)	0.56766	第 12 次實驗 紀錄的文字備註引用
4.2(樹搜尋工具第 2 版,node #17,邊界推進成員入池,本場最佳)	0.57066	第 12 次實驗

階段 5 | + 外部想法注入(ERA 第二支柱)

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-09:stacking**——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic),以 nested-CV 避免洩漏。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們**已算好的 OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

```
階段5 注入候選(stacking)OOF QWK = 0.477239
階段4 冠軍          OOF QWK = 0.570660
差距 = -0.093421 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4
```

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的 ERA 第二支柱誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場資料乾淨(無缺失、無重複、無共線問題),真正的難點在目標本身: quality 是 6 級、嚴重不平衡的序數標籤,而 QWK 是離散化指標。第一個關鍵決策是採迴歸頭而非多分類頭——讓大宗等級的連續訊號幫助定位資料稀少的極端等級;第 11 次實驗的多分類期望值解碼頭成員權重被搜尋歸零,反向印證了這個選擇。

第二個關鍵決策是把「後處理」當一級公民:同一組模型與權重,後處理由四捨五入換成 OptimizedRounder 切點即帶來本場單一最大增益(第 2 次實驗→第 3 次實驗);其後所有加入/捨棄決策一律只看切點離散化後的 QWK,並把同一原則貫徹到 Optuna 的目標函數(同樣直接優化此分數)與樹搜尋評估器(取整規則內建於每個節點)。

各階段增益來源清楚分層:階段1→2 來自 skill 管線的特徵工程與切點後處理(0.47871 → 0.52687),階段2→3 來自 Optuna 直接 QWK 調參的成員 LGB_tuned、CAT_tuned(→ 0.56769),階段3→4 來自樹搜尋挖出的邊界推進成員 LGBBOUND(→ 0.57066)。本場為此批競賽中前兩階段增幅最大的一場,顯示離散化指標下「指標特化後處理 + 直接優化最終指標」的複利效果。

結果可信度:CV 全程固定同一組 StratifiedKFold 折,分數跨實驗可直接比較;以巢狀驗證檢驗切點(第 7、10 次實驗)顯示切點過擬風險隨集成池成熟而縮小。但須如實標注:本場所有實驗皆未提交 Kaggle(無憑證),最終 0.57066 僅有 OOF 分數且未重跑上述巢狀驗證檢驗,缺乏排行榜對照驗證。

重現本實驗的最短路徑:見第 7 節。

階段 5(外部想法注入) 經快評未勝過階段4:注入機制可運作、也產生了候選(stacking),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的 ERA 第二支柱誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 第 1 次實驗:通用批次管線(11 特徵)
uv run python3 competitions/run_competition.py playground-series-s3e5

# 第 2、3 次實驗(2.3):手刻管線(EDA → 特徵工程 → 訓練/CV/集成 → naive-round vs OptimizedRounder)
uv run python3 competitions/playground-series-s3e5/scripts/eda.py
uv run python3 competitions/playground-series-s3e5/scripts/features.py
uv run python3 competitions/playground-series-s3e5/scripts/train.py
```

```

# 第 4-11 次實驗(階段 3 自我改進迭代,依序執行;每步寫入 experiments.json,
# 並快取 scripts/cache/*.npz 供後續步驟重用)
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py base           # 第 4 次實驗
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py tune_lgb      # Optuna 調校 LGB(寫入
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py r1_pool       # 第 5 次實驗(3.2)
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py seed_bag      # 第 6 次實驗(3.4)
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py nested_cut    # 第 7 次實驗
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py tune_cat      # Optuna 調校 CAT(寫入
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py r2_pool       # 第 8 次實驗(3.2)
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py seed_bag      # 第 9 次實驗(3.4)
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py nested_cut    # 第 10 次實驗
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py r3_multiclass # 第 11 次實驗
uv run python3 competitions/playground-series-s3e5/scripts/iterate.py submit        # 產出提交檔

# 第 12 次實驗(4.2):樹搜尋第 2 版(best;可中斷/續跑;樹狀態存 experiments_tree_v2.json,
# 與第 1 版的 experiments_tree.json 各自獨立;只算 00F 分數,不產生提交檔)
uv run python3 tree_search/run_s3e5_v2.py

# 提交至 Kaggle(本場執行環境未設定憑證,以下指令供後續有憑證時使用)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e5 -f <submission.csv> -m "<msg>"

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 00F、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s3e5

```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle` ;所有 Python 執行皆透過 `uv run` 以確保 套件環境一致。