

競賽分析報告:playground-series-s3e7

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

目錄	
1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格表	4
3.4 推論表	5
3.5 評估指標	5
4. 實驗軌跡	6
5. 效能對照(逐階段)	6
6. 總結	7
7. 重現指令	8

1. 競賽目的

What:依訂房紀錄的各項欄位(提前預訂天數、房價、住客組成、市場區隔、歷史取消紀錄等) 預測該筆訂房最終是否被取消(`booking_status` ,1 = 取消),為二元分類問題。

Why:評估指標為 **ROC-AUC(maximize)**。取消與未取消存在輕度不平衡(約四成取消), ROC-AUC 是與分類門檻無關的排序型指標,直接衡量模型能否把「會取消」的訂房排在「不會取消」之前,不需選定機率門檻、也不要求機率校準,適合此類輕度不平衡的二元分類。

項目	值
競賽	playground-series-s3e7
問題型別	classification
評估指標	roc_auc(maximize)
目標欄位	booking_status

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第3版(較早另有第2版掃描的中間結果)。交叉驗證採直接對 `booking_status` 分層的 StratifiedKFold(設計理由見第3.3節)。

2.2 本場專業術語

本場無特有專業術語,所需詞彙均見《前言》第5節。

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段1 | 無 skill 基線

- 1.1 單模型基線 — 使用
- 1.2 三模型 blend — 使用

階段2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(併入第3次實驗,無獨立分數)
- 2.2 EDA 驅動特徵工程 — 使用(第2次實驗→第3次實驗,反思刪減工程特徵)
- 2.3 指標感知後處理 — 本場未使用(ROC-AUC 無需後處理)
- 2.4 場內反思回退 — 本場未使用

階段3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 使用
- 3.3 調參入池 — 使用(含於3.2之作法)
- 3.4 seed bagging — 本場未使用
- 3.5 結構化去噪 — 本場未使用

階段4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 使用(較早掃描之中間結果)
- 4.3 先驗注入+去重 — 使用(v2/v3 內建)
- 4.4 邊界推進 mutation — 使用(EXPL_BOUND2 成員)

- 4.5 預算相位機 — 使用(本場最佳)

階段 5 | +外部想法注入 — 全案已實測:注入機制建置完成,但注入候選未勝過階段4(階段5=階段4,見總結報告第 7 節)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	42,100
test 列數	28,068
原始欄位數	17
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

17 個特徵全為數值型(餐型、房型、市場區隔等類別欄位已預先 label-encode);train/test 皆 無缺失值,亦無高共線特徵對。目標 booking_status 為 0/1 整數,mean 0.392019(約四成 取消),非 log 轉換候選。單一最強關聯特徵為 lead_time (pearson 0.374865), no_of_special_requests 呈保護性負相關(pearson -0.220278)。

補充說明:本次分析記錄 train 重複列 562;另一份進度筆記敘述則為「無重複列/重複 id」,兩者計算方式不同(前者以特徵欄位計、不含 id 欄)。本報告以本次分析之數字為準。

3.2 實驗總表

語意澄清(本報告全文適用):ROC-AUC 為排序型指標,本場無取整/門檻類後處理,故各 實驗的「原始 OOF」即「決策分數」,兩欄同值;且本場全部決策皆以本機 OOF 為準(未提交 Kaggle,見第 3.4 節)。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	1.2	LGB/XGB/CAT(0.1/0.6/0.3)	17	0.89882	0.89882	基線參照
2	2.2	LGB/XGB/CAT(0.45/0.45/0.1)	31	0.89788	0.89788	否,低於基線
3	2.2	LGB/XGB/CAT(0.5/0.4/0.1)	25	0.899395	0.899395	是,階段 2 最佳
4	3.2	LGB(Optuna)/XGB/CAT(0.55/0.4/0.05)	25	0.899891	0.899891	是
5	3.2	LGB(tuned)/XGB(Optuna)/CAT(0.5/0.35/0.15)	25	0.899722	0.899722	否,多樣性受損
6	3	第 4 次實驗 基模型 + 0.01 間隔權重網格精修(0.54/0.4/0.06)	25	0.899893	0.899893	是,線性迭代最終
7	4.5	38 成員 mega-blend(node #48,9 個非零權重)	無紀錄	0.900455	0.900455	是,本場最佳
8	5	外部注入快評候選(EXT-09(stacking))	—	—	0.900437	

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
						否(未勝過階段4, 見 § 5)

最佳解成員表(第 7 次實驗, mega-blend; 權重搜尋將 29/38 個成員歸零)

成員	權重	solo 分數	備註
SEEDBAG	0.358	無紀錄	調參 LGB 之 seed-bagging 變體
XGBDIV family(4 節點)	0.459	無紀錄	刻意多樣化之深 XGB 家族, 合計權重最大
EXPL_BOUND2	0.114	0.897541	邊界推進衍生的淺層(深度 2)LGB; solo 較弱但第 3 大權重
root	0.038	0.899215	搜尋根節點 = 第 4 次實驗 之 Optuna 調參 LGB(同模型紀錄)
FEATPRUNE-child	0.018	無紀錄	特徵修剪變體
XGBHAND-child	0.013	無紀錄	手設 XGB 之子節點

選型脈絡: 第 4 次實驗 以 Optuna 只調 LGB, 單模 0.898824 升至 0.899215 成最強單模, blend +0.000496; 第 5 次實驗 同法調 XGB, 單模微升至 0.89886 但 blend 退步 -0.000169——調參後 XGB 與調參 LGB 樹形趨同、喪失多樣性, 故保留手設 XGB。第 6 次實驗 僅在 0.01 間隔的權重網格上精修 混合層, +0.000002 屬噪音級, 連同 第 5 次實驗 計兩輪無實質改進, 依協定停止線性迭代。

第 7 次實驗 由樹搜尋工具(第 3 版)的強制探索爆發機制注入 mega-blend(把當時全部 38 個 solo 池成員都納入, 先將各成員預測轉為排名再做權重搜尋)而得; 超越第 2 版重現高原 (0.900054) 的增益全數來自此機制, 而非任何單模突破。

補充說明: 最佳解紀錄(第 7 次實驗)以 OOF 分數最大選出, 為樹搜尋結果、只算出 OOF 分數——未產生 test 預測、無 submission 檔、未提交 Kaggle; 其權重直接對全 OOF 擬合(無巢狀驗證), 0.0002 等級的增益帶有 OOF 權重過擬風險, 方向性結論(探索爆發 mega-blend 優於手工成長 blend)較第 4 位小數穩健。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1	5fold	5	無紀錄
2	5fold(StratifiedKFold on booking_status)	5	42
3	5fold(StratifiedKFold on booking_status)	5	42
4	5fold(StratifiedKFold on booking_status)	5	42
5	5fold(StratifiedKFold on booking_status)	5	42
6	5fold(StratifiedKFold on booking_status)	5	42
7	5fold(StratifiedKFold on booking_status)	5	42

目標為二元且輕度不平衡, 直接對 booking_status 分層即可讓每折正負比例一致, 無需分箱; 第 2–7 次實驗 固定同一組折, 7 個實驗分數可直接比較, 樹搜尋(第 7 次實驗)亦沿用完全相同的折。

Objective 與關鍵超參(有紀錄者,節錄自 第 6 次實驗 之成員設定;LGB 為 Optuna 調參結果,「淺而強正則」——與跨競賽經驗「中小型資料獎勵正則化而非容量」一致):

```
LGB(Optuna):objective=binary, n_estimators=3000, learning_rate≈0.068, max_depth=3,
            num_leaves=178(depth=3 下實際不起作用), min_child_samples=47,
            subsample≈0.889, colsample_bytree≈0.532, reg_alpha≈2.14, reg_lambda≈0.0115
XGB(手設): objective=binary:logistic, n_estimators=3000, learning_rate=0.03, max_depth=6,
            min_child_weight=5, subsample=0.8, colsample_bytree=0.8
CAT(手設): loss_function=Logloss, iterations=4000, learning_rate=0.03, depth=7,
            l2_leaf_reg=5.0
```

第 7 次實驗(樹搜尋)僅附權重與部分 solo 分數,未附完整超參數——無紀錄,不臆測。

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無後處理紀錄	sub_generic_0.89882_20260703_120542.csv	否
2	無後處理紀錄	sub_blend_0.89788_20260703_185938.csv	否
3	無後處理紀錄	sub_blend_0.89939_20260703_190223.csv	否
4	無後處理紀錄	sub_blend_0.89989_20260703_203932.csv	否
5	無後處理紀錄	無紀錄	否
6	無後處理紀錄	sub_blend_0.89989_20260703_205132.csv	否
7	無後處理紀錄	無紀錄(僅 OOF 分數,未產生 test 預測)	否

ROC-AUC 為排序型指標,無門檻轉換或機率校準之後處理需求,各實驗皆無後處理紀錄。表中 submission 檔為本機產出之預測檔;本場全程未提交 Kaggle,無排行榜紀錄,故「已提交」一律為否。欄位格式:id 欄 id、目標欄 booking_status。

3.5 評估指標

指標定義:ROC-AUC = 隨機抽一筆正類(取消)與一筆負類(未取消),模型將正類排在前面的 機率;0.5 為隨機、1 為完美排序,越高越好。

項目	OOF ROC-AUC
LGB(第 6 次實驗 成員,Optuna 調參)	0.899215
XGB(第 6 次實驗 成員,手設)	0.898765
CAT(第 6 次實驗 成員,手設)	0.896709
Ensemble(第 6 次實驗,線性迭代終點)	0.899893
Ensemble(第 7 次實驗,樹搜尋 best)	0.900455
Public / Private LB	無紀錄(未提交)

本場未提交 Kaggle,無排行榜表,CV↔LB gap 無法計算。第 7 次實驗 相對 第 6 次實驗 之改善:

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	2026-07-03T12:05:42	0.89882	1.2	17 原始特徵三模型 blend,設定待超越基線
2	2026-07-03T18:59:38	0.89788	2.2	加入 14 個工程特徵反而低於基線
3	2026-07-03T19:02:23	0.899395	2.2	反思後精簡為 8 個工程特徵,回升越過基線
4	2026-07-03T20:39:32	0.899891	3.2	Optuna 調參 LGB,線性階段主要躍升
5	2026-07-03T20:47:55	0.899722	3.2	Optuna 調參 XGB 使多樣性受損,棄用
6	2026-07-03T20:51:32	0.899893	3	僅精修混合層,噪音級改善後依協定停止
7	2026-07-04T11:59:43	0.900455	4.5	探索爆發 mega-blend,本場最佳
8	—	0.900437	5	外部注入快評:EXT-09(stacking) 候選 OOF 未勝過階段4,不採納

- **轉折 1(第 2 次實驗→第 3 次實驗):**第一輪特徵工程加入的週期性月份/日期編碼與價格交乘項是噪音 而非訊號,反思後刪除,分數由低於基線的 0.89788 回升至 0.899395,是一次「假設→驗證」式修正。
- **轉折 2(第 3 次實驗→第 4 次實驗):**Optuna(每組參數先只在第 0 折評分以省時)找到淺而強正則的 LGB 配置,單模 0.898824 → 0.899215,blend +0.000496,為線性迭代階段最大單筆增益。
- **轉折 3(第 6 次實驗→第 7 次實驗):**樹搜尋工具(第 3 版)在所有第一代系譜連續未刷新最佳而凍結 後,自動注入探索爆發的 38 成員 mega-blend,由線性終點 0.899893 升至 0.900455(+0.000562)。

5. 效能對照(逐階段)

階段	配置	分數	相對改善
1	基線(Claude Code 直接執行,未引入 skill;第 1 次實驗 通用批次三模型 blend)	0.89882	—(基線)
2	+ kaggle-agent skill 六階段流程(第 3 次實驗,精簡特徵三模型 blend)	0.899395	0.06%
3	+ self-improvement 線性迭代(第 6 次實驗,三輪之終點)	0.899893	0.06%
4	+ 樹搜尋(第 7 次實驗,node #48 mega-blend)	0.900455	0.06%

相對改善計算式(每階段對前一階段)

階段1→2: $0.899395 - 0.89882 = 0.000575$, 相對改善 $0.000575 / 0.89882 = 0.0640\%$
 階段2→3: $0.899893 - 0.899395 = 0.000498$, 相對改善 $0.000498 / 0.899395 = 0.0554\%$
 階段3→4: $0.900455 - 0.899893 = 0.000562$, 相對改善 $0.000562 / 0.899893 = 0.0625\%$

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:XGB)	0.89821	第 1 次實驗
1.2(三模權重 blend)	0.89882	第 1 次實驗
2.2(第一輪特徵工程:17 原始 + 14 工程特徵,反而低於基線)	0.89788	第 2 次實驗
2.2(第二輪精簡:17 原始 + 8 工程特徵,回升越過基線)	0.899395	第 3 次實驗
3.2(Optuna 調參 LGB,加入池,線性階段最大單筆增益)	0.899891	第 4 次實驗
3.2(Optuna 調參 XGB,多樣性受損,blend 退步未採用)	0.899722	第 5 次實驗
4.2(樹搜尋工具第 2 版,較早 22-節點掃描之最佳)	0.900242	第 7 次實驗 紀錄的文字備註引用
4.5(樹搜尋工具第 3 版,node #48,探索爆發 mega-blend,本場最佳)	0.900455	第 7 次實驗

階段 5 | +外部想法注入(快評)

在階段4收斂點注入外部想法候選(本場來源:EXT-09(stacking)),以快取 OOF 評估其能否勝過階段4:

```

階段5 注入候選 OOF auc = 0.900437
階段4(committed)      = 0.900455
delta = -0.000018 → 未勝過階段4,搜尋不採納 → 階段5 = 階段4(外部注入無增益)

```

(階段5 為全案「停滯時注入外部想法」機制的快評結果,非完整重跑;機制與 15 場跨場 結論見《總結報告》第 7 節與 docs/phase_j_j3_findings。)

6. 總結

本場資料乾淨:17 個特徵全為已數值編碼、無缺失值、無高共線對,目標約四成取消的輕度不平衡,直接對 `booking_status` 做 StratifiedKFold 即得穩定 CV; `lead_time` 是單一最強訊號。第 2 次實驗 起全程固定同一組折,使所有實驗分數可直接比較,是後續每一步小增益仍可辨識的前提。

關鍵決策有三:其一,第 2 次實驗 堆特徵反而低於基線後,以反思刪除噪音特徵而非繼續堆疊,第 3 次實驗 隨即 越過基線;其二,第 5 次實驗 揭示「單模變強、blend 變差」的多樣性教訓,保留手設 XGB 而否決調參 結果;其三,第 6 次實驗 改善僅噪音級,依「連兩輪無實質改進即停」協定如實收手,把剩餘預算讓給 結構化搜尋。

各階段增益皆為正但幅度極小,是本批次中增益幅度最小的一場:skill 流程、線性迭代與樹搜尋各貢獻一小步,沒有單一大躍升;最後一階段的 0.900455 全數來自探索爆發機制注入的全池 mega-blend,而非任何單模突破——blend 貢獻與 solo 分數脫鉤(EXPL_BOUND2 solo 僅 0.897541 卻拿第 3 大權重)是本場最具遷移價值的觀察。

可信度方面須如實說明:本場全程僅本機 OOF、未提交 Kaggle,無排行榜對照;第 7 次實驗 權重直接對全 OOF 擬合、無巢狀驗證,0.0002 等級增益帶有 OOF 權重過擬風險。方向性結論(探索爆發 mega-blend 優於手工成長 blend)是穩健的部分,第 4 位小數不是。

重現本實驗的最短路徑:見第 7 節。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 階段 2:EDA
uv run python3 competitions/playground-series-s3e7/scripts/eda.py

# 2.2 / 第 3 次實驗:特徵工程 + 建模(LGB/XGB/CAT,5-fold StratifiedKFold,00F 權重搜尋 blend)
uv run python3 competitions/playground-series-s3e7/scripts/train.py

# 3.2 / 第 4 次實驗:Optuna 調參 LGB(50 trials,僅以第 0 折評分挑參)+ blend
uv run python3 competitions/playground-series-s3e7/scripts/optuna_lgb.py

# 3.2 / 第 5 次實驗:Optuna 調參 XGB(未採納)
uv run python3 competitions/playground-series-s3e7/scripts/optuna_xgb.py

# 階段 3 / 第 6 次實驗:混合層精修(0.01 網格 + rank blend,線性迭代終點)
uv run python3 competitions/playground-series-s3e7/scripts/blend_refine.py

# 4.5 / 第 7 次實驗:樹搜尋第 3 版(本場最佳;可中斷續跑,樹狀態存 experiments_tree_v3.json)
uv run python3 tree_search/run_s3e7_v3.py

# 報告產生(本檔)
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e7
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py \
    competitions/playground-series-s3e7/REPORT.md competitions/playground-series-s3e7/facts.json
bash .claude/skills/kaggle-report/assets/md2pdf.sh competitions/playground-series-s3e7/REPORT.md \
    competitions/playground-series-s3e7/s3e7_REPORT.pdf

# 提交至 Kaggle(本場未執行;需先設定有效之 KAGGLE_API_TOKEN)
export KAGGLE_API_TOKEN=$(python3 -c "import json; print(json.load(open('/home/tjyen/.kaggle/kaggle.json'))['key'])")
uv run kaggle competitions submit -c playground-series-s3e7 \
    -f competitions/playground-series-s3e7/submissions/sub_blend_0.89989_20260703_205132.csv \
    -m "Optuna-tuned LGB + XGB + CAT blend (0.54/0.40/0.06), 00F 0.899893"
```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 uv run 。