

競賽分析報告:playground-series-s3e9

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

目錄

1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格表	4
3.4 推論表	5
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	5
5. 效能對照(逐階段)	6
6. 總結	7
7. 重現指令	8

1. 競賽目的

What:依混凝土配方中八種成分用量(水泥、爐渣、飛灰、水、減水劑、粗骨材、細骨材)與 養護天數 (AgeInDays)預測混凝土抗壓強度(Strength),為連續數值輸出的迴歸問題,即 經典 Concrete Compressive Strength 資料集的 Kaggle Playground 版本。

Why:評估指標為 **RMSE(minimize)**。抗壓強度為工程安全量,嚴重錯估的後果(結構 風險、材料浪費)遠重於小誤差;RMSE 以原始單位呈現誤差並對大誤差施以平方懲罰,能引導 模型優先壓制離譜預測,適合此任務。

項目	值
競賽	playground-series-s3e9
問題型別	regression
評估指標	rmse(minimize)
目標欄位	Strength

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場第1版與第2版皆有使用(結果只算出 OOF 分數,未併入正式實驗紀錄)。交叉驗證採依 strength 十分位分層的 StratifiedKFold(設計理由見第3.3節)。

2.2 本場專業術語

本場無特有專業術語,所需詞彙均見《前言》第5節。

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段 1 | 無 skill 基線

- 1.1 單模型基線 — 使用
- 1.2 三模型 blend — 使用

階段 2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(併入第2次實驗,無獨立分數)
- 2.2 EDA 驅動特徵工程 — 使用(併入第2次實驗,無獨立分數)
- 2.3 指標感知後處理 — 本場未使用(RMSE 迴歸原值直接輸出)
- 2.4 場內反思回退 — 使用(第3次實驗 交互特徵探索,反而變差已還原)

階段 3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 使用
- 3.3 調參入池 — 使用(含於3.2之作法)
- 3.4 seed bagging — 使用
- 3.5 結構化去噪 — 使用(第5次實驗 重複列群組平滑,無改善已還原)

階段 4 | +樹搜尋

- 4.1 單模型節點樹 — 使用(輸給線性最佳)
- 4.2 ensemble 節點樹 — 使用(精確追平線性最佳,未超越)
- 4.3 先驗注入+去重 — 使用(v1/v2 內建)
- 4.4 邊界推進 mutation — 本場未使用

- 4.5 預算相位機 — 本場未使用

階段 5 | +外部想法注入 — 全案已實測:注入機制建置完成,但注入候選未勝過階段4(階段5=階段4,見總結報告第 7 節)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	5,407
test 列數	3,605
原始欄位數	8
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

8 個特徵全為數值型、無類別欄位;train/test 皆無缺失值。目標 `Strength` 近似對稱 (mean 35.45、median 33.95、skew 0.38),非 log 轉換候選。 `AgeInDays` 為最強關聯特徵 (pearson 0.334、spearman 0.604)且右偏 (skew 2.75),支持 log 養護時間類特徵;爐渣、飛灰、減水劑為零膨脹欄位(零值列數 3,166 / 3,927 / 3,143),屬配方選用而非缺失。

補充說明(重複列的計算方式):本次分析記錄 train 重複列 2,401——此數字只計「特徵完全相同、但量測目標值不同」的列,且不含每組的第一筆 (佔比 44.4%,第 5 次實驗 紀錄的文字備註之 `dup_frac 0.4441`);另一份進度筆記所述「約 56% 列屬於某重複群組」是同一結構、把每組第一筆也算進去的算法,兩者不矛盾。此為量測/重抽樣噪音而非洩漏,構成本場 CV 分數的不可約噪音上限,並懲罰高容量模型。

train/test 分佈接近(平均值差異最大者為 `AgeInDays` 的 -5.02% 與 `BlastFurnaceSlag` 的 -4.79%),無 covariate shift 疑慮;亦無高共線特徵對紀錄。

3.2 實驗總表

語意澄清(本報告全文適用):本場指標為連續 RMSE,無取整/門檻類後處理,「原始 OOF」即「決策分數」,兩欄恆相等;且全部決策皆以本機 OOF 為準(未提交 Kaggle,見第 3.4 節)。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	1.2	LGB/XGB/CAT(0/0/1.0)	8	12.54287	12.54287	基線參照
2	2	LGB/XGB/CAT(0.15/0/0.85)	22	12.073474	12.073474	是,階段 2 最佳
3	2.4	同 第 2 次實驗 成員,+3 交互特徵	25	12.094826	12.094826	否,變差後還原
4	2	同 第 2 次實驗	22	12.073474	12.073474	是,逐位元重現 第 2 次實驗
5	3.5	LGB/XGB/CAT(0.05/0.1/0.85)	22	12.081216	12.081216	否,變差後還原
6	3.2	4-way(調參 LGB 權重 0)	22	12.073474	12.073474	持平,成員保留

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
7	3.4	5-way(CAT 0.773/seed2 0.227)	22	12.071429	12.071429	是
8	3.4	7-way seed-bag blend	22	12.070034	12.070034	是,本場最佳

最佳解成員表(第 8 次實驗,7-way blend;權重由演算法在 OOF 上搜尋而得)

成員	權重	solo 分數	備註
LGB(orig,正則化)	0.0	12.11061	權重歸零
XGB(orig,正則化)	0.0	12.12086	權重歸零
CAT(orig)	0.478	12.07459	最強單模,權重最大
LGB_tuned(Optuna)	0.0	12.12074	調參原 seed 權重歸零
LGB_tuned_seed2	0.127	12.10843	調參 LGB 之 seed 1042 變體
CAT_seed2	0.265	12.07852	CAT 之 seed 1042 變體
LGB_tuned_seed3	0.129	12.0977	調參 LGB 之 seed 2042 變體

選型脈絡:小型噪音資料獎勵正則化而非容量——第 1 次實驗 未正則化時 LGB(13.2055)/XGB (12.98156)過擬合嚴重、權重全數歸零由 CAT 獨拿;第 2 次實驗 對兩者施加淺深度+強 L1/L2 後 LGB 才取回 0.15 權重。階段 3 的線性迭代四輪中,去噪(第 5 次實驗)與調參(第 6 次實驗)皆未改善,全部 增益來自 seed bagging 的變異數縮減:調參 LGB 原 seed 權重為 0,其 seed 變體卻合計拿下 約四分之一權重,CAT 的 seed-bag(第 8 次實驗)則貢獻單輪最大增益。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1	5fold	5	無紀錄
2-8	5fold_stratified_strength_decile(StratifiedKFold on Strength 十分位)	5	42

目標為連續值且資料量小、噪音大,對 Strength 十分位分層可讓每折目標分佈一致、降低折間 變異;第 2 次實驗 起 CV 全程固定,八個實驗分數可直接比較,樹搜尋兩輪亦沿用完全相同的折。

Objective 一律為 RMSE。關鍵超參(節錄自 第 2、6 次實驗 紀錄的文字備註):

```
LGB(手設正則化): num_leaves=15, max_depth=5, reg_alpha(L1)=2, reg_lambda(L2)=4
XGB(手設正則化): max_depth=4, reg_alpha(L1)=2, reg_lambda(L2)=4
CAT(手設):      depth=6, l2_leaf_reg=6
LGB_tuned(Optuna 60-trial): learning_rate≈0.0198, num_leaves=11, max_depth=3,
    min_child_samples=31, subsample≈0.602, colsample_bytree≈0.501,
    reg_alpha≈0.112, reg_lambda≈0.302, n_estimators=3000
seed-bag 成員超參與原成員完全相同,僅換 random seed(1042 / 2042)
```

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無後處理紀錄	sub_generic_12.54287_20260703_120632.csv	否
2	無後處理紀錄	sub_blend_12.07347_20260703_191007.csv	否
3	無後處理紀錄	sub_blend_12.09483_20260703_191047.csv	否
4	無後處理紀錄	sub_blend_12.07347_20260703_191124.csv	否
5	無後處理紀錄	無紀錄	否
6	無後處理紀錄	無紀錄	否
7	無後處理紀錄	無紀錄	否
8	無後處理紀錄	sub_blend_12.07003_20260703_235120.csv	否

`id_column = id`、`target_column = Strength`。本場無任何後處理紀錄(迴歸原值直接輸出)。所有 submission 檔皆為本機產出、未上傳 Kaggle(本次執行無 API 憑證);第 3 次實驗之劣化 submission 檔已依進度筆記刪除,僅保留最佳與基線檔案。

3.5 評估指標 / 排行榜

指標定義:RMSE = 預測誤差平方平均之平方根,單位與 Strength 相同,對大誤差懲罰重於 MAE。

項目	OOF RMSE
LGB(第 2 次實驗 成員,正則化)	12.11061
XGB(第 2 次實驗 成員,正則化)	12.12086
CAT(第 2 次實驗 成員)	12.07459
Ensemble(第 2 次實驗,階段 2 最佳)	12.073474
Ensemble(第 8 次實驗,本場最佳)	12.070034
Public / Private LB	無紀錄(未提交)

本場未提交 Kaggle,無排行榜表,CV↔LB gap 無法計算。全場分數的唯一比較基準為同一固定 CV 下的 OOF RMSE。整體與階段 3 改善量:

第 1 次實驗 → 第 8 次實驗: $12.54287 - 12.070034 = 0.472836$, 相對改善 $0.472836 / 12.54287 = 3.7698\%$
階段 3 增益: 12.073474 (第 2、4 次實驗) - 12.070034 (第 8 次實驗) = 0.003440

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	2026-07-03T12:06:32	12.54287	1.2	8 原始特徵未調參 blend,LGB/XGB 過擬合權重歸零
2	2026-07-03T19:10:07	12.073474	2	正則化+22 工程特徵,全場最大單筆躍升

實驗編號	時間	決策分數	階段	摘要
3	2026-07-03T19:10:47	12.094826	2.4	加入 3 個交互特徵反而變差,還原
4	2026-07-03T19:11:24	12.073474	2	還原後重跑,逐位元重現 第 2 次實驗,確認決定論
5	2026-07-03T23:41:35	12.081216	3.5	重複群組目標平滑無效,還原
6	2026-07-03T23:49:50	12.073474	3.2	Optuna 調參 LGB 入池,權重 0 持平
7	2026-07-03T23:49:55	12.071429	3.4	seed-bag 調參 LGB 為第 5 成員,改善
8	2026-07-03T23:51:20	12.070034	3.4	seed-bag CAT + 第 3 個調參 LGB seed,7-way 本場最佳

- **轉折 1(第 1 次實驗→第 2 次實驗):**同時施加明確正則化(淺深度+L1/L2)與 22 個工程特徵 (log_age、water/binder 比值等),12.54287→12.073474,佔全場改善的絕大部分。
- **轉折 2(第 3、5 次實驗 的負面結果):**交互特徵(樹模型本可自行學得,徒增過擬合面)與 重複群組平滑(平方損失本就隱含擬合群組均值)先後失敗,確立「標籤噪音上限」診斷——正確的診斷不保證顯式修正有效。
- **轉折 3(第 6 次實驗→第 7 次實驗→第 8 次實驗):**階段 3 全部增益來自 seed bagging(-0.00204、-0.00140,報酬遞減);在噪音上限處,對獨立 seed 模型取平均是僅存的「免費」方向。
- **階段 5(外部想法注入,快評):**在階段4收斂點注入 EXT-09(stacking) 候選,OOF rmse 12.094465 未勝過階段 4(12.070034),不採納,詳見第 5 節末與《總結報告》第 7 節。

5. 效能對照(逐階段)

階段	配置	分數	相對改善
1	基線(Claude Code 直接執行,未引入 skill;第 1 次實驗 通用批次 blend)	12.54287	—(基線)
2	+ kaggle-agent skill 六階段流程(第 2 次實驗)	12.073474	3.74%
3	+ self-improvement 線性迭代(第 8 次實驗,四輪終點)	12.070034	0.03%
4	+ 樹搜尋(無樹搜尋節點超越線性最佳,與階段 3 同為 第 8 次實驗)	12.070034	0%(樹搜尋追平,未超越)

相對改善計算式(每階段對前一階段)

階段1→2: $12.54287 - 12.073474 = 0.469396$, 相對改善 $0.469396 / 12.54287 = 3.7423\%$
 階段2→3: $12.073474 - 12.070034 = 0.003440$, 相對改善 $0.003440 / 12.073474 = 0.0285\%$
 階段3→4: $12.070034 - 12.070034 = 0$, 相對改善 0% (追平,依協定如實標記)

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

補充說明(階段 4 的分數來源):階段 4 之 12.070034 即 第 8 次實驗 本身——跨場對照紀錄註記「無樹搜尋節點超越線性最佳,與階段 3 打平」。實際樹搜尋跑了兩輪(依進度筆記,只算 OOF 分數、不產生 submission):第 1 版(單模節點空間,20 節點)最佳僅 12.07459 (即已知的 CAT 單模),輸給線性最佳;第 2 版(ensemble 節點樹之後續搜尋, 26 節點)以 13-way blend(node #13)在第 14 個評估節點精確追平 12.070034(至小數第 6 位),其後所有變異僅追平或變差。兩條獨立路徑收斂於同一分數,與第 3.1 節的標籤噪音 上限診斷一致——本場為噪音上限場次。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:CAT,亦為 blend 全部權重)	12.54287	第 1 次實驗
1.2(三模權重 blend,權重收斂為 100% CAT)	12.54287	第 1 次實驗
2.4(場內反思:+3 交互特徵,反而變差,已還原)	12.094826	第 3 次實驗
3.5(結構化去噪嘗試:重複列群組目標平滑,無改善,已還原)	12.081216	第 5 次實驗
3.2(Optuna 全 5-fold CV 調參 LGB,加入池,權重搜尋給 0,持平)	12.073474	第 6 次實驗
3.4(seed bagging,調參 LGB 之 seed 1042 版,第 5 成員)	12.071429	第 7 次實驗
3.4(seed bagging 擴充,+CAT seed 1042 + 調參 LGB 第 3 個 seed,7-way,線性迭代最佳)	12.070034	第 8 次實驗

階段 5 | +外部想法注入(快評)

在階段4收斂點注入外部想法候選(本場來源:EXT-09(stacking)),以快取 OOF 評估其能否勝過階段4:

```
階段5 注入候選 OOF rmse = 12.094465
階段4(committed)          = 12.070034
delta = -0.024431 → 未勝過階段4,搜尋不採納 → 階段5 = 階段4(外部注入無增益)
```

(階段5 為全案「停滯時注入外部想法」機制的快評結果,非完整重跑;機制與 15 場跨場 結論見《總結報告》第 7 節與 docs/phase_j_j3_findings。)

6. 總結

本場資料小而噪:5,407 列、8 個數值配方特徵, AgeInDays 為對數線性主訊號;最關鍵的 結構性事實是 2,401 列重複配方列(特徵全同、不含每組第一筆)帶有不同量測 strength —— 不可約標籤噪音直接 劃定 CV 分數上限,並使本場全程獎勵正則化而懲罰容量。

關鍵決策有三:其一,第 2 次實驗 起固定 strength 十分位分層的 5-fold CV(seed 42),使八個 實驗與兩輪樹搜尋分數全部可直接比較;其二,第 1 次實驗 的權重歸零異常被正確歸因為過擬合,以「正則化+特徵工程」一次修正,成為全場最大躍升;其三,反思紀律——交互特徵(第 3 次實驗) 與重複群組平滑(第 5 次實驗)變差即還原,第 4 次實驗 並以逐位元重現確認管線決定論。

增益來源逐階遞減且歸屬清楚:階段1→2 靠正則化與特徵工程(12.54287→12.073474); 階段2→3 靠線性迭代,且全部來自 seed bagging(12.070034),調參與去噪皆未直接貢獻; 階段3→4 為 0%——第 1 版樹搜尋因節點只含單一模型、結構上構不到 blend 而落敗,第 2 版 改為 ensemble 節點樹後精確追平線性最佳,但 26 節點內無任何變異超越之。

可信度方面須如實說明:本場全程未提交 Kaggle,無 LB 外部對照,所有結論建立在同一固定 CV 的 OOF 之上。但「線性迭代與第 2 版樹搜尋兩條獨立方法收斂於同一分數、且去噪/調參/交互特徵 全數失敗」共同支持噪音上限解讀:12.070034 很可能已貼近本資料可達的下限,而非搜尋不足。

重現本實驗的最短路徑:見第 7 節。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 階段 2:EDA
uv run python3 competitions/playground-series-s3e9/scripts/eda.py

# 階段 2 / 第 2 次實驗:特徵工程+建模(LGB/XGB/CAT,5-fold 十分位分層 CV,00F 權重搜尋 blend)
#(features.py 由 train.py 匯入呼叫,無需獨立執行)
uv run python3 competitions/playground-series-s3e9/scripts/train.py

# 階段 3 自我改進迭代(依序執行;第 4 輪讀取第 2/3 輪產生的 npz checkpoint)
uv run python3 competitions/playground-series-s3e9/scripts/train_dup_smooth.py      # 3.5 → 第 5 次實驗(負面)
uv run python3 competitions/playground-series-s3e9/scripts/train_optuna_pool.py     # 3.2+3.4 → 第 6、7 次實驗
uv run python3 competitions/playground-series-s3e9/scripts/train_round4_seedbag.py   # 3.4 → 第 8 次實驗 最佳

# 樹搜尋(只算 00F 分數,不產生 submission;樹狀態各自持久化,可中斷續跑)
uv run python3 tree_search/run_s3e9.py      # 4.1(第 1 版)→ experiments_tree.json
uv run python3 tree_search/run_s3e9_v2.py   # 4.2(第 2 版)→ experiments_tree_v2.json

# 報告產生(本檔)
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e9
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py \
    competitions/playground-series-s3e9/REPORT.md competitions/playground-series-s3e9/facts.json
bash .claude/skills/kaggle-report/assets/md2pdf.sh competitions/playground-series-s3e9/REPORT.md \
    competitions/playground-series-s3e9/s3e9_REPORT.pdf

# 提交至 Kaggle(本場未執行;需先設定有效之 KAGGLE_API_TOKEN)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e9 \
    -f competitions/playground-series-s3e9/submissions/sub_blend_12.07003_20260703_235120.csv \
    -m "7-way seed-bag blend, 00F RMSE 12.070034"
```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 `uv run` 。