

競賽分析報告:playground-series-s3e9

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-03

1. 競賽目的

What:本競賽要解決的問題是「Predict concrete compressive strength」——根據混凝土配方 中各成分的用量(水泥、爐渣、飛灰、水、減水劑、粗細骨材)與養護天數,預測混凝土的抗壓強度 (Strength)。這是一個 regression 任務。

Why:評估指標為 rmse,以 minimize 為優化方向。RMSE 對誤差取平方後開根號,會放大對「大幅 偏離」預測的懲罰,這對混凝土抗壓強度預測是合理的選擇——工程上嚴重低估或高估強度的後果(結構 安全風險、材料浪費)遠比小誤差嚴重,因此比起對離群誤差不敏感的 MAE,RMSE 更能反映此任務中「避免大誤差」優先於「平均誤差小」的實務考量。

項目	值
競賽	playground-series-s3e9
URL	https://www.kaggle.com/competitions/playground-series-s3e9
問題型別	regression
評估指標	rmse(minimize)
目標欄位	Strength
ID 欄位	id

2. 流程(how):五大元件

2.1 資料規格

facts.json 未記錄列數/欄位數(row/column counts),故列數與欄位數寫「無紀錄」。可從 experiments[].n_features 得知特徵數量的演變:baseline(experiment_id 1)使用 8 個原始特徵,最佳實驗(experiment_id 8)使用 22 個特徵(8 原始 + 14 工程特徵,與 experiment_id 2 相同 特徵清單)。

特別規則(來源: competition.special_rules):- 外部資料:不允許(external_data_allowed: false)- 預訓練模型:不允許(pretrained_models_allowed: false)- 網路存取:不允許(internet_access_allowed: false)- 每日提交上限:5 次(daily_submission_limit: 5)

competition.notes 記載:「Aygun et al. Nature 2026 Kaggle Playground benchmark (Season 3 Episode 9).」

本場素材等級為 full (非 baseline-only),故 EDA 與特徵工程階段皆已執行(細節見 STATUS.md,惟本節數字僅取自 facts.json)。

2.2 模型規格

最佳實驗(experiment_id 8)是 7 成員加權 blend: 「7-way blend: Round-3 pool + CAT_seed2 + LGB_tuned_seed3 (seed-bag expansion)」。

7 個成員 = experiment_id 7 的 5 成員 pool(orig LGB / orig XGB / orig CAT / Optuna 調參 LGB / 調參 LGB 第 2 seed)再加 2 個 seed-bag 成員。

各成員單模 OOF 分數 (來源: experiments[] 中 experiment_id 6/7/8 的 base_models):

Model	RMSE	訓練時間(s)	來源實驗
LGB(orig,正則化)	12.11061	6.6	experiment_id 6
XGB(orig,正則化)	12.12086	6.6	experiment_id 6
CAT(orig)	12.07459	2.7	experiment_id 6
LGB_tuned(Optuna)	12.12074	371.6	experiment_id 6
LGB_tuned_seed2(seed 1042)	12.10843	4.4	experiment_id 7
CAT_seed2(seed 1042)	12.07852	2.7	experiment_id 8
LGB_tuned_seed3(seed 2042)	12.0977	6.0	experiment_id 8

Ensemble 權重(來源: best.ensemble.weights ,方法
oof_weight_search(dirichlet8000+coord_descent_fine)):

Model	權重
LGB	0.0
XGB	0.0
CAT	0.478
LGB_tuned	0.0
LGB_tuned_seed2	0.127
CAT_seed2	0.265
LGB_tuned_seed3	0.129

Ensemble 後最終分數(來源: best.score):12.070034。

選型理由(敘述,參考 STATUS.md 脈絡):七個成員皆為梯度提升樹,適合小型表格資料。CatBoost 的 ordered boosting 正則化機制在本資料集上單模型最強(12.07459),其原 seed 與 第 2 seed 的合計權重(衍生計算,置於 code block):

```
CAT + CAT_seed2 權重合計: 0.478 + 0.265 = 0.743
LGB_tuned_seed2 + LGB_tuned_seed3 權重合計: 0.127 + 0.129 = 0.256
```

值得注意的是:調參 LGB 的「原 seed」(LGB_tuned,單模 12.12074)與 orig LGB/XGB 權重皆為 0——本輪增益完全來自 seed bagging(以不同 random seed 重訓同超參模型再平均)的變異數 縮減,而非調參本身。

2.3 訓練規格

CV 方案(來源: `best.cv`):

欄位	值
strategy	5fold_stratified_strength_decile
seed	42
n_splits	無紀錄(best.cv 未記錄此欄位)

Objective 與關鍵超參:facts.json 的 `best.base_models` 未提供結構化的 `params` 欄位。orig 三模型超參記載於 experiment_id 2 的 notes(逐字節錄):

```
"Regularized LGB(num_leaves=15,depth5,L1=2/L2=4)/XGB(depth4,L1=2/L2=4) +  
CatBoost(depth6,l2=6) with 8 engineered features (log_age, water/binder ratios) vs baseline  
exp#1 (generic untuned blend, RMSE 12.54287, CatBoost 100% weight)."
```

Optuna 調參 LGB 的超參記載於 experiment_id 6 的 `base_models[3].note` (逐字節錄):

```
"Optuna 60-trial full-5fold-CV objective tuned LGB; params={'learning_rate':  
0.019795655587585677, 'num_leaves': 11, 'max_depth': 3, 'min_child_samples': 31,  
'subsample': 0.6018504151952752, 'colsample_bytree': 0.5006835428888052, 'reg_alpha':  
0.1120861378640153, 'reg_lambda': 0.3020804107290036, 'n_estimators': 3000}"
```

seed-bag 成員與原成員超參完全相同,僅更換 random seed(1042 / 2042;見 experiment_id 7/8 的 `base_models[].note`)。

為何用此 CV:strategy 名稱顯示此為「以 Strength 十分位數分層」的 5-fold StratifiedKFold(`5fold_stratified_strength_decile`)。相較於單純 KFold,對迴歸目標分層 可讓每個 fold 的目標分布更一致,在資料量較小時能降低 fold 間變異——這與 baseline (experiment_id 1)僅記錄 `cv.scheme = "5fold"` (未分層)形成對比。

2.4 推論程序

後處理: `best.postprocess` 未記錄 → 無後處理紀錄。

Submission 格式(來源: `best.submission` 、 `competition.id_column / target_column`):

欄位	值
Submission 檔名	sub_blend_12.07003_20260703_235120.csv
ID 欄位	id

欄位	值
目標欄位	Strength

2.5 評估指標

指標定義:RMSE(Root Mean Squared Error)是預測值與真實值差異平方之平均值,再開根號,數值與目標欄位同單位,對大誤差的懲罰重於 MAE。

分數總表(來源: `best.*`、各實驗紀錄):

項目	RMSE
Baseline blend(experiment_id 1)	12.54287
3-way blend(experiment_id 2,前一輪最佳)	12.073474
Phase B Round 1:dup-smoothing(experiment_id 5)	12.081216
Phase B Round 2:+Optuna LGB(experiment_id 6)	12.073474
Phase B Round 3:+seed-bag 調參 LGB(experiment_id 7)	12.071429
最佳 Ensemble(experiment_id 8,7-way seed-bag)	12.070034

`facts.missing` 記錄 `["leaderboard"]`,即本場 **未提交至 Kaggle**,無 **Public/Private LB 分數**,故無法計算 CV↔LB gap(僅當 leaderboard 存在時才計算,依規格第 2.5 節)。

以下為 baseline / 前一輪最佳與最佳 CV 分數的改善量(衍生計算,數字皆逐字取自 `facts.json`,置於 code block 中):

```
12.54287 (baseline blend_score, experiment_id 1)
- 12.070034 (best score, experiment_id 8)
= 0.472836
```

相對改善: $0.472836 / 12.54287 * 100 = 3.769758\ldots\%$

Phase B 迭代增益:

```
12.073474 (experiment_id 2/4, 前一輪最佳)
- 12.070034 (experiment_id 8)
= 0.003440
```

3. 實驗軌跡

逐實驗分數表(來源: `trajectory`):

experiment_id	timestamp	score	source_format
1	2026-07-03T12:06:32	12.54287	generic_batch

experiment_id	timestamp	score	source_format
2	2026-07-03T19:10:07	12.073474	v2
3	2026-07-03T19:10:47	12.094826	v2
4	2026-07-03T19:11:24	12.073474	v2
5	2026-07-03T23:41:35	12.081216	v2
6	2026-07-03T23:49:50	12.073474	v2
7	2026-07-03T23:49:55	12.071429	v2
8	2026-07-03T23:51:20	12.070034	v2

突破點敘述:主要分數躍升發生在 experiment_id 2(timestamp 2026-07-03T19:10:07), score 由 baseline 的 12.54287 降至 12.073474。依 experiments[2].notes (逐字節錄同第 2.3 節),此次變動同時改了兩件事:(a) 對 LGB/XGB 加入明確正則化超參數 (num_leaves=15/depth5/L1=2/L2=4 與 depth4/L1=2/L2=4),(b) 從 8 個原始特徵擴充為 22 個 工程特徵(含 log_age、water/binder 比值等)。experiment_id 3 是延伸嘗試(加入 3 個 interaction 特徵, n_features 從 22 增至 25),score 反而變差(12.094826),隨後 experiment_id 4 以相同 22 特徵重新執行,score 完全重現為 12.073474。

Phase B 自我改進迭代(experiment_id 5-8):每輪僅改一件事,fold/seed/特徵不變: - Round 1(experiment_id 5):fold-safe 重複列群組目標平滑(訓練目標改為訓練 fold 內同 配方群組的平均 Strength; 驗證目標與指標不動)→ 12.081216,劣於 12.073474,棄用。依 notes:GBDT 平方損失本就隱含以群組均值擬合重複列,顯式平滑無新資訊。 - Round 2(experiment_id 6):Optuna(TPE 60 trials,完整 5-fold CV 為目標函式,實際 371.6s)調參 LGB 加入 pool 為第 4 成員 → 12.073474(持平;調參 LGB 單模 12.12074 劣於 orig LGB 12.11061,權重搜尋給 0)。 - Round 3(experiment_id 7):調參 LGB 以第 2 個 seed(1042)重訓、加為第 5 成員 → **12.071429**(改善;權重 CAT 0.773 / LGB_tuned_seed2 0.227)。 - Round 4(experiment_id 8):seed-bag 權重最大的 CatBoost(seed 1042)+ 第 3 個調參 LGB seed(2042),7-way 權重搜尋 → **12.070034**(最終最佳)。

整個 Phase B 的增益(第 2.5 節 code block 中的 12.073474 – 12.070034 衍生計算)完全來自 seed bagging, 調參與去噪(dup-smoothing)本身皆未直接貢獻——與 STATUS.md 的標籤噪音 天花板診斷一致:分數已貼近噪音上限時,對獨立 seed 的模型取平均是僅存的「免費」改善方向。

facts.unparsed 為空陣列,無「無法解析之紀錄」。

4. 重現指令

以下命令序列參考 STATUS.md 的 Reproduce 節,並依 competitions/playground-series-s3e9/scripts/ 實際檔名組成。執行目錄為專案根目錄,需先安裝 uv。

```
cd /home/tjyen/ai_agents/kaggle
```

```
# 1. EDA
```

```
uv run python3 competitions/playground-series-s3e9/scripts/eda.py

# 2. 特徵工程 + 訓練 + 5-fold CV + 00F weight-search blend(3-way,exp #2)
# (features.py 由 train.py 匯入呼叫,無需獨立執行步驟)
uv run python3 competitions/playground-series-s3e9/scripts/train.py

# 3. Phase B 自我改進迭代(依序執行;round 4 讀取 round 2/3 產生的 npz checkpoint)
uv run python3 competitions/playground-series-s3e9/scripts/train_dup_smooth.py      # round 2
uv run python3 competitions/playground-series-s3e9/scripts/train_optuna_pool.py      # round 3
uv run python3 competitions/playground-series-s3e9/scripts/train_round4_seedbag.py    # round 4

# 4. 提交至 Kaggle(本次執行未提交;需要有效 KAGGLE_API_TOKEN 憑證)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e9 \
  -f competitions/playground-series-s3e9/submissions/sub_blend_12.07003_20260703_235120.csv \
  -m "<msg>"
```

