

競賽分析報告:playground-series-s3e11

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-03

1. 競賽目的

What:本場競賽(Kaggle Playground Series, Season 3 Episode 11)要求預測媒體行銷活動的 成本 (cost)。輸入為門市與商品層級的屬性(門市面積、附設設施旗標、商品重量/包裝、顧客家庭屬性 等),輸出為連續數值的活動成本,是一個標準的表格型迴歸問題。此資料集亦為 Aygun et al.(Nature 2026)Kaggle Playground 基準之一(來源: competition.notes)。

Why:評估指標為 **RMSLE(Root Mean Squared Logarithmic Error,minimize)**。成本類目標 通常關心「相對誤差」而非絕對誤差——把一筆高成本活動預測差一截,與把一筆低成本活動預測差 同樣金額,對業務的意義不同;RMSLE 在對數空間計算平方誤差,懲罰的是比例偏差,並且天然 壓抑大數值樣本對損失的支配,是成本/金額類目標的合理選擇。實務上這也決定了訓練策略: 對 $\log_{1p}(\text{cost})$ 以 RMSE objective 訓練,即可直接優化 RMSLE(見節 4)。

項目	值
競賽	playground-series-s3e11
問題型別	regression
評估指標	rmsle(minimize)
目標欄位	cost

2. 資料規格

- 訓練/測試列數:facts.json 未記載,無紀錄(實際形狀見 scripts/eda.py 執行輸出)。
- 原始特徵 15 欄(來源: experiments[0].n_features 、 experiments[1].features):門市屬性 (store_sqft 與 coffee_bar/video_store/salad_bar/prepared_food/florist 五個附設設施旗標)、商品屬性 (gross_weight 、 units_per_case 、 recyclable_package 、 low_fat 、 銷售額/銷量)、顧客家庭屬性(total_children 、 num_children_at_home 、 avg_cars_at_home(approx).1)。全部為數值型,但多數實為低基數「類別型偽裝」欄位(EDA 發現,見下)。
- 特別規則:不可使用外部資料、不可使用預訓練模型、不可存取網路;每日提交上限 5 次 (來源: competition.special_rules)。

- **EDA 摘要**(`scripts/eda.py` ,質性描述;數值細節見腳本輸出):目標 `cost` 分布近乎對稱、**並非** 右偏,log1p 轉換後反而輕微左偏——採用 log 目標的理由是「直接優化 RMSLE」而非 矯正偏態;無缺失值、無重複列、train/test id 不重疊、各欄位 train/test 平均一致(無明顯 covariate shift);所有原始特徵與目標的單變量相關皆極弱(低訊號資料集);最強訊號來自 `store_sqft` 加五個設施旗標組成的「store profile」組合——其組平均對目標的解釋力遠高於 任何單一欄位,是特徵工程主攻方向(需 out-of-fold 編碼防洩漏)。

3. 模型規格

本場共八筆實驗:前三筆(Phase A)為 LightGBM + XGBoost + CatBoost 三模型加權集成,差別在 特徵集與訓練方法;後五筆(Phase B 自我改進迭代 R1-R5)在最佳特徵集上調整模型池組成 (刪除 XGBoost、Optuna 調參 CatBoost、seed bagging、特徵消融)。

實驗 1(`generic_batch` ,通用批次基線;15 原始特徵)— base models:

Model	OOF RMSLE
LGB	0.29731
XGB	0.29877
CAT	0.2977

Ensemble 權重(來源: `experiments[0].ensemble.weights`):LGB 0.7 / XGB 0.0 / CAT 0.3, Ensemble 分數(來源: `experiments[0].ensemble.score`):**0.29723**。

實驗 2(`v2` ,skill 管線 base 模式;15 原始特徵 + log1p 目標 + early stopping)— base models:

Model	OOF RMSLE	time_s
LGB	0.29765	94.4
XGB	0.29827	25.7
CAT	0.29715	49.2

Ensemble 權重(來源: `experiments[1].ensemble.weights`):LGB 0.2 / XGB 0.0 / CAT 0.8, 集成分數(來源: `experiments[1].score`):**0.2971**。

實驗 3(`v2` ,skill 管線 engineered 模式;21 特徵,Phase A 最佳)— base models:

Model	OOF RMSLE	time_s
LGB	0.29661	70.4

Model	OOF RMSLE	time_s
XGB	0.29713	24.5
CAT	0.29618	58.3

Ensemble 權重(來源: `experiments[2].ensemble.weights`):LGB 0.2 / XGB 0.0 / CAT 0.8, 集成分數(來源: `experiments[2].score`):**0.296143**。

特徵差異:實驗 3 在 15 個原始欄位之上加入 6 個工程特徵(來源: `experiments[2].features`, `n_features = 21`): `amenity_count` (五個設施旗標加總)、`weight_per_case`、`sales_ratio`、`children_away`、`cars_per_child`,以及關鍵的 `store_te` —— store profile(`store_sqft` + 五個設施旗標的組合鍵)的 K-fold target encoding,於每個 fold 內僅以訓練折資料計算組平均、套用到驗證折,測試集端取五個 fold 編碼的平均(來源: `experiments[2].notes`),避免目標洩漏。

選型理由:三個梯度提升樹模型在表格資料上穩健且歸納偏誤互異,以 OOF 權重搜尋做加權集成 可降低單一模型方差。兩次 skill 管線 run 的權重搜尋皆收斂到 CatBoost 為主(0.8)、XGBoost 權重 0 的組合,顯示 CatBoost 在此低訊號資料集上最強、XGB 與其他兩者高度冗餘。

Phase B 自我改進迭代(實驗 4–8,同一 21 特徵集,除實驗 7):

實驗	改動(每輪一項)	Ensemble 分數
4(R1)	刪除 XGBoost(前兩輪權重皆 0),LGB+CAT 雙模型池	0.296143
5(R2)	Optuna(TPE 40 trials,fold-0 proxy)調參 CatBoost,調參版 加入 池(不替換)	0.295781
6(R3)	調參 CatBoost 以 <code>random_seed=2024</code> 重訓,加為第 4 成員(seed bagging)	0.295715
7(R4)	加 3 個 per-store_combo 特徵均值(24 特徵)—— 退步,棄用	0.2962
8(R5)	調參 CatBoost 第三個 seed(7),5-way 池	0.295648

(分數來源: `experiments[3..7].score` ;`facts.best` = 實驗 8。)

實驗 5 的 Optuna 最佳參數(來源: `experiments[4].notes` ,原值照錄):`depth=10`、`learning_rate=0.08243442179862394`、`l2_leaf_reg=5.4822780685788235`、`min_data_in_leaf=33`、`random_strength=0.09160286047373326`;搜尋耗時 319.3s(40 trials,timeout guard 480s)。

實驗 8(facts.best,R5 5-way 池)— base models 與權重:

Member	OOF RMSLE	time_s	權重
LGB	0.29661	75.5	0.0
CAT_orig	0.29618	58.2	0.0

Member	OOF RMSLE	time_s	權重
CAT_tuned	0.29579	31.4	0.4
CAT_tuned_seed2024	0.29591	34.0	0.2
CAT_tuned_seed7	0.29578	31.9	0.4

(來源: `experiments[7].base_models` 、 `experiments[7].ensemble.weights`) 權重搜尋把全部權重給了調參 CatBoost 家族——調參後單模(0.29579)已勝 Phase A 三模型 blend(0.296143),LGB 與原參數 CatBoost 淪為冗餘。

4. 訓練規格

實驗	CV scheme	n_splits	seed
1	5fold	5	無紀錄
2-8	5fold_kfold_shuffle	5(自 strategy 名稱)	42

(來源: `experiments[]`.cv 。實驗 1 的 seed 無對應欄位,寫「無紀錄」。實驗 2-8 全部使用同一 fold 切分,分數可直接比較。)

Objective:實驗 2、3 對 **log1p(cost)** 以 RMSE objective 訓練(LGB regression 、 XGB reg:squarederror 、 CAT RMSE),因為 RMSLE 即「log1p 空間的 RMSE」,如此 objective 與競賽指標完全一致;預測時經 `expm1` 逆轉換並 clip 至非負(來源: `experiments[1].notes` 、 `experiments[2].notes`)。各模型均使用 early stopping。其餘超參數 `facts.json` 未記錄欄位,無紀錄(可直接查 `scripts/train.py`)。

為何用此 CV:EDA 未發現時間或群組結構;store profile 每種組合重複數千列,隨機切分不會讓任何 fold 缺少某個 profile,故採標準 5-fold KFold(shuffle, seed=42)。實驗 2 與 3 使用同一組 fold 切分,分數可直接比較。target encoding 在 fold 迴圈內計算,與 CV 方案一致、無洩漏。

5. 推論程序

`facts.best` (實驗 8)之 `postprocess` 欄位未記錄 → **無後處理紀錄**;惟各實驗 notes 記載推論流程本身包含「`expm1` 逆轉換 + clip 至非負」,這是 log 目標訓練的必要配套步驟而非額外後處理。測試集的 `store_te` 特徵取五個 fold 編碼平均、未見過的 profile 以訓練折全域平均代入(fallback)。最終預測為 5 個成員測試預測(各自已是 5-fold 平均)在 log 空間的加權和,再做 `expm1` + clip。

Submission: `sub_r5_seedbag3_0.29565_20260703_223829.csv` (來源: `experiments[7].submission` ,即 `facts.best.submission`),格式為兩欄 ——

`id ( competition.id_column )`與 `cost ( competition.target_column )`,每列對應一筆測試樣本的成本預測值。

注意:本場為週末自主批次執行,八筆實驗皆**未提交** Kaggle 排行榜(`facts.missing` 含 `leaderboard`), 無 Public/Private LB 分數。

6. 評估指標

指標定義: $\text{RMSLE} = \sqrt{\text{mean}((\log_{1p}(\text{pred}) - \log_{1p}(\text{actual}))^2)}$,衡量對數空間的均方根誤差, 懲罰相對(比例)偏差。

項目	OOF RMSLE
實驗 1 Ensemble(generic 基線)	0.29723
實驗 2 Ensemble(skill base)	0.2971
實驗 3 Ensemble(skill engineered,Phase A 最佳)	0.296143
實驗 5 Ensemble(R2 Optuna CatBoost)	0.295781
實驗 6 Ensemble(R3 seed bagging)	0.295715
實驗 8 Ensemble(R5 seed bagging × 3, facts.best)	0.295648
Public LB	無紀錄(未提交)
Private LB	無紀錄(未提交)

相對基線改善(衍生算式,依 Hard Rule 置於 code block):

```
Phase A:
實驗 3 - 實驗 1:0.29723 - 0.296143 = 0.001087    (RMSLE 下降,~0.37% 相對改善)
實驗 3 - 實驗 2:0.29710 - 0.296143 = 0.000957    (特徵工程貢獻,佔改善絕大部分)
實驗 2 - 實驗 1:0.29723 - 0.29710 = 0.000130    (方法論差異:log1p 目標 + early stopping)

Phase B(自我改進迭代):
實驗 5 - 實驗 3:0.296143 - 0.295781 = 0.000362    (Optuna 調參 CatBoost,Phase B 最大單項)
實驗 6 - 實驗 5:0.295781 - 0.295715 = 0.000066    (seed bagging 第 2 個 seed)
實驗 8 - 實驗 6:0.295715 - 0.295648 = 0.000067    (seed bagging 第 3 個 seed)
實驗 7 - 實驗 6:0.2962 - 0.295715 = 0.000485    (退步:per-combo 特徵均值,棄用)
實驗 8 - 實驗 3:0.296143 - 0.295648 = 0.000495    (Phase B 總增益,~0.17% 相對改善)
```

CV↔LB gap:無排行榜紀錄,無法計算。

7. 實驗軌跡

experiment_id	timestamp	score	source_format
1	2026-07-03T12:10:20	0.29723	generic_batch
2	2026-07-03T19:25:07	0.2971	v2
3	2026-07-03T19:28:19	0.296143	v2
4	2026-07-03T22:23:54	0.296143	v2
5	2026-07-03T22:31:01	0.295781	v2
6	2026-07-03T22:32:05	0.295715	v2
7	2026-07-03T22:36:33	0.2962	v2
8	2026-07-03T22:38:30	0.295648	v2

(來源: `facts.trajectory` 。最佳分數出現於第 8 筆,即 `facts.best` 。)

突破點(Phase A):主要改善發生在第 2 → 第 3 筆之間。第 2 筆只是把通用基線的方法論換成「log1p 目標 + early stopping + 權重搜尋」,分數僅微幅改善;第 3 筆加入 6 個工程特徵——尤其是 store profile 的 K-fold target encoding(`store_te`)——帶來 Phase A 絕大部分的增益(見節 6 的 衍生算式)。這與 EDA 的判讀一致:單欄位訊號極弱,但 store profile 組合的組平均是資料中 最強的可利用結構;在低訊號 playground 資料集上,能把這類「組合層級」訊號餵給模型的特徵 工程,比模型/超參數調整 更有價值。

突破點(Phase B):第 4 筆(R1)驗證刪除兩輪零權重的 XGBoost 不損分數(與第 3 筆分數 完全相同);第 5 筆(R2)Optuna fold-0 proxy 調參 CatBoost 是 Phase B 最大單項增益,且調參版 是「加入」模型池而 非替換原成員(跨競賽驗證過的配方);第 6、8 筆(R3/R5)兩次 seed bagging 各貢獻噪音級以上的小增 益;第 7 筆(R4)在 `store_te` 之上再加 per-combo 特徵均值反而全面退步 ——樹模型已能從 `store_te` 與 原始欄位取得該組合的訊號,額外的組彙總只添冗餘——故棄用,最終最佳(第 8 筆)回到 21 特徵集。迭 代依「連續退步/增益縮至噪音級即停」原則於 R5 後收手。

`facts.unparsed` 為空陣列,無法解析之紀錄:無。

8. 重現指令

```
cd /home/tjyen/ai_agents/kaggle
```

```

# 0) 環境:依 pyproject.toml 以 uv 管理;資料已在 competitions/playground-series-s3e11/data
#      (train.csv / test.csv / sample_submission.csv;如需重新下載:)
# export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
# uv run kaggle competitions download -c playground-series-s3e11 -p competitions/playground-series-s3e11

# 1) EDA(全量資料、僅快速統計)
uv run python3 competitions/playground-series-s3e11/scripts/eda.py

# 2) 實驗 2:skill base 模式(15 原始特徵,方法論對照)
uv run python3 competitions/playground-series-s3e11/scripts/train.py base

# 3) 實驗 3:skill engineered 模式(21 特徵,含 store_target encoding;Phase A 最佳)
uv run python3 competitions/playground-series-s3e11/scripts/train.py engineered
#      → submissions/sub_engineered_*.csv,並自動以 log_experiment_v2 寫入 experiments.json

# 4) Phase B 自我改進迭代(實驗 4–8;checkpointed,cache 命中會跳過已訓練成員)
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r1      # 實驗 1
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py tune    # Optuna 超參數調優
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r2      # 實驗 2
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r3      # 實驗 3
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r4      # 實驗 4
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r5      # 實驗 5

# 5) (未執行)提交排行榜:
# uv run kaggle competitions submit -c playground-series-s3e11 \
#      -f competitions/playground-series-s3e11/submissions/sub_r5_seedbag3_0.29565_20230901 \
#      -m "r5 seed-bagged tuned CatBoost blend"

```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle`;所有 Python 執行皆透過 `uv run` 以確保套件環境一致。特徵工程程式碼在 `scripts/features.py` (被 `train.py` 匯入), target encoding 因需 fold 內計算,實作於 `train.py`。