

競賽分析報告:playground-series-s3e11

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-03

1. 競賽目的

What:本場競賽(Kaggle Playground Series, Season 3 Episode 11)要求預測媒體行銷活動的 成本 (cost)。輸入為門市與商品層級的屬性(門市面積、附設設施旗標、商品重量/包裝、顧客家庭屬性 等),輸出為連續數值的活動成本,是一個標準的表格型迴歸問題。此資料集亦為 Aygun et al.(Nature 2026)Kaggle Playground 基準之一(來源: competition.notes)。

Why:評估指標為 **RMSLE(Root Mean Squared Logarithmic Error,minimize)**。成本類目標 通常關心「相對誤差」而非絕對誤差——把一筆高成本活動預測差一截,與把一筆低成本活動預測差 同樣金額,對業務的意義不同;RMSLE 在對數空間計算平方誤差,懲罰的是比例偏差,並且天然 壓抑大數值樣本對損失的支配,是成本/金額類目標的合理選擇。實務上這也決定了訓練策略: 對 $\log_{1p}(\text{cost})$ 以 RMSE objective 訓練,即可直接優化 RMSLE(見節 4)。

項目	值
競賽	playground-series-s3e11
問題型別	regression
評估指標	rmsle(minimize)
目標欄位	cost

2. 資料規格

- 訓練/測試列數:facts.json 未記載,無紀錄(實際形狀見 scripts/eda.py 執行輸出)。
- 原始特徵 15 欄(來源: experiments[0].n_features 、 experiments[1].features):門市屬性 (store_sqft 與 coffee_bar/video_store/salad_bar/prepared_food/florist 五個附設設施旗標)、商品屬性 (gross_weight 、 units_per_case 、 recyclable_package 、 low_fat 、 銷售額/銷量)、顧客家庭屬性(total_children 、 num_children_at_home 、 avg_cars_at_home(approx).1)。全部為數值型,但多數實為低基數「類別型偽裝」欄位(EDA 發現,見下)。
- 特別規則:不可使用外部資料、不可使用預訓練模型、不可存取網路;每日提交上限 5 次 (來源: competition.special_rules)。

- **EDA 摘要**(`scripts/eda.py` ,質性描述;數值細節見腳本輸出):目標 `cost` 分布近乎對稱、**並非** 右偏,`log1p` 轉換後反而輕微左偏——採用 `log` 目標的理由是「直接優化 `RMSLE`」而非 矯正偏態;無缺失值、無重複列、`train/test id` 不重疊、各欄位 `train/test` 平均一致(無明顯 `covariate shift`);所有原始特徵與目標的單變量相關皆極弱(低訊號資料集);最強訊號來自 `store_sqft` 加五個設施旗標組成的「`store profile`」組合——其組平均對目標的解釋力遠高於 任何單一欄位,是特徵工程主攻方向(需 `out-of-fold` 編碼防洩漏)。

3. 模型規格

本場共三筆實驗,皆為 `LightGBM` + `XGBoost` + `CatBoost` 三模型加權集成,差別在特徵集與訓練方法:

實驗 1(`generic_batch` ,通用批次基線;15 原始特徵)— base models:

Model	OOF RMSLE
LGB	0.29731
XGB	0.29877
CAT	0.2977

Ensemble 權重(來源: `experiments[0].ensemble.weights`):`LGB 0.7 / XGB 0.0 / CAT 0.3`, Ensemble 分數(來源: `experiments[0].ensemble.score`):**0.29723**。

實驗 2(`v2` ,skill 管線 base 模式;15 原始特徵 + `log1p` 目標 + `early stopping`)— base models:

Model	OOF RMSLE	time_s
LGB	0.29765	94.4
XGB	0.29827	25.7
CAT	0.29715	49.2

Ensemble 權重(來源: `experiments[1].ensemble.weights`):`LGB 0.2 / XGB 0.0 / CAT 0.8`, 集成分數(來源: `experiments[1].score`):**0.2971**。

實驗 3(`v2` ,skill 管線 engineered 模式;21 特徵,`facts.best`)— base models:

Model	OOF RMSLE	time_s
LGB	0.29661	70.4
XGB	0.29713	24.5
CAT	0.29618	58.3

Ensemble 權重(來源: `experiments[2].ensemble.weights`): LGB 0.2 / XGB 0.0 / CAT 0.8, 集成分數(來源: `experiments[2].score`, 即 `facts.best.score`): **0.296143**。

特徵差異: 實驗 3 在 15 個原始欄位之上加入 6 個工程特徵(來源: `experiments[2].features`, `n_features = 21`): `amenity_count` (五個設施旗標加總)、`weight_per_case`、`sales_ratio`、`children_away`、`cars_per_child`, 以及關鍵的 `store_te` —— store profile(`store_sqft` + 五個設施旗標的組合鍵)的 K-fold target encoding, 於每個 fold 內僅以訓練折資料計算組平均、套用到驗證折, 測試集端取五個 fold 編碼的平均(來源: `experiments[2].notes`), 避免目標洩漏。

選型理由: 三個梯度提升樹模型在表格資料上穩健且歸納偏誤互異, 以 OOF 權重搜尋做加權集成 可降低單一模型方差。兩次 skill 管線 run 的權重搜尋皆收斂到 CatBoost 為主(0.8)、XGBoost 權重 0 的組合, 顯示 CatBoost 在此低訊號資料集上最強、XGB 與其他兩者高度冗餘。

4. 訓練規格

實驗	CV scheme	n_splits	seed
1	5fold	5	無紀錄
2	5fold_kfold_shuffle	5(自 strategy 名稱)	42
3	5fold_kfold_shuffle	5(自 strategy 名稱)	42

(來源: `experiments[1].cv`。實驗 1 的 seed 無對應欄位, 寫「無紀錄」。)

Objective: 實驗 2、3 對 **log1p(cost)** 以 RMSE objective 訓練(LGB regression、XGB `reg:squarederror`、CAT RMSE), 因為 RMSLE 即「log1p 空間的 RMSE」, 如此 objective 與競賽指標完全一致; 預測時經 `expm1` 逆轉換並 clip 至非負(來源: `experiments[1].notes`、`experiments[2].notes`)。各模型均使用 early stopping。其餘超參數 `facts.json` 未記錄欄位, 無紀錄(可直接查 `scripts/train.py`)。

為何用此 CV: EDA 未發現時間或群組結構; store profile 每種組合重複數千列, 隨機切分不會讓任何 fold 缺少某個 profile, 故採標準 5-fold KFold(shuffle, seed=42)。實驗 2 與 3 使用同一組 fold 切分, 分數可直接比較。target encoding 在 fold 迴圈內計算, 與 CV 方案一致、無洩漏。

5. 推論程序

`facts.best` (實驗 3) 之 `postprocess` 欄位未記錄 → **無後處理紀錄**; 惟 `experiments[2].notes` 記載推論流程本身包含「`expm1` 逆轉換 + clip 至非負」, 這是 log 目標訓練的必要配套步驟而非額外後處理。測試集的 `store_te` 特徵取五個 fold 編碼平均、未見過的 profile 以訓練折全域平均代入(fallback)。

Submission: sub_engineered_0.29614_20260703_192819.csv (來源: experiments[2].submission), 格式為兩欄 — id (competition.id_column)與 cost (competition.target_column), 每列對應一筆測試樣本的成本預測值。

注意:本場為週末自主批次執行,三筆實驗皆未提交 Kaggle 排行榜(facts.missing 含 leaderboard), 無 Public/Private LB 分數。

6. 評估指標

指標定義:RMSLE = $\sqrt{\text{mean}((\log_{1p}(\text{pred}) - \log_{1p}(\text{actual}))^2)}$,衡量對數空間的均方根誤差, 懲罰相對(比例)偏差。

項目	OOF RMSLE
實驗 1 Ensemble(generic 基線)	0.29723
實驗 2 Ensemble(skill base)	0.2971
實驗 3 Ensemble(skill engineered,facts.best)	0.296143
Public LB	無紀錄(未提交)
Private LB	無紀錄(未提交)

相對基線改善(衍生算式,依 Hard Rule 置於 code block):

實驗 3 - 實驗 1:0.29723 - 0.296143 = 0.001087	(RMSLE 下降,~0.37% 相對改善)
實驗 3 - 實驗 2:0.29710 - 0.296143 = 0.000957	(特徵工程貢獻,佔改善絕大部分)
實驗 2 - 實驗 1:0.29723 - 0.29710 = 0.000130	(方法論差異:log1p 目標 + early stopping)

CV↔LB gap:無排行榜紀錄,無法計算。

7. 實驗軌跡

experiment_id	timestamp	score	source_format
1	2026-07-03T12:10:20	0.29723	generic_batch
2	2026-07-03T19:25:07	0.2971	v2
3	2026-07-03T19:28:19	0.296143	v2

(來源: facts.trajectory 。三筆實驗中最佳分數出現於第 3 筆。)

突破點:主要改善發生在第 2 → 第 3 筆之間。第 2 筆只是把通用基線的方法論換成「log1p 目標 + early stopping + 權重搜尋」,分數僅微幅改善;第 3 筆加入 6 個工程特徵——尤其是 store profile 的 K-fold target encoding(store_te)——帶來本場絕大部分的增益(見節 6 的 衍生算式)。這與 EDA 的判讀一致:單欄位訊號極弱,但 store profile 組合的組平均是資料中 最強的可用結構;在低訊號 playground 資料集上,能把這類「組合層級」訊號餵給模型的特徵 工程,比模型/超參數調整更有價值。

facts.unparsed 為空陣列,無法解析之紀錄:無。

8. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 0) 環境:依 pyproject.toml 以 uv 管理;資料已在 competitions/playground-series-s3e11/data
#      (train.csv / test.csv / sample_submission.csv;如需重新下載:)
# export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
# uv run kaggle competitions download -c playground-series-s3e11 -p competitions/playground-series-s3e11

# 1) EDA(全量資料、僅快速統計)
uv run python3 competitions/playground-series-s3e11/scripts/eda.py

# 2) 實驗 2:skill base 模式(15 原始特徵,方法論對照)
uv run python3 competitions/playground-series-s3e11/scripts/train.py base

# 3) 實驗 3:skill engineered 模式(21 特徵,含 store_te target encoding;最佳)
uv run python3 competitions/playground-series-s3e11/scripts/train.py engineered
#      → submissions/sub_engineered_*.csv,並自動以 log_experiment_v2 寫入 experiments.json

# 4) (未執行)提交排行榜:
# uv run kaggle competitions submit -c playground-series-s3e11 \
#      -f competitions/playground-series-s3e11/submissions/sub_engineered_0.29614_20230901.csv \
#      -m "engineered blend"
```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 uv run 以確保套件環境一致。特徵工程程式碼在 scripts/features.py (被 train.py 匯入),target encoding 因需 fold 內計算,實作於 train.py 。