

競賽分析報告:playground-series-s3e11

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

目錄	
1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格表	4
3.4 推論表	5
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	6
5. 效能對照(逐階段)	7
6. 總結	8
7. 重現指令	8

1. 競賽目的

What:依門市與商品層級屬性(門市面積與五個附設設施旗標、商品重量/包裝、銷售額/銷量、顧客家庭屬性等 15 個欄位)預測媒體行銷活動成本(`cost`),為連續數值之表格型迴歸問題; 資料集屬 Aygun et al.(Nature 2026)Kaggle Playground 基準(Season 3 Episode 11)。

Why:評估指標為 **RMSLE(minimize)**。成本類目標關心相對誤差而非絕對誤差:RMSLE 在 `log1p` 空間計算 RMSE,懲罰比例偏差並壓抑大值樣本對損失的支配,適合恆正的金額型目標。此定義也直接決定訓練策略——對 `log1p(cost)` 以 RMSE objective 訓練即等同直接優化 RMSLE。

項目	值
競賽	playground-series-s3e11
問題型別	regression
評估指標	rmsle(minimize)
目標欄位	cost

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第2版(重用線性迭代之 OOF 快取)。交叉驗證採標準 KFold(shuffle)5 折(設計理由見第 3.3 節)。

2.2 本場專業術語

專業術語	定義
store profile(門市組合)	store_sqft 加五個設施旗標構成的欄位組合;同一組合大量重複出現,是本場最強的訊號來源

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段 1-4 本場皆有執行,各子階段採用情形如下。

階段 1 | 無 skill 基線

- 1.1 單模型基線 — 使用
- 1.2 三模型 blend — 使用

階段 2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(併入第2次實驗,無獨立分數)
- 2.2 EDA 驅動特徵工程 — 使用(第2次實驗→第3次實驗, store_te 目標編碼)
- 2.3 指標感知後處理 — 使用(log1p 目標對齊 RMSLE,第2次實驗起全部實驗)
- 2.4 場內反思回退 — 本場未使用

階段 3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 使用
- 3.3 調參入池 — 使用(含於 3.2 之作法,入池不替換)
- 3.4 seed bagging — 使用
- 3.5 結構化去噪 — 本場未使用

階段 4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 使用
- 4.3 先驗注入+去重 — 使用(v2 內建)

- 4.4 邊界推進 mutation — 使用(CAT depth 10→12 突破調參上界)
- 4.5 預算相位機 — 本場未使用

階段 5 | +外部想法注入(ERA 第二支柱)

- 5.1 外部想法庫 + 篩選去重 — 使用(依 comp_meta 篩選、[INT] 去重)
- 5.2 想法→搜尋候選翻譯器 — 使用(本場注入 stacking——對各成員 OOF 預測疊一層 meta 模型)
- 5.3 plateau 觸發 + 限次數(快評)— 使用(在階段4收斂點以快取 OOF 評估)
- 5.4 注入候選採納 — 否(未勝過階段4 → 階段5=階段4;全案 15 場一致,見第 5 節與總結報告第 7 節)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	360,336
test 列數	240,224
原始欄位數	15(全數值)
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

EDA 已執行:15 個特徵全為數值型,其中多數實為低基數「類別型偽裝」欄位(五個 0/1 設施旗標、家庭屬性等);train 無缺失值、無重複列; salad_bar 與 prepared_food 相關 0.999839,為唯一高共線特徵對(近乎重複欄)。

目標 cost $\in [50.79, 149.75]$, mean 99.614729、median 98.81、skew 0.019132——分布近乎對稱,EDA 判定非 log 轉換候選;採 log1p 目標的理由是「RMSLE = log1p 空間之 RMSE,直接優化競賽指標」,而非矯正偏態,預測經 expm1 後 clip ≥ 0 。

低訊號資料集:單變量關聯最強者僅 florist (pearson -0.110414)。store_sqft 加五個設施 旗標構成大量重複出現的 store profile(門市組合),是最強特徵候選,需以 fold-safe 目標 編碼防洩漏;EDA 的驗證建議為「連續目標、各列獨立 → 標準 KFold」。

3.2 實驗總表

語意澄清(本報告全文適用):RMSLE 為連續迴歸指標,本場無取整/門檻類後處理,故各 實驗的「原始 OOF」即「決策分數」,兩欄同值;且本場為無人值守批次執行,全程未提交 Kaggle,所有決策皆以本機 OOF 為準,下文不再重複解釋。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	1.2	LGB/XGB/CAT(0.7/0.0/0.3)	15	0.29723	0.29723	基線參照
2	2	LGB/XGB/CAT(0.2/0.0/0.8),log1p 目標	15	0.2971	0.2971	同特徵對照組
3	2.2	LGB/XGB/CAT(0.2/0.0/0.8)+ store_te	21	0.296143	0.296143	是,階段 2 最佳

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
4	3	LGB/CAT_orig(0.2/0.8), 移除 XGB	21	0.296143	0.296143	是, 分數不變
5	3.2	+ CAT_tuned(Optuna, 0.9 權重)	21	0.295781	0.295781	是
6	3.4	+ CAT_tuned seed=2024(4-way)	21	0.295715	0.295715	是
7	3	4-way pool + 門市組合均值特徵	24	0.2962	0.2962	否, 退步棄用
8	3.4	+ CAT_tuned seed=7(5-way)	21	0.295648	0.295648	是, 線性迭代最佳
9	4.2	7-way blend(depth-12 CAT 家族 + DEEPLGB)	21(同 第 8 次實驗)	0.29528	0.29528	是, 本場最佳
10	5	外部注入快評候選(EXT-09(stacking); 沿用階段4成員 OOF)	21	0.298328	0.298328	否(未勝過階段4, 見 § 5)

最佳解成員表(第 9 次實驗, node #20, 新成員家族出現後的純權重再搜尋)

成員	權重	solo 分數	備註
CAT_D12_S7	0.2478	0.295461	調參 CAT depth 10→12(突破 Optuna 搜尋上界), 全樹最佳 solo
CAT_D12_S3000	0.3187	0.295462	depth-12 家族 seed 變體
CAT_D12_S3001	0.239	0.295483	depth-12 家族 seed 變體
CAT_S7_D10	0.0091	0.295779	線性迭代之 depth-10 tuned CAT(seed 7), 自快取重用
CAT_S99	0.0031	0.295786	第 4 個 tuned-CAT seed, 線性迭代未嘗試
CAT_TUNED_ROOT	0.0039	0.29579	線性迭代最強 solo(Optuna 調參 CAT, seed 42), 快取重用
DEEPLGB	0.1783	0.295833	刻意多樣化之深 LGB(num_leaves 255); solo 平庸但權重第 3 大

選型脈絡: 第 1–3 次實驗 三模型權重搜尋連兩輪將 XGB 權重歸 0, 第 4 次實驗 移除 XGB 後 blend 分數不變, 驗證零權重裁決無代價; 第 5 次實驗 起 Optuna 調參 CatBoost 成為主力, 權重全數流向 tuned CAT 家族; 第 7 次實驗 在 store_te 之上再加門市組合均值特徵全面退步, 棄用回退; 第 8 次實驗 以第三個 seed 收在 0.295648, 增益已縮至噪音級, 依協定停止線性迭代。

補充說明: 最佳解紀錄(第 9 次實驗)以 OOF 分數最小選出, 為**只算出 OOF 分數**的樹搜尋結果——未產生 test 預測、無 submission 檔、未提交 Kaggle; 其權重由權重搜尋直接對全 OOF 擬合(無巢狀驗證), 0.0004 等級的增益帶有 OOF 權重過擬風險, 方向性結論(深度突破 Optuna 上界後重開 blend)較第 4 位小數穩健。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1	5fold	5	無紀錄
2	5fold_kfold_shuffle	5	42
3	5fold_kfold_shuffle	5	42
4	5fold_kfold_shuffle	5	42

實驗編號	CV 方案	folds	seed
5	5fold_kfold_shuffle	5	42
6	5fold_kfold_shuffle	5	42
7	5fold_kfold_shuffle	5	42
8	5fold_kfold_shuffle	5	42
9	KFold(shuffle)	5	42

目標為連續值、各列獨立(無時間/群組結構,見 EDA 的驗證建議),且門市組合大量重複、隨機切分安全,故用 KFold(shuffle, seed=42);第 2-9 次實驗(含樹搜尋)沿用同一組固定折,跨實驗分數可直接比較。

Objective 與關鍵超參:全程對 $\log_{1p}(\text{cost})$ 以 RMSE objective 訓練,預測 expm1 後 clip ≥ 0 (第 2 次實驗起)。
第 5 次實驗之 Optuna(TPE,每組參數先只在第 0 折評分以省時)最佳 CatBoost 參數:

```
Optuna:TPE 40 trials(319.3s,timeout guard 480s),僅以第 0 折評分挑參
CatBoost tuned:depth=10, learning_rate≈0.0824, l2_leaf_reg≈5.482,
min_data_in_leaf=33, random_strength≈0.0916
第 9 次實驗 樹搜尋關鍵變體:CAT depth 10→12(Optuna 原搜尋空間上界為 10)、
DEEPLGB num_leaves=255
```

其餘 base model(手設 LGB/XGB/CAT)之超參無結構化紀錄,不臆測。

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無後處理紀錄	sub_generic_0.29723_20260703_121020.csv	否
2	expm1 + clip ≥ 0	sub_base_0.29710_20260703_192507.csv	否
3	expm1 + clip ≥ 0	sub_engineered_0.29614_20260703_192819.csv	否
4	expm1 + clip ≥ 0	sub_r1_noxgb_0.29614_20260703_222353.csv	否
5	expm1 + clip ≥ 0	sub_r2_cattuned_0.29578_20260703_223101.csv	否
6	expm1 + clip ≥ 0	sub_r3_seedbag_0.29571_20260703_223204.csv	否
7	expm1 + clip ≥ 0	sub_r4_deepstore_0.29620_20260703_223633.csv(棄用)	否
8	expm1 + clip ≥ 0	sub_r5_seedbag3_0.29565_20260703_223829.csv	否
9	無(僅 OOF 分數)	無紀錄(未產生 test 預測)	否

「後處理」欄之 expm1 + clip ≥ 0 為 $\log_{1p}$ 目標之逆轉換與安全網(各實驗均有註記),非指標特化後處理。欄位格式:id 欄 id、目標欄 cost。本場為無人值守批次執行,僅產生本機 submission 檔、未觸碰 Kaggle 憑證,「是否已提交」一律為否。

3.5 評估指標 / 排行榜

指標定義:RMSLE = 對預測值與真值各取 $\log_{1p}$ 後計算 RMSE,衡量比例(相對)誤差,越低越好。

項目	OOF RMSLE
CAT_tuned(第 8 次實驗 成員,Optuna 調參,seed 42)	0.29579
CAT_tuned_seed2024(第 8 次實驗 成員)	0.29591
CAT_tuned_seed7(第 8 次實驗 成員)	0.29578
Ensemble(第 8 次實驗,線性迭代終點,5-way)	0.295648
Ensemble(第 9 次實驗,樹搜尋 best,7-way)	0.29528
Public / Private LB	無紀錄(未提交)

本場未提交 Kaggle,無排行榜紀錄,故無排行榜表,CV↔LB gap 無法計算。第 9 次實驗 相對 第 8 次實驗 之改善:

第 8 次實驗 - 第 9 次實驗:0.295648 - 0.29528 = 0.000368

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	2026-07-03T12:10:20	0.29723	1.2	15 原始特徵三模型 blend,設定待超越基線
2	2026-07-03T19:25:07	0.2971	2	換 log1p 目標 + 調參 + 提前停止,同特徵對照組
3	2026-07-03T19:28:19	0.296143	2.2	21 特徵 + 門市組合 fold-safe 目標編碼,階段 2 最佳
4	2026-07-03T22:23:54	0.296143	3	移除連兩輪零權重之 XGB,分數不變
5	2026-07-03T22:31:01	0.295781	3.2	Optuna 調參 CatBoost 入池,線性迭代主要躍升
6	2026-07-03T22:32:05	0.295715	3.4	tuned CAT seed bagging(seed 2024,4-way)
7	2026-07-03T22:36:33	0.2962	3	門市組合均值特徵全面退步,棄用
8	2026-07-03T22:38:30	0.295648	3.4	第三 seed(7)5-way blend,線性迭代最佳後停止
9	2026-07-04T12:17:25	0.29528	4.2	樹搜尋 node #20 之 7-way 再混合,本場最佳
10	2026-07-08T11:46:18	0.298328	5	外部注入快評:EXT-09(stacking) 候選 OOF 未勝過階段4,不採納

- **突破點 1(第 2 次實驗→第 3 次實驗):** store_te (門市組合的 fold-safe 目標編碼)一舉由 0.2971 降至 0.296143,為階段 2 主要增益來源。
- **突破點 2(第 4 次實驗→第 5 次實驗):**Optuna(每組參數先只在第 0 折評分)調參 CatBoost 以「入池不替換」加入,0.296143 → 0.295781,為線性迭代階段最大單筆增益。
- **突破點 3(第 8 次實驗→第 9 次實驗):**樹搜尋把 CAT depth 推到 12——超出 Optuna 自身搜尋上界 10 ——並在新 solo 家族出現後重開 blend 權重搜尋,0.295648 → 0.29528。

5. 效能對照(逐階段)

階段	配置	分數	相對改善
1	基線(Claude Code 直接執行,未引入 skill;第 1 次實驗 通用批次三模型 blend)	0.29723	—(基線)
2	+ kaggle-agent skill 六階段流程(第 3 次實驗,特徵工程版)	0.296143	0.37%
3	+ self-improvement 線性迭代(第 8 次實驗,5-way blend)	0.295648	0.17%
4	+ 樹搜尋(第 9 次實驗,node #20 之 7-way blend)	0.29528	0.12%
5	+ 外部想法注入(第 10 次實驗,快評)	0.29528	0.00%(未勝過)

相對改善計算式(每階段對前一階段)

階段1→2: $0.29723 - 0.296143 = 0.001087$, 相對改善 $0.001087 / 0.29723 = 0.3657\%$
階段2→3: $0.296143 - 0.295648 = 0.000495$, 相對改善 $0.000495 / 0.296143 = 0.1671\%$
階段3→4: $0.295648 - 0.29528 = 0.000368$, 相對改善 $0.000368 / 0.295648 = 0.1245\%$
階段4→5: 注入候選 0.298328 未勝過階段4 0.29528, 搜尋保留階段4 → 相對改善 0.00%(外部注入無增益)

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

注:指標為 RMSLE(minimize),分數越低越好,各階段逐階下降、無同值階段。階段 4(第 9 次實驗)為 只算出 OOF 分數的樹搜尋結果,本場無任何 Kaggle 提交、無排行榜對照,各階段分數皆為同一組固定折之 本機 OOF。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:LGB)	0.29731	第 1 次實驗
1.2(三模權重 blend)	0.29723	第 1 次實驗
2.2(特徵工程前:15 原始特徵,log1p+RMSE 目標對照組)	0.2971	第 2 次實驗
2.2(特徵工程後:21 特徵 + store_te fold-safe 目標編碼)	0.296143	第 3 次實驗
3.2(Optuna 調參 CatBoost——僅以第 0 折評分挑參,加入池)	0.295781	第 5 次實驗
3.4(seed bagging,tuned CAT seed 2024,4-way)	0.295715	第 6 次實驗
3.4(seed bagging 擴充,tuned CAT 第 3 個 seed,5-way,線性迭代終點)	0.295648	第 8 次實驗
4.2(樹搜尋 node #20,CAT depth 推進至 12,7-way 再混合,本場最佳)	0.29528	第 9 次實驗

階段 5 | + 外部想法注入(ERA 第二支柱)

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-09:stacking**——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic),以 nested-CV 避免洩漏。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們**已算好的 OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

```
階段5 注入候選(stacking)OOF RMSLE = 0.298328
階段4 冠軍          OOF RMSLE = 0.295280
差距 = -0.003048 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4
```

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的 ERA 第二支柱誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場資料量大(360,336 列)而訊號弱:15 個全數值特徵之單變量關聯皆極低(最強僅 `florist pearson` -0.110414),真正的結構藏在 `store_sqft` 加五個設施旗標構成的重複 `store profile` 中。目標近乎對稱、非 log 轉換候選,採 `log1p` 目標純粹是為了讓 RMSE objective 直接等於競賽指標 RMSLE。

關鍵決策有四:以 fold-safe 目標編碼 `store_te` 榨取門市組合訊號(第 3 次實驗,階段 2 主要 增益);尊重零權重裁決移除 XGB(第 4 次實驗,分數不變、釋出預算);Optuna 調參 CatBoost 入池 加 seed bagging(第 5-8 次實驗);第 7 次實驗 在 `store_te` 之上疊門市組合均值特徵退步後果斷回退,並在增益縮至噪音級時依協定停止線性迭代。

各階段增益中階段1→2 最大(特徵工程),階段2→3 次之(調參 + seed bagging), 階段3→4 由樹搜尋貢獻:最大單筆發現是把 CAT depth 推到 12——Optuna 的最優解原本就 落在其搜尋上界 10 上,上界本身即是下一個突變方向;而最終 0.29528 來自新 depth-12 家族 出現後重開的 blend 權重再搜尋,且 solo 平庸的 DEEPLGB 仍拿到 0.1783 權重,再次印證 blend 貢獻與 solo 分數脫鉤。

可信度方面須誠實:本場全程僅本機 OOF、未提交 Kaggle,無排行榜外部驗證;第 2-9 次實驗 使用同一組固定折,分數排序可直接比較,但 第 9 次實驗 僅有 OOF 分數且權重直接對全 OOF 擬合,0.0004 等級 增益帶有過擬風險。方向性結論(深度突破調參上界、突破後重開 blend)是穩健的部分。

重現本實驗的最短路徑:見第 7 節。

階段 5(外部想法注入) 經快評未勝過階段4:注入機制可運作、也產生了候選(stacking),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的 ERA 第二支柱誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 資料下載(需先設定 KAGGLE_API_TOKEN;data/ 已存在者可略過)
uv run kaggle competitions download -c playground-series-s3e11 \
  -p competitions/playground-series-s3e11/data

# 階段 2:EDA
uv run python3 competitions/playground-series-s3e11/scripts/eda.py
```

```

# 第 1 次實驗(階段 1):通用批次管線
uv run python3 competitions/run_competition.py playground-series-s3e11

# 第 2 次實驗(階段 2):skill base(log1p 目標,15 原始特徵,同特徵對照組)
uv run python3 competitions/playground-series-s3e11/scripts/train.py base

# 第 3 次實驗(2.2):skill engineered(21 特徵 + store_te,階段 2 最佳)
uv run python3 competitions/playground-series-s3e11/scripts/train.py engineered

# 階段 3(第 4–8 次實驗;checkpointed,cache 命中會跳過已訓練成員)
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r1
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py tune
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r2
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r3
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r4 # 退步,棄用
uv run python3 competitions/playground-series-s3e11/scripts/iterate2.py r5 # 第 8 次實驗,線性迭代最佳

# 第 9 次實驗(4.2):樹搜尋工具第 2 版(本場最佳;只算 00F 分數,重用 scripts/cache/*.npz)
uv run python3 tree_search/run_s3e11.py

# 報告產生(本檔)
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e11
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py \
    competitions/playground-series-s3e11/REPORT.md competitions/playground-series-s3e11/facts.json
bash .claude/skills/kaggle-report/assets/md2pdf.sh competitions/playground-series-s3e11/REPORT.md \
    competitions/playground-series-s3e11/s3e11_REPORT.pdf

# 提交至 Kaggle(本場未執行;需先設定有效之 KAGGLE_API_TOKEN)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e11 \
    -f competitions/playground-series-s3e11/submissions/sub_r5_seedbag3_0.29565_20260703_223829.csv \
    -m "R5 5-way seed-bagged tuned CatBoost blend, 00F RMSLE 0.295648"

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 00F、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s3e11

```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 uv run 以確保套件環境一致。本場為無人值守批次執行,未提交至 Kaggle 排行榜、未觸碰 Kaggle 憑證。