

競賽分析報告:playground-series-s3e14

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-03(2026-07-04 更新:Phase G-1b 樹搜尋成果入帳,實驗 8)

1. 競賽目的

What:本場競賽要求依野生藍莓田區的環境與授粉相關量測值,預測藍莓產量(`yield`)。這是一個 以連續數值輸出產量估計的迴歸問題。

Why:評估指標為 **MAE(平均絕對誤差,minimize)**。以絕對誤差的平均衡量預測誤差,單位與 產量本身一致,直觀反映「平均預測誤差是多少產量單位」,不會像平方誤差類指標般被少數極端樣本 過度放大,適合作為此類連續產量預測任務的評估基準。

項目	值
競賽	playground-series-s3e14
問題型別	regression
評估指標	mae(minimize)
目標欄位	yield

2. 資料規格

本場已完整執行 EDA(`scripts/eda.py`)與特徵工程(`scripts/features.py`), `facts.json` 的 `material_level` 為 `full` , `status_md_present` 為 `true` (競賽層 `STATUS.md` 已建立,記錄 EDA narrative 發現)。

- 依 `facts.json` ,本場共有 8 筆實驗紀錄:第 1 筆(`generic_batch` ,通用批次基線)使用 16 個特徵 (來源: `experiments[0].n_features`);第 2 筆(特徵工程 iteration 1)使用 27 個特徵 (來源: `experiments[1].n_features`);第 3 筆(特徵剪枝 iteration 2)起至第 7 筆(線性迭代 終點)均使用 21 個特徵(來源: `experiments[2].n_features / experiments[6].n_features`)。第 4-7 筆為 Phase B 自我改進迭代(Optuna 調參、blend 成員擴充、isotonic 校準試驗、seed bagging)。第 8 筆(**`facts.best`,Phase G-1b 樹搜尋**)不是線性迭代的延續回合,細節見第 3 節末小節。
- 原始資料列數/欄位型別、缺漏值計數等具體數值未被 `collect.py` 收錄進 `facts.json` (該檔僅記錄 competition 中繼資料與 `experiments` 結構化欄位,不解析 EDA 腳本輸出),故此類細項

為 無紀錄。

- 特別規則:不可使用外部資料、不可使用預訓練模型、不可存取網路;每日提交上限 5 次(來源: `competition.special_rules`)。

3. 模型規格

`facts.json` 目前的 best 是 `experiment_id=8`——一筆樹搜尋(`tree-search`)結果(細節見 3b 小節),而非本節原本描述的線性迭代終點(`experiment_id=7`)。兩者皆完整說明如下。

3a. 線性迭代最佳(`experiment_id=7`,Phase B round 4 之終點)

五個 base model 分數:

Model	OOF MAE
LGB	342.02154
LGB_TUNED	341.68775
XGB	342.21778
CAT	343.60196
LGB_SEED2024	342.04208

Ensemble 權重(來源: `best.ensemble.weights`,方法 `best.ensemble.method = grid_simplex_5way`): LGB 0.2 / LGB_TUNED 0.15 / XGB 0.2 / CAT 0.25 / LGB_SEED2024 0.2,Ensemble 分數(來源: `best.ensemble.score`):**340.65207**。

選型理由(來源: `best.notes`、`experiments[3..6].notes`,並參照 `STATUS.md` 脈絡):Phase B 自我改進共 4 輪,每輪只改一件事。round 1(`experiments[3]`)以 Optuna fold-0 代理調參 LightGBM, 單模自 342.02154 進步到 341.68775,但直接「替換」原 LGB 使 blend 反退步(340.75961→340.95316,多樣性流失);round 2(`experiments[4]`)改為「保留原 LGB 並加入調參版 LGB」作為第 4 個成員, 4-way 網格混合勝出(340.62702);round 3(`experiments[5]`)測試對混合輸出做 nested OOF isotonic 校準,isotonic 本身分數 346.99717 明顯更差,被自動否決;round 4(`experiments[6]`,best)再加入一個 seed 多樣化的 LGB(相同超參、`random_state 2024`)作為第 5 個成員,取得 340.59891 (線性迭代終點)。

3b. 樹搜尋最佳(best,`experiment_id=8`)——本次更新(Phase G-1b)新增

Phase F-2(harness v3,2026-07-04,預設自動策略驗證跑)樹搜尋在 `experiment_id=7` 的相同 21-特徵集上另闢節點空間,於 `experiments_tree_v3.json` 的 node #44 找到 MAE 更低的 **34-way 「kitchen-sink」 mega-blend**——這是 harness v3 的 explore-burst 機制強制觸發的 長射(long-

shot)節點,把整場搜尋累積的全部 34 個 solo 成員一次納入權重搜尋 (第 60-評估硬上限中的第 44 次評估;node wall_s=1.64s,純權重搜尋、零重訓)。

模型	OOF MAE
LGB_ROOT	342.02154
CAT	343.60196
XGB	342.21778
LGBTUNED	341.68775
SEEDBAG_S2024	342.04208
FEAT	342.02283
REG	342.93033
XGBTUNED	341.9943
LGBTUNED_NEW	341.89372
LGBTUNED_S4000	341.63373
LGBTUNED_S4001	341.91928
XGBTUNED_S4000	342.36635
XGBTUNED_S4001	342.1212
XGBTUNED_S4002	342.49949
FEAT_NEW2	342.28883
FEAT_S4000	341.89382
FEAT_S4001	342.07229
SEEDBAG_S555	341.68944
SEEDBAG_S4000	342.05908
SEEDBAG_S4001	342.23701
XGB_NEW	342.521
XGB_S4000	342.89275
XGB_S4001	342.57559
REG_L2	342.85043
REG_LEAVES90	343.73934
REG_S4000	342.81987

模型	OOF MAE
CAT_NEW	344.30153
CAT_S4000	343.88165
CAT_S4001	343.99525
EXPL_DART	6156.32115
EXPL_XT	344.82504
EXPL_CATDEEP	345.1579
EXPL_XGBLEAF	343.21412
EXPL_REGDEEP	341.99788

(來源: `best.base_models`, 34 個成員。注意 EXPL_DART 是災難性的離群 solo(OOF MAE 6156.32115), Boosting 用了 DART 模式, 是 explore-burst 「長射」機制刻意嘗試的高風險想法 之一, 並未拖累最終 blend——見下方權重說明。)

Ensemble(`best.ensemble`): 方法為「harness_v3 explore_burst mega-blend: k=800 dirichlet + coordinate-ascent 權重搜尋, 34 個快取 solo OOF 向量、零重訓」。raw blend 分數 `score_raw` = 340.57853, 經 snap-to-grid 後(`best.postprocess`) 為 **340.35572** (= `best.score`)。個別成員權重未被此 `harness_v3` 樹節點格式記錄下來(不同於 v2 節點 schema)——`experiments_tree_v3.json` 僅記錄成員清單與 raw/snap 兩個分數。依 `best.ensemble.n_members_weight_over_0.005` = 28, 34 個成員中有 28 個保留 >0.005 的權重(其餘未記錄, 不臆測); 依 STATUS.md 的敘述性記錄(數值未收錄進 facts.json), 4 個 CatBoost 變體合計約 0.22 權重, 兩個 explore-burst 長射倖存者 EXPL_CATDEEP(solo 345.1579, 權重約 0.051) 與 EXPL_REGDEEP(solo 341.99788, 權重約 0.045) 亦進入最終 blend。

選型理由/來源說明(`best.notes`): 這是 Phase F-2 樹搜尋(harness v3 預設自動策略驗證 跑)結果, 不是線性迭代的延續回合。較 `experiment_id=7`(340.59891) 改善 -0.24319(約 -0.071% 相對改善, 詳見第 6 節程式區塊), 也優於先前 harness v1-proto 樹的結果(Phase C-2b, 340.52635)。explore-burst(評估 39–44) 貢獻了 exploit 階段結束後全部的增益 (340.45150 → 340.35572); 本輪 60 次評估在硬預算上限停止, 並非透過 patience 自動停止 機制觸發。完整節點鏈、phase machine 行為、與誠實操作記錄(含 6 次災難性 DART 評估) 見 `competitions/playground-series-s3e14/STATUS.md` 〈Appendix: Phase F-2 harness v3 validation run〉。

重要澄清: `best.notes` 明確記載這是 **OOF-only** 搜尋結果——未產生任何 test 預測, 亦未提交至 Kaggle(facts.json 本筆無 submission 欄位)。best 是以 OOF score 最小者選出(本場 metric 為 mae, minimize), 與是否已提交至 Kaggle 無關; 本場(`experiment_id=7` 與 `experiment_id=8` 皆同)未提交至 Kaggle(見第 6 節), 因此沒有 leaderboard 分數可與 best 對照。

作為對照,第 1 筆實驗(通用批次基線)的 base model 分數為:

Model	OOF MAE
LGB	345.32118
XGB	344.13027
CAT	344.24276

(來源: `experiments[0].base_models` ,ensemble 權重 LGB 0.3 / XGB 0.3 / CAT 0.4,分數 341.40782,來源: `experiments[0].ensemble` 。)

4. 訓練規格

實驗	source_format	CV scheme	n_splits	seed
1(baseline)	generic_batch	5fold	5	無紀錄
2(iteration 1)	v2	5fold_kfold	5	42
3(iteration 2)	v2	5fold_kfold	5	42
4(Phase B round 1)	v2	5fold_kfold	5	42
5(Phase B round 2)	v2	5fold_kfold	5	42
6(Phase B round 3)	v2	5fold_kfold	5	42
7(Phase B round 4,線性迭代終點)	v2	5fold_kfold	5	42
8(樹搜尋,best)	v2	5fold_kfold	5	42

(來源: `experiments[].cv` ;第 1 筆之 `cv` 物件無 `seed` 欄位,故寫「無紀錄」;第 2-8 筆 `seed` 均為 42,與線性迭代同折,分數可直接比較。)

多數 base model 之 objective/超參數未記錄於 `experiments[].base_models[]` 對應欄位中,惟第 4 筆 (`experiments[3].notes`)完整記錄了 Optuna 為 LightGBM 找到的最佳超參: `learning_rate` 0.015389816656608301、`num_leaves` 63、`max_depth` 5、`min_child_samples` 30、`subsample` 0.7899031923134097、`colsample_bytree` 0.6842166782718478、`reg_alpha` 0.012648426946439915、`reg_lambda` 0.00346212601571565(36 trials、293 秒,採 fold-0 單折代理目標)。此組超參即後續 第 5、7 筆中的 `LGB_TUNED` 成員。

為何用此 CV:第 2、3 筆實驗改採 5-fold KFold(shuffle,seed=42)。依 `STATUS.md` 記載之 EDA 脈絡,目標為連續值且無分組/時間結構,train/test 各欄位分布差異小,故不需分層抽樣(與 `s3e16` 的離散 Age 目標不同),一般 i.i.d. KFold 即為合適的驗證方案。

5. 推論程序

facts.json 現在的 best 是 **experiment_id=8(樹搜尋)**,其 `postprocess` 欄位記錄 `"snap_to_grid (applied inside metric_fn on the raw blend OOF, not just at submission time)"` ——與 **experiment_id=7** 的差異在於樹搜尋版本於 **metric_fn 內部**對 raw blend OOF 直接做 snap-to-grid 評分,而非僅在 submission 階段套用。

以下為線性迭代終點 **experiment_id=7** 的後處理紀錄(來源: `experiments[6].postprocess`):

1. `"snap_to_grid=used (raw=340.65207, snapped=340.59891)"`

即:5-way 網格混合輸出最終被「snap 至訓練集中曾觀測到的最近 yield 值」,分數自 340.65207 降至 340.59891。snap-to-grid 在本場歷次迭代(含樹搜尋)皆為正向後處理。

作為對照,round 3(`experiments[5].postprocess`)另記錄了一項被否決的後處理決策原文:

`"isotonic=rejected (raw=340.69924, iso=346.99717)"` —— 對混合輸出做 nested OOF isotonic 校準 反而使分數自 340.69924 惡化到 346.99717,因此被自動捨棄。

Submission 檔名(best.submission,experiment_id=8):無紀錄——**experiment_id=8** 是 樹搜尋 (OOF-only)結果,facts.json 本筆未附 submission 欄位,未產生 test 預測、未提交 Kaggle(見 3b 節澄清)。線性迭代終點(**experiment_id=7**)有提交檔案供參考:

`sub_blend_v6_340.59891_20260703_211503.csv` (對應 OOF 340.59891,非目前 best 的 340.35572),
對應 `id_column = id`、`target_column = yield` (來源: `competition.id_column / competition.target_column`)。

6. 評估指標

指標定義:MAE(Mean Absolute Error)= 預測值與真實值絕對差的平均,單位與目標欄位相同 (此處為產量)。

實驗	Model/Ensemble	OOF MAE
1(baseline)	LGB	345.32118
1(baseline)	XGB	344.13027
1(baseline)	CAT	344.24276
1(baseline)	Ensemble	341.40782
7(best)	LGB	342.02154
7(best)	LGB_TUNED	341.68775

實驗	Model/Ensemble	OOF MAE
7(best)	XGB	342.21778
7(best)	CAT	343.60196
7(best)	LGB_SEED2024	342.04208
7(線性迭代終點)	Ensemble(後處理前)	340.65207
7(線性迭代終點)	Ensemble(snap-to-grid 後)	340.59891
8(樹搜尋,best)	Ensemble(raw,34-way)	340.57853
8(樹搜尋,best)	Ensemble(snap-to-grid 後,= best.score)	340.35572
Public LB	—	無紀錄
Private LB	—	無紀錄

(來源: `experiments[0].base_models / .ensemble` 、 `experiments[6].base_models / .ensemble / .score` 、 `best.ensemble / .score (experiment_id=8)`; `facts.leaderboard` 為 `null` , `facts.missing` 列出 `leaderboard` ,顯示本場未提交至 Kaggle 排行榜,故無法計算 CV↔LB gap 。)

線性迭代終點(exp7)相對第 1 筆基線的分數差距:

```
341.40782 (experiments[0].score, baseline)
- 340.59891 (experiments[6].score, Phase B round 4, 線性迭代終點)
= 0.80891
```

Phase B 自我改進相對前一階段最佳(iteration 2)的增量:

```
340.711795 (experiments[2].score, iteration 2)
- 340.59891 (experiments[6].score, Phase B round 4)
= 0.112885
```

樹搜尋(exp8,best)相對線性迭代終點(exp7)的改善:

```
340.59891 (experiments[6].score, 線性迭代終點)
- 340.35572 (best.score, 樹搜尋 node #44)
= 0.24319
0.24319 / 340.59891 × 100 ≈ 0.0714...%(約 -0.071% 相對改善)
```

樹搜尋(exp8)相對先前 harness v1-proto 樹結果(Phase C-2b,340.52635,未列於本場 experiments.json,見 STATUS.md)的改善:

340.52635 - 340.35572 = 0.17063

即最佳實驗較基線有小幅但一致的下降(對絕對誤差指標而言為改善方向),Phase B 4 輪迭代再貢獻上方第二個算式所示的額外改善,樹搜尋(Phase G-1b 入帳)再貢獻第三個算式所示的額外改善。

7. 實驗軌跡

experiment_id	timestamp	score	source_format
1	2026-07-03T12:11:46	341.40782	generic_batch
2	2026-07-03T19:36:46	340.958565	v2
3	2026-07-03T19:39:59	340.711795	v2
4	2026-07-03T21:07:27	340.826945	v2
5	2026-07-03T21:11:27	340.627017	v2
6	2026-07-03T21:12:45	340.627017	v2
7	2026-07-03T21:15:03	340.59891	v2
8	2026-07-04T12:17:48	340.35572	v2

(來源: facts.trajectory 。最佳分數現為第 8 筆(樹搜尋),即 facts.best 。)

突破點敘述(來源: experiments[].notes):分數整體呈逐步下降。第 2 筆(iteration 1)引入 27 個特徵並選用 snap-to-grid,分數自 341.40782 降至 340.958565;第 3 筆(iteration 2)剔除 6 個趨近零貢獻特徵、CatBoost 改用原生類別處理,分數再降至 340.711795。Phase B 4 輪:第 4 筆以 Optuna 調參 LGB 並替換原成員,分數 340.826945(較第 3 筆退步,示範「替換破壞多樣性」);第 5 筆改為「加入」調參版 LGB 為第 4 成員,分數降至 340.627017(新最佳);第 6 筆試 isotonic 校準被否決,結果與第 5 筆同分 340.627017;第 7 筆再加入 seed-2024 的 LGB 為第 5 成員,分數降至 340.59891,為線性迭代終點。

突破點(Phase G-1b,本次更新新增):第 8 筆不是線性迭代的延續回合,而是 Phase F-2 (2026-07-04)以 harness v3 執行的**樹搜尋(tree-search)**結果——來源 experiments_tree_v3.json 的 node #44,harness v3 的 explore-burst 機制強制觸發的「kitchen-sink mega-blend」,把整場搜尋累積的全部 34 個 solo 成員一次納入權重搜尋 (60-評估硬上限中的第 44 次評估)。樹搜尋在 exp7 的相同 21-特徵集上另闢節點空間,分數由 340.59891 降至 340.35572(相對改善見上方第 6 節程式區塊)。**誠實 CV-only 警語:**此結果 為 OOF-only 搜尋產物——tree_search harness 未產生任何 test 預測檔,facts.json 本筆亦無 submission 欄位,**未提交至 Kaggle**;不可與 exp7 實際提交的 submission 檔

案混淆(見第 5 節)。完整節點鏈、explore-burst 機制、與誠實操作記錄(含 6 次災難性 DART 評估)見 `competitions/playground-series-s3e14/STATUS.md` 〈Appendix: Phase F-2 harness v3 validation run〉。

`facts.unparsed` 為空陣列,無法解析之紀錄:無。

8. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# Stage 1: EDA
uv run python3 competitions/playground-series-s3e14/scripts/eda.py

# Stage 3: 建模(iteration 1,分數 340.958565,對應 experiments[1]/submission
#   sub_blend_340.95856_20260703_193646.csv)
uv run python3 competitions/playground-series-s3e14/scripts/train.py

# Stage 3: 建模(iteration 2,分數 340.711795,對應
#   sub_blend_v2_340.71180_20260703_193959.csv)
uv run python3 competitions/playground-series-s3e14/scripts/train_v2.py

# Phase B round 1(Optuna 調參 LGB,分數 340.826945,對應 experiments[3])
uv run python3 competitions/playground-series-s3e14/scripts/train_v3.py

# Phase B round 2(4-way blend,分數 340.627017,對應 experiments[4];
#   會寫出 data/oof_v4.npz 供 round 3/4 重用)
uv run python3 competitions/playground-series-s3e14/scripts/train_v4.py

# Phase B round 3(isotonic 校準試驗,被否決,分數 340.627017,對應 experiments[5];需 oof_v4
uv run python3 competitions/playground-series-s3e14/scripts/train_v5.py

# Phase B round 4(seed bagging 5-way blend,分數 340.59891,線性迭代終點,對應
#   sub_blend_v6_340.59891_20260703_211503.csv;需 oof_v4.npz)
uv run python3 competitions/playground-series-s3e14/scripts/train_v6.py

# Phase F-2 樹搜尋 v3(best,實驗 8,分數 340.35572)— resumable;軌跡存於 experiments_tree_v
uv run python3 tree_search/run_s3e14_v3.py
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle` ;所有指令均透過 `uv run` 以確保套件環境一致。`scripts/features.py` 由各 `train*.py` 以模組方式匯入,不需單獨執行;`train_v5.py` / `train_v6.py` 依賴 `train_v4.py` 產生的 `data/oof_v4.npz` ,須先執行 round 2 。本場未提交至 Kaggle 排行榜(此環境無 Kaggle 憑證),故無對應的 `kaggle competitions submit` 指令可重現。