

# 競賽分析報告:playground-series-s3e16

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-04(Phase G-1a 樹搜尋成果入帳後更新;本次同時補上先前 未重產報告的 Phase B 迭代 exp 3、4,詳見第 3、6、7 節)

## 1. 競賽目的

**What:**本場競賽要求依螃蟹的物理量測值(長度、直徑、高度、整體重量與各部位重量等)預測其 年齡 ( Age )。這是一個以連續數值輸出年齡估計的迴歸問題。

**Why:**評估指標為 **MAE(平均絕對誤差,minimize)**。年齡標籤為正整數且分布右偏(多數個體 年齡集中在較低區間、少數個體年齡偏高),MAE 以「絕對誤差的平均」衡量預測誤差,相較平方誤差 類指標對少數高齡離群樣本更穩健,不會讓少數極端樣本主導損失,因此是此類偏態計數型目標的合理 選擇。

| 項目   | 值                       |
|------|-------------------------|
| 競賽   | playground-series-s3e16 |
| 問題型別 | regression              |
| 評估指標 | mae(minimize)           |
| 目標欄位 | Age                     |

## 2. 資料規格

- 訓練集 74,051 列、測試集 49,368 列;共 8 個原始欄位(1 個類別型 Sex ,其餘 7 個為連續型的 尺寸/重量量測值)加上目標欄位 Age (來源: competition.notes )。
- 特別規則:不可使用外部資料、不可使用預訓練模型、不可存取網路;每日提交上限 5 次(來源: competition.special\_rules )。
- 實驗 1( skill\_train 手刻管線)在原始 8 欄位基礎上,經特徵工程展開為 24 個特徵(來源: experiments[0].n\_features 、 experiments[0].features ),包含 Sex one-hot 展開、 is\_infant 旗標、各部位重量佔比、 weight\_resid 、體積/密度衍生量等(欄位清單詳 facts.json 之 experiments[0].features )。
- 實驗 2( generic\_batch 通用批次管線)僅使用原始 8 個欄位,未套用上述特徵工程(來源: experiments[1].n\_features )。

### 3. 模型規格

本場現有 5 筆實驗紀錄。**重要語意澄清(本節通篇適用)**:實驗 1、2 的 `score` 欄位是「原始 (未取整) OOF MAE」(source\_format 分別為 `skill_train / generic_batch, collect.py` 正規化時 直接取用未取整的 blend OOF 值);實驗 3、4、5 的 `score` 欄位則是**取整後(rounded) OOF MAE**——因目標 `Age` 為整數,取整後 MAE 才是本場實際決策指標(見 STATUS.md 記載,取整前後 分數會反向移動,細節見實驗 5 說明)。`facts.best` 純以數字最小值選出,不區分這兩種語意,故其挑中的實驗未必是「同一把尺」下最佳者——本節下方逐筆說明,不混淆。

#### 實驗 1( `skill_train` ,含特徵工程)— base models:

| Model | OOF MAE | time_s |
|-------|---------|--------|
| LGB   | 1.35651 | 30.8   |
| XGB   | 1.35763 | 36.7   |
| CAT   | 1.36162 | 23.7   |

Ensemble 權重(來源: `experiments[0].ensemble.weights`):LGB 0.6 / XGB 0.3 / CAT 0.1, Ensemble 分數(來源: `experiments[0].ensemble.score`):**1.35589**。

#### 實驗 2( `generic_batch` ,通用批次管線)— base models:

| Model | OOF MAE |
|-------|---------|
| LGB   | 1.3623  |
| XGB   | 1.35886 |
| CAT   | 1.35714 |

Ensemble 權重(來源: `experiments[1].ensemble.weights`):LGB 0.3 / XGB 0.2 / CAT 0.5, Ensemble 分數(來源: `experiments[1].ensemble.score`):**1.35441**(原始 OOF MAE,未取整)。

**選型理由(實驗 1、2)**:三個梯度提升樹模型(LightGBM、XGBoost、CatBoost)在表格型資料上 普遍穩健,各自的歸納偏誤不同,故以加權集成降低單一模型的方差。實驗 1 額外投入特徵工程(24 個特徵)並針對 MAE 目標調整訓練細節;實驗 2 為通用批次管線的預設跑法,未套用上述特徵工程但 集成權重不同,結果原始 OOF 分數反而略低——惟此結果僅為內部原始 OOF 比較,實驗 2 並未提交至 Kaggle 排行榜驗證(見節 5、6)。

#### 實驗 3(Phase B round 1,加入 Optuna fold0-proxy 調參 LGB 為第 4 個池成員)— base models:

| Model     | OOF MAE |
|-----------|---------|
| LGB       | 1.35651 |
| XGB       | 1.35763 |
| CAT       | 1.36162 |
| LGB_tuned | 1.35583 |

Ensemble 權重(來源: `experiments[2].ensemble.weights`):LGB 0.3 / XGB 0.1 / CAT 0.1 / LGB\_tuned 0.5,原始 Ensemble 分數(來源: `experiments[2].ensemble.score`):**1.35541** (較實驗 1 的 1.35589 略有改善)。但 `experiments[2].score` (取整後 OOF MAE)= **1.3385**, 劣於當時既有最佳 (實驗 1 取整後 1.33812,未記入結構化欄位,見 STATUS.md)——原始分數 進步、取整分數退步,未被採納。

實驗 4(Phase B round 2,加入 seed=2024 之調參 LGB 為第 5 個池成員)— base models:

| Model              | OOF MAE |
|--------------------|---------|
| LGB                | 1.35651 |
| XGB                | 1.35763 |
| CAT                | 1.36162 |
| LGB_tuned          | 1.35583 |
| LGB_tuned_seed2024 | 1.35604 |

Ensemble 權重(來源: `experiments[3].ensemble.weights`):LGB 0.2 / XGB 0.1 / CAT 0.1 / LGB\_tuned 0.4 / LGB\_tuned\_seed2024 0.2,原始 Ensemble 分數(來源: `experiments[3].ensemble.score`):**1.35533**(本場原始 OOF 最佳)。但 `experiments[3].score` (取整後)= **1.33893**,同樣劣於實驗 1 的取整後 1.33812——連續兩輪 取整分數未改善,依 Phase B 停止準則(連 2 輪無改善即停)於此輪後停止線性迭代。

實驗 5(Phase E-3 樹搜尋, `facts.best`):見 3a 節。

3a. 樹搜尋最佳(best, `experiment_id=5`)——本次更新新增

Phase E-3(harness v2 於「取整整數 MAE」上的酸性測試,2026-07-04)在 `experiments_tree.json` 的 node #15 找到本場目前最佳**取整後**OOF MAE:8-way blend(來源: `best.base_models`):

| 成員        | 權重     | solo 取整後 MAE | 備註 |
|-----------|--------|--------------|----|
| LGB(root) | 0.0198 | 1.33885      | —  |

| 成員                 | 權重     | solo 取整後<br>MAE | 備註                                                |
|--------------------|--------|-----------------|---------------------------------------------------|
| XGB                | 0.0256 | 1.3416          | —                                                 |
| CAT                | 0.5061 | 1.33846         | 主導權重                                              |
| LGB_tuned          | 0.0075 | 1.33979         | —                                                 |
| LGB_tuned_seed2024 | 0.0626 | 1.33914         | —                                                 |
| LGBBOUND           | 0.1117 | 1.3395          | 邊界推進 LGB, learning_rate=0.005                     |
| TWEEDIE            | 0.0004 | 1.37467         | 權重近乎歸零,但加入時貢獻本次搜尋單筆最大增益                           |
| FEATPRUNE          | 0.2662 | 1.34025         | 去除與 Weight 高度共線( $r=0.993$ )之欄位;新成員中權重最高,催生全域最佳節點 |

**Ensemble**(best.ensemble):method = "harness\_v2 dirichlet(k=800)+coordinate-ascent weight search, decided directly on ROUNDED MAE",取整後 score = **1.33563** ( best.score );同一組權重的原始(未取整)OOF MAE = **1.35712**( best.ensemble.score ) ——比實驗 1 的原始 1.35589 更差。

**選型理由/來源說明**(best.notes):這是本場「原始 vs 取整」語意反轉的最強例證——本節點 原始 OOF MAE(1.35712)劣於已提交的線性冠軍(實驗 1,原始 1.35589),但**取整後** OOF MAE (1.33563)優於線性冠軍的取整後 1.33812(改善 -0.00249)。此為實驗 3/4 失敗模式的鏡像 (那裡:原始進步、取整退步;這裡:原始退步、取整進步)——合起來是「決策必須依取整分數、不能依原始 OOF」這條規則最完整的正反雙向證據。完整節點鏈、backtrack/dedup 統計、與各 lineage 的誠實歸因見 [competitions/playground-series-s3e16/STATUS.md](#) 〈Appendix — Tree-search v2(Phase E-3,harness\_v2,2026-07-04)〉。

**重要澄清:**best.notes 明確記載這是 **OOF-only** 搜尋結果——未產生任何 test 預測,亦 未提交至 Kaggle(facts.json 本筆無 submission 欄位)。此結果不可與已提交的 LB 分數 混淆——本場官方排行榜結果仍是實驗 1 的 Public 1.34356 / Private 1.34075(見第 5、6 節),facts.best 挑中實驗 5 純粹是「取整後 OOF MAE 數字最小」,與是否已提交至 Kaggle 無關。

## 4. 訓練規格

| 實驗 | CV scheme               | n_splits | seed |
|----|-------------------------|----------|------|
| 1  | 5fold_stratified_agebin | 5        | 無紀錄  |
| 2  | 5fold                   | 5        | 無紀錄  |
| 3  | 5fold_stratified_agebin | 5        | 42   |
| 4  | 5fold_stratified_agebin | 5        | 42   |

| 實驗          | CV scheme               | n_splits | seed |
|-------------|-------------------------|----------|------|
| 5(best,樹搜尋) | 5fold_stratified_agebin | 5        | 42   |

(來源: `experiments[].cv`; 實驗 1、2 之 `cv` 未記錄 `seed` 欄位,故寫「無紀錄」; 實驗 3-5 皆為 `5fold_stratified_agebin (n_splits=5, seed=42)` 同一組固定折,樹搜尋(實驗 5)沿用與 Phase B 迭代完全相同的 CV。)

各 base model 之 objective/超參數在 `experiments[].base_models[]` 中未記錄對應欄位,故此項亦為「無紀錄」(實驗 3 之 Optuna 超參僅記於 `experiments[2].notes` 文字說明:fold-0-proxy、21/50 trials、300s timeout,依 Hard Rule 1 不作為表格數字引用)。

**為何用此 CV:**年齡標籤為右偏的整數計數型目標,若採用一般隨機 K-fold 切分,高齡樣本較少,可能造成各 fold 之目標分布不均、驗證分數不穩定。實驗 1 因此改用「依年齡分箱後分層抽樣」的 StratifiedKFold(將高齡樣本合併為單一分箱以避免箱內樣本過少),使各 fold 的年齡分布更一致,讓交叉驗證分數更能反映模型的真實泛化能力。

## 5. 推論程序

`facts.best` (實驗 5,樹搜尋)之 `postprocess` (來源: `best.postprocess`): `["round"]` (對取整後 MAE 做決策,見第 3a 節)。**Submission 檔名(best.submission):無紀錄**——實驗 5 是樹搜尋(OOF-only)結果,`facts.json` 本筆未附 `submission` 欄位,未產生 test 預測、**未提交 Kaggle**。

實驗 2(通用批次管線,原始 OOF 分數在實驗 1、2 中最低者)之 `postprocess` 欄位未記錄任何後處理步驟,故此欄寫「無後處理紀錄」。其 `submission` 檔名為

`sub_generic_1.35441_20260703_115739.csv` (來源: `experiments[1].submission`),對應 `id_column = id`、`target_column = Age`,但此筆**並未提交至 Kaggle 排行榜**(`facts.json` 中該實驗無 `leaderboard` 欄位)。

實際提交排行榜者為實驗 1,其 `postprocess` 記錄為 `["round"]` (即對預測值四捨五入,因目標 Age 為整數),`submission` 檔名為 `sub_blend_20260703_091840.csv` (來源: `experiments[0].submission`),同樣對應 `id_column = id`、`target_column = Age`。此筆之排行榜結果見節 6。實驗 3、4(Phase B 迭代)之 `submission` 欄位在 `facts.json` 中亦無紀錄(見第 3 節,兩輪皆未通過「取整分數需改善」的採納門檻,故未產生正式提交檔)。

## 6. 評估指標

**指標定義:**MAE(Mean Absolute Error)= 預測值與真實值絕對差的平均,單位與目標欄位相同 (此處為年齡)。

| 項目                                | 分數             | 語意                                                    |
|-----------------------------------|----------------|-------------------------------------------------------|
| 實驗 1 Ensemble(已提交 LB 之線性冠軍)       | 1.35589        | 原始 OOF MAE                                            |
| 實驗 2 Ensemble                     | 1.35441        | 原始 OOF MAE                                            |
| 實驗 3 Ensemble(Phase B round1,未採納) | 1.3385         | 取整後 OOF MAE( <code>experiments[2].score</code> )      |
| 實驗 4 Ensemble(Phase B round2,未採納) | 1.33893        | 取整後 OOF MAE( <code>experiments[3].score</code> )      |
| 實驗 5 樹搜尋 Ensemble(facts.best)     | <b>1.33563</b> | 取整後 OOF MAE( <code>best.score</code> )                |
| 實驗 5 樹搜尋 Ensemble,同一組權重           | 1.35712        | 原始 OOF MAE( <code>best.ensemble.score</code> ,劣於實驗 1) |
| Public LB(實驗 1 之提交,本場官方結果)        | 1.34356        | 取整後(提交檔已四捨五入)                                         |
| Private LB(實驗 1 之提交,本場官方結果)       | 1.34075        | 取整後(提交檔已四捨五入)                                         |

(來源: `experiments[].ensemble.score` 、 `experiments[].score` 、 `facts.leaderboard` 。  
`facts.leaderboard` 對應的是實驗 1 的提交結果,而非 `facts.best` 指向的實驗 5——因為只有 實驗 1 實際提交過排行榜,實驗 5(樹搜尋)為 OOF-only、未提交。)

**CV↔LB gap**(僅實驗 1 有排行榜可比較,差值以內嵌算式呈現;實驗 1 的 1.35589 為其原始 OOF, LB 分數則是對應提交檔取整後的官方結果,兩者本非同一把尺,此處僅依循原報告既有比較方式):

實驗 1 原始 OOF MAE - Public LB = 1.35589 - 1.34356 = 0.01233  
 實驗 1 原始 OOF MAE - Private LB = 1.35589 - 1.34075 = 0.01514

OOF 分數略高於(即劣於)Public/Private LB,顯示交叉驗證分數並未過度樂觀高估模型表現,LB 分數反而比 OOF 更好,CV 具參考價值,可安心依 OOF 排序後續實驗。

**樹搜尋(實驗 5)相對已提交線性冠軍(實驗 1)之取整後 MAE 改善,以及同一節點原始 OOF 之劣化(見第 3a 節「反轉」現象),以內嵌算式呈現:**

實驗5取整後 - 實驗1取整後(1.33812,未記入實驗1結構化欄位,取自 `experiments[2/3/4].notes` 文字紀錄,此處僅供敘述脈絡):  
 1.33563 - 1.33812 = -0.00249 (改善)

實驗5原始00F – 實驗1原始00F：

1.35712 – 1.35589 = 0.00123 (劣化,方向與上面相反)

本場排行榜結果仍以實驗 1 的 **Public 1.34356 / Private 1.34075** 為官方唯一提交紀錄;實驗 5 的 1.33563 是未提交的 OOF-only 樹搜尋發現,兩者不可混為一談。

## 7. 實驗軌跡

| experiment_id | timestamp           | score   | source_format |
|---------------|---------------------|---------|---------------|
| 1             | 2026-07-03T09:18:40 | 1.35589 | skill_train   |
| 2             | 2026-07-03T11:57:39 | 1.35441 | generic_batch |
| 3             | 2026-07-03T22:56:33 | 1.3385  | v2            |
| 4             | 2026-07-03T22:58:34 | 1.33893 | v2            |
| 5             | 2026-07-04T11:59:43 | 1.33563 | v2            |

(來源：`facts.trajectory`；注意實驗 1、2 之 score 為原始 OOF MAE,實驗 3–5 之 score 為取整後 OOF MAE,兩者非同一把尺,見第 3 節開頭澄清。)

**突破點 1(exp 1→2):**第 2 筆實驗(`generic_batch`,通用批次管線)的原始 OOF 分數(1.35441)低於第 1 筆(`skill_train`,含特徵工程,1.35589)。第 2 筆僅使用原始 8 個欄位、未套用第 1 筆的 24 個工程特徵,但集成權重不同(LGB 0.3 / XGB 0.2 / CAT 0.5,相較第 1 筆之 LGB 0.6 / XGB 0.3 / CAT 0.1 更偏重 CatBoost),使內部原始 OOF 分數略優於第 1 筆。惟此結果 僅為原始 OOF 內部比較,第 2 筆並未提交 Kaggle 排行榜驗證,無法確認其是否真的更能泛化(見節 5)。

**Phase B 自我改進迭代(exp 3、4,先前執行但未重產報告,本次補上):**兩輪皆針對 LightGBM 做 Optuna 調參(exp 3:fold0-proxy,21/50 trials,300s timeout 觸發;exp 4:加碼 seed=2024 的 seed bagging),依驗證過的配方將調參版加入池而非取代原成員。兩輪的**原始** OOF MAE 皆單調進步(1.35589 → 1.35541 → 1.35533),但**取整後** OOF MAE 皆退步(1.33812 → 1.3385 → 1.33893,退步幅度取自 `experiments[2,3].notes`)——連續 2 輪取整分數未改善,依協定於 exp 4 後停止線性迭代。此為 `knowledge/experience.md` 記載的「取整整數目標」邊界條件之直接證據:調參+seed-bagging 帶來的原始增益太小,無法在取整步驟中倖存。

**突破點 2(exp 4→5,本次更新新增,facts.best):**實驗 5 不是線性迭代的延續回合,而是 Phase E-3(2026-07-04)以 harness v2 對「取整整數 MAE」做的酸性測試——來源 `experiments_tree.json` 的 node #15(27 節點總計,24 已評估,3 個失敗但無害,wall 1409.4s)。此節點的**原始** OOF MAE(1.35712)延續 exp3/4 的退步趨勢、比實驗 1 的 1.35589 更差,但其**取整後** OOF MAE(1.33563)首次真正**優於**實驗 1 的取整後 1.33812(見第 3a、6 節之反轉現象與內嵌算式)。**誠實 CV-only 警語:**此

結果為 OOF-only 搜尋 產物——tree\_search harness 未產生任何 test 預測檔,facts.json 本筆亦無 submission 欄位,未提交至 Kaggle;本場排行榜官方結果仍是實驗 1 的 Public 1.34356 / Private 1.34075,不可與此樹搜尋發現混淆。完整節點鏈、8-way blend 組成、與各 lineage 的誠實 歸因見 `competitions/playground-series-s3e16/STATUS.md` 〈Appendix — Tree-search v2 (Phase E-3, harness\_v2, 2026-07-04)〉。

`facts.unparsed` 為空陣列,無法解析之紀錄:無。

## 8. 重現指令

---

```
cd /home/tjyen/ai_agents/kaggle

# 實驗 1:手刻管線(EDA → 特徵工程 → 訓練/CV/集成)
uv run python3 competitions/playground-series-s3e16/scripts/eda.py
uv run python3 competitions/playground-series-s3e16/scripts/train.py

# 實驗 2:通用批次管線
uv run python3 competitions/run_competition.py playground-series-s3e16

# Phase B round 1(實驗 3:Optuna fold0-proxy 調參 LGB,未採納)
uv run python3 competitions/playground-series-s3e16/scripts/tune_lgb_optuna.py
uv run python3 competitions/playground-series-s3e16/scripts/round1.py

# Phase B round 2(實驗 4:seed-bagged 調參 LGB,未採納)
uv run python3 competitions/playground-series-s3e16/scripts/round2.py

# Phase E-3 樹搜尋 v2(實驗 5,本場目前 facts.best;可中斷/續跑;樹狀態存
# experiments_tree.json;OOF-only,不產生 test 預測)
uv run python3 tree_search/run_s3e16_v2.py

# 提交至 Kaggle(需先設定有效的 KAGGLE_API_TOKEN)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e16 -f <submission.csv> -m
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle` ;所有 Python 執行皆透過 `uv run` 以確保套件環境一致。