

競賽分析報告:playground-series-s3e16

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-04(Phase G-1a 樹搜尋成果入帳後更新;本次同時補上先前 未重產報告的 Phase B 迭代 exp 3、4,詳見第 3、6、7 節)

1. 競賽目的

What:本場競賽要求依螃蟹的物理量測值(長度、直徑、高度、整體重量與各部位重量等)預測其 年齡 (Age)。這是一個以連續數值輸出年齡估計的迴歸問題。

Why:評估指標為 **MAE(平均絕對誤差,minimize)**。年齡標籤為正整數且分布右偏(多數個體 年齡集中在較低區間、少數個體年齡偏高),MAE 以「絕對誤差的平均」衡量預測誤差,相較平方誤差 類指標對少數高齡離群樣本更穩健,不會讓少數極端樣本主導損失,因此是此類偏態計數型目標的合理 選擇。

項目	值
競賽	playground-series-s3e16
問題型別	regression
評估指標	mae(minimize)
目標欄位	Age

2. 資料規格

- 訓練集 74,051 列、測試集 49,368 列;共 8 個原始欄位(1 個類別型 Sex ,其餘 7 個為連續型的 尺寸/重量量測值)加上目標欄位 Age (來源: competition.notes)。
- 特別規則:不可使用外部資料、不可使用預訓練模型、不可存取網路;每日提交上限 5 次(來源: competition.special_rules)。
- 實驗 1(skill_train 手刻管線)在原始 8 欄位基礎上,經特徵工程展開為 24 個特徵(來源: experiments[0].n_features 、 experiments[0].features),包含 Sex one-hot 展開、 is_infant 旗標、各部位重量佔比、 weight_resid 、體積/密度衍生量等(欄位清單詳 facts.json 之 experiments[0].features)。
- 實驗 2(generic_batch 通用批次管線)僅使用原始 8 個欄位,未套用上述特徵工程(來源: experiments[1].n_features)。

3. 模型規格

本場現有 5 筆實驗紀錄。**重要語意澄清(本節通篇適用):**實驗 1、2 的 score 欄位是「原始 (未取整)OOF MAE」(source_format 分別為 skill_train / generic_batch , collect.py 正規化時 直接取用未取整的

blend OOF 值);實驗 3、4、5 的 `score` 欄位則是**取整後(rounded)OOF MAE**——因目標 `Age` 為整數,取整後 MAE 才是本場實際決策指標(見 STATUS.md 記載,取整前後 分數會反向移動,細節見實驗 5 說明)。

`facts.best` 純以數字最小值選出,不區分這兩種語意,故其挑中的實驗未必是「同一把尺」下最佳者——本節下方逐筆說明,不混淆。

實驗 1(`skill_train` ,含特徵工程)— base models:

Model	OOF MAE	time_s
LGB	1.35651	30.8
XGB	1.35763	36.7
CAT	1.36162	23.7

Ensemble 權重(來源: `experiments[0].ensemble.weights`):LGB 0.6 / XGB 0.3 / CAT 0.1, Ensemble 分數(來源: `experiments[0].ensemble.score`):**1.35589**。

實驗 2(`generic_batch` ,通用批次管線)— base models:

Model	OOF MAE
LGB	1.3623
XGB	1.35886
CAT	1.35714

Ensemble 權重(來源: `experiments[1].ensemble.weights`):LGB 0.3 / XGB 0.2 / CAT 0.5, Ensemble 分數(來源: `experiments[1].ensemble.score`):**1.35441**(原始 OOF MAE,未取整)。

選型理由(實驗 1、2):三個梯度提升樹模型(LightGBM、XGBoost、CatBoost)在表格型資料上 普遍穩健,各自的歸納偏誤不同,故以加權集成降低單一模型的方差。實驗 1 額外投入特徵工程(24 個特徵)並針對 MAE 目標調整訓練細節;實驗 2 為通用批次管線的預設跑法,未套用上述特徵工程但 集成權重不同,結果原始 OOF 分數反而略低——惟此結果僅為內部原始 OOF 比較,實驗 2 並未提交至 Kaggle 排行榜驗證(見節 5、6)。

實驗 3(Phase B round 1,加入 Optuna fold0-proxy 調參 LGB 為第 4 個池成員)— base models:

Model	OOF MAE
LGB	1.35651
XGB	1.35763
CAT	1.36162
LGB_tuned	1.35583

Ensemble 權重(來源: `experiments[2].ensemble.weights`):LGB 0.3 / XGB 0.1 / CAT 0.1 / LGB_tuned 0.5, 原始 Ensemble 分數(來源: `experiments[2].ensemble.score`):**1.35541**(較實驗 1 的 1.35589 略有改善)。但 `experiments[2].score` (取整後 OOF MAE)= **1.3385**, 劣於當時既有最佳(實驗 1 取整後 1.33812,未記入結構化欄位,見 STATUS.md)——原始分數 進步、取整分數退步,未被採納。

實驗 4(Phase B round 2,加入 seed=2024 之調參 LGB 為第 5 個池成員)— base models:

Model	OOF MAE
LGB	1.35651
XGB	1.35763
CAT	1.36162
LGB_tuned	1.35583
LGB_tuned_seed2024	1.35604

Ensemble 權重(來源: experiments[3].ensemble.weights):LGB 0.2 / XGB 0.1 / CAT 0.1 / LGB_tuned 0.4 / LGB_tuned_seed2024 0.2,原始 Ensemble 分數(來源: experiments[3].ensemble.score):**1.35533**(本場原始 OOF 最佳)。但 experiments[3].score (取整後)= **1.33893**,同樣劣於實驗 1 的取整後 1.33812——連續兩輪 取整分數未改善,依 Phase B 停止準則(連 2 輪無改善即停)於此輪後停止線性迭代。

實驗 5(Phase E-3 樹搜尋, facts.best):見 3a 節。

3a. 樹搜尋最佳(best, experiment_id=5)——本次更新新增

Phase E-3(harness v2 於「取整整數 MAE」上的酸性測試,2026-07-04)在 experiments_tree.json 的 node #15 找到本場目前最佳**取整後**OOF MAE:8-way blend(來源: best.base_models):

成員	權重	solo 取整後 MAE	備註
LGB(root)	0.0198	1.33885	—
XGB	0.0256	1.3416	—
CAT	0.5061	1.33846	主導權重
LGB_tuned	0.0075	1.33979	—
LGB_tuned_seed2024	0.0626	1.33914	—
LGBBOUND	0.1117	1.3395	邊界推進 LGB,learning_rate=0.005
TWEEDIE	0.0004	1.37467	權重近乎歸零,但加入時貢獻本次搜尋單筆最大增益
FEATPRUNE	0.2662	1.34025	去除與 Weight 高度共線(r=0.993)之欄位;新成員中權重最高,催生全域最佳節點

Ensemble(best.ensemble):method = "harness_v2 dirichlet(k=800)+coordinate-ascent weight search, decided directly on ROUNDED MAE",取整後 score = **1.33563** (best.score);同一組權重的原始(未取整)OOF MAE = **1.35712**(best.ensemble.score) ——比實驗 1 的原始 1.35589 更差。

選型理由/來源說明(best.notes):這是本場「原始 vs 取整」語意反轉的最強例證——本節點 原始 OOF MAE(1.35712)劣於已提交的線性冠軍(實驗 1,原始 1.35589),但**取整後** OOF MAE (1.33563)優於線性冠軍的取整後 1.33812(改善 -0.00249)。此為實驗 3/4 失敗模式的鏡像 (那裡:原始進步、取整退步;這裡:原始退步、取整進步)——合起來是「決策必須依取整分數、不能依原始 OOF」這條規則最完整的正反雙向證據。完整節點鏈、backtrack/dedup 統計、與各 lineage 的誠實歸因見 competitions/playground-series-s3e16/STATUS.md 〈Appendix — Tree-search v2(Phase E-3,harness_v2,2026-07-04)〉。

重要澄清:best.notes 明確記載這是 **OOF-only 搜尋結果——未產生任何 test 預測,亦 未提交至 Kaggle**(facts.json 本筆無 submission 欄位)。此結果**不可與已提交的 LB 分數 混淆——本場官方**排行榜結果仍是實驗 1 的 Public 1.34356 / Private 1.34075(見第 5、6 節),facts.best 挑中實驗 5 純粹是「取整後 OOF MAE 數字最小」,與是否已提交至 Kaggle 無關。

4. 訓練規格

實驗	CV scheme	n_splits	seed
1	5fold_stratified_agebin	5	無紀錄
2	5fold	5	無紀錄
3	5fold_stratified_agebin	5	42
4	5fold_stratified_agebin	5	42
5(best,樹搜尋)	5fold_stratified_agebin	5	42

(來源: experiments[].cv ;實驗 1、2 之 cv 未記錄 seed 欄位,故寫「無紀錄」;實驗 3-5 皆為 5fold_stratified_agebin (n_splits=5, seed=42)同一組固定折,樹搜尋(實驗 5)沿用與 Phase B 迭代完全相同的 CV。)

各 base model 之 objective/超參數在 experiments[].base_models[] 中未記錄對應欄位,故此項亦為「無紀錄」(實驗 3 之 Optuna 超參僅記於 experiments[2].notes 文字說明:fold-0-proxy、21/50 trials、300s timeout,依 Hard Rule 1 不作為表格數字引用)。

為何用此 CV:年齡標籤為右偏的整數計數型目標,若採用一般隨機 K-fold 切分,高齡樣本較少,可能造成各 fold 之目標分布不均、驗證分數不穩定。實驗 1 因此改用「依年齡分箱後分層抽樣」的 StratifiedKFold(將高齡樣本合併為單一分箱以避免箱內樣本過少),使各 fold 的年齡分布更一致,讓交叉驗證分數更能反映模型的真實泛化能力。

5. 推論程序

facts.best (實驗 5,樹搜尋)之 postprocess (來源: best.postprocess): ["round"] (對取整後 MAE 做決策,見第 3a 節)。**Submission 檔名(best.submission):無紀錄——實驗 5 是樹搜尋(OOF-only)結果,facts.json 本筆未附 submission 欄位,未產生 test 預測、未提交 Kaggle。**

實驗 2(通用批次管線,原始 OOF 分數在實驗 1、2 中最低者)之 postprocess 欄位未記錄任何後處理步驟,故此欄寫「無後處理紀錄」。其 submission 檔名為 sub_generic_1.35441_20260703_115739.csv (來源: experiments[1].submission),對應 id_column = id、target_column = Age,但此筆**並未提交至 Kaggle 排行榜**(facts.json 中該實驗無 leaderboard 欄位)。

實際提交排行榜者為實驗 1,其 postprocess 記錄為 ["round"] (即對預測值四捨五入,因目標 Age 為整數),submission 檔名為 sub_blend_20260703_091840.csv (來源: experiments[0].submission),同樣對應 id_column = id、target_column = Age。此筆之排行榜結果見節 6。實驗 3、4(Phase B 迭代)之

submission 欄位在 facts.json 中亦無紀錄(見第 3 節,兩輪皆未通過「取整分數需改善」的採納門檻,故未產生正式提交檔)。

6. 評估指標

指標定義:MAE(Mean Absolute Error)= 預測值與真實值絕對差的平均,單位與目標欄位相同 (此處為年齡)。

項目	分數	語意
實驗 1 Ensemble(已提交 LB 之線性冠軍)	1.35589	原始 OOF MAE
實驗 2 Ensemble	1.35441	原始 OOF MAE
實驗 3 Ensemble(Phase B round1,未採納)	1.3385	取整後 OOF MAE(experiments[2].score)
實驗 4 Ensemble(Phase B round2,未採納)	1.33893	取整後 OOF MAE(experiments[3].score)
實驗 5 樹搜尋 Ensemble(facts.best)	1.33563	取整後 OOF MAE(best.score)
實驗 5 樹搜尋 Ensemble,同一組權重	1.35712	原始 OOF MAE(best.ensemble.score ,劣於實驗 1)
Public LB(實驗 1 之提交,本場官方結果)	1.34356	取整後(提交檔已四捨五入)
Private LB(實驗 1 之提交,本場官方結果)	1.34075	取整後(提交檔已四捨五入)

(來源: experiments[].ensemble.score 、 experiments[].score 、 facts.leaderboard 。 facts.leaderboard 對應的是實驗 1 的提交結果,而非 facts.best 指向的實驗 5——因為只有 實驗 1 實際提交過排行榜,實驗 5(樹搜尋)為 OOF-only、未提交。)

CV↔LB gap(僅實驗 1 有排行榜可比較,差值以內嵌算式呈現;實驗 1 的 1.35589 為其原始 OOF, LB 分數則是對應提交檔取整後的官方結果,兩者本非同一把尺,此處僅依循原報告既有比較方式):

實驗 1 原始 OOF MAE – Public LB = 1.35589 – 1.34356 = 0.01233
實驗 1 原始 OOF MAE – Private LB = 1.35589 – 1.34075 = 0.01514

OOF 分數略高於(即劣於)Public/Private LB,顯示交叉驗證分數並未過度樂觀高估模型表現,LB 分數 反而比 OOF 更好,CV 具參考價值,可安心依 OOF 排序後續實驗。

樹搜尋(實驗 5)相對已提交線性冠軍(實驗 1)之取整後 MAE 改善,以及同一節點原始 OOF 之 劣化(見第 3a 節「反轉」現象),以內嵌算式呈現:

實驗5取整後 – 實驗1取整後(1.33812, 未記入實驗1結構化欄位,取自 experiments[2/3/4].notes 文字紀錄,此處僅供敘述脈絡):
1.33563 – 1.33812 = -0.00249 (改善)
實驗5原始OOF – 實驗1原始OOF:
1.35712 – 1.35589 = 0.00123 (劣化,方向與上面相反)

本場排行榜結果仍以實驗 1 的 Public 1.34356 / Private 1.34075 為官方唯一提交紀錄;實驗 5 的 1.33563 是未提交的 OOF-only 樹搜尋發現,兩者不可混為一談。

7. 實驗軌跡

experiment_id	timestamp	score	source_format
1	2026-07-03T09:18:40	1.35589	skill_train
2	2026-07-03T11:57:39	1.35441	generic_batch
3	2026-07-03T22:56:33	1.3385	v2
4	2026-07-03T22:58:34	1.33893	v2
5	2026-07-04T11:59:43	1.33563	v2

(來源：`facts.trajectory`；注意實驗 1、2 之 score 為原始 OOF MAE,實驗 3–5 之 score 為取整後 OOF MAE,兩者非同一把尺,見第 3 節開頭澄清。)

突破點 1(exp 1→2):第 2 筆實驗(`generic_batch`,通用批次管線)的原始 OOF 分數 (1.35441)低於第 1 筆 (`skill_train`,含特徵工程,1.35589)。第 2 筆僅使用原始 8 個欄位、未套用第 1 筆的 24 個工程特徵,但集成權重不同(LGB 0.3 / XGB 0.2 / CAT 0.5,相較第 1 筆之 LGB 0.6 / XGB 0.3 / CAT 0.1 更偏重 CatBoost),使內部原始 OOF 分數略優於第 1 筆。惟此結果 僅為原始 OOF 內部比較,第 2 筆並未提交 Kaggle 排行榜驗證,無法確認其是否真的更能泛化 (見節 5)。

Phase B 自我改進迭代(exp 3、4,先前執行但未重產報告,本次補上):兩輪皆針對 LightGBM 做 Optuna 調參 (exp 3:fold0-proxy,21/50 trials,300s timeout 觸發;exp 4:加碼 seed=2024 的 seed bagging),依驗證過的配方將調參版加入池而非取代原成員。兩輪的**原始** OOF MAE 皆 單調進步(1.35589 → 1.35541 → 1.35533),但**取整後** OOF MAE 皆退步(1.33812 → 1.3385 → 1.33893,退步幅度取自 `experiments[2,3].notes`)——連續 2 輪取整分數未改善,依 協定於 exp 4 後停止線性迭代。此為 `knowledge/experience.md` 記載的「取整整數目標」邊界條件 之直接證據:調參+seed-bagging 帶來的原始增益太小,無法在取整步驟中倖存。

突破點 2(exp 4→5,本次更新新增,facts.best):實驗 5 不是線性迭代的延續回合,而是 Phase E-3(2026-07-04)以 harness v2 對「取整整數 MAE」做的酸性測試——來源 `experiments_tree.json` 的 node #15(27 節點總計,24 已評估,3 個失敗但無害,wall 1409.4s)。此節點的**原始** OOF MAE(1.35712)延續 exp3/4 的退步趨勢、比實驗 1 的 1.35589 更差,但其**取整後** OOF MAE(1.33563)首次真正**優於**實驗 1 的取整後 1.33812 (見第 3a、6 節之反轉現象與內嵌算式)。**誠實 CV-only 警語:**此結果為 OOF-only 搜尋 產物——`tree_search harness` 未產生任何 test 預測檔,facts.json 本筆亦無 submission 欄位,**未提交至 Kaggle**;本場排行榜官方結果仍是實驗 1 的 Public 1.34356 / Private 1.34075,不可與此樹搜尋發現混淆。完整節點鏈、8-way blend 組成、與各 lineage 的誠實 歸因見 `competitions/playground-series-s3e16/STATUS.md` 〈Appendix — Tree-search v2 (Phase E-3, harness_v2, 2026-07-04)〉。

`facts.unparsed` 為空陣列,無法解析之紀錄:無。

8. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 實驗 1:手刻管線(EDA → 特徵工程 → 訓練/CV/集成)
uv run python3 competitions/playground-series-s3e16/scripts/eda.py
uv run python3 competitions/playground-series-s3e16/scripts/train.py

# 實驗 2:通用批次管線
uv run python3 competitions/run_competition.py playground-series-s3e16

# Phase B round 1(實驗 3:Optuna fold0-proxy 調參 LGB,未採納)
uv run python3 competitions/playground-series-s3e16/scripts/tune_lgb_optuna.py
uv run python3 competitions/playground-series-s3e16/scripts/round1.py

# Phase B round 2(實驗 4:seed-bagged 調參 LGB,未採納)
uv run python3 competitions/playground-series-s3e16/scripts/round2.py

# Phase E-3 樹搜尋 v2(實驗 5,本場目前 facts.best;可中斷/續跑;樹狀態存
# experiments_tree.json;00F-only,不產生 test 預測)
uv run python3 tree_search/run_s3e16_v2.py

# 提交至 Kaggle(需先設定有效的 KAGGLE_API_TOKEN)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e16 -f <submission.csv> -m "<msg>
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle` ;所有 Python 執行皆透過 `uv run` 以確保套件環境一致。