

競賽分析報告:playground-series-s3e16

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-06(真實 Kaggle LB 驗證入帳後更新;實驗 5 樹搜尋 最佳 blend 已提交排行榜,取得 Public 1.34315 / Private 1.33859,詳見第 2.2a、2.4、2.5、3 節。 先前 2026-07-04 版本涵蓋 Phase G-1a 樹搜尋成果入帳、Phase B 迭代 exp 3、4 補記)

1. 競賽目的

What:本場競賽要求依螃蟹的物理量測值(長度、直徑、高度、整體重量與各部位重量等)預測其 年齡 (Age)。這是一個以連續數值輸出年齡估計的迴歸問題。

Why:評估指標為 **MAE(平均絕對誤差,minimize)**。年齡標籤為正整數且分布右偏(多數個體 年齡集中在較低區間、少數個體年齡偏高),MAE 以「絕對誤差的平均」衡量預測誤差,相較平方誤差 類指標對少數高齡離群樣本更穩健,不會讓少數極端樣本主導損失,因此是此類偏態計數型目標的合理 選擇。

項目	值
競賽	playground-series-s3e16
問題型別	regression
評估指標	mae(minimize)
目標欄位	Age

2. 流程(how):五大元件

2.1 資料規格

- 訓練集 74,051 列、測試集 49,368 列;共 8 個原始欄位(1 個類別型 Sex ,其餘 7 個為連續型的 尺寸/重量量測值)加上目標欄位 Age (來源: competition.notes)。
- 特別規則:不可使用外部資料、不可使用預訓練模型、不可存取網路;每日提交上限 5 次(來源: competition.special_rules)。
- 實驗 1(skill_train 手刻管線)在原始 8 欄位基礎上,經特徵工程展開為 24 個特徵(來源: experiments[0].n_features 、 experiments[0].features),包含 Sex one-hot 展開、is_infant 旗標、各部位重量佔比、 weight_resid 、體積/密度衍生量等(欄位清單詳 facts.json 之 experiments[0].features)。
- 實驗 2(generic_batch 通用批次管線)僅使用原始 8 個欄位,未套用上述特徵工程(來源: experiments[1].n_features)。

2.2 模型規格

本場現有 5 筆實驗紀錄。**重要語意澄清(本節通篇適用)**:實驗 1、2 的 `score` 欄位是「原始 (未取整) OOF MAE」(`source_format` 分別為 `skill_train / generic_batch, collect.py` 正規化時 直接取用未取整的 `blend OOF` 值);實驗 3、4、5 的 `score` 欄位則是**取整後(rounded) OOF MAE**——因目標 `Age` 為整數,取整後 MAE 才是本場實際決策指標(見 `STATUS.md` 記載,取整前後 分數會反向移動,細節見實驗 5 說明)。
`facts.best` 純以數字最小值選出,不區分這兩種語意,故其挑中的實驗未必是「同一把尺」下最佳者——本節下方逐筆說明,不混淆。

實驗 1(`skill_train` ,含特徵工程)— base models:

Model	OOF MAE	time_s
LGB	1.35651	30.8
XGB	1.35763	36.7
CAT	1.36162	23.7

Ensemble 權重(來源: `experiments[0].ensemble.weights`):LGB 0.6 / XGB 0.3 / CAT 0.1, Ensemble 分數(來源: `experiments[0].ensemble.score`):**1.35589**。

實驗 2(`generic_batch` ,通用批次管線)— base models:

Model	OOF MAE
LGB	1.3623
XGB	1.35886
CAT	1.35714

Ensemble 權重(來源: `experiments[1].ensemble.weights`):LGB 0.3 / XGB 0.2 / CAT 0.5, Ensemble 分數(來源: `experiments[1].ensemble.score`):**1.35441**(原始 OOF MAE,未取整)。

選型理由(實驗 1、2):三個梯度提升樹模型(LightGBM、XGBoost、CatBoost)在表格型資料上 普遍穩健,各自的歸納偏誤不同,故以加權集成降低單一模型的方差。實驗 1 額外投入特徵工程(24 個特徵)並針對 MAE 目標調整訓練細節;實驗 2 為通用批次管線的預設跑法,未套用上述特徵工程但 集成權重不同,結果原始 OOF 分數反而略低——惟此結果僅為內部原始 OOF 比較,實驗 2 並未提交至 Kaggle 排行榜驗證(見節 2.4、2.5)。

實驗 3(Phase B round 1,加入 Optuna fold0-proxy 調參 LGB 為第 4 個池成員)— base models:

Model	OOF MAE
LGB	1.35651
XGB	1.35763
CAT	1.36162
LGB_tuned	1.35583

Ensemble 權重(來源: `experiments[2].ensemble.weights`):LGB 0.3 / XGB 0.1 / CAT 0.1 / LGB_tuned 0.5, 原始 Ensemble 分數(來源: `experiments[2].ensemble.score`):**1.35541** (較實驗 1 的 1.35589 略有改善)。

但 `experiments[2].score` (取整後 OOF MAE)= **1.3385**, 劣於當時既有最佳(實驗 1 取整後 1.33812,未記入結構化欄位,見 STATUS.md)——原始分數 進步、取整分數退步,未被採納。

實驗 4(Phase B round 2,加入 seed=2024 之調參 LGB 為第 5 個池成員)— base models:

Model	OOF MAE
LGB	1.35651
XGB	1.35763
CAT	1.36162
LGB_tuned	1.35583
LGB_tuned_seed2024	1.35604

Ensemble 權重(來源: `experiments[3].ensemble.weights`):LGB 0.2 / XGB 0.1 / CAT 0.1 / LGB_tuned 0.4 / LGB_tuned_seed2024 0.2,原始 Ensemble 分數(來源: `experiments[3].ensemble.score`):**1.35533**(本場原始 OOF 最佳)。但 `experiments[3].score` (取整後)= **1.33893**,同樣劣於實驗 1 的取整後 1.33812——連續兩輪 取整分數未改善,依 Phase B 停止準則(連 2 輪無改善即停)於此輪後停止線性迭代。

實驗 5(Phase E-3 樹搜尋, facts.best):見 2.2a 節。

2.2a 樹搜尋最佳(best, experiment_id=5)——本次更新新增

Phase E-3(harness v2 於「取整整數 MAE」上的酸性測試,2026-07-04)在 `experiments_tree.json` 的 node #15 找到本場目前最佳**取整後**OOF MAE:8-way blend(來源: `best.base_models`):

成員	權重	solo 取整後 MAE	備註
LGB(root)	0.0198	1.33885	—
XGB	0.0256	1.3416	—
CAT	0.5061	1.33846	主導權重
LGB_tuned	0.0075	1.33979	—
LGB_tuned_seed2024	0.0626	1.33914	—
LGBBOUND	0.1117	1.3395	邊界推進 LGB,learning_rate=0.005
TWEEDIE	0.0004	1.37467	權重近乎歸零,但加入時貢獻本次搜尋單筆最大增益
FEATPRUNE	0.2662	1.34025	去除與 Weight 高度共線(r=0.993)之欄位;新成員中權重最高,催生全域最佳節點

Ensemble(`best.ensemble`):`method = "harness_v2 dirichlet(k=800)+coordinate-ascent weight search, decided directly on ROUNDED MAE"`,取整後 `score = 1.33563` (`best.score`);同一組權重的原始(未取整)OOF MAE = **1.35712**(`best.ensemble.score`) ——比實驗 1 的原始 1.35589 更差。

選型理由/來源說明(`best.notes`):這是本場「原始 vs 取整」語意反轉的最強例證——本節點 原始 OOF MAE(1.35712)劣於已提交的線性冠軍(實驗 1,原始 1.35589),但**取整後** OOF MAE (1.33563)優於線性冠軍的取整後 1.33812(改善 -0.00249)。此為實驗 3/4 失敗模式的鏡像 (那裡:原始進步、取整退步;這裡:原始退步、取整進步)——合起來是「決策必須依取整分數、不能依原始 OOF」這條規則最完整的正反雙向證據。完整節

點鏈、backtrack/dedup 統計、與各 lineage 的誠實歸因見 `competitions/playground-series-s3e16/STATUS.md` 〈Appendix — Tree-search v2(Phase E-3,harness_v2,2026-07-04)〉。

更新(2026-07-06):best.notes 描述的是樹搜尋當下(2026-07-04)的狀態——彼時確為 OOF-only、未提交。此後 `scripts/rebuild_tree_best.py` 重建出 test 預測並實際提交 `Kaggle( best.submission = sub_tree_best_1.33563_20260706_115200.csv )`,取得 `best.leaderboard` :**Public 1.34315 / Private 1.33859**(提交:2026-07-06)。此結果 已是本場兩筆 **真實 LB 提交之一**,與實驗 1 的 Public 1.34356 / Private 1.34075 併陳於 第 2.5 節(含改善算式與 CV↔LB gap 一致性檢查)。

2.3 訓練規格

實驗	CV scheme	n_splits	seed
1	5fold_stratified_agebin	5	無紀錄
2	5fold	5	無紀錄
3	5fold_stratified_agebin	5	42
4	5fold_stratified_agebin	5	42
5(best,樹搜尋)	5fold_stratified_agebin	5	42

(來源: `experiments[].cv` ;實驗 1、2 之 `cv` 未記錄 `seed` 欄位,故寫「無紀錄」;實驗 3–5 皆為 `5fold_stratified_agebin (n_splits=5, seed=42)`同一組固定折,樹搜尋(實驗 5)沿用與 Phase B 迭代完全相同的 CV。)

各 base model 之 objective/超參數在 `experiments[].base_models[]` 中未記錄對應欄位,故此項亦為「無紀錄」(實驗 3 之 Optuna 超參僅記於 `experiments[2].notes` 文字說明:fold-0-proxy、21/50 trials、300s timeout,依 Hard Rule 1 不作為表格數字引用)。

為何用此 CV:年齡標籤為右偏的整數計數型目標,若採用一般隨機 K-fold 切分,高齡樣本較少,可能 造成各 fold 之目標分布不均、驗證分數不穩定。實驗 1 因此改用「依年齡分箱後分層抽樣」的 StratifiedKFold(將高齡樣本合併為單一分箱以避免箱內樣本過少),使各 fold 的年齡分布更一致, 讓交叉驗證分數更能反映模型的真實泛化能力。

2.4 推論程序

`facts.best` (實驗 5,樹搜尋)之 `postprocess` (來源: `best.postprocess`): `["round"]` (對取整後 MAE 做決策,見第 2.2a 節)。**Submission 檔名(best.submission):** `sub_tree_best_1.33563_20260706_115200.csv` ——由 `scripts/rebuild_tree_best.py` 重建 8 個成員的 test 預測、以同一組全精度權重混合後產生(2026-07-06),已提交 Kaggle 排行榜 (`best.leaderboard` ,結果見第 2.5 節)。

實驗 2(通用批次管線,原始 OOF 分數在實驗 1、2 中最低者)之 `postprocess` 欄位未記錄任何後 處理步驟,故此欄寫「無後處理紀錄」。其 submission 檔名為 `sub_generic_1.35441_20260703_115739.csv` (來

源: experiments[1].submission),對應 id_column = id 、 target_column = Age ,但此筆並未提交至 Kaggle 排行榜(facts.json 中該實驗無 leaderboard 欄位)。

實際提交排行榜者為實驗 1,其 postprocess 記錄為 ["round"] (即對預測值四捨五入,因目標 Age 為整數),submission 檔名為 sub_blend_20260703_091840.csv (來源: experiments[0].submission),同樣對應 id_column = id 、 target_column = Age 。此筆之排行榜 結果見節 2.5 。實驗 3 、 4(Phase B 迭代)之 submission 欄位在 facts.json 中亦無紀錄(見第 2.2 節,兩輪皆未通過「取整分數需改善」的採納門檻,故未產生正式提交檔)。

2.5 評估指標

指標定義:MAE(Mean Absolute Error)= 預測值與真實值絕對差的平均,單位與目標欄位相同 (此處為年齡)。

項目	分數	語意
實驗 1 Ensemble(2026-07-03 提交#1,線性冠軍)	1.35589	原始 OOF MAE
實驗 2 Ensemble	1.35441	原始 OOF MAE
實驗 3 Ensemble(Phase B round1,未採納)	1.3385	取整後 OOF MAE(experiments[2].score)
實驗 4 Ensemble(Phase B round2,未採納)	1.33893	取整後 OOF MAE(experiments[3].score)
實驗 5 樹搜尋 Ensemble(facts.best,2026-07-06 提交#2)	1.33563	取整後 OOF MAE(best.score)
實驗 5 樹搜尋 Ensemble,同一組權重	1.35712	原始 OOF MAE(best.ensemble.score ,劣於實驗 1)
Public LB — 提交#1(實驗 1,2026-07-03)	1.34356	取整後(提交檔已四捨五入)
Private LB — 提交#1(實驗 1,2026-07-03)	1.34075	取整後(提交檔已四捨五入)
Public LB — 提交#2(實驗 5 樹搜尋最佳,2026-07-06)	1.34315	取整後(提交檔已四捨五入)
Private LB — 提交#2(實驗 5 樹搜尋最佳,2026-07-06)	1.33859	取整後(提交檔已四捨五入)

(來源: experiments[].ensemble.score 、 experiments[].score 、 experiments[0].leaderboard 、 experiments[4].leaderboard 。本場現有兩筆真實 Kaggle 提交:實驗 1(2026-07-03)與 實驗 5(2026-07-06); facts.leaderboard (collect.py 規則:取最後一筆帶 leaderboard 欄位的實驗)現指向較新的實驗 5。)

CV↔LB gap(提交#1,實驗 1,差值以內嵌算式呈現;實驗 1 的 1.35589 為其原始 OOF, LB 分數則是對應提交檔取整後的官方結果,兩者本非同一把尺,此處僅依循原報告既有比較方式):

實驗 1 原始 OOF MAE – Public LB = 1.35589 – 1.34356 = 0.01233
實驗 1 原始 OOF MAE – Private LB = 1.35589 – 1.34075 = 0.01514

OOF 分數略高於(即劣於)Public/Private LB,顯示交叉驗證分數並未過度樂觀高估模型表現,LB 分數 反而比 OOF 更好,CV 具參考價值,可安心依 OOF 排序後續實驗。

樹搜尋(實驗 5)相對已提交線性冠軍(實驗 1)之取整後 MAE 改善,以及同一節點原始 OOF 之 劣化(見第 2.2a 節「反轉」現象),以內嵌算式呈現:

實驗5取整後 - 實驗1取整後(1.33812, 未記入實驗1結構化欄位, 取自 experiments[2/3/4].notes 文字紀錄, 此處僅供敘述脈絡):

$$1.33563 - 1.33812 = -0.00249 \quad (\text{改善})$$

實驗5原始00F - 實驗1原始00F:

$$1.35712 - 1.35589 = 0.00123 \quad (\text{劣化, 方向與上面相反})$$

雙 LB 錨點改善(提交#2 相對提交#1, 以內嵌算式呈現):

$$\text{Public 改善: 提交\#1(1.34356) - 提交\#2(1.34315) = 0.00041}$$

$$\text{Private 改善: 提交\#1(1.34075) - 提交\#2(1.33859) = 0.00216}$$

兩個榜(Public、Private)皆改善(MAE 降低), 且改善方向一致——樹搜尋在 OOF 上發現的取整後增益, 此次首度獲得真實 LB 的雙榜獨立驗證, 不再只是 OOF-only 的內部比較。

CV↔LB gap 一致性檢查(提交#2, 實驗 5 樹搜尋最佳, 取整後 OOF vs 真實 LB, 以內嵌算式呈現):

$$\text{Public LB - 實驗5取整後00F} = 1.34315 - 1.33563 = 0.00752$$

$$\text{Private LB - 實驗5取整後00F} = 1.33859 - 1.33563 = 0.00296$$

對照提交#1(實驗1, 取整後00F 1.33812, 未記入實驗1結構化欄位, 取自 experiments[2/3/4].notes 文字紀錄, 此處僅供敘述脈絡):

$$\text{Public LB - 實驗1取整後00F} = 1.34356 - 1.33812 = 0.00544$$

$$\text{Private LB - 實驗1取整後00F} = 1.34075 - 1.33812 = 0.00263$$

兩筆提交的 Public/Private gap(見上方算式)皆為正值、同一數量級, 即真實 LB 分數略劣於(數字略高於)取整後 OOF——同一方向、同一量級的差距在兩次獨立提交間穩定重現, 顯示取整後 OOF MAE 對這個決策指標而言是可信賴的排序依據, 未見對 Public LB 過擬合的跡象。**本場排行榜結果現有兩筆真實提交紀錄:**實驗 1 的 Public 1.34356 / Private 1.34075 (2026-07-03), 以及實驗 5 樹搜尋最佳的 Public 1.34315 / Private 1.33859(2026-07-06, 雙榜皆優於提交#1)。

3. 實驗軌跡

experiment_id	timestamp	score	source_format
1	2026-07-03T09:18:40	1.35589	skill_train
2	2026-07-03T11:57:39	1.35441	generic_batch
3	2026-07-03T22:56:33	1.3385	v2
4	2026-07-03T22:58:34	1.33893	v2
5	2026-07-04T11:59:43	1.33563	v2

(來源: `facts.trajectory` ; 注意實驗 1、2 之 score 為原始 OOF MAE,實驗 3–5 之 score 為 取整後 OOF MAE,兩者非同一把尺,見第 2.2 節開頭澄清。)

突破點 1(exp 1→2):第 2 筆實驗(`generic_batch`,通用批次管線)的原始 OOF 分數 (1.35441)低於第 1 筆 (`skill_train`,含特徵工程,1.35589)。第 2 筆僅使用原始 8 個欄位、未套用第 1 筆的 24 個工程特徵,但集成權重不同(LGB 0.3 / XGB 0.2 / CAT 0.5,相較第 1 筆之 LGB 0.6 / XGB 0.3 / CAT 0.1 更偏重 CatBoost),使內部原始 OOF 分數略優於第 1 筆。惟此結果 僅為原始 OOF 內部比較,第 2 筆並未提交 Kaggle 排行榜驗證,無法確認其是否真的更能泛化 (見節 2.4)。

Phase B 自我改進迭代(exp 3、4,先前執行但未重產報告,本次補上):兩輪皆針對 LightGBM 做 Optuna 調參 (exp 3:fold0-proxy,21/50 trials,300s timeout 觸發;exp 4:加碼 seed=2024 的 seed bagging),依驗證過的配方將調參版加入池而非取代原成員。兩輪的**原始** OOF MAE 皆 單調進步(1.35589 → 1.35541 → 1.35533),但**取整後** OOF MAE 皆退步(1.33812 → 1.3385 → 1.33893,退步幅度取自 `experiments[2,3].notes`)——連續 2 輪取整分數未改善,依 協定於 exp 4 後停止線性迭代。此為 `knowledge/experience.md` 記載的「取整整數目標」邊界條件 之直接證據:調參+seed-bagging 帶來的原始增益太小,無法在取整步驟中倖存。

突破點 2(exp 4→5,本次更新新增,facts.best):實驗 5 不是線性迭代的延續回合,而是 Phase E-3(2026-07-04) 以 harness v2 對「取整整數 MAE」做的酸性測試——來源 `experiments_tree.json` 的 node #15(27 節點總計,24 已評估,3 個失敗但無害,wall 1409.4s)。此節點的**原始** OOF MAE(1.35712)延續 exp3/4 的退步趨勢、比實驗 1 的 1.35589 更差,但其**取整後** OOF MAE(1.33563)首次真正**優於**實驗 1 的取整後 1.33812 (見第 2.2a、2.5 節之反轉現象與內嵌算式)。**更新(2026-07-06,不再是 CV-only):** `scripts/rebuild_tree_best.py` 重建出此節點的 test 預測(8 個成員逐一 gate 驗證,重建 OOF 與快取數字逐位一致,詳見 STATUS.md 〈Rebuild verification〉 節),並實際提交至 Kaggle: `sub_tree_best_1.33563_20260706_115200.csv` (`best.submission`),取得 `best.leaderboard`: **Public 1.34315 / Private 1.33859**(提交:2026-07-06)——雙榜皆 優於實驗 1 的 Public 1.34356 / Private 1.34075(改善算式、CV↔LB gap 一致性檢查見第 2.5 節)。此為這套樹搜尋配方首次獲得的外部(真實排行榜)驗證,而非僅 OOF-only 推論。完整 節點鏈、8-way blend 組成、與各 lineage 的誠實歸因見 `competitions/playground-series-s3e16/STATUS.md` 〈Appendix — Tree-search v2 (Phase E-3, harness_v2, 2026-07-04)〉與 〈Rebuild verification〉 節。

`facts.unparsed` 為空陣列,無法解析之紀錄:無。

4. 重現指令

```
cd /home/tjyen/ai_agents/kaggle
```

```
# 實驗 1:手刻管線(EDA → 特徵工程 → 訓練/CV/集成)
```

```
uv run python3 competitions/playground-series-s3e16/scripts/eda.py
```

```
uv run python3 competitions/playground-series-s3e16/scripts/train.py
```

```
# 實驗 2:通用批次管線
uv run python3 competitions/run_competition.py playground-series-s3e16

# Phase B round 1(實驗 3:Optuna fold0-proxy 調參 LGB,未採納)
uv run python3 competitions/playground-series-s3e16/scripts/tune_lgb_optuna.py
uv run python3 competitions/playground-series-s3e16/scripts/round1.py

# Phase B round 2(實驗 4:seed-bagged 調參 LGB,未採納)
uv run python3 competitions/playground-series-s3e16/scripts/round2.py

# Phase E-3 樹搜尋 v2(實驗 5,本場目前 facts.best;可中斷/續跑;樹狀態存
# experiments_tree.json;00F-only,不產生 test 預測)
uv run python3 tree_search/run_s3e16_v2.py

# 提交至 Kaggle(需先設定有效的 KAGGLE_API_TOKEN)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e16 -f <submission.csv> -m "<msg>
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle` ;所有 Python 執行皆透過 `uv run` 以確保套件環境一致。

