

競賽分析報告:playground-series-s3e16

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-06 本報告所有數字皆出自 facts.json,經 verify_report.py 驗證。

1. 競賽目的

What:依螃蟹的物理量測值(長度、直徑、高度、整體重量與各部位重量等)預測其年齡 (Age),為連續數值輸出的迴歸問題。

Why:評估指標為 **MAE(minimize)**。年齡標籤為正整數且分布右偏(多數個體年齡集中在較低區間),MAE 以絕對誤差的平均衡量預測誤差,相較平方誤差類指標對少數高齡離群樣本更 穩健,是此類偏態計數型目標的合理選擇。

項目	值
競賽	playground-series-s3e16
問題型別	regression
評估指標	mae(minimize)
目標欄位	Age
素材等級	full

2. 使用工具與環境

工具	用途
LightGBM / XGBoost / CatBoost	三個梯度提升樹基礎模型,構成 exp1/2 blend 主體與 exp5 8-way blend 的核心成員
Optuna	Phase B round1 對 LGB 做超參搜尋(fold-0 proxy,詳見訓練規格節)
自建樹搜尋 harness	Phase E-3 搜尋特徵/模型/超參組合空間,於 node #15 找到 exp5 之 8-way blend
5-fold CV 框架(scikit-learn)	依年齡分箱做分層抽樣的 StratifiedKFold,5 折交叉驗證
uv	Python 套件與虛擬環境管理,所有腳本皆以 uv run 執行

本場工具鏈組合邏輯:Claude Code(LLM)負責選型、特徵工程與何時停損等決策(如判斷線性迭代 兩輪取整分數退步後依協定停止,即 Phase B);Auto-ML 工具(Optuna、樹搜尋 harness)負責系統化 執行超參搜尋與組合空間探索,兩者分工互補。

3. 流程(how):五大元件

3.1 資料規格

項目	值
train 列數	74,051
test 列數	49,368
原始欄位數	8
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

exp1 在原始 8 欄位上經特徵工程展開為 24 個特徵(sex one-hot、 is_infant 旗標、各部位 重量佔比、 weight_resid、體積/密度等衍生量);exp2-5 之特徵數見下表,exp2 僅用原始 8 個欄位。

3.2 實驗總表

語意澄清(本報告全文適用):exp1、2 的分數為**原始(未取整)**OOF MAE;因目標 Age 為整數,exp3、4、5 改以**取整(rounded)**後的 OOF MAE 做決策。下文一律以「(原始)」「(取整)」二字標記,不再重複解釋。

ex p	階段	模型/成員	特徵數	原始 OOF	決策分數	採納
1	Baseline(手刻管線)	LGB/XGB/CAT(.6/.3/.1)	24	1.35589	1.35589(原始)	是,提交#1 LB 冠軍
2	Baseline(通用批次)	LGB/XGB/CAT(.3/.2/.5)	8	1.35441	1.35441(原始)	否,未提交 LB
3	Phase B round1	+LGB_tuned(4-way)	24	1.35541	1.3385(取整)	否,劣於冠軍 1.33812
4	Phase B round2	+LGB_tuned_seed2024(5-way)	24	1.35533	1.33893(取整)	否,連 2 輪退步後停止
5	Phase E-3 樹搜尋 (best)	8-way blend(node #15)	24	1.35712	1.33563 (取整)	是,提交#2

誠實但書:exp3/4 用以比較的線性冠軍取整分數 1.33812,僅見於 experiments[2].notes / experiments[3].notes 文字紀錄,未列入結構化欄位。

best 成員表(exp5,8-way blend)

成員	權重	solo 分數	備註
LGB(root)	0.0198	1.33885	—
XGB	0.0256	1.3416	—
CAT	0.5061	1.33846	主導權重
LGB_tuned	0.0075	1.33979	—
LGB_tuned_seed2024	0.0626	1.33914	—

成員	權重	solo 分數	備註
LGBBOUND	0.1117	1.3395	邊界推進 LGB, learning_rate=0.005
TWEEDIE	0.0004	1.37467	權重近乎歸零,但為本次搜尋單筆最大增益貢獻者
FEATPRUNE	0.2662	1.34025	去除與 Weight 高度共線(r=0.993)之欄位,權重最高

三個梯度提升樹模型(LightGBM/XGBoost/CatBoost)基礎上,exp5 由 harness v2 之 Dirichlet+coordinate-ascent 權重搜尋(experiments_tree.json :27 節點、24 已評估、3 個失敗但無害,wall 1409.4s)於 node #15 找到;CAT、FEATPRUNE 為主要貢獻權重, TWEEDIE 雖近乎歸零但加入時貢獻單次最大增益。

3.3 訓練規格表

exp	CV 方案	folds	seed
1	5fold_stratified_agebin	5	無紀錄
2	5fold	5	無紀錄
3	5fold_stratified_agebin	5	42
4	5fold_stratified_agebin	5	42
5	5fold_stratified_agebin	5	42

年齡標籤右偏,一般隨機 K-fold 易使高齡樣本在各 fold 分布不均;exp1 起改用依年齡分箱後 分層抽樣的 StratifiedKFold(高齡樣本合併為單一分箱),exp3-5 沿用同一組固定折。各 base model 之 objective/超參數欄位 無紀錄(exp3 之 Optuna 設定僅見於 notes:fold-0-proxy、21/50 trials、300s timeout)。

3.4 推論表

exp	後處理	submission 檔	已提交
1	round	sub_blend_20260703_091840.csv	是
2	無後處理紀錄	sub_generic_1.35441_20260703_115739.csv	否
3	round	無紀錄	否
4	round	無紀錄	否
5	round	sub_tree_best_1.33563_20260706_115200.csv	是

id_column = id、target_column = Age。exp5 之 submission 由 scripts/rebuild_tree_best.py 重建 8 個成員的 test 預測、以同一組全精度權重混合後產生。

3.5 評估指標 / 排行榜

指標定義:MAE = 預測值與真實值絕對差之平均,單位與 Age 相同。

提交	日期	Public	Private
#1(exp1)	2026-07-03	1.34356	1.34075
#2(exp5,best)	2026-07-06	1.34315	1.33859

CV↔LB gap (提交#1,exp1 原始 OOF 對 LB):
 $1.35589 - 1.34356 = 0.01233$ (Public)
 $1.35589 - 1.34075 = 0.01514$ (Private)

雙 LB 錨點改善 (提交#2 相對提交#1):
 $1.34356 - 1.34315 = 0.00041$ (Public)
 $1.34075 - 1.33859 = 0.00216$ (Private)

CV↔LB gap 一致性檢查 (取整後 OOF 對 LB; 1.33812 見上方誠實但書):
提交#1: $1.34356 - 1.33812 = 0.00544$ (Public) / $1.34075 - 1.33812 = 0.00263$ (Private)
提交#2: $1.34315 - 1.33563 = 0.00752$ (Public) / $1.33859 - 1.33563 = 0.00296$ (Private)

兩榜皆對提交#1 改善,方向一致;OOF 略高於(劣於)LB,顯示 CV 未過度樂觀,取整後 OOF 是可信賴的排序依據,兩次獨立提交的 gap 同方向、同量級,未見對 Public LB 過擬合的跡象。

4. 實驗軌跡

實驗階段對照表(內部代號使用前先定義,R-W8)

代號	白話名稱	對應層級
Phase B	self-improvement 線性迭代	tier3
Phase E-3	樹搜尋執行(harness)	tier4

exp	時間	決策分數	階段	一句話摘要
1	2026-07-03T09:18:40	1.35589	Baseline(手刻)	24 特徵三模型 blend,提交#1 LB 冠軍
2	2026-07-03T11:57:39	1.35441	Baseline(通用)	8 特徵三模型 blend,原始 OOF 略優但未提交
3	2026-07-03T22:56:33	1.3385	Phase B round1	加入 Optuna 調參 LGB,取整分數退步未採納
4	2026-07-03T22:58:34	1.33893	Phase B round2	加入 seed-bagged LGB,連 2 輪退步後停止
5	2026-07-04T11:59:43	1.33563	Phase E-3 樹搜尋(best)	8-way blend,取整分數本場最佳,2026-07-06 提交#2

- **突破點 1(exp2→3/4):**Phase B 兩輪原始 OOF 單調進步(1.35589→1.35541→1.35533), 但取整後退步(1.33812→1.3385→1.33893),依「連 2 輪無改善即停」協定停止線性迭代。
- **突破點 2(exp4→5):**harness v2 樹搜尋(node #15)找到原始 OOF 劣化(1.35712)但 取整後改善(1.33563)的節點,方向與 exp3/4 相反,互為正反證據。
- **突破點 3(exp5 提交):**node #15 於 2026-07-06 經 `rebuild_tree_best.py` 重建 test 預測並提交 Kaggle,取得 Public 1.34315 / Private 1.33859,雙榜皆優於提交#1,為此樹 搜尋配方首次獲得的真實排行榜驗證。

facts.unparsed 為空陣列,無法解析之紀錄:無。

5. 效能對照:四層消融

層級	配置	分數	相對改善
tier 1	基線(Claude Code 直接執行,未引入 skill;exp2 通用批次 3 模型 blend)	1.35441(取整)	—(基線)
tier 2	+ kaggle-agent skill 六階段流程(exp1 手刻管線,24 特徵三模型 blend)	1.33812(取整)	見下方算式
tier 3	+ self-improvement 線性迭代(exp1 不變,Phase B 兩輪皆未通過取整門檻)	1.33812(取整)	0%(迭代未帶來改善,依協定停止)
tier 4	+ 樹搜尋(exp5,node #15,8-way blend)	1.33563(取整)	見下方算式

tier1→tier2:1.35441 - 1.33812 = 0.01629,相對改善 0.01629 / 1.35441 = 1.2027%
tier2→tier3:1.33812 - 1.33812 = 0.00000,相對改善 0%
tier3→tier4:1.33812 - 1.33563 = 0.00249,相對改善 0.00249 / 1.33812 = 0.1861%

本場由導入報告功能後之版本執行,分數自 tier2 起未低於前一層——符合計畫書目標三(效能不 退步)。

本表沿用第 3.5 節已作的取整口徑澄清:tier2–tier4 皆為(取整)後 OOF MAE,非 collect.py 一般 adapter 輸出的(原始)分數,不再重複解釋。

子刻度分解(選填)

依 § 5 附錄子刻度分類法(僅作分類字典,不強制逐級測量),下表僅列本場 experiments.json 天然存在對應中間紀錄之子刻度;無對應紀錄之子刻度不列,分數逐字引用自 facts.json。

子刻度	優化辦法	分數	出處(exp# 或 tree node)
1.a	單模預設參數(tier1 三模型中最佳者:CAT)	1.35714(取整)	exp2
1.b	多模+OOF 權重搜尋 blend(tier1 三模型混合)	1.35441(取整)	exp2
3.b	Optuna fold-0 代理調參 LGB,加入 pool(取整分數退步未採納)	1.3385	exp3
3.d	seed bagging(調參 LGB seed 2024,5-way,取整分數續退步後停止)	1.33893	exp4
4.b	樹搜尋 harness v2(node #15,8-way blend,對取整 MAE 直接評分,本場最佳、已提交 LB)	1.33563	exp5

6. 總結

本場目標欄位 Age 為右偏的正整數,依螃蟹物理量測值預測年齡;右偏分布使一般隨機 K-fold 易讓高齡樣本在各折分布不均,因此自 exp1 起即改用依年齡分箱的分層抽樣,是貫穿全程的關鍵 決策。目標為整數這項資料特性,進一步決定了「取整後處理」是本場最大的槓桿——決策指標必須是取整後的 OOF MAE,而非 collect.py 一般 adapter 輸出的原始 blend_oof_mae。

各階段增益來源分佈不均:tier1→tier2(手刻管線,24 特徵三模型 blend)取整分數自 1.35441 進步到 1.33812,是最大單一增益;tier2→tier3 的線性迭代(Optuna 調參 + seed bagging)雖讓 (原始)OOF 單調進步,(取整)後卻連續兩輪退步,依協定誠實停止,tier3 與 tier2 同值; tier3→tier4 的樹搜尋(node #15)則是本場第二起(原始)/(取整)反轉案例——其(原始)OOF 劣於線性冠軍,(取整)後卻更優,最終取整分數來到 1.33563。

最終結果的可信度來自兩次獨立的真實 Kaggle 提交:提交#1(exp1)取得 Public 1.34356 / Private 1.34075,提交 #2(exp5,best)取得 Public 1.34315 / Private 1.33859,兩榜皆對提交#1 改善且方向一致,CV↔LB gap 同量級、未見對 Public LB 過擬合的跡象,顯示取整後 OOF 是本場 可信賴的排序依據。

重現本實驗的最短路徑:見第 7 節。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# exp1:手刻管線(EDA → 特徵工程 → 訓練/CV/集成)
uv run python3 competitions/playground-series-s3e16/scripts/eda.py
uv run python3 competitions/playground-series-s3e16/scripts/train.py

# exp2:通用批次管線
uv run python3 competitions/run_competition.py playground-series-s3e16

# exp3(Phase B round1,未採納)
uv run python3 competitions/playground-series-s3e16/scripts/tune_lgb_optuna.py
uv run python3 competitions/playground-series-s3e16/scripts/round1.py

# exp4(Phase B round2,未採納)
uv run python3 competitions/playground-series-s3e16/scripts/round2.py

# exp5:Phase E-3 樹搜尋(best;可中斷/續跑;樹狀態存 experiments_tree.json;OOF-only)
uv run python3 tree_search/run_s3e16_v2.py

# 提交至 Kaggle(需先設定有效的 KAGGLE_API_TOKEN)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e16 -f <submission.csv> -m "<msg>"
```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 uv run 。