

競賽分析報告:playground-series-s3e16

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-07

目錄

1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格表	4
3.4 推論表	4
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	5
5. 效能對照(逐階段)	6
6. 總結	7
7. 重現指令	7

1. 競賽目的

What:依螃蟹的物理量測值(長度、直徑、高度、整體重量與各部位重量等)預測其年齡 (Age),為連續數值輸出的迴歸問題。

Why:評估指標為 **MAE(minimize)**。年齡標籤為正整數且分布右偏(多數個體年齡集中在較低區間),MAE 以絕對誤差的平均衡量預測誤差,相較平方誤差類指標對少數高齡離群樣本更 穩健,是此類偏態計數型目標的合理選擇。

項目	值
競賽	playground-series-s3e16
問題型別	regression
評估指標	mae(minimize)
目標欄位	Age

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第2版。交叉驗證採依年齡分箱分層的 StratifiedKFold(設計理由見第4節)。

2.2 本場專業術語

專業術語	定義
(原始)/(取整)	原始 = blend 輸出直接計分;取整 = 四捨五入成整數後計分(Age 為整數,實際決策看的是取整後的分數)
Tweedie	一種偏態計數資料的損失函數,此處作為增加集成多樣性的成員

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段1 | 無 skill 基線

- 1.1 單模型基線 — 使用
- 1.2 三模型 blend — 使用

階段2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(併入第1次實驗,無獨立分數)
- 2.2 EDA 驅動特徵工程 — 使用(併入第1次實驗,無獨立分數)
- 2.3 指標感知後處理 — 使用(併入第1次實驗,無獨立分數)
- 2.4 場內反思回退 — 本場未使用

階段3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 使用
- 3.3 調參入池 — 使用(含於3.2之作法)
- 3.4 seed bagging — 使用
- 3.5 結構化去噪 — 本場未使用

階段4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 使用

- 4.3 先驗注入+去重 — 使用(v2 內建)
- 4.4 邊界推進 mutation — 使用(LGBBOUND 成員)
- 4.5 預算相位機 — 本場未使用

階段 5 | +外部想法注入

- 5.1 外部想法庫先驗 — 使用(快評注入 stacking meta 模型,在階段4收斂點以快取 OOF 評估;未勝過階段4 → 階段5=階段4)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	74,051
test 列數	49,368
原始欄位數	8
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

第 1 次實驗 在原始 8 欄位上經特徵工程展開為 24 個特徵(sex one-hot、 is_infant 旗標、各部位 重量佔比、 weight_resid、體積/密度等衍生量);第 2 次實驗 僅用原始 8 個欄位。

3.2 實驗總表

計分方式說明(全文適用):第 1、2 次實驗 的決策分數為(原始)OOF MAE;第 3、4 次實驗、5 改以 (取整)OOF MAE 決策——目標為整數,取整後的分數才反映真實誤差(定義見第 2.2 節)。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	2	LGB/XGB/CAT(.6/.3/.1)	24	1.35589	1.35589(原始)	是,提交#1
2	1.2	LGB/XGB/CAT(.3/.2/.5)	8	1.35441	1.35441(原始)	否,未提交
3	3.2	+Optuna 調參 LGB(4-way)	24	1.35541	1.3385(取整)	否,劣於 1.33812
4	3.4	+調參 LGB seed2024(5-way)	24	1.35533	1.33893(取整)	否,連 2 輪退步後停止
5	4.2	樹搜尋 8-way blend(node #15)	24	1.35712	1.33563 (取整)	是,提交#2
6	5	外部注入快評候選(EXT-09(stacking);沿用階段4成員 OOF)	24	—	1.369664	否(未勝過階段4, 見 § 5)

補充說明:第 3、4 次實驗 的比較基準——階段 2 冠軍(第 1 次實驗)的取整分數 1.33812——取自 實驗紀錄的文字備註, 未列入正式數值欄位。

最佳解成員表(第 5 次實驗,8-way blend)

成員	權重	solo 分數	備註
LGB(root)	0.0198	1.33885	—
XGB	0.0256	1.3416	—
CAT	0.5061	1.33846	主導權重
LGB_tuned	0.0075	1.33979	—
LGB_tuned_seed2024	0.0626	1.33914	—
LGBBOUND	0.1117	1.3395	邊界推進 LGB,learning_rate=0.005
TWEEDIE	0.0004	1.37467	權重近乎歸零,但加入當下貢獻單筆最大增益
FEATPRUNE	0.2662	1.34025	移除與 Weight 高度共線($r=0.993$)之欄位,新成員中權重最高

第 5 次實驗 由樹搜尋工具(第 2 版)的權重搜尋找到;該次搜尋共 27 節點、24 個完成評估、3 個失敗但無害,總耗時 1409.4 秒。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1	5fold_stratified_agebin	5	無紀錄
2	5fold	5	無紀錄
3	5fold_stratified_agebin	5	42
4	5fold_stratified_agebin	5	42
5	5fold_stratified_agebin	5	42

年齡右偏,一般隨機切折易使高齡樣本在各折分布不均;自 第 1 次實驗 起改用依年齡分箱的分層抽樣 (高齡合併為單一分箱),第 3–5 次實驗 沿用同一組固定折,確保跨實驗分數可比。各模型的損失函數與超參數未完整記錄;第 3 次實驗 的 Optuna 設定為:每組參數先只在第 0 折評分以省時(勝出者再以完整 5 折確認)、完成 21/50 次試驗、300 秒逾時上限。

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	round	sub_blend_20260703_091840.csv	是
2	無後處理紀錄	sub_generic_1.35441_20260703_115739.csv	否
3	round	無紀錄	否
4	round	無紀錄	否

實驗編號	後處理	submission 檔	是否已提交
5	round	sub_tree_best_1.33563_20260706_115200.csv	是

`id_column = id`、`target_column = Age`。第 5 次實驗的提交檔由重建流程重新訓練 8 個成員產出 test 預測、以同一組全精度權重混合而成 (重建指令見第 7 節)。

3.5 評估指標 / 排行榜

指標定義見第 2.2 節(MAE、Public/Private LB、CV↔LB gap)。

提交	日期	Public	Private
#1(第 1 次實驗,階段 2)	2026-07-03	1.34356	1.34075
#2(第 5 次實驗,階段 4 最佳)	2026-07-06	1.34315	1.33859

CV↔LB gap(提交#1,第 1 次實驗 原始 OOF 對 LB):

$1.35589 - 1.34356 = 0.01233(\text{Public})$

$1.35589 - 1.34075 = 0.01514(\text{Private})$

雙榜改善(提交#2 相對提交#1):

$1.34356 - 1.34315 = 0.00041(\text{Public})$

$1.34075 - 1.33859 = 0.00216(\text{Private})$

CV↔LB gap 一致性檢查(取整 OOF 對 LB;1.33812 見第 3.2 節補充說明):

提交#1: $1.34356 - 1.33812 = 0.00544(\text{Public})$ / $1.34075 - 1.33812 = 0.00263(\text{Private})$

提交#2: $1.34315 - 1.33563 = 0.00752(\text{Public})$ / $1.33859 - 1.33563 = 0.00296(\text{Private})$

兩榜皆對提交#1 改善且方向一致;OOF 略劣於 LB、兩次獨立提交的 gap 同方向同量級,顯示 本地驗證未過度樂觀、(取整)OOF 是可信賴的排序依據。

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	2026-07-03T09:18:40	1.35589	2	24 特徵三模型 blend,提交#1
2	2026-07-03T11:57:39	1.35441	1.2	8 特徵通用批次,原始 OOF 略優但未提交
3	2026-07-03T22:56:33	1.3385	3.2	Optuna 調參 LGB 入池,取整分數退步未採納
4	2026-07-03T22:58:34	1.33893	3.4	seed bagging,連 2 輪退步依準則停止
5	2026-07-04T11:59:43	1.33563	4.2	樹搜尋 8-way blend,本場最佳,提交#2
6	2026-07-08T11:46:18	1.369664	5	外部注入快評:EXT-09(stacking) 候選 OOF 未勝過階段4,不採納

- **轉折 1(第 3→4 次實驗,階段 3 停止):**兩輪的(原始)OOF 單調進步($1.35589 \rightarrow 1.35541 \rightarrow 1.35533$),(取整)卻連續退步($1.33812 \rightarrow 1.3385 \rightarrow 1.33893$)——增益太小,過不了取整 這道門檻,依「連 2 輪無改善即停」準則結束階段 3。

- **轉折 2(第 4→5 次實驗,階段 4 突破):**樹搜尋找到反向案例——(原始)OOF 劣化(1.35712) 但(取整)改善(1.33563)。與轉折 1 互為正反證據:這個資料集的決策只能看取整分數。
- **轉折 3(第 5 次實驗 上榜):**重建 test 預測提交後取得 Public 1.34315 / Private 1.33859, 雙榜皆優於提交#1——樹搜尋的增益獲得真實排行榜驗證,而非僅本地推論。

5. 效能對照(逐階段)

階段	配置	分數(取整)	相對改善
1	未用 skill,通用批次 blend(第 2 次實驗)	1.35441	—(基線)
2	+ kaggle-agent skill 六階段(第 1 次實驗)	1.33812	1.20%
3	+ 線性自我迭代(兩輪皆未過取整門檻,維持 第 1 次實驗)	1.33812	0%
4	+ 樹搜尋(第 5 次實驗)	1.33563	0.19%
5	+ 外部想法注入(第 6 次實驗,快評)	1.33563	0.00%(未勝過)

相對改善計算式(每階段對前一階段)

階段1→2: $1.35441 - 1.33812 = 0.01629$, 相對改善 $0.01629 / 1.35441 = 1.2027\%$
 階段2→3: $1.33812 - 1.33812 = 0.00000$, 相對改善 0%
 階段3→4: $1.33812 - 1.33563 = 0.00249$, 相對改善 $0.00249 / 1.33812 = 0.1861\%$
 階段4→5: 注入候選 1.369664 未勝過階段4 1.33563, 搜尋保留階段4 → 相對改善 0.00% (外部注入無增益)

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一層——符合計畫書目標三(效能不退步)。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:CAT)	1.35714(取整)	第 2 次實驗
1.2(三模權重 blend)	1.35441(取整)	第 2 次實驗
3.2(Optuna 入池)	1.3385(取整,未採納)	第 3 次實驗
3.4(seed bagging)	1.33893(取整,未採納)	第 4 次實驗
4.2(樹搜尋 8-way)	1.33563 (取整,已上榜)	第 5 次實驗

階段 5 | + 外部想法注入

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-09:stacking**——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic),以 nested-CV 避免洩漏。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們**已算好的 OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

```
階段5 注入候選(stacking)00F 取整MAE = 1.369664
階段4 冠軍          00F 取整MAE = 1.335630
差距 = -0.034034 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4
```

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場的資料本質決定了一切:目標 Age 是右偏的正整數。右偏使得 CV 必須用年齡分箱的分層 切折(否則高齡樣本分布不均、分數不穩);整數性質則使「取整後的分數」才是真實的決策依據,而這正是本場最重要的一課——階段 3 的兩輪優化在原始分數上都有進步,卻全部死在取整門檻上;階段 4 的樹搜尋反而以一個原始分數更差的組合,在取整後拿下全場最佳。同一個機制的 正反兩面,都指向「決策時算分數的方式,必須與最終評分的方式一致」。

增益的分布也很清楚:最大的一步是階段 1→2(特徵工程與 CV 設計的功勞,幅度見第 5 節算式);階段 3 誠實掛零;階段 4 再擠出 0.19%。這個「大頭在流程、尾巴靠搜尋」的形狀,與其他九場競賽的 整體結論一致。

最終可信度由兩次真實提交背書:提交#2 在 Public 與 Private 兩榜皆優於提交#1,CV↔LB gap 在兩次提交間同方向同量級——本地驗證體系(分箱分層 CV + 取整計分)經得起排行榜檢驗。

重現本實驗的最短路徑:見第 7 節。

階段 5(外部想法注入) 經快評未勝過階段4:注入機制可運作、也產生了候選(stacking),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 第 1 次實驗(階段 2):skill 手刻管線(EDA → 特徵工程 → 訓練/CV/集成)
uv run python3 competitions/playground-series-s3e16/scripts/eda.py
uv run python3 competitions/playground-series-s3e16/scripts/train.py

# 第 2 次實驗(階段 1):通用批次管線
uv run python3 competitions/run_competition.py playground-series-s3e16

# 第 3 次實驗(3.2):Optuna 調參 + 第一輪迭代(未採納)
uv run python3 competitions/playground-series-s3e16/scripts/tune_lgb_optuna.py
uv run python3 competitions/playground-series-s3e16/scripts/round1.py

# 第 4 次實驗(3.4):seed bagging 第二輪(未採納)
uv run python3 competitions/playground-series-s3e16/scripts/round2.py

# 第 5 次實驗(4.2):樹搜尋(可中斷/續跑;樹狀態存 experiments_tree.json)
```

```
uv run python3 tree_search/run_s3e16_v2.py

# 提交至 Kaggle(需先設定有效的 KAGGLE_API_TOKEN)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions submit -c playground-series-s3e16 -f <submission.csv> -m "<msg>"

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 00F、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s3e16
```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 `uv run` 。