

競賽分析報告:playground-series-s3e19

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-03

1. 競賽目的

What(解什麼問題):本競賽為 Kaggle Playground Series Season 3 Episode 19(Aygun et al. Nature 2026 Kaggle Playground benchmark),任務是「Forecast mini-course sales」——依日期(date)、國家(country)、店面(store)、產品(product)四個維度,預測每日課程銷量 `num_sold`。訓練資料涵蓋 2017 至 2021 年,測試集為整個 2022 年,屬於典型的零售銷售時間序列外推問題。

Why(為何重要、指標為何合理):銷售預測是零售與電商的核心營運問題,直接影響備貨與行銷決策。評估指標為 **SMAPE**(symmetric mean absolute percentage error,minimize):各序列的銷量規模差異大(不同國家/店面/產品的量級不同),絕對誤差類指標會被大量級序列主導;SMAPE 以「真值與預測值的平均」作分母,將誤差正規化為相對比例,使大小序列的預測品質獲得同等權重,對此類多序列、多量級的銷售預測是合理選擇。

項目	值
競賽	playground-series-s3e19
URL	https://www.kaggle.com/competitions/playground-series-s3e19
問題型別	regression
評估指標	smape(minimize)
目標欄位	num_sold
ID 欄位	id

2. 資料規格

- 檔案:train.csv、test.csv、sample_submission.csv。
- 列數:facts.json 無紀錄(依 STATUS.md 敘述脈絡:訓練集為 2017-01-01 至 2021-12-31 的每日資料,測試集為 2022 全年;精確列數此處不引數字)。
- 欄位:原始特徵為 date 加三個類別欄(country、store、product),目標為整數 `num_sold`;無缺失值、無重複列。基線實驗(#1)使用 8 個通用特徵,本場工程後為 20 個特徵(清單見第 4 節)。
- 序列結構(EDA scripts/eda.py 執行結果,定性描述):5 國 × 3 店 × 5 產品共 75 條完整日序列;店面與產品占年度總量的比例逐年幾乎恆定,國家占比則逐年緩慢漂移;週末(尤其週日)與 12

月/1月有明顯季節性抬升,1月1日有單日尖峰;目標右偏、log1p後接近對稱;年度總量非單調(2020年下滑、2021年回升)。

特別規則:

規則	值
外部資料	不允許
預訓練模型	不允許
網路存取	不允許
每日提交上限	5

3. 模型規格

本場共三筆實驗;**facts.json**的**best**(分數最佳)為實驗 #3(診斷用 KFold 重跑),而實際產生提交檔的是**實驗 #2(時間序 CV)**。兩者特徵與模型完全相同,僅 CV 方案不同,分數不可跨方案直接比較(詳見第 4、7 節)。

實驗 #2 — 提交所用(TimeSeriesSplit 5-fold)

Base model	OOF SMAPE
LightGBM	10.17758
XGBoost	10.46
CatBoost	10.73064

Ensemble:OOF 加權平均網格搜尋(grid_step 0.1),最佳權重 **LGB 0.9 / XGB 0.0 / CAT 0.1**,blend SMAPE **10.175397**。

實驗 #3 — facts.best(診斷用,shuffled KFold,未產生提交檔)

Base model	OOF SMAPE
LightGBM	4.31618
XGBoost	4.33201
CatBoost	4.3239

Ensemble:同樣的權重網格搜尋,最佳權重 **LGB 0.4 / XGB 0.2 / CAT 0.4**,blend SMAPE **4.281421**。

選型理由:LGB/XGB/CatBoost 三種梯度提升樹是中型表格資料的標準組合,皆原生支援類別特徵並可用早停控制訓練成本。外推情境(實驗 #2)下 LGB 明顯領先、XGB 權重被搜到 0——與基線實驗 #1(權重 LGB 0.7 / XGB 0.0 / CAT 0.3)的型態一致;內插情境(實驗 #3)三模型幾乎同分,blend 分散權重。最終提交採用實驗 #2 的權重(0.9/0.0/0.1),因為真實測試集(2022 年)正是外推情境。

4. 訓練規格

實驗	CV 方案	n_splits	seed
#2(提交)	TimeSeriesSplit-5fold-on-unique-dates	5	無紀錄
#3(診斷)	KFold-5fold-shuffled-seed42	5	無紀錄(方案字串內含 seed42)

Objective 與關鍵超參(實驗 #2 紀錄):目標經 log1p 轉換後以迴歸目標訓練,預測以 expm1 反轉後計算 SMAPE。

模型	關鍵超參
LightGBM	n_estimators 2000、learning_rate 0.03、num_leaves 63、min_child_samples 20、subsample 0.9、colsample_bytree 0.8、reg_lambda 1.0
XGBoost	n_estimators 2000、learning_rate 0.03、max_depth 7、subsample 0.9、colsample_bytree 0.8、reg_lambda 1.0
CatBoost	iterations 2000、learning_rate 0.05、depth 8、l2_leaf_reg 3.0

三模型皆對各 fold 的驗證區塊做早停。

為何用此 CV:測試期(2022)完全落在訓練期(2017–2021)之後、零重疊,模型實際面對的是「外推到未見年份」;隨機 KFold 會讓驗證日夾在已見的季節循環之間,對此任務系統性樂觀。因此主實驗(#2)採 TimeSeriesSplit 於排序後的唯一日期上切分,每折以擴張窗訓練、驗證嚴格較晚的日期區塊,忠實模擬 train→test 的時間缺口。實驗 #3 刻意改用與基線相同型態的隨機 KFold,只作為「特徵集是否有效」的對照診斷,不用於選模。

特徵(20 個):year、month、day、dow、day_of_year、weekofyear、quarter、is_weekend、is_month_start、is_month_end、is_new_year、month_sin、month_cos、dow_sin、dow_cos、doy_sin、doy_cos、country_cat、store_cat、product_cat。

5. 推論程序

- **最終模型:**實驗 #2 的三個模型以相同超參在 100% 訓練資料上重訓,再按權重 LGB 0.9 / XGB 0.0 / CAT 0.1 加權平均。

- **後處理**: facts.json 的 postprocess 欄位無紀錄;依實驗 notes,預測值由 log1p 空間經 expm1 反轉回原始銷量尺度(訓練腳本另將負值截斷為 0)。
- **Submission**: sub_lgb_xgb_cat_blend_10.17540_20260703_194908.csv ,格式為兩欄(id , num_sold),與 sample_submission.csv 之形狀、id 順序逐一驗證通過。本場為無人值守批次執行,未實際提交至 Kaggle。

6. 評估指標

定義: $\text{SMAPE} = 100\% \times \text{平均}(|\text{真值} - \text{預測}| / ((|\text{真值}| + |\text{預測}|)/2))$,對稱化的相對誤差,越低越好。

分數總表

實驗	CV 方案	LGB	XGB	CAT	Blend
#1 基線	5fold	5.45633	7.41858	6.09778	5.31891
#2 提交	TimeSeriesSplit 5-fold	10.17758	10.46	10.73064	10.175397
#3 診斷	shuffled KFold 5-fold	4.31618	4.33201	4.3239	4.281421

Public/Private LB:無紀錄(未提交,facts.missing 含 leaderboard),故無 CV↔LB gap 可計算。

同方案(隨機 KFold)下,工程後特徵相對基線的改善幅度:

$$5.31891 - 4.281421 = 1.037489$$

$$1.037489 / 5.31891 \times 100 \approx 19.5\% (\text{SMAPE 下降})$$

跨方案的差距(同特徵、同模型,僅 CV 方案不同):

$$10.175397 - 4.281421 = 5.893976$$

此差距全部來自「外推 vs 內插」的驗證難度差異,不是模型退步(見第 7 節)。

7. 實驗軌跡

id	timestamp	score (SMAPE)	source_format
1	2026-07-03T12:14:06	5.31891	generic_batch
2	2026-07-03T19:49:08	10.175397	v2
3	2026-07-03T19:53:27	4.281421	v2

軌跡敘述與突破點:

- **#1 → #2**:加入 20 個日曆/週期/類別特徵並改採 log1p 目標,但同時把 CV 從隨機 5-fold 換成時間序 TimeSeriesSplit。分數表面上大幅變差(5.31891 → 10.175397),一度像是退步。
- **#2 → #3(Reflexion 診斷,本場的關鍵轉折)**:為釐清變差來自「特徵」還是「CV 方案」,以完全相同的 20 個特徵與三模型、改回與基線同型態的隨機 KFold 重測,得到 **4.281421**——優於基線的 5.31891。結論:特徵工程確實有效(同方案下最佳分數出現在實驗 #3),實驗 #2 的分數純粹反映時間序驗證是更誠實、更困難的量尺;預期實際 LB 落在兩個數字之間、偏向時間序估計。
- **教訓**:不同 CV 方案的分數不可直接比較;v2 schema 的 `cv.strategy` 欄位讓每筆實驗的方案都可回溯,本場正是靠它避免誤判。

無法解析之紀錄:無(facts.unparsed 為空)。

8. 重現指令

```
# 環境:Linux + uv(Python 由 uv 管理);執行目錄:專案根目錄
cd /home/tjyen/ai_agents/kaggle

# 0) 資料下載(需 KAGGLE_API_TOKEN;本場資料已在 data/ 內,可略過)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions download -c playground-series-s3e19 \
    -p competitions/playground-series-s3e19/data
unzip -o competitions/playground-series-s3e19/data/playground-series-s3e19.zip \
    -d competitions/playground-series-s3e19/data

# 1) EDA(輸出資料概況與 CV 方案決策依據)
uv run python3 competitions/playground-series-s3e19/scripts/eda.py

# 2) 特徵工程(產出 data/train_processed.csv、data/test_processed.csv)
uv run python3 competitions/playground-series-s3e19/scripts/features.py

# 3) 主訓練:TimeSeriesSplit 5-fold CV + 00F 權重搜尋 + 全量重訓 + 產出 submission
# (submission 寫入 competitions/playground-series-s3e19/submissions/,並記錄 experim
uv run python3 competitions/playground-series-s3e19/scripts/train.py

# 4) (選用)Reflexion 診斷:同特徵改用 shuffled KFold,對照基線
uv run python3 competitions/playground-series-s3e19/scripts/diagnostic_kfold.py
```

5) (選用)提交至 Kaggle

```
uv run kaggle competitions submit -c playground-series-s3e19 \  
    -f competitions/playground-series-s3e19/submissions/sub_lgb_xgb_cat_blend_10.175 \  
    -m "LGB+XGB+CAT blend, time-based CV"
```

