

競賽分析報告:playground-series-s3e19

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-06 本報告所有數字皆出自 facts.json,經 verify_report.py 驗證。

1. 競賽目的

What:Playground Series S3E19 「Forecast mini-course sales」——依日期(date)、國家(country)、店面(store)、產品(product)四個維度,預測每日課程銷量 num_sold。訓練資料為 2017–2021 年,測試集為整個 2022 年,是典型的多序列銷售時間序列外推問題。

Why:銷售預測直接影響備貨與行銷決策。評估指標為 **SMAPE(minimize)**:各序列量級 差異大(不同國家/店面/產品),絕對誤差類指標會被大量級序列主導;SMAPE 以真值與預測的 平均作分母,把誤差正規化為相對比例,讓大小序列的預測品質獲得同等權重,適合此類任務。

項目	值
競賽	playground-series-s3e19
問題型別	regression
評估指標	smape(minimize)
目標欄位	num_sold
素材等級	full

2. 使用工具與環境

工具	用途
LightGBM / XGBoost / CatBoost	三個梯度提升樹基模型;LGB 為全程主力,XGB 於 exp 4 起因權重歸零而移除
Optuna	Phase B 超參搜尋(TPE,fold-5 代理目標):exp 7 調出更淺、更強正則的 LGB
自建樹搜尋 harness(v2)	Phase D-5 搜尋 seed/特徵子集/混合權重組合空間,於 node #17 找到 exp 8 的 10-way blend
時序 CV 框架(scikit-learn)	TimeSeriesSplit 5 折(於排序後的唯一日期上切分)為決策量尺;另以 shuffled KFold 執行一次對照診斷
uv	Python 套件與虛擬環境管理,所有腳本皆以 uv run 執行

本場工具鏈組合邏輯:Claude Code(LLM)負責決策——選擇誠實的時序 CV、設計 Reflexion 診斷分離「特徵 vs CV 方案」效應、否決比例分解成員、決定調參代理折與何時停損;Auto-ML 工具(Optuna、樹搜尋 harness)負責系統

化執行超參搜尋與組合空間探索,兩者分工互補。

3. 流程(how):五大元件

3.1 資料規格

項目	值
train 列數	136,950
test 列數	27,375
原始欄位數	4(date/country/store/product;另有 id 與目標欄)
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

目標 `num_sold` 為整數(mean 165.522636、median 98、max 1380),右偏(skew 1.747438), 為 log 轉換候選——全程以 `log1p` 目標訓練、`expm1` 反轉。train/test 皆無缺失值、無重複列; date 有 1,826 個唯一日期,test 的 2022 年日期**全部未在 train 出現**,facts.eda 的 `validation_hint` 亦提示應採時間切分驗證以避免洩漏。

EDA(`scripts/eda.py`)關鍵定性發現:5 國 × 3 店 × 5 產品共 75 條完整日序列;店面與 產品占年度總量的比例逐年幾乎恆定,國家占比則逐年漂移(外推最難的部分);週末與 12 月/ 1 月有明顯季節抬升、1 月 1 日單日尖峰;年度總量非單調(2020 下滑、2021 回升),無可靠 線性趨勢。

3.2 實驗總表

語意澄清(本報告全文適用):本場同時存在兩種 CV 方案——(時序)= `TimeSeriesSplit` 5 折(每折驗證區塊嚴格晚於訓練窗,模擬 train 2017–21 → test 2022 的外推缺口)與 (隨機)= `shuffled KFold` 5 折(內插式,對本任務系統性樂觀)。**兩種方案的分數不可互相比較**;所有 keep/reject 決策一律以(時序)分數為準。SMAPE 無取整/門檻類後處理,故 各實驗「原始 OOF」即「決策分數」,兩欄同值。

ex p	階段	模型/成員	特徵數	原始 OOF	決策分數	採納
1	Baseline(通用批次)	LGB/XGB/CAT(0.7/0.0/0.3)	8	5.31891(隨機)	5.31891(隨機)	基線參照;與(時序)各實驗不可比
2	Phase A(skill 六階段)	LGB/XGB/CAT(0.9/0.0/0.1)	20	10.175397(時序)	10.175397(時序)	是,Phase A 最佳
3	Reflexion 診斷	LGB/XGB/CAT(0.4/0.2/0.4)	20	4.281421(隨機)	4.281421(隨機)	否,僅診斷用,不入決策
4	Phase B R1	LGB/CAT/RatioDecomp(0.95/0.05/0.0)	20	10.17489(時序)	10.17489(時序)	RD 成員棄用(權重 0;微幅增益僅來自較細權重網格)

exp	階段	模型/成員	特徵數	原始 OOF	決策分數	採納
5	Phase B R2	LGB seed 42/2024 + CAT(0.65/0.3/0.05)	20	10.16604 5(時序)	10.16604 5(時序)	是
6	Phase B R3	LGB×3 seeds + CAT×2 seeds(5-way)	20	10.15721 2(時序)	10.15721 2(時序)	是
7	Phase B R4(線性終點)	6-way + Optuna 調參 LGB(權重 0.5)	20	10.01946 3(時序)	10.01946 3(時序)	是,線性迭代最終;現行最佳提交檔
8	Phase D-5 樹搜尋(best)	10-way blend + auto_scale ×1.02(node #17)	20(池內含特徵子集探針)	9.75707 (時序)	9.75707 (時序)	是,本場誠實口徑最佳(OOF-only)

best 成員表(exp 8,dirichlet 權重搜尋 + auto_scale 全域乘數 1.02)

成員	權重	solo 分數	備註
SEEDBAG_TUNED_S3000	0.2559	9.990227	調參 LGB 之 seed 3000 變體
SEEDBAG_TUNED_S2024	0.2448	9.974778	調參 LGB 之 seed 2024 變體;solo 即勝過 exp 7 全 blend
LGB_S7	0.1989	10.19448	手設 LGB,seed 7
CALSUBSET	0.1781	10.137705	刪 weekofyear 等冗餘欄之特徵子集探針
DEEPLGB	0.0746	10.347073	刻意多樣化之深/輕正則 LGB;solo 弱但有貢獻
LGB_S42	0.0238	10.177577	手設 LGB,seed 42
LGB_S2024	0.0115	10.210617	手設 LGB,seed 2024
LGB_TUNED_ROOT	0.0089	10.148325	搜尋根節點 = exp 7 之 Optuna 調參 LGB
CAT_S2024	0.0032	10.983835	手設 CatBoost,seed 2024
CAT_S42	0.0003	10.730642	手設 CatBoost,seed 42

選型脈絡:三種梯度提升樹是中型表格資料的標準組合,皆原生支援類別特徵。外推情境下 LGB 明顯領先,XGB 兩度被權重搜尋歸零後移除;exp 4 的結構式比例分解成員(solo 14.75038) 也被歸零——GBDT 的原生類別分裂已學走佔比結構,真正瓶頸(總量一年外推)對所有方法一視同仁。exp 8 的兩個決定性槓桿:對調參 LGB 做 seed bagging(調參目標是 fold-5 代理而非全 OOF,留有真實 seed 變異可平均消除),與修正時序 OOF 系統性偏低約 2% 的全域 ×1.02 乘數(每折驗證區塊皆晚於訓練窗、序列成長至 2021,此偏差結構上與真實 2022 缺口同型)。

誠實但書(exp 8 與 facts.best;全文其他引用處不再重複): 1. facts.json 的 best 欄位以分數最小選出,落在 exp 3(4.281421)——那是(隨機) 診斷量尺的產物,不可作為本場最佳;誠實口徑((時序))的最佳為 exp 8。2. exp 8 為 OOF-only 樹搜尋結果:未產生 test 預測、無 submission 檔、未提交 Kaggle;「現行最佳提交檔」屬 exp 7(見 3.4 節)。3. **9.75707 帶雙重但書:**(a)與 exp 2-7 相同,fold 5 既是 Optuna 調參目標又佔 OOF 的 1/5,分數含 fold-5 double-dip 樂觀

成分;(b)exp 8 額外的 scale 乘數與 seed 挑選皆直接對 OOF 擬合(無巢狀驗證)。各為 1 至數個參數、擬合於 114,000 列 OOF,單項過擬風險低,但真實可期望的 2022 SMAPE 應解讀為「明顯低於 10.02」,而非字面上的 9.76。

3.3 訓練規格表

exp	CV 方案	folds	seed
1	5fold(隨機)	5	無紀錄
2	TimeSeriesSplit-5fold-on-unique-dates	5	無紀錄
3	KFold-5fold-shuffled-seed42	5	無紀錄(方案名含 seed42)
4-7	TimeSeriesSplit-5fold-on-unique-dates(與 exp 2 同折)	5	無紀錄
8	TimeSeriesSplit-5fold-on-unique-dates(逐位驗證與 exp 2-7 同折)	5	無紀錄

為何用此 CV:測試期(2022)完全落在訓練期之後、零日期重疊,模型實際面對「外推到 未見年份」;隨機 KFold 讓驗證日夾在已見季節循環之間,對本任務系統性樂觀。故主軌跡在 排序後的唯一日期上做 TimeSeriesSplit,每折以擴張窗訓練、驗證嚴格較晚的日期區塊。exp 3 刻意改回與基線同型態的隨機 KFold,僅作為特徵集有效性的對照診斷,不用於選模。

Objective:log1p(num_sold) 迴歸,預測經 expm1 反轉後計 SMAPE。關鍵超參(有紀錄者):

```
LGB(手設,exp 2): n_estimators=2000, learning_rate=0.03, num_leaves=63,
                  min_child_samples=20, subsample=0.9, colsample_bytree=0.8, reg_lambda=1.0
XGB(手設,exp 2): n_estimators=2000, learning_rate=0.03, max_depth=7,
                  subsample=0.9, colsample_bytree=0.8, reg_lambda=1.0
CAT(手設,exp 2): iterations=2000, learning_rate=0.05, depth=8, l2_leaf_reg=3.0
LGB_tuned(Optuna,exp 7):learning_rate≈0.0371, num_leaves=20, min_child_samples=38,
                  subsample≈0.61, colsample_bytree≈0.90, reg_alpha≈0.001,
                  reg_lambda≈0.43, n_estimators=2000
```

調參版比手設更淺、更強正則(num_leaves 63 → 20),與「外推情境獎勵正則化」的跨賽 經驗一致。特徵 20 個:year、month、day、dow、day_of_year、weekofyear、quarter、is_weekend、is_month_start、is_month_end、is_new_year、month/dow/doy 之 sin/cos、country_cat、store_cat、product_cat(類別欄原生餵入三模型)。

3.4 推論表

exp	後處理	submission 檔	已提交
1	無後處理紀錄	sub_generic_5.31891_20260703_121406.csv	否
2	expm1 反轉	sub_lgb_xgb_cat_blend_10.17540_20260703_194908.csv	否
3	expm1 反轉	無(診斷用,未產生提交檔)	否
4	expm1 反轉	sub_lgb_cat_rd_blend_10.17489_20260704_000355.csv	否

ex p	後處理	submission 檔	已提 交
5	expm1 反轉	sub_lgb_seedbag_cat_blend_10.16605_20260704_000957.csv	否
6	expm1 反轉	sub_lgb3seed_cat2seed_blend_10.15721_20260704_001501.csv	否
7	expm1 反轉、負值截 0	sub_6way_optuna_blend_10.01946_20260704_002039.csv	否
8	expm1 反轉 + auto_scale $\times 1.02$ (OOF 內擬合)	無(OOF-only,未產生 test 預測)	否

facts 各實驗無 postprocess 欄位,表中後處理描述取自各實驗 notes。submission 為兩欄 格式(id 欄 id、目標欄 num_sold)。本場為無人值守批次執行,全程未提交 Kaggle (leaderboard 列於 facts.missing);exp 7 檔案為現行最佳提交檔,其成員以各自超參在 100% 訓練資料上重訓後按權重加權平均,預測 mean 178.2 / max 1432.9,對成長中的 2022 屬合理範圍。

3.5 評估指標

指標定義:SMAPE = 對每筆取 $|真值 - 預測|$ 除以兩者絕對值之平均,再對全體取平均並以 百分比表示;對稱化的相對誤差,越低越好。

項目	OOF SMAPE(時序)
LGB_tuned(exp 7 成員,最佳單模)	10.14833
LGB_s42(exp 7 成員)	10.17758
LGB_s2024(exp 7 成員)	10.21059
LGB_s7(exp 7 成員)	10.19446
CAT_s42(exp 7 成員)	10.73064
CAT_s2024(exp 7 成員)	10.98383
Ensemble(exp 7,線性迭代終點)	10.019463
Ensemble(exp 8,樹搜尋 best)	9.75707
Public / Private LB	無紀錄(未提交)

本場無排行榜表(leaderboard 為空),CV↔LB gap 無法計算。主要改善幅度:

Phase B 淨改善(同折時序): $10.175397 - 10.019463 = 0.155934, 0.155934 / 10.175397 \approx 1.53\%$
 樹搜尋再改善(同折時序): $10.019463 - 9.75707 = 0.262393, 0.262393 / 10.019463 \approx 2.62\%$
 跨方案差距(同特徵同模型): $10.175397 - 4.281421 = 5.893976$ — 全部來自外推 vs 內插的驗證難度差,不是模型退步

4. 實驗軌跡

exp	時間	決策分數	階段	一句話摘要
1	2026-07-03T12:14:06	5.31891(隨機)	Baseline(通用批次)	8 通用特徵三模型 blend,隨機 KFold 口徑
2	2026-07-03T19:49:08	10.175397(時序)	Phase A	20 特徵 + log1p 目標,改採誠實的時序 CV
3	2026-07-03T19:53:27	4.281421(隨機)	Reflexion 診斷	同特徵改回隨機 KFold,證明變差來自 CV 方案而非特徵
4	2026-07-04T00:03:25	10.17489(時序)	Phase B R1	比例分解成員權重歸零,結構信號輸給 GBDT
5	2026-07-04T00:09:24	10.166045(時序)	Phase B R2	LGB seed bagging(+seed 2024)
6	2026-07-04T00:13:58	10.157212(時序)	Phase B R3	擴充 seed bagging(+LGB s7、+CAT s2024)
7	2026-07-04T00:19:34	10.019463(時序)	Phase B R4	Optuna fold-5 代理調參 LGB 入池,線性最大單輪增益
8	2026-07-04T12:18:09	9.75707 (時序)	Phase D-5 樹搜尋	10-way blend + auto_scale,node #17(22 節點,wall 321.0s)

- **突破點 1(exp 2→3,關鍵轉折)**:exp 2 表面上大幅變差(5.31891 → 10.175397), 診斷以完全相同的特徵/模型改回隨機 KFold 得 4.281421——優於基線,證明特徵工程有效、差距純粹來自「時序驗證是更誠實的量尺」;教訓:不同 CV 方案的分數永不互比。
- **突破點 2(exp 6→7)**:時序折不可互換,故以訓練窗最大、最接近 2022 外推情境的 fold 5 作 Optuna 代理目標;調參 LGB solo 10.14833(最佳單模)入池後拿 0.5 權重, blend 10.157212 → 10.019463,線性階段最大增益。
- **突破點 3(exp 7→8)**:樹搜尋兩槓桿——seed-bag 調參 LGB(SEEDBAG_TUNED_S2024 solo 9.974778,單模即勝過 exp 7 全 blend)與 auto_scale ×1.02(單筆最大增益 -0.168)——合計把分數推至 9.75707(但書見 3.2 節)。

無法解析之紀錄:無(facts.unparsed 為空陣列)。

5. 效能對照:四層消融

層級	配置	分數	相對改善
tier 1	基線(Claude Code 直接執行,未引入 skill;exp 1 通用批次)	無可比 generic(隨機 KFold 口徑,見下方 call-out)	—(基線;無可比)

層級	配置	分數	相對改善
tier 2	+ kaggle-agent skill 六階段流程(exp 2,時序 CV)	10.175397	—(本場消融比較的錨點)
tier 3	+ self-improvement 線性迭代(exp 7,Phase B 四輪終點)	10.019463	見下方算式 (tier2→tier3)
tier 4	+ 樹搜尋(exp 8,harness v2 node #17)	9.75707	見下方算式 (tier3→tier4)

tier2→tier3: $10.175397 - 10.019463 = 0.155934$, 相對改善 $0.155934 / 10.175397 \approx 1.53\%$
 tier3→tier4: $10.019463 - 9.75707 = 0.262393$, 相對改善 $0.262393 / 10.019463 \approx 2.62\%$
 tier2→tier4: $10.175397 - 9.75707 = 0.418327$, 相對改善 $0.418327 / 10.175397 \approx 4.11\%$
 (與 benchmark_facts.json 主表口径一致:該表相對變化欄改報 tier2→tier3 與 tier2→tier4)

同 CV 方案(隨機 KFold)側寫診斷對(僅供 CV-scheme 偏誤參考,不併入上表):
 generic 5.31891 → 同特徵同模型診斷重跑 4.281421,改善 $\approx 19.51\%$

本場由導入報告功能後之版本執行,分數自 tier2 起未低於前一層——符合計畫書目標三(效能不退步)。

CV 口径注記(s3e19 特殊場次):tier1 的 generic 批次實驗(exp 1,5.31891)使用 隨機 KFold,而 tier2/tier3/tier4 皆使用 TimeSeriesSplit——test 為嚴格未來期,時序 CV 才是誠實量尺,兩方案分數**不可比**(見 3.2 節澄清),故 tier1 標「無可比 generic」,消融算式改以 tier2 為錨點報 tier2→tier3 與 tier3→tier4(另附 tier2→tier4)。skill 特徵/模型層面的真實增益由上方**同 KFold 診斷對**(5.31891 → 4.281421)單獨呈現,僅作側面診斷,不併入主表任何 tier 計算。tier4 的 9.75707 另帶雙重但書 (fold-5 double-dip + scale/seed OOF 擬合),詳見 3.2 節 call-out,此處不重複; 依該但書,真實可期望的 2022 SMAPE 應讀作「明顯低於 10.02」,而非字面上的 9.76。

6. 總結

本場資料乾淨而結構鮮明:75 條完整日序列、無缺失無重複,店面/產品年度佔比近乎恆定、國家佔比逐年漂移,目標右偏經 log1p 對稱化;測試期為嚴格未來的 2022 年,決定了本場最重要的一步——以 TimeSeriesSplit 取代隨機 KFold 作為唯一決策量尺。

關鍵決策有三:其一,exp 3 的 Reflexion 診斷把「分數變差」歸因到 CV 方案而非特徵,避免誤判退步;其二,exp 4 誠實棄用比例分解——結構要贏 GBDT,目標須在該維度跨年近乎 恆定,而本場總量本身不可外推;其三,exp 7 以 fold-5 代理調參,選出更淺更正則的 LGB。

增益來源清楚分層:Phase A 建立時序口径基準(10.175397);Phase B 靠 seed bagging 與 Optuna 調參推進至 10.019463(約 1.53%);樹搜尋再以「seed-bag 調參 LGB」與「auto_scale $\times 1.02$ 修正時序 OOF 系統性偏低」兩槓桿推至 9.75707(約 2.62%)——後者是所有已跑樹搜尋 場次中相對幅度最大的一場,且兩個槓桿都是線性階段明確列為「未試」的想法。

可信度方面須誠實:全程未提交 Kaggle、無排行榜錨點;9.75707 帶雙重但書(見 3.2 節), 真實可期望的 2022 SMAPE 應解讀為「明顯低於 10.02」,而非字面上的 9.76。方向性結論 (時序口徑下逐層改善、變異縮減類槓桿在時序 CV 下報酬放大)是穩健的部分。

重現本實驗的最短路徑:見第 7 節。

7. 重現指令

```
# 環境:Linux + uv(Python 由 uv 管理);執行目錄:專案根目錄
cd /home/tjyen/ai_agents/kaggle

# 0) 資料下載(需 KAGGLE_API_TOKEN;本場資料已在 data/ 內,可略過)
uv run kaggle competitions download -c playground-series-s3e19 \
    -p competitions/playground-series-s3e19/data
unzip -o competitions/playground-series-s3e19/data/playground-series-s3e19.zip \
    -d competitions/playground-series-s3e19/data

# 1) EDA(輸出資料概況與時序 CV 決策依據)
uv run python3 competitions/playground-series-s3e19/scripts/eda.py

# 2) 特徵工程(產出 data/train_processed.csv data/test_processed.csv)
uv run python3 competitions/playground-series-s3e19/scripts/features.py

# 3) 主訓練:TimeSeriesSplit 5 折 + 00F 權重搜尋 + 全量重訓 + submission(exp 2)
uv run python3 competitions/playground-series-s3e19/scripts/train.py

# 4) (選用)Reflexion 診斷:同特徵改用 shuffled KFold(exp 3)
uv run python3 competitions/playground-series-s3e19/scripts/diagnostic_kfold.py

# 5) Phase B 迭代(依序;exp 7 產出現行最佳 submission)
uv run python3 competitions/playground-series-s3e19/scripts/train_ratio.py      # exp 4(RD 棄用)
uv run python3 competitions/playground-series-s3e19/scripts/train_seedbag.py   # exp 5
uv run python3 competitions/playground-series-s3e19/scripts/train_seedbag2.py  # exp 6
uv run python3 competitions/playground-series-s3e19/scripts/train_optuna.py    # exp 7

# 6) Phase D-5 樹搜尋 harness v2(exp 8,00F-only;軌跡存 experiments_tree.json)
uv run python3 tree_search/run_s3e19.py

# 7) 報告產生與驗證(本檔)
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e19
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py \
    competitions/playground-series-s3e19/REPORT.md competitions/playground-series-s3e19/facts.json
bash .claude/skills/kaggle-report/assets/md2pdf.sh competitions/playground-series-s3e19/REPORT.md \
    competitions/playground-series-s3e19/s3e19_REPORT.pdf

# 8) (選用)提交至 Kaggle(本場未執行;需有效之 KAGGLE_API_TOKEN)
uv run kaggle competitions submit -c playground-series-s3e19 \
    -f competitions/playground-series-s3e19/submissions/sub_6way_optuna_blend_10.01946_20260704_0020 \
    -m "6-way blend: LGB seeds + CAT seeds + Optuna fold-5-proxy tuned LGB, time-based CV"
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle` ;所有 Python 執行皆透過 `uv run` 。