

競賽分析報告:playground-series-s3e19

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

目錄

1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格表	5
3.4 推論表	6
3.5 評估指標	6
4. 實驗軌跡	7
5. 效能對照(逐階段)	7
6. 總結	9
7. 重現指令	9

1. 競賽目的

What:Playground Series S3E19「Forecast mini-course sales」——依日期(date)、國家(country)、店面(store)、產品(product)四個維度,預測每日課程銷量 `num_sold`。訓練資料為 2017–2021 年,測試集為整個 2022 年,是典型的多序列銷售時間序列外推問題。

Why:銷售預測直接影響備貨與行銷決策。評估指標為 **SMAPE(minimize)**:各序列量級 差異大(不同國家/店面/產品),絕對誤差類指標會被大量級序列主導;SMAPE 以真值與預測的 平均作分母,把誤差正規化為相對比例,讓大小序列的預測品質獲得同等權重,適合此類任務。

項目	值
競賽	playground-series-s3e19
問題型別	regression
評估指標	smape(minimize)
目標欄位	num_sold

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第2版。交叉驗證採於排序後唯一日期上切分的 TimeSeriesSplit 5 折,另以隨機 KFold 執行一次 對照診斷(設計理由見第3.3節)。

2.2 本場專業術語

專業術語	定義
(時序)/(隨機)	分數來源標記:時序 = TimeSeriesSplit 折的 OOF;隨機 = shuffled KFold 折的 OOF;兩者不可互比
auto_scale	對全體預測乘上一個在 OOF 上擬合的全域乘數(本場 $\times 1.02$),修正時序 OOF 系統性偏低
比例分解成員	把序列拆成「總量 $\times$ 各維度佔比」再組回預測的結構式成員(RatioDecomp);本場權重被搜尋歸零

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段1 | 無 skill 基線

- 1.1 單模型基線 — 使用
- 1.2 三模型 blend — 使用

階段2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(第2次實驗 改採時序切分,本場最重要決策)
- 2.2 EDA 驅動特徵工程 — 使用(第2次實驗,20個日期/類別特徵)
- 2.3 指標感知後處理 — 使用(log1p 目標與 expm1 反轉,第2次實驗起)
- 2.4 場內反思回退 — 使用(第3次實驗 反思診斷:分離 CV 方案與特徵效應)

階段3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 使用(第7次實驗,只以第5折評分挑參)
- 3.3 調參入池 — 使用(含於3.2之作法)
- 3.4 seed bagging — 使用(第5、6次實驗)
- 3.5 結構化去噪 — 本場未使用

階段4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用

- 4.2 ensemble 節點樹 — 使用
- 4.3 先驗注入+去重 — 使用(v2 內建)
- 4.4 邊界推進 mutation — 本場未使用(無獨立紀錄)
- 4.5 預算相位機 — 本場未使用

階段 5 | +外部想法注入(ERA 第二支柱)

- 5.1 外部想法庫 + 篩選去重 — 使用(依 comp_meta 篩選、[INT] 去重)
- 5.2 想法→搜尋候選翻譯器 — 使用(本場注入 stacking——對各成員 OOF 預測疊一層 meta 模型)
- 5.3 plateau 觸發 + 限次數(快評)— 使用(在階段4收斂點以快取 OOF 評估)
- 5.4 注入候選採納 — 否(未勝過階段4 → 階段5=階段4;全案 15 場一致,見第 5 節與總結報告第 7 節)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	136,950
test 列數	27,375
原始欄位數	4(date/country/store/product;另有 id 與目標欄)
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

目標 num_sold 為整數(mean 165.522636、median 98、max 1380),右偏(skew 1.747438), 為 log 轉換候選——全程以 log1p 目標訓練、expm1 反轉。train/test 皆無缺失值、無重複列; date 有 1,826 個唯一日期,test 的 2022 年日期**全部未在 train 出現**,EDA 的驗證建議 亦提示應採時間切分驗證以避免洩漏。

EDA 關鍵定性發現:5 國 × 3 店 × 5 產品共 75 條完整日序列;店面與 產品占年度總量的比例逐年幾乎恆定,國家占比則逐年漂移(外推最難的部分);週末與 12 月/ 1 月有明顯季節抬升、1 月 1 日單日尖峰;年度總量非單調(2020 下滑、2021 回升),無可靠 線性趨勢。

3.2 實驗總表

語意澄清(本報告全文適用):本場同時存在兩種 CV 方案——(時序)= TimeSeriesSplit 5 折(每折驗證區塊嚴格晚於訓練窗,模擬 train 2017–21 → test 2022 的外推缺口)與 (隨機)= shuffled KFold 5 折(內插式,對本任務系統性樂觀)。**兩種方案的分數不可互相比較**;所有 keep/reject 決策一律以(時序)分數為準。SMAPE 無取整/門檻類後處理,故 各實驗「原始 OOF」即「決策分數」,兩欄同值。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	1.2	LGB/XGB/CAT(0.7/0.0/0.3)	8	5.31891(隨機)	5.31891(隨機)	基線參照;與(時序)各實驗不可比

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
2	2	LGB/XGB/CAT(0.9/0.0/0.1)	20	10.175397(時序)	10.175397(時序)	是,階段 2 最佳
3	2.4	LGB/XGB/CAT(0.4/0.2/0.4)	20	4.281421(隨機)	4.281421(隨機)	否,僅診斷用,不入決策
4	3	LGB/CAT/比例分解(0.95/0.05/0.0)	20	10.17489(時序)	10.17489(時序)	比例分解成員棄用(權重 0;微幅增益僅來自較細權重網格)
5	3.4	LGB seed 42/2024 + CAT(0.65/0.3/0.05)	20	10.166045(時序)	10.166045(時序)	是
6	3.4	LGB×3 seeds + CAT×2 seeds(5-way)	20	10.157212(時序)	10.157212(時序)	是
7	3.2	6-way + Optuna 調參 LGB(權重 0.5)	20	10.019463(時序)	10.019463(時序)	是,線性迭代最終;現行最佳提交檔
8	4.2	10-way blend + auto_scale ×1.02(node #17)	20(池內含刪冗餘欄位的檢查型成員)	9.75707(時序)	9.75707(時序)	是,本場誠實計分下最佳(僅 OOF 分數)
9	5	外部注入快評候選(EXT-09(stacking);沿用階段 4 成員 OOF)	20	50.857609	50.857609	否(未勝過階段 4,見 § 5)

最佳解成員表(第 8 次實驗,權重搜尋 + auto_scale 全域乘數 1.02)

成員	權重	solo 分數	備註
SEEDBAG_TUNED_S3000	0.2559	9.990227	調參 LGB 之 seed 3000 變體
SEEDBAG_TUNED_S2024	0.2448	9.974778	調參 LGB 之 seed 2024 變體;solo 即勝過 第 7 次實驗 全 blend
LGB_S7	0.1989	10.19448	手設 LGB,seed 7
CALSUBSET	0.1781	10.137705	刪 weekofyear 等冗餘欄重訓的檢查型成員
DEEPLGB	0.0746	10.347073	刻意多樣化之深/輕正則 LGB;solo 弱但有貢獻
LGB_S42	0.0238	10.177577	手設 LGB,seed 42
LGB_S2024	0.0115	10.210617	手設 LGB,seed 2024
LGB_TUNED_ROOT	0.0089	10.148325	搜尋根節點 = 第 7 次實驗 之 Optuna 調參 LGB
CAT_S2024	0.0032	10.983835	手設 CatBoost,seed 2024
CAT_S42	0.0003	10.730642	手設 CatBoost,seed 42

選型脈絡:三種梯度提升樹是中型表格資料的標準組合,皆原生支援類別特徵。外推情境下 LGB 明顯領先,XGB 兩度被權重搜尋歸零後移除;第 4 次實驗 的結構式比例分解成員(solo 14.75038) 也被歸零——GBDT 的原生類別分裂已學走佔比結構,真正瓶頸(總量一年外推)對所有方法一視同仁。第 8 次實驗 的兩個決定性作法:對調參 LGB 做 seed bagging(調參只以第 5 折評分挑參、未對全 OOF 擬合,留有真實 seed 變異可平均消除),與修正

時序 OOF 系統性偏低約 2% 的全域 $\times 1.02$ 乘數(每折驗證區塊皆晚於訓練窗、序列成長至 2021,此偏差結構上與真實 2022 缺口同型)。

補充說明(第 8 次實驗 與最佳解的計分方式;全文其他引用處不再重複): 1. 最佳解紀錄以分數最小選出,落在 第 3 次實驗(4.281421)——那是(隨機) 診斷量尺的產物,不可作為本場最佳;誠實計分((時序))下的最佳為 第 8 次實驗。2. 第 8 次實驗 為樹搜尋結果,只算出 OOF 分數:未產生 test 預測、無 submission 檔、未提交 Kaggle;「現行最佳提交檔」屬 第 7 次實驗(見第 3.4 節)。3. **9.75707 帶雙重但書:**(a)與 第 2–7 次實驗 相同,fold 5 既是 Optuna 調參目標又佔 OOF 的 1/5,分數含 fold 5 雙重使用的樂觀成分;(b)第 8 次實驗 額外的 scale 乘數與 seed 挑選皆直接對 OOF 擬合(無巢狀驗證)。各為 1 至數個參數、擬合於 114,000 列 OOF,單項過擬風險低,但真實可期望的 2022 SMAPE 應解讀為「明顯低於 10.02」,而非字面上的 9.76。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1	5fold(隨機)	5	無紀錄
2	TimeSeriesSplit-5fold-on-unique-dates	5	無紀錄
3	KFold-5fold-shuffled-seed42	5	無紀錄(方案名含 seed42)
4–7	TimeSeriesSplit-5fold-on-unique-dates(與 第 2 次實驗 同折)	5	無紀錄
8	TimeSeriesSplit-5fold-on-unique-dates(逐位驗證與 第 2–7 次實驗 同折)	5	無紀錄

為何用此 CV:測試期(2022)完全落在訓練期之後、零日期重疊,模型實際面對「外推到 未見年份」;隨機 KFold 讓驗證日夾在已見季節循環之間,對本任務系統性樂觀。故主軌跡在 排序後的唯一日期上做 TimeSeriesSplit,每折以擴張窗訓練、驗證嚴格較晚的日期區塊。第 3 次實驗 刻意改回與基線同型態的隨機 KFold,僅作為特徵集有效性的對照診斷,不用於選模。

Objective:log1p(num_sold) 迴歸,預測經 expm1 反轉後計 SMAPE。關鍵超參(有紀錄者):

```
LGB(手設,第 2 次實驗): n_estimators=2000, learning_rate=0.03, num_leaves=63,
                        min_child_samples=20, subsample=0.9, colsample_bytree=0.8, reg_lambda=1.0
XGB(手設,第 2 次實驗): n_estimators=2000, learning_rate=0.03, max_depth=7,
                        subsample=0.9, colsample_bytree=0.8, reg_lambda=1.0
CAT(手設,第 2 次實驗): iterations=2000, learning_rate=0.05, depth=8, l2_leaf_reg=3.0
LGB_tuned(Optuna,第 7 次實驗):learning_rate≈0.0371, num_leaves=20, min_child_samples=38,
                                subsample≈0.61, colsample_bytree≈0.90, reg_alpha≈0.001,
                                reg_lambda≈0.43, n_estimators=2000
```

調參版比手設更淺、更強正則(num_leaves 63 $\rightarrow$ 20),與「外推情境獎勵正則化」的跨賽經驗一致。特徵 20 個:year、month、day、dow、day_of_year、weekofyear、quarter、is_weekend、is_month_start、is_month_end、is_new_year、month/dow/doy 之 sin/cos、country_cat、store_cat、product_cat(類別欄原生餵入三模型)。

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無後處理紀錄	sub_generic_5.31891_20260703_121406.csv	否
2	expm1 反轉	sub_lgb_xgb_cat_blend_10.17540_20260703_194908.csv	否
3	expm1 反轉	無(診斷用,未產生提交檔)	否
4	expm1 反轉	sub_lgb_cat_rd_blend_10.17489_20260704_000355.csv	否
5	expm1 反轉	sub_lgb_seedbag_cat_blend_10.16605_20260704_000957.csv	否
6	expm1 反轉	sub_lgb3seed_cat2seed_blend_10.15721_20260704_001501.csv	否
7	expm1 反轉、負值截 0	sub_6way_optuna_blend_10.01946_20260704_002039.csv	否
8	expm1 反轉 + auto_scale $\times 1.02$ (OOF 內擬合)	無(僅 OOF 分數,未產生 test 預測)	否

原始紀錄無正式後處理欄位,表中後處理描述取自各實驗的文字備註。submission 為兩欄 格式(id 欄 id、目標欄 num_sold)。本場為無人值守批次執行,全程未提交 Kaggle;第 7 次實驗 檔案為現行最佳提交檔,其成員以各自超參在 100% 訓練資料上重訓後按權重加權平均,預測 mean 178.2 / max 1432.9,對成長中的 2022 屬合理範圍。

3.5 評估指標

指標定義:SMAPE = 對每筆取 $|真值 - 預測|$ 除以兩者絕對值之平均,再對全體取平均並以 百分比表示;對稱化的相對誤差,越低越好。

項目	OOF SMAPE(時序)
LGB_tuned(第 7 次實驗 成員,最佳單模)	10.14833
LGB_s42(第 7 次實驗 成員)	10.17758
LGB_s2024(第 7 次實驗 成員)	10.21059
LGB_s7(第 7 次實驗 成員)	10.19446
CAT_s42(第 7 次實驗 成員)	10.73064
CAT_s2024(第 7 次實驗 成員)	10.98383
Ensemble(第 7 次實驗,線性迭代終點)	10.019463
Ensemble(第 8 次實驗,樹搜尋 best)	9.75707
Public / Private LB	無紀錄(未提交)

本場未提交 Kaggle,無排行榜紀錄,故無排行榜表,CV↔LB gap 無法計算。主要改善幅度:

階段 3 淨改善(同折時序): $10.175397 - 10.019463 = 0.155934, 0.155934 / 10.175397 \approx 1.53\%$

樹搜尋再改善(同折時序): $10.019463 - 9.75707 = 0.262393, 0.262393 / 10.019463 \approx 2.62\%$

跨方案差距 (同特徵同模型) : $10.175397 - 4.281421 = 5.893976$ — 全部來自外推 vs 內插
的驗證難度差, 不是模型退步

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	2026-07-03T12:14:06	5.31891(隨機)	1.2	8 通用特徵三模型 blend,隨機 KFold 計分
2	2026-07-03T19:49:08	10.175397(時序)	2	20 特徵 + log1p 目標,改採誠實的時序 CV
3	2026-07-03T19:53:27	4.281421(隨機)	2.4	同特徵改回隨機 KFold,證明變差來自 CV 方案而非特徵
4	2026-07-04T00:03:25	10.17489(時序)	3	比例分解成員權重歸零,結構信號輸給 GBDT
5	2026-07-04T00:09:24	10.166045(時序)	3.4	LGB seed bagging(+seed 2024)
6	2026-07-04T00:13:58	10.157212(時序)	3.4	擴充 seed bagging(+LGB s7、+CAT s2024)
7	2026-07-04T00:19:34	10.019463(時序)	3.2	Optuna 調參 LGB(只以第 5 折評分挑參)入池,線性最大單輪增益
8	2026-07-04T12:18:09	9.75707(時序)	4.2	10-way blend + auto_scale,node #17(22 節點,耗時 321.0 秒)
9	2026-07-08T11:46:18	50.857609	5	外部注入快評:EXT-09(stacking) 候選 OOF 未勝過階段4,不採納

- **突破點 1(第 2→3 次實驗,關鍵轉折):**第 2 次實驗 表面上大幅變差($5.31891 \rightarrow 10.175397$), 診斷以完全相同的特徵/模型改回隨機 KFold 得 4.281421——優於基線,證明特徵工程有效、 差距純粹來自「時序驗證是更誠實的量尺」;教訓:不同 CV 方案的分數永不互比。
- **突破點 2(第 6→7 次實驗):**時序折不可互換,故 Optuna 只以訓練窗最大、最接近 2022 外推情境的 fold 5 評分挑參;調參 LGB solo 10.14833(最佳單模)入池後拿 0.5 權重, blend $10.157212 \rightarrow 10.019463$,線性階段最大增益。
- **突破點 3(第 7→8 次實驗):**樹搜尋的兩個作法——seed-bag 調參 LGB(SEEDBAG_TUNED_S2024 solo 9.974778,單模即勝過 第 7 次實驗 全 blend)與 auto_scale $\times 1.02$ (單筆最大增益 -0.168)——合計把分數推至 9.75707(見第 3.2 節補充說明)。

5. 效能對照(逐階段)

階段	配置	分數	相對改善
1	基線(Claude Code 直接執行,未引入 skill;第 1 次實驗通用批次)	無可比分數(隨機 KFold 計分,見下方注記)	—(基線;無可比)
2		10.175397	

階段	配置	分數	相對改善
	+ kaggle-agent skill 六階段流程(第 2 次實驗,時序 CV)		—(本場逐階比較的基準)
3	+ self-improvement 線性迭代(第 7 次實驗,四輪終點)	10.019463	1.53%(階段2→3)
4	+ 樹搜尋(第 8 次實驗,node #17)	9.75707	2.62%(階段3→4)
5	+ 外部想法注入(第 9 次實驗,快評)	9.75707	0.00%(未勝過)

相對改善計算式(每階段對前一階段)

階段2→3: $10.175397 - 10.019463 = 0.155934$, 相對改善 $0.155934 / 10.175397 \approx 1.53\%$
 階段3→4: $10.019463 - 9.75707 = 0.262393$, 相對改善 $0.262393 / 10.019463 \approx 2.62\%$
 階段2→4: $10.175397 - 9.75707 = 0.418327$, 相對改善 $0.418327 / 10.175397 \approx 4.11\%$
 階段4→5: 注入候選 50.857609 未勝過階段4 9.75707, 搜尋保留階段4 → 相對改善 0.00% (外部注入無增益)
 (與跨場彙總報告主表計分方式一致: 該表相對變化欄改報 階段2→3 與 階段2→4)

同 CV 方案(隨機 KFold)對照診斷(僅供 CV 方案偏差參考,不併入上表):
 通用批次 5.31891 → 同特徵同模型診斷重跑 4.281421, 改善 $\approx 19.51\%$

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

CV 計分方式注記(s3e19 特殊場次):階段 1 的通用批次實驗(第 1 次實驗,5.31891)使用 隨機 KFold,而階段 2/3/4 皆使用 TimeSeriesSplit——test 為嚴格未來期,時序 CV 才是誠實量尺,兩方案分數**不可比**(見第 3.2 節澄清),故階段 1 標「無可比 分數」,逐階算式改以階段 2 為基準報 階段2→3 與 階段3→4(另附 階段2→4)。skill 特徵/模型層面的真實增益由上方**同 KFold 診斷對**(5.31891 → 4.281421)單獨 呈現,僅作側面診斷,不併入主表任何階段計算。階段 4 的 9.75707 另帶雙重但書 (fold 5 雙重使用 + scale/seed 對 OOF 擬合),詳見第 3.2 節補充說明,此處不重複; 依該但書,真實可期望的 2022 SMAPE 應讀作「明顯低於 10.02」,而非字面上的 9.76。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:LGB,隨機 KFold 計分)	5.45633	第 1 次實驗
1.2(三模權重 blend,隨機 KFold 計分)	5.31891	第 1 次實驗
3.2(Optuna 調參 LGB——只以第 5 折評分挑參,加入池,線性迭代最大單輪增益)	10.019463	第 7 次實驗
3.4(seed bagging,+LGB seed 2024)	10.166045	第 5 次實驗
3.4(seed bagging 擴充,+LGB seed 7、+CAT seed 2024)	10.157212	第 6 次實驗
4.2(樹搜尋 node #17,10-way blend + auto_scale,本場最佳)	9.75707	第 8 次實驗

階段 5 | + 外部想法注入(ERA 第二支柱)

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-09:stacking**——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic),以 nested-CV 避免洩漏。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們已算好的 OOF 預測(快取),在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

```
階段5 注入候選(stacking)OOF SMAPE = 50.857609
階段4 冠軍          OOF SMAPE = 9.757070
差距 = -41.100539 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4
```

(本場註:stacking 的 Ridge meta 對 SMAPE/時序嚴重不對齊,故 OOF 遠差;搜尋當然不採納。)

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的 ERA 第二支柱誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場資料乾淨而結構鮮明:75 條完整日序列、無缺失無重複,店面/產品年度佔比近乎恆定、國家佔比逐年漂移,目標右偏經 log1p 對稱化;測試期為嚴格未來的 2022 年,決定了本場 最重要的一步——以 TimeSeriesSplit 取代隨機 KFold 作為唯一決策量尺。

關鍵決策有三:其一,第 3 次實驗 的反思診斷把「分數變差」歸因到 CV 方案而非特徵,避免誤判退步;其二,第 4 次實驗 誠實棄用比例分解——結構要贏 GBDT,目標須在該維度跨年近乎 恆定,而本場總量本身不可外推;其三,第 7 次實驗 調參時只以第 5 折評分挑參,選出更淺更正則的 LGB。

增益來源清楚分層:階段 2 建立時序計分基準(10.175397);階段 3 靠 seed bagging 與 Optuna 調參推進至 10.019463(約 1.53%);樹搜尋再以「seed-bag 調參 LGB」與「auto_scale $\times 1.02$ 修正時序 OOF 系統性偏低」兩個作法推至 9.75707(約 2.62%)——後者是所有已跑樹搜尋 場次中相對幅度最大的一場,且兩個作法都是線性階段明確列為「未試」的想法。

可信度方面須誠實:全程未提交 Kaggle、無排行榜對照;9.75707 帶雙重但書(見第 3.2 節),真實可期望的 2022 SMAPE 應解讀為「明顯低於 10.02」,而非字面上的 9.76。方向性結論 (時序計分下逐階改善、變異縮減類作法在時序 CV 下報酬放大)是穩健的部分。

重現本實驗的最短路徑:見第 7 節。

階段 5(外部想法注入) 經快評未勝過階段4:注入機制可運作、也產生了候選(stacking),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的 ERA 第二支柱誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
# 環境:Linux + uv(Python 由 uv 管理);執行目錄:專案根目錄
cd /home/tjyen/ai_agents/kaggle

# 0) 資料下載(需 KAGGLE_API_TOKEN;本場資料已在 data/ 內,可略過)
```

```

uv run kaggle competitions download -c playground-series-s3e19 \
  -p competitions/playground-series-s3e19/data
unzip -o competitions/playground-series-s3e19/data/playground-series-s3e19.zip \
  -d competitions/playground-series-s3e19/data

# 1) EDA(輸出資料概況與時序 CV 決策依據)
uv run python3 competitions/playground-series-s3e19/scripts/eda.py

# 2) 特徵工程(產出 data/train_processed.csv、data/test_processed.csv)
uv run python3 competitions/playground-series-s3e19/scripts/features.py

# 3) 主訓練:TimeSeriesSplit 5 折 + 00F 權重搜尋 + 全量重訓 + submission(第 2 次實驗)
uv run python3 competitions/playground-series-s3e19/scripts/train.py

# 4) (選用)2.4 / 第 3 次實驗:反思診斷,同特徵改用 shuffled KFold
uv run python3 competitions/playground-series-s3e19/scripts/diagnostic_kfold.py

# 5) 階段 3 迭代(依序;第 7 次實驗 產出現行最佳 submission)
uv run python3 competitions/playground-series-s3e19/scripts/train_ratio.py      # 第 4 次實驗(比例分解棄用)
uv run python3 competitions/playground-series-s3e19/scripts/train_seedbag.py   # 第 5 次實驗(3.4)
uv run python3 competitions/playground-series-s3e19/scripts/train_seedbag2.py  # 第 6 次實驗(3.4)
uv run python3 competitions/playground-series-s3e19/scripts/train_optuna.py    # 第 7 次實驗(3.2)

# 6) 4.2 / 第 8 次實驗:樹搜尋工具第 2 版(只算 00F 分數;軌跡存 experiments_tree.json)
uv run python3 tree_search/run_s3e19.py

# 7) 報告產生與驗證(本檔)
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e19
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py \
  competitions/playground-series-s3e19/REPORT.md competitions/playground-series-s3e19/facts.json
bash .claude/skills/kaggle-report/assets/md2pdf.sh competitions/playground-series-s3e19/REPORT.md \
  competitions/playground-series-s3e19/s3e19_REPORT.pdf

# 8) (選用)提交至 Kaggle(本場未執行;需有效之 KAGGLE_API_TOKEN)
uv run kaggle competitions submit -c playground-series-s3e19 \
  -f competitions/playground-series-s3e19/submissions/sub_6way_optuna_blend_10.01946_20260704_002039.cs
  -m "6-way blend: LGB seeds + CAT seeds + Optuna fold-5-proxy tuned LGB, time-based CV"

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 00F、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s3e19

```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 uv run 。