

# 競賽分析報告:playground-series-s3e19

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

| 目錄                |   |
|-------------------|---|
| 1. 競賽目的           | 1 |
| 2. 本場工具、專業術語與採用策略 | 2 |
| 2.1 本場工具          | 2 |
| 2.2 本場專業術語        | 2 |
| 2.3 採用策略          | 2 |
| 3. 實驗方法           | 3 |
| 3.1 資料規格          | 3 |
| 3.2 實驗總表          | 3 |
| 3.3 訓練規格表         | 5 |
| 3.4 推論表           | 5 |
| 3.5 評估指標          | 6 |
| 4. 實驗軌跡           | 6 |
| 5. 效能對照(逐階段)      | 7 |
| 6. 總結             | 8 |
| 7. 重現指令           | 9 |

## 1. 競賽目的

**What:**Playground Series S3E19 「Forecast mini-course sales」——依日期(date)、國家(country)、店面(store)、產品(product)四個維度,預測每日課程銷量 num\_sold。訓練資料為 2017–2021 年,測試集為整個 2022 年,是典型的多序列銷售時間序列外推問題。

**Why:**銷售預測直接影響備貨與行銷決策。評估指標為 **SMAPE(minimize)**:各序列量級 差異大(不同國家/店面/產品),絕對誤差類指標會被大量級序列主導;SMAPE 以真值與預測的 平均作分母,把誤差正規化為相對比例,讓大小序列的預測品質獲得同等權重,適合此類任務。

| 項目   | 值                       |
|------|-------------------------|
| 競賽   | playground-series-s3e19 |
| 問題型別 | regression              |
| 評估指標 | smape(minimize)         |
| 目標欄位 | num_sold                |

## 2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

### 2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第2版。交叉驗證採於排序後唯一日期上切分的 TimeSeriesSplit 5 折,另以隨機 KFold 執行一次 對照診斷(設計理由見第3.3節)。

### 2.2 本場專業術語

| 專業術語       | 定義                                                                   |
|------------|----------------------------------------------------------------------|
| (時序)/(隨機)  | 分數來源標記:時序 = TimeSeriesSplit 折的 OOF;隨機 = shuffled KFold 折的 OOF;兩者不可互比 |
| auto_scale | 對全體預測乘上一個在 OOF 上擬合的全域乘數(本場 $\times 1.02$ ),修正時序 OOF 系統性偏低            |
| 比例分解成員     | 把序列拆成「總量 $\times$ 各維度佔比」再組回預測的結構式成員(RatioDecomp);本場權重被搜尋歸零           |

### 2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);下表列本場使用情形。

| 階段  | 簡稱                 | 本場是否使用                         |
|-----|--------------------|--------------------------------|
| 1   | 無 skill 基線         | 使用                             |
| 1.1 | 單模型基線              | 使用                             |
| 1.2 | 三模型 blend          | 使用                             |
| 2   | kaggle-agent skill | 使用                             |
| 2.1 | EDA 驅動 CV 設計       | 使用(第2次實驗 改採時序切分,本場最重要決策)       |
| 2.2 | EDA 驅動特徵工程         | 使用(第2次實驗,20 個日期/類別特徵)          |
| 2.3 | 指標感知後處理            | 使用(log1p 目標與 expm1 反轉,第2次實驗 起) |
| 2.4 | 場內反思回退             | 使用(第3次實驗 反思診斷:分離 CV 方案與特徵效應)   |
| 3   | +線性自我迭代            | 使用                             |
| 3.1 | 經驗庫先驗              | 本場未使用(經驗庫晚於本場建立)               |
| 3.2 | Optuna 超參搜尋        | 使用(第7次實驗,只以第5折評分挑參)            |
| 3.3 | 調參入池               | 使用(含於3.2之作法)                   |
| 3.4 | seed bagging       | 使用(第5、6次實驗)                    |
| 3.5 | 結構化去噪              | 本場未使用                          |
| 4   | +樹搜尋               | 使用                             |
| 4.1 | 單模型節點樹             | 本場未使用                          |

| 階段  | 簡稱            | 本場是否使用       |
|-----|---------------|--------------|
| 4.2 | ensemble 節點樹  | 使用           |
| 4.3 | 先驗注入+去重       | 使用(v2 內建)    |
| 4.4 | 邊界推進 mutation | 本場未使用(無獨立紀錄) |
| 4.5 | 預算相位機         | 本場未使用        |
| 5   | +外部想法注入       | 本場未執行(全案規劃中) |
| 5.1 | 外部想法庫先驗       | 本場未執行        |
| 5.2 | 重組 mutation   | 本場未執行        |

## 3. 實驗方法

### 3.1 資料規格

| 項目       | 值                                        |
|----------|------------------------------------------|
| train 列數 | 136,950                                  |
| test 列數  | 27,375                                   |
| 原始欄位數    | 4(date/country/store/product;另有 id 與目標欄) |
| 特別規則摘要   | 禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次            |

目標 `num_sold` 為整數(mean 165.522636、median 98、max 1380),右偏(skew 1.747438), 為 log 轉換候選——全程以 `log1p` 目標訓練、`expm1` 反轉。train/test 皆無缺失值、無重複列; date 有 1,826 個唯一日期,test 的 2022 年日期**全部未在 train 出現**,EDA 的驗證建議 亦提示應採時間切分驗證以避免洩漏。

EDA 關鍵定性發現:5 國 × 3 店 × 5 產品共 75 條完整日序列;店面與 產品占年度總量的比例逐年幾乎恆定,國家占比則逐年漂移(外推最難的部分);週末與 12 月/ 1 月有明顯季節抬升、1 月 1 日單日尖峰;年度總量非單調(2020 下滑、2021 回升),無可靠 線性趨勢。

### 3.2 實驗總表

**語意澄清(本報告全文適用):**本場同時存在兩種 CV 方案——(時序)= TimeSeriesSplit 5 折(每折驗證區塊嚴格晚於訓練窗,模擬 train 2017–21 → test 2022 的外推缺口)與 (隨機)= shuffled KFold 5 折(內插式,對本任務系統性樂觀)。**兩種方案的分數不可互相比較**;所有 keep/reject 決策一律以(時序)分數為準。SMAPE 無取整/門檻類後處理,故 各實驗「原始 OOF」即「決策分數」,兩欄同值。

| 實驗編號 | 階段  | 模型/成員                        | 特徵數 | 原始 OOF        | 決策分數          | 是否採納             |
|------|-----|------------------------------|-----|---------------|---------------|------------------|
| 1    | 1.2 | LGB/XGB/<br>CAT(0.7/0.0/0.3) | 8   | 5.31891(隨機)   | 5.31891(隨機)   | 基線參照;與(時序)各實驗不可比 |
| 2    | 2   | LGB/XGB/<br>CAT(0.9/0.0/0.1) | 20  | 10.175397(時序) | 10.175397(時序) | 是,階段 2 最佳        |

| 實驗編號 | 階段  | 模型/成員                                            | 特徵數                        | 原始 OOF        | 決策分數          | 是否採納                             |
|------|-----|--------------------------------------------------|----------------------------|---------------|---------------|----------------------------------|
| 3    | 2.4 | LGB/XGB/<br>CAT(0.4/0.2/0.4)                     | 20                         | 4.281421(隨機)  | 4.281421(隨機)  | 否,僅診斷用,不入決策                      |
| 4    | 3   | LGB/CAT/比例分解<br>(0.95/0.05/0.0)                  | 20                         | 10.17489(時序)  | 10.17489(時序)  | 比例分解成員棄用<br>(權重 0;微幅增益僅來自較細權重網格) |
| 5    | 3.4 | LGB seed 42/2024 +<br>CAT(0.65/0.3/0.05)         | 20                         | 10.166045(時序) | 10.166045(時序) | 是                                |
| 6    | 3.4 | LGB×3 seeds + CAT×2<br>seeds(5-way)              | 20                         | 10.157212(時序) | 10.157212(時序) | 是                                |
| 7    | 3.2 | 6-way + Optuna 調參<br>LGB(權重 0.5)                 | 20                         | 10.019463(時序) | 10.019463(時序) | 是,線性迭代最終;現行最佳提交檔                 |
| 8    | 4.2 | 10-way blend +<br>auto_scale × 1.02(node<br>#17) | 20(池內含刪<br>冗餘欄位的檢<br>查型成員) | 9.75707(時序)   | 9.75707(時序)   | 是,本場誠實計分下最佳(僅 OOF 分數)            |

#### 最佳解成員表(第 8 次實驗,權重搜尋 + auto\_scale 全域乘數 1.02)

| 成員                  | 權重     | solo 分數   | 備註                                             |
|---------------------|--------|-----------|------------------------------------------------|
| SEEDBAG_TUNED_S3000 | 0.2559 | 9.990227  | 調參 LGB 之 seed 3000 變體                          |
| SEEDBAG_TUNED_S2024 | 0.2448 | 9.974778  | 調參 LGB 之 seed 2024 變體;solo 即勝過 第 7 次實驗 全 blend |
| LGB_S7              | 0.1989 | 10.19448  | 手設 LGB,seed 7                                  |
| CALSUBSET           | 0.1781 | 10.137705 | 刪 weekofyear 等冗餘欄重訓的檢查型成員                      |
| DEEPLGB             | 0.0746 | 10.347073 | 刻意多樣化之深/輕正則 LGB;solo 弱但有貢獻                     |
| LGB_S42             | 0.0238 | 10.177577 | 手設 LGB,seed 42                                 |
| LGB_S2024           | 0.0115 | 10.210617 | 手設 LGB,seed 2024                               |
| LGB_TUNED_ROOT      | 0.0089 | 10.148325 | 搜尋根節點 = 第 7 次實驗 之 Optuna 調參 LGB                |
| CAT_S2024           | 0.0032 | 10.983835 | 手設 CatBoost,seed 2024                          |
| CAT_S42             | 0.0003 | 10.730642 | 手設 CatBoost,seed 42                            |

選型脈絡:三種梯度提升樹是中型表格資料的標準組合,皆原生支援類別特徵。外推情境下 LGB 明顯領先,XGB 兩度被權重搜尋歸零後移除;第 4 次實驗 的結構式比例分解成員(solo 14.75038) 也被歸零——GBDT 的原生類別分裂已學走佔比結構,真正瓶頸(總量一年外推)對所有方法一視同仁。第 8 次實驗 的兩個決定性作法:對調參 LGB 做 seed bagging(調參只以第 5 折評分挑參、未對全 OOF 擬合,留有真實 seed 變異可平均消除),與修正時序 OOF 系統性偏低約 2% 的全域 × 1.02 乘數(每折驗證區塊皆晚於訓練窗、序列成長至 2021,此偏差結構上與真實 2022 缺口同型)。

**補充說明(第 8 次實驗 與最佳解的計分方式;全文其他引用處不再重複):** 1. 最佳解紀錄以分數最小選出,落在 第 3 次實驗(4.281421)——那是(隨機) 診斷量尺的產物,不可作為本場最佳;誠實計分((時序))下的最佳為 第 8 次實驗。2. 第 8 次實驗 為樹搜尋結果,只算出 OOF 分數:未產生 test 預測、無 submission 檔、未提交 Kaggle;「現行最佳提交檔」

屬第 7 次實驗(見第 3.4 節)。3. **9.75707 帶雙重但書**:(a)與第 2-7 次實驗相同,fold 5 既是 Optuna 調參目標又佔 OOF 的 1/5,分數含 fold 5 雙重使用的樂觀成分;(b)第 8 次實驗額外的 scale 乘數與 seed 挑選皆直接對 OOF 擬合(無巢狀驗證)。各為 1 至數個參數、擬合於 114,000 列 OOF,單項過擬風險低,但真實可期望的 2022 SMAPE 應解讀為「明顯低於 10.02」,而非字面上的 9.76。

### 3.3 訓練規格表

| 實驗編號 | CV 方案                                                   | folds | seed             |
|------|---------------------------------------------------------|-------|------------------|
| 1    | 5fold(隨機)                                               | 5     | 無紀錄              |
| 2    | TimeSeriesSplit-5fold-on-unique-dates                   | 5     | 無紀錄              |
| 3    | KFold-5fold-shuffled-seed42                             | 5     | 無紀錄(方案名含 seed42) |
| 4-7  | TimeSeriesSplit-5fold-on-unique-dates(與第 2 次實驗同折)       | 5     | 無紀錄              |
| 8    | TimeSeriesSplit-5fold-on-unique-dates(逐位驗證與第 2-7 次實驗同折) | 5     | 無紀錄              |

**為何用此 CV:**測試期(2022)完全落在訓練期之後、零日期重疊,模型實際面對「外推到未見年份」;隨機 KFold 讓驗證日夾在已見季節循環之間,對本任務系統性樂觀。故主軌跡在排序後的唯一日期上做 TimeSeriesSplit,每折以擴張窗訓練、驗證嚴格較晚的日期區塊。第 3 次實驗刻意改回與基線同型態的隨機 KFold,僅作為特徵集有效性的對照診斷,不用於選模。

Objective:log1p(num\_sold) 迴歸,預測經 expm1 反轉後計 SMAPE。關鍵超參(有紀錄者):

```
LGB(手設,第 2 次實驗): n_estimators=2000, learning_rate=0.03, num_leaves=63,
                        min_child_samples=20, subsample=0.9, colsample_bytree=0.8, reg_lambda=1.0
XGB(手設,第 2 次實驗): n_estimators=2000, learning_rate=0.03, max_depth=7,
                        subsample=0.9, colsample_bytree=0.8, reg_lambda=1.0
CAT(手設,第 2 次實驗): iterations=2000, learning_rate=0.05, depth=8, l2_leaf_reg=3.0
LGB_tuned(Optuna,第 7 次實驗):learning_rate≈0.0371, num_leaves=20, min_child_samples=38,
                        subsample≈0.61, colsample_bytree≈0.90, reg_alpha≈0.001,
                        reg_lambda≈0.43, n_estimators=2000
```

調參版比手設更淺、更強正則(num\_leaves 63 → 20),與「外推情境獎勵正則化」的跨賽經驗一致。特徵 20 個:year、month、day、dow、day\_of\_year、weekofyear、quarter、is\_weekend、is\_month\_start、is\_month\_end、is\_new\_year、month/dow/doy 之 sin/cos、country\_cat、store\_cat、product\_cat(類別欄原生餵入三模型)。

### 3.4 推論表

| 實驗編號 | 後處理      | submission 檔                                           | 是否已提交 |
|------|----------|--------------------------------------------------------|-------|
| 1    | 無後處理紀錄   | sub_generic_5.31891_20260703_121406.csv                | 否     |
| 2    | expm1 反轉 | sub_lgb_xgb_cat_blend_10.17540_20260703_194908.csv     | 否     |
| 3    | expm1 反轉 | 無(診斷用,未產生提交檔)                                          | 否     |
| 4    | expm1 反轉 | sub_lgb_cat_rd_blend_10.17489_20260704_000355.csv      | 否     |
| 5    | expm1 反轉 | sub_lgb_seedbag_cat_blend_10.16605_20260704_000957.csv | 否     |

| 實驗編號 | 後處理                                                 | submission 檔                                             | 是否已提交 |
|------|-----------------------------------------------------|----------------------------------------------------------|-------|
| 6    | expm1 反轉                                            | sub_lgb3seed_cat2seed_blend_10.15721_20260704_001501.csv | 否     |
| 7    | expm1 反轉、負值截 0                                      | sub_6way_optuna_blend_10.01946_20260704_002039.csv       | 否     |
| 8    | expm1 反轉 +<br>auto_scale $\times 1.02$ (OOF<br>內擬合) | 無(僅 OOF 分數,未產生 test 預測)                                  | 否     |

原始紀錄無正式後處理欄位,表中後處理描述取自各實驗的文字備註。submission 為兩欄 格式(id 欄 id、目標欄 num\_sold)。本場為無人值守批次執行,全程未提交 Kaggle;第 7 次實驗 檔案為現行最佳提交檔,其成員以各自超參在 100% 訓練資料上重訓後按權重加權平均,預測 mean 178.2 / max 1432.9,對成長中的 2022 屬合理範圍。

### 3.5 評估指標

指標定義:SMAPE = 對每筆取  $|真值 - 預測|$  除以兩者絕對值之平均,再對全體取平均並以 百分比表示;對稱化的相對誤差,越低越好。

| 項目                         | OOF SMAPE(時序)  |
|----------------------------|----------------|
| LGB_tuned(第 7 次實驗 成員,最佳單模) | 10.14833       |
| LGB_s42(第 7 次實驗 成員)        | 10.17758       |
| LGB_s2024(第 7 次實驗 成員)      | 10.21059       |
| LGB_s7(第 7 次實驗 成員)         | 10.19446       |
| CAT_s42(第 7 次實驗 成員)        | 10.73064       |
| CAT_s2024(第 7 次實驗 成員)      | 10.98383       |
| Ensemble(第 7 次實驗,線性迭代終點)   | 10.019463      |
| Ensemble(第 8 次實驗,樹搜尋 best) | <b>9.75707</b> |
| Public / Private LB        | 無紀錄(未提交)       |

本場未提交 Kaggle,無排行榜紀錄,故無排行榜表,CV↔LB gap 無法計算。主要改善幅度:

階段 3 淨改善(同折時序):  $10.175397 - 10.019463 = 0.155934, 0.155934 / 10.175397 \approx 1.53\%$   
 樹搜尋再改善(同折時序):  $10.019463 - 9.75707 = 0.262393, 0.262393 / 10.019463 \approx 2.62\%$   
 跨方案差距(同特徵同模型):  $10.175397 - 4.281421 = 5.893976$  — 全部來自外推 vs 內插  
 的驗證難度差,不是模型退步

## 4. 實驗軌跡

| 實驗編號 | 時間                  | 決策分數        | 階段  | 摘要                          |
|------|---------------------|-------------|-----|-----------------------------|
| 1    | 2026-07-03T12:14:06 | 5.31891(隨機) | 1.2 | 8 通用特徵三模型 blend,隨機 KFold 計分 |

| 實驗編號 | 時間                  | 決策分數                | 階段  | 摘要                                                   |
|------|---------------------|---------------------|-----|------------------------------------------------------|
| 2    | 2026-07-03T19:49:08 | 10.175397(時序)       | 2   | 20 特徵 + log1p 目標,改採誠實的時序 CV                          |
| 3    | 2026-07-03T19:53:27 | 4.281421(隨機)        | 2.4 | 同特徵改回隨機 KFold,證明變差來自 CV 方案而非特徵                       |
| 4    | 2026-07-04T00:03:25 | 10.17489(時序)        | 3   | 比例分解成員權重歸零,結構信號輸給 GBDT                               |
| 5    | 2026-07-04T00:09:24 | 10.166045(時序)       | 3.4 | LGB seed bagging(+seed 2024)                         |
| 6    | 2026-07-04T00:13:58 | 10.157212(時序)       | 3.4 | 擴充 seed bagging(+LGB s7、+CAT s2024)                  |
| 7    | 2026-07-04T00:19:34 | 10.019463(時序)       | 3.2 | Optuna 調參 LGB(只以第 5 折評分挑參)入池,線性最大單輪增益                |
| 8    | 2026-07-04T12:18:09 | <b>9.75707</b> (時序) | 4.2 | 10-way blend + auto_scale,node #17(22 節點,耗時 321.0 秒) |

- **突破點 1(第 2→3 次實驗,關鍵轉折):**第 2 次實驗 表面上大幅變差(5.31891 → 10.175397), 診斷以完全相同的特徵/模型改回隨機 KFold 得 4.281421——優於基線,證明特徵工程有效、 差距純粹來自「時序驗證是更誠實的量尺」;教訓:不同 CV 方案的分數永不互比。
- **突破點 2(第 6→7 次實驗):**時序折不可互換,故 Optuna 只以訓練窗最大、最接近 2022 外推情境的 fold 5 評分挑參;調參 LGB solo 10.14833(最佳單模)入池後拿 0.5 權重, blend 10.157212 → 10.019463,線性階段最大增益。
- **突破點 3(第 7→8 次實驗):**樹搜尋的兩個作法——seed-bag 調參 LGB(SEEDBAG\_TUNED\_S2024 solo 9.974778,單模即勝過 第 7 次實驗 全 blend)與 auto\_scale × 1.02(單筆最大增益 -0.168)——合計把分數推至 9.75707(見第 3.2 節補充說明)。

5. 效能對照(逐階段)

| 階段 | 配置                                         | 分數                       | 相對改善          |
|----|--------------------------------------------|--------------------------|---------------|
| 1  | 基線(Claude Code 直接執行,未引入 skill;第 1 次實驗通用批次) | 無可比分數(隨機 KFold 計分,見下方注記) | —(基線;無可比)     |
| 2  | + kaggle-agent skill 六階段流程(第 2 次實驗,時序 CV)  | 10.175397                | —(本場逐階比較的基準)  |
| 3  | + self-improvement 線性迭代(第 7 次實驗,四輪終點)      | 10.019463                | 見下方算式(階段 2→3) |
| 4  | + 樹搜尋(第 8 次實驗,node #17)                    | <b>9.75707</b>           | 見下方算式(階段 3→4) |

階段2→3:  $10.175397 - 10.019463 = 0.155934$ , 相對改善  $0.155934 / 10.175397 \approx 1.53\%$   
階段3→4:  $10.019463 - 9.75707 = 0.262393$ , 相對改善  $0.262393 / 10.019463 \approx 2.62\%$   
階段2→4:  $10.175397 - 9.75707 = 0.418327$ , 相對改善  $0.418327 / 10.175397 \approx 4.11\%$   
(與跨場彙總報告主表計分方式一致:該表相對變化欄改報 階段2→3 與 階段2→4)

同 CV 方案(隨機 KFold)對照診斷(僅供 CV 方案偏差參考,不併入上表):  
通用批次 5.31891 → 同特徵同模型診斷重跑 4.281421,改善  $\approx 19.51\%$

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

**CV 計分方式註記(s3e19 特殊場次):**階段 1 的通用批次實驗(第 1 次實驗,5.31891)使用 隨機 KFold,而階段 2/3/4 皆使用 TimeSeriesSplit——test 為嚴格未來期,時序 CV 才是誠實量尺,兩方案分數**不可比**(見第 3.2 節澄清),故階段 1 標「無可比分數」,逐階算式改以階段 2 為基準報 階段2→3 與 階段3→4(另附 階段2→4)。skill 特徵/模型層面的真實增益由上方**同 KFold 診斷對**(5.31891 → 4.281421)單獨 呈現,僅作側面診斷,不併入主表任何階段計算。階段 4 的 9.75707 另帶雙重但書 (fold 5 雙重使用 + scale/seed 對 OOF 擬合),詳見第 3.2 節補充說明,此處不重複; 依該但書,真實可期望的 2022 SMAPE 應讀作「明顯低於 10.02」,而非字面上的 9.76。

**子階段分數表**(定義見第 2.3 節;僅列本場有既有紀錄者)

| 子階段                                              | 分數             | 出處      |
|--------------------------------------------------|----------------|---------|
| 1.1(最佳單模:LGB,隨機 KFold 計分)                        | 5.45633        | 第 1 次實驗 |
| 1.2(三模權重 blend,隨機 KFold 計分)                      | 5.31891        | 第 1 次實驗 |
| 3.2(Optuna 調參 LGB——只以第 5 折評分挑參,加入池,線性迭代最大單輪增益)   | 10.019463      | 第 7 次實驗 |
| 3.4(seed bagging,+LGB seed 2024)                 | 10.166045      | 第 5 次實驗 |
| 3.4(seed bagging 擴充,+LGB seed 7、+CAT seed 2024)  | 10.157212      | 第 6 次實驗 |
| 4.2(樹搜尋 node #17,10-way blend + auto_scale,本場最佳) | <b>9.75707</b> | 第 8 次實驗 |

## 6. 總結

本場資料乾淨而結構鮮明:75 條完整日序列、無缺失無重複,店面/產品年度佔比近乎恆定、國家佔比逐年漂移,目標右偏經 log1p 對稱化;測試期為嚴格未來的 2022 年,決定了本場 最重要的一步——以 TimeSeriesSplit 取代 隨機 KFold 作為唯一決策量尺。

關鍵決策有三:其一,第 3 次實驗 的反思診斷把「分數變差」歸因到 CV 方案而非特徵,避免誤判退步;其二,第 4 次實驗 誠實棄用比例分解——結構要贏 GBDT,目標須在該維度跨年近乎 恆定,而本場總量本身不可外推;其三,第 7 次實驗 調參時只以第 5 折評分挑參,選出更淺更正則的 LGB。

增益來源清楚分層:階段 2 建立時序計分基準(10.175397);階段 3 靠 seed bagging 與 Optuna 調參推進至 10.019463(約 1.53%);樹搜尋再以「seed-bag 調參 LGB」與「auto\_scale  $\times 1.02$  修正時序 OOF 系統性偏低」兩個作法推至 9.75707(約 2.62%)——後者是所有已跑樹搜尋 場次中相對幅度最大的一場,且兩個作法都是 線性階段明確列為「未試」的想法。

可信度方面須誠實:全程未提交 Kaggle、無排行榜對照;9.75707 帶雙重但書(見第 3.2 節), 真實可期望的 2022 SMAPE 應解讀為「明顯低於 10.02」,而非字面上的 9.76。方向性結論 (時序計分下逐階改善、變異縮減類作法在時序 CV 下報酬放大)是穩健的部分。

**重現本實驗的最短路徑:**見第 7 節。

## 7. 重現指令

```
# 環境:Linux + uv(Python 由 uv 管理);執行目錄:專案根目錄
cd /home/tjyen/ai_agents/kaggle

# 0) 資料下載(需 KAGGLE_API_TOKEN;本場資料已在 data/ 內,可略過)
uv run kaggle competitions download -c playground-series-s3e19 \
    -p competitions/playground-series-s3e19/data
unzip -o competitions/playground-series-s3e19/data/playground-series-s3e19.zip \
    -d competitions/playground-series-s3e19/data

# 1) EDA(輸出資料概況與時序 CV 決策依據)
uv run python3 competitions/playground-series-s3e19/scripts/eda.py

# 2) 特徵工程(產出 data/train_processed.csv、data/test_processed.csv)
uv run python3 competitions/playground-series-s3e19/scripts/features.py

# 3) 主訓練:TimeSeriesSplit 5 折 + 00F 權重搜尋 + 全量重訓 + submission(第 2 次實驗)
uv run python3 competitions/playground-series-s3e19/scripts/train.py

# 4) (選用)2.4 / 第 3 次實驗:反思診斷,同特徵改用 shuffled KFold
uv run python3 competitions/playground-series-s3e19/scripts/diagnostic_kfold.py

# 5) 階段 3 迭代(依序;第 7 次實驗 產出現行最佳 submission)
uv run python3 competitions/playground-series-s3e19/scripts/train_ratio.py      # 第 4 次實驗(比例分解棄用)
uv run python3 competitions/playground-series-s3e19/scripts/train_seedbag.py   # 第 5 次實驗(3.4)
uv run python3 competitions/playground-series-s3e19/scripts/train_seedbag2.py  # 第 6 次實驗(3.4)
uv run python3 competitions/playground-series-s3e19/scripts/train_optuna.py    # 第 7 次實驗(3.2)

# 6) 4.2 / 第 8 次實驗:樹搜尋工具第 2 版(只算 00F 分數;軌跡存 experiments_tree.json)
uv run python3 tree_search/run_s3e19.py

# 7) 報告產生與驗證(本檔)
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e19
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py \
    competitions/playground-series-s3e19/REPORT.md competitions/playground-series-s3e19/facts.json
bash .claude/skills/kaggle-report/assets/md2pdf.sh competitions/playground-series-s3e19/REPORT.md \
    competitions/playground-series-s3e19/s3e19_REPORT.pdf

# 8) (選用)提交至 Kaggle(本場未執行;需有效之 KAGGLE_API_TOKEN)
uv run kaggle competitions submit -c playground-series-s3e19 \
    -f competitions/playground-series-s3e19/submissions/sub_6way_optuna_blend_10.01946_20260704_002039.cs
    -m "6-way blend: LGB seeds + CAT seeds + Optuna fold-5-proxy tuned LGB, time-based CV"
```

執行目錄為專案根目錄 /home/tjyen/ai\_agents/kaggle ;所有 Python 執行皆透過 uv run 。