

競賽分析報告:playground-series-s3e20

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-04

1. 競賽目的

What:本競賽(Predict CO2 emissions in Rwanda using satellite data)要求以盧安達境內 497 個地理位置在 2019–2021 年的衛星感測資料(雲層、氣膠、UV 等 75 個欄位)與時空座標 (latitude / longitude / year / week_no),預測 2022 年各位置每週的二氧化碳排放量 (emission)。本質上是一個「跨年外推」的時空面板迴歸問題。

Why:區域級 CO2 排放估計是碳監測與環境政策的基礎,而衛星遙測是缺乏地面監測站地區 (如盧安達) 唯一可規模化的資料來源。評估指標為 RMSE(minimize):目標高度右偏 (median 45.6、mean 81.9、max 3167.8),RMSE 的平方懲罰使大排放源的預測誤差主導總分,與「抓準高排放熱點」的實務需求一致。

項目	值
競賽	playground-series-s3e20
URL	https://www.kaggle.com/competitions/playground-series-s3e20
問題型別	regression
評估指標	rmse(minimize)
目標欄位	emission
ID 欄位	ID_LAT_LON_YEAR_WEEK

⚠ 本競賽 Late Submission 已關閉,無法上傳提交;全程僅以本地 CV(OOF)評估, leaderboard 無紀錄。

2. 資料規格

- 檔案: train.csv / test.csv / sample_submission.csv 。
- 時序結構:train 為 2019–2021 三個年度、test 為 2022 年; week_no 0–52 。
- 空間結構:latitude / longitude(盧安達境內,497 個唯一位置)。
- 特徵:75 個欄位,多數來自衛星感測(Cloud、Aerosol、UV 量測群組)。

- 缺失:部分特徵群組缺失極重(UvAerosolLayerHeight 群組達 99.4%);v2 起將 >90% 缺失的 7 個感測欄位刪除,保留 63 個感測欄位(來源:facts.json best.features:「70 base (63 sensors, dropped 7)」)。
- 目標分布:重度右偏(median 45.6、mean 81.9、max 3167.8),訓練時取 log1p。
- 特別規則:外部資料不允許、預訓練模型不允許、internet 不允許、每日提交上限 5。
- 關鍵資料性質(EDA 驗證,見 STATUS.md):同一 (latitude, longitude, week_no) 的 emission 跨年近乎恆定 —— 這是全場最重要的結構訊號。

3. 模型規格

最佳實驗(exp #7, train_v5.py)為 4 成員 blend:三個 GBDT + 一個「去噪後的 location-week 歷史均值」(TE)結構預測器。

成員	OOF RMSE
LGB	32.074
XGB	28.0674
CAT	28.8466
TE (denoised loc-week mean)	21.1487

Ensemble(OOF simplex 粗網格權重搜尋):

成員	權重
LGB	0.0
XGB	0.0
CAT	0.0
TE	1.0

Blend OOF RMSE = 21.1487(等於 TE 單體 —— 權重搜尋把三個 GBDT 全數歸零)。

選型理由:v2(exp #4)已發現純 loc-week 歷史均值(22.6488)完勝任何 GBDT (最佳 GBDT blend 28.3424,exp #3),且權重搜尋將全部權重給予 TE。Phase-B(exp #5-#7) 因此把改進重心放在 TE 本身的三項去噪: 1. **經驗貝葉斯收縮**(exp #5):每折 cell 均值僅 n=2 個觀測,向 ~106 個觀測的 location 均值收縮($\alpha=0.935$)。 2. **COVID 年降權**(exp #6):2020 年排放受疫情壓低,計算歷史均值時將該年權重降至 W2020=0.29(完全排除比降權更差)。 3. **鄰週平滑**(exp #7):cell 均值與同位置 week ± 1 的 cell 均值加權平均(WNB=0.28); 此步驟吸收了第 1 項的收縮(α 重調後收斂至 1.0)。

GBDT 保留在 pool 中僅作對照,每輪權重搜尋均自動淘汰(權重 0)。

4. 訓練規格

項目	值
CV 方案	Leave-One-Year-Out (2019/2020/2021)
折數	3
seed	42

- **為何用此 CV:** test 為未來年度(2022), LOYO 每折保留一整年作驗證, 忠實模擬「以其他年度歷史預測整年」的真實情境; 目標編碼(TE)每折僅用訓練年度計算, 無洩漏。v3-v5 與 v2 完全同折, 分數全程可比。
- GBDT objective: RMSE on log1p(emission), 預測後 expm1 還原。
- GBDT 詳細超參: facts.json 無紀錄(與 v2 一致未改動; 實際數值見 `scripts/train_v5.py` 的 `run_models`)。
- TE 超參(exp #7): $\alpha=1.0$ 、 $w_{2020}=0.24$ 、 $w_{nb}=0.28$ (在同一 LOYO CV 上以網格 pre-sweep 選定)。

5. 推論程序

- 後處理: `clip >= 0` (排放量不可為負; 來源: facts.json best.postprocess)。
- 最終 test 預測: TE 以「全部三個訓練年度」重算歷史均值(套用同一組 w_{2020} / w_{nb} 參數) 後直接輸出(blend 權重 TE=1.0)。
- Submission: `sub_v5_blend_21.1487_20260704_011931.csv`, 格式兩欄:
`ID_LAT_LON_YEAR_WEEK, emission` (列數同 test 集)。
- 註: 競賽已關閉, 此檔為 artifact, 無法實際上傳。

6. 評估指標

RMSE = 預測誤差平方均值的平方根, 對大誤差施以平方級懲罰。

分數總表(最佳實驗 exp #7, LOYO OOF):

項目	OOF RMSE
LGB	32.074
XGB	28.0674
CAT	28.8466
TE (denoised loc-week mean)	21.1487

項目	OOF RMSE
Ensemble(TE=1.0)	21.1487
Public/Private LB	無紀錄(Late Submission 已關閉)

CV↔LB gap:無紀錄(無 LB 分數可比)。

7. 實驗軌跡

exp #	timestamp	OOF RMSE	source_format
1	20260214_161647	38.507172	v2
2	20260214_161743	33.205568	v2
3	2026-07-03T09:59:53	28.3424	v2
4	2026-07-03T10:12:09	22.6488	v2
5	2026-07-04T00:58:26	22.4897	v2
6	2026-07-04T01:16:24	21.6317	v2
7	2026-07-04T01:19:31	21.1487	v2
8	2026-07-04T01:35:00	21.1487	v2

突破點: - **exp #3** → **#4**(28.3424 → 22.6488):把「純 loc-week 歷史均值」加入 blend pool, 權重搜尋將全部權重給予該成員 —— 確立本場的訊號本質是結構而非感測特徵。 - **exp #6**(22.4897 → 21.6317):單輪最大增益,來自 2020 COVID 年降權($W_{2020}=0.29$)。 - **exp #7**(21.6317 → 21.1487):鄰週 (week±1)平滑,最終最佳。 - **exp #8**(分數不變,診斷輪):(a) 平滑窗加寬至 ±2/±3 週全部變差;(b) LGB 殘差模型 (訓練於 $y - TE$)以任何比例加回皆變差 —— 證明感測特徵連殘差都無法解釋,結構已飽和 全部可預測訊號。此為刻意保留的負向結果紀錄。

無法解析之紀錄:無。

8. 重現指令

```
# 執行目錄:專案根目錄 /home/tjyen/ai_agents/kaggle(依 CLAUDE.md 使用 uv 管理環境)
# 0) 環境
uv sync

# 1) 資料(競賽已關閉,若 API 仍可下載歷史資料)
export KAGGLE_API_TOKEN=<your_token>
```

```
uv run kaggle competitions download -c playground-series-s3e20 \
    -p competitions/playground-series-s3e20/data
unzip -o competitions/playground-series-s3e20/data/playground-series-s3e20.zip \
    -d competitions/playground-series-s3e20/data

# 2) v2 baseline(LOYO CV + loc-week TE + 3 GBDT blend;log 至 experiments.json)
uv run python competitions/playground-series-s3e20/scripts/train_v2.py

# 3) Phase-B 迭代(一輪一改動,分數全程與 v2 同折可比)
uv run python competitions/playground-series-s3e20/scripts/train_v3.py # +EB 收縮 (
uv run python competitions/playground-series-s3e20/scripts/train_v4.py # +COVID 降權
uv run python competitions/playground-series-s3e20/scripts/train_v5.py # +鄰週平滑 (
# 產出:competitions/playground-series-s3e20/submissions/sub_v5_blend_*.csv
# (競賽 Late Submission 已關閉,無提交指令)
```

