

競賽分析報告:playground-series-s3e20

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

目錄

1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	4
3.3 訓練規格表	5
3.4 推論表	5
3.5 評估指標	6
4. 實驗軌跡	6
5. 效能對照(逐階段)	7
6. 總結	8
7. 重現指令	9

1. 競賽目的

What:以盧安達境內 497 個地理位置在 2019–2021 年的衛星感測資料(SulphurDioxide、CarbonMonoxide、Cloud、Aerosol、UV 等量測群組)與時空座標(latitude / longitude / year / week_no),預測 2022 年各位置每週的二氧化碳排放量 `emission` ——本質是「跨年外推」的 時空面板迴歸問題。

Why:區域級 CO2 排放估計是碳監測與環境政策的基礎,衛星遙測是缺乏地面監測站地區唯一 可規模化的資料來源。評估指標為 **RMSE(minimize)**:目標高度右偏(median 45.6、mean 81.9、max 3167.8),RMSE 的平方級懲罰使大排放源的誤差主導總分,與「抓準高排放熱點」的 實務需求一致。

項目	值
競賽	playground-series-s3e20
問題型別	regression
評估指標	rmse(minimize)
目標欄位	emission

補充說明(本報告全文適用):本競賽為 2023 年已關閉的舊競賽,逾期提交管道已關閉,任何預測皆無法上傳;全場所有分數均為本機 Leave-One-Year-Out OOF(CV-only),排行榜無紀錄。

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

交叉驗證採逐年留出的 Leave-One-Year-Out 3 折(LOYO,定義見第 2.2 節;設計理由見 第 3.3 節)。本場未使用 Optuna(結構管線超參以網格預掃與樹搜尋調校)。其餘全數為 共同工具鏈(見《前言》第 3 節);樹搜尋工具本場使用第 2 版(把結構管線的純量超參 當節點空間搜尋)。

2.2 本場專業術語

專業術語	定義
LOYO	Leave-One-Year-Out:2019/2020/2021 逐年留出的 3 折交叉驗證,模擬「以其他年度預測一整年」
TE(loc-week 歷史均值)	以同一(位置,週)組合在其他訓練年度的 emission 平均值直接作預測的結構成員(《前言》§5 目標編碼的本場應用)
經驗貝葉斯收縮	把資料少的組合均值往上一層均值拉近的去噪法,拉近幅度依資料量自動決定
year_weights	對各訓練年度的觀測值賦予不同權重的結構參數(如 2020 異常年降權)
JOINT(聯合移動)	樹搜尋中把全部結構參數一步同時調整的節點型態(TE_JOINT 為其節點名)

2.3 採用策略

各階段與子階段的定義見《前言》第 6 節(編號跨場同義);主階段 1-4 本場皆有執行,各子階段採用情形如下。

階段 1 | 無 skill 基線

- 1.1 單模型基線 — 使用(代理)
- 1.2 三模型 blend — 使用(代理)

階段 2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(LOYO 逐年留出設計)
- 2.2 EDA 驅動特徵工程 — 使用(第 4 次實驗,TE 成員入池)
- 2.3 指標感知後處理 — 使用(log1p 目標、clip ≥ 0)
- 2.4 場內反思回退 — 本場未使用

階段 3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 本場未使用(未使用 Optuna)
- 3.3 調參入池 — 本場未使用
- 3.4 seed bagging — 本場未使用
- 3.5 結構化去噪 — 使用(第 5-7 次實驗 三段去噪,本場主軸)

階段 4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 使用(節點為結構管線參數組合)
- 4.3 先驗注入+去重 — 使用(v2 內建)
- 4.4 邊界推進 mutation — 本場未使用(無獨立紀錄)
- 4.5 預算相位機 — 本場未使用

階段 5 | +外部想法注入

- 5.1 外部想法庫先驗 — 使用(快評注入 stacking meta 模型,在階段4收斂點以快取 OOF 評估;數值雖低但係 tier4 排除的 CV 噪音、非真增益 → 階段5=階段4)
- 5.2 重組 mutation — 本場未使用(機制已建置[harness_v4 機械版 + LLM 版];跨場 pilot 實測與 mega-blend 搜尋冗餘、無增益,見 docs/recombine_findings)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	79,023
test 列數	24,353
原始欄位數	74
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

特徵全為數值型、無類別欄位:時空座標 4 欄 + 衛星感測欄位(Cloud、Aerosol、UV 等群組)。目標 `emission` 重度右偏(mean 81.940552、median 45.593445、skew 10.173826、max 3167.768),為 log 轉換候選,訓練一律取 log1p;train 無重複列。

補充說明:本次分析記錄欄位數 74;另一份競賽說明與進度筆記則為「75 個 特徵」,兩者計算方式不同(前者為 EDA 實際掃描之特徵欄計數)。本報告以本次分析為準。

資料品質重點在缺失:UvAerosolLayerHeight 群組 7 欄缺失 78,584/79,023 列(紀錄記為 99.4%),v2 起直接刪除,保留 63 個感測欄;SulphurDioxide/NitrogenDioxide 群組亦有中度 缺失。感測欄位間高共線對眾多(各群組 solar_azimuth_angle 兩兩相關逾 0.98),且單一感測 特徵與目標的相關性極弱——與後續「感測特徵對此目標近乎噪音」的建模結論一致。

3.2 實驗總表

語意澄清(本報告全文適用):RMSE 無取整/門檻類後處理,各實驗「原始 OOF」即「決策 分數」,兩欄同值;第 1-2 次實驗 為 2026-02-14 舊 session 的單一時間切分結果,與 第 3 次實驗 起的 Leave-One-Year-Out CV **不可直接比較**,僅列入軌跡供完整性。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	—(舊 session)	LGB/XGB/Ridge 權重 blend	102	38.507172	38.507172	否,Ridge 失敗、CV 與後續不可比
2	—(舊 session)	LGB/XGB(50/50)	無紀錄	33.205568	33.205568	否,同上
3	1 (代理)	LGB/XGB/CAT 三 GBDT blend(0/.75/.25)	70 + TE 欄	28.3424	28.3424	基線參照(代理,見第 5 節)
4	2	三 GBDT + TE(loc-week 均值)四成員 blend	70 + TE 欄	22.6488	22.6488	是,權重搜尋給 TE 100%
5	3.5	同 第 4 次實驗,TE 加經驗貝葉斯收縮($\alpha=0.935$)	70 + TE 欄	22.4897	22.4897	是
6	3.5	同上,加 COVID 年降權(W2020=0.29, $\alpha=0.945$)	70 + TE 欄	21.6317	21.6317	是,線性階段最大單輪增益
7	3.5	同上,加鄰週平滑(WNB=0.28, α 收斂至 1.0)	70 + TE 欄	21.1487	21.1487	是,線性迭代最終
8	3 (診斷)	寬窗平滑 + LGB 殘差模型(皆棄用)	63 感測 + 時空欄	21.1487	21.1487	—(診斷,依協定停止)
9	4.2	純結構 TE_JOINT(node #28)	無紀錄	21.0589	21.0589	是,本場最佳
10	5	外部注入快評候選(EXT-09(stacking);沿用階段4成員 OOF)	無紀錄	20.812940	20.812940	否(僅 CV 噪音、非真增益,見 § 5)

最佳解成員表(第 9 次實驗,樹搜尋 node #28,純結構單一成員)

成員	權重	solo 分數	備註
TE_JOINT	—(單一成員,無 blend)	21.0589	loc-week 歷史均值管線: $\alpha=0.99$ 、w2020=0.2、wnb=0.3、window=1,加新軸 year_weights(2019: 0.6/2020: 0.2/2021: 1.2)

選型脈絡:第 3 次實驗 的純 GBDT blend 是本場 GBDT 能力上限;第 4 次實驗 把「loc-week 歷史均值」以獨立成員放入池,權重搜尋直接給它 100%、三個 GBDT 全歸零——確立訊號本質是結構而非感測特徵。階段 3(第

5-7 次實驗)遂只對 TE 本身做三段去噪(收縮、COVID 降權、鄰週平滑),第 8 次實驗 以寬窗與 殘差模型雙診斷 確認結構已飽和可預測訊號後停止線性迭代。

第 9 次實驗 由樹搜尋工具產出:重掃描已手調參數(W2020、WNB)僅誠實打平階段 3 既有最優;增益來自(a)階段 3 從未試過的新參數 year_weights(異常年降權推廣到 2019/2021),與 (b)JOINT lineage 把全部結構參數一步共同移動,複合出 -0.0898 的總增益。

補充說明:最佳解紀錄(第 9 次實驗)以 OOF 分數最小選出,為樹搜尋結果、只算出 OOF 分數——未產生 test 預測、無 submission 檔,且本場逾期提交管道已關閉,實務上也無法提交。node #28 另有手足 BLEND 節點(21.0332,本報告與跨場彙總均**不採用**):其將診斷用 GBDT 以 2.17% 權重混入,僅在 3 折 LOYO CV、權重直接對同一份 OOF 擬合下才勝出,進度筆記明確記為低信心、CV 噪音範圍內的微小發現;採用純結構節點是刻意的保守方法選擇,非疏漏。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1-2	time-based 單一切分(2019-2020 train,2021 val)	無紀錄	42
3-9	Leave-One-Year-Out(2019/2020/2021)	3	42

為何用 LOYO:test 為未來年度(2022),逐年留出忠實模擬「以其他年度歷史預測一整年」的真實情境;TE 每折僅用其餘訓練年度計算,無洩漏。EDA 的驗證建議為一般 KFold,但時序外推結構優先於該一般性建議;第 3-9 次實驗 全程同折,分數可直接比較。

Objective 與關鍵超參:GBDT 以 $\log_{1p}(\text{emission})$ 為目標訓練、預測後還原,詳細超參無結構化紀錄(不臆測);結構管線超參有完整紀錄——第 7 次實驗 為 $\alpha=1.0$ 、 $w_{2020}=0.24$ 、 $w_{nb}=0.28$ (網格預掃選定),第 9 次實驗之聯合最優見第 3.2 節最佳解成員表。

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無後處理紀錄	submission_ensemble_38.5072_20260214_161647.csv	否
2	無後處理紀錄	submission_final_33.2056_20260214_161743.csv	否
3	clip ≥ 0	sub_v2_blend_28.3424_20260703_095953.csv	否
4	clip ≥ 0	sub_v2_blend_22.6488_20260703_101209.csv	否
5	clip ≥ 0	sub_v3_blend_22.4897_20260704_005826.csv	否
6	clip ≥ 0	sub_v4_blend_21.6317_20260704_011624.csv	否
7	clip ≥ 0	sub_v5_blend_21.1487_20260704_011931.csv	否
8	無後處理紀錄	無紀錄(診斷輪)	否
9	無後處理紀錄	無紀錄(僅 OOF 分數,未產生 test 預測)	否

`clip >= 0` 為唯一後處理(排放量不可為負)。submission 檔格式兩欄: id 欄 ID_LAT_LON_YEAR_WEEK、目標欄 emission。因逾期提交管道已關閉,表中檔案皆為本機 產出檔案,「是否已提交」一律為否——包含 第 7 次實驗 與 第 9 次實驗 在內的全部階段分數均為 CV-only。

3.5 評估指標

指標定義: RMSE = 預測誤差平方均值的平方根, 對大誤差施以平方級懲罰, 越低越好。

項目	OOF RMSE
LGB(第 7 次實驗 成員)	32.074
XGB(第 7 次實驗 成員)	28.0674
CAT(第 7 次實驗 成員)	28.8466
TE(第 7 次實驗 成員, 去噪 loc-week 均值)	21.1487
Ensemble(第 7 次實驗, TE 權重 1.0)	21.1487
TE_JOINT(第 9 次實驗, 樹搜尋 best)	21.0589
Public / Private LB	無紀錄(逾期提交管道已關閉, 未提交)

本場排行榜無紀錄(提交管道已關閉), 故無排行榜表, CV↔LB gap 無法計算, 不作 推測性比較。第 9 次實驗 相對 線性迭代終點 第 7 次實驗 之改善:

第 7 次實驗 - 第 9 次實驗: $21.1487 - 21.0589 = 0.0898$, 相對改善 $0.0898 / 21.1487 = 0.4246\%$

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	20260214_161647	38.507172	—(舊 session)	102 特徵 LGB/XGB/Ridge blend, Ridge 失敗、單一時間切分
2	20260214_161743	33.205568	—(舊 session)	LGB/XGB 50/50, 舊 session 終點
3	2026-07-03T09:59:53	28.3424	1 (代理)	三 GBDT blend 於 LOYO CV, GBDT 能力上限
4	2026-07-03T10:12:09	22.6488	2	TE 成員拿 100% 權重, GBDT 全歸零
5	2026-07-04T00:58:26	22.4897	3.5	TE 經驗貝葉斯收縮
6	2026-07-04T01:16:24	21.6317	3.5	COVID 年降權, 線性階段最大單輪增益
7	2026-07-04T01:19:31	21.1487	3.5	鄰週平滑, 線性迭代終點
8	2026-07-04T01:35:00	21.1487	3 (診斷)	寬窗、殘差模型皆負向, 依協定停止
9	2026-07-04T12:18:33	21.0589	4.2	node #28 純結構 JOINT 最優, 本場最佳

實驗編號	時間	決策分數	階段	摘要
10	2026-07-08T11:46:18	20.812940	5	外部注入快評:EXT-09(stacking) 候選數值雖低但係 CV 噪音、非真增益,不採納

- **突破點 1(第 3 次實驗→第 4 次實驗):**把純 loc-week 歷史均值作為獨立成員放入集成池,權重 搜尋將 100% 給該成員(28.3424 → 22.6488)——「理解資料」勝過模型複雜度的本場定調。
- **突破點 2(第 5 次實驗→第 6 次實驗):**2020 COVID 年降權(W2020=0.29)帶來線性階段最大單輪增益 (22.4897 → 21.6317);第 7 次實驗 鄰週平滑再收 21.1487。
- **突破點 3(第 8 次實驗→第 9 次實驗):**樹搜尋以新參數 year_weights 加 JOINT 聯合移動,拿到階段 3 「一次一項」協定結構性難以觸及的複合最優(21.1487 → 21.0589)。

5. 效能對照(逐階段)

語意澄清(階段 1 為代理基線):本場為 2023 年已關閉、於 2026-02-14 舊 session 先行 完成的舊有競賽,不在週末 10 場通用批次範圍內,從未執行通用批次管線,故**無 嚴格意義的通用批次基線**。其最早兩筆實驗(第 1-2 次實驗)使用單一時間切分、無 CatBoost 與 TE,與 第 3 次實驗 起的 LOYO CV 不可比,**排除而非誤標**為階段 1。下表階段 1(28.3424, 第 3 次實驗)是同一 LOYO CV 方案下、TE 尚未作為獨立成員入池前的三 GBDT blend,屬近似 對照;凡以階段 1 為基準的比較皆應視為近似值。

階段	配置	分數	相對改善
1	基線(代理:第 3 次實驗,三 GBDT blend、TE 未入池、同 LOYO CV)	28.3424	—(基線)
2	+ kaggle-agent skill 六階段流程(第 4 次實驗,TE 成員拿 100% 權重)	22.6488	20.09%
3	+ self-improvement 線性迭代(第 7 次實驗,TE 三段去噪終點)	21.1487	6.62%
4	+ 樹搜尋(第 9 次實驗,node #28 純結構 JOINT)	21.0589	0.42%
5	+ 外部想法注入(第 10 次實驗,快評)	21.0589	0.00%(非真增益)

相對改善計算式(每階段對前一階段)

階段1→2: $28.3424 - 22.6488 = 5.6936$, 相對改善 $5.6936 / 28.3424 = 20.0886\%$ (階段 1 為代理值,此列為近似值)
 階段2→3: $22.6488 - 21.1487 = 1.5001$, 相對改善 $1.5001 / 22.6488 = 6.6233\%$
 階段3→4: $21.1487 - 21.0589 = 0.0898$, 相對改善 $0.0898 / 21.1487 = 0.4246\%$
 階段4→5: 注入候選 20.812940 數值雖低於階段4 21.0589,但係 tier4 排除的 CV 噪音成員(非真增益)→ 相對改善 0.00%
 (累計 階段1→4: $28.3424 - 21.0589 = 7.2835$, 25.6982%, 同受代理基線限制)

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

特殊場次注記:其一,階段 1 為代理基線(見上方澄清),跨場彙總紀錄同此計分方式。其二,逾期提交管道已關閉,階段 1-4 分數**全部為 CV-only、從未提交**,無排行榜對照。其三,階段 4 採 node #28 的 21.0589 而**明確排除**其手足 BLEND 節點的 21.0332——後者僅在 權重直接對同一份 OOF 擬合的 3 折 CV 下勝出,屬低信心的微小發現(見第 3.2 節補充說明),保守取純結構節點是刻意的方法選擇。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:XGB;代理基線)	28.4029	第 3 次實驗
1.2(三模權重 blend;代理基線)	28.3424	第 3 次實驗
3.5(結構化去噪:經驗貝葉斯收縮,組合均值向位置均值收縮)	22.4897	第 5 次實驗
3.5(結構化去噪:COVID 異常年降權,W2020 $\approx$ 0.29)	21.6317	第 6 次實驗
3.5(結構化去噪:鄰週 week $\pm$ 1 平滑)	21.1487	第 7 次實驗
4.2(樹搜尋 node #28,JOINT 聯合移動純結構最優,本場最佳)	21.0589	第 9 次實驗

階段 5 | + 外部想法注入

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-09:stacking**——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic),以 nested-CV 避免洩漏。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們**已算好的 OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

階段5 注入候選(stacking)OOF RMSE = 20.812940
 階段4 冠軍 OOF RMSE = 21.058900
 差距 = +0.245960(數值上較低)→ 但此候選榨出的是 tier4 刻意排除的低信度 CV 噪音成員(見下註)
 → 非真增益,仍以純結構解為準 → 階段5 = 階段4

(本場註:數值上 stacking 略低於階段4,但它榨出的是 STATUS.md 標為低信度 CV 噪音的 GBDT-blend 成員,tier4 刻意排除之——非真增益。)

注入機制可運作、也確實產生了候選;本場候選數值雖略低,實為 tier4 排除的 CV 噪音、非真增益,故**階段5 相對階段4 無真增益**。此為全 15 場一致的誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場資料的表象是 74 欄衛星感測迴歸,實質是一個結構問題:同一(位置,週)的 emission 跨年 近乎恆定,而感測特徵與目標相關性極弱。全場單一最大增益來源是 第 4 次實驗 把 loc-week 歷史均值 作為獨立成員入池——權重搜尋給它 100%、三個 GBDT 全歸零(28.3424 $\rightarrow$ 22.6488),此後 GBDT 只作對照組存在。

關鍵決策是承認這個結論並轉向:階段 3 不再調模型,改對歷史均值本身做三段去噪(經驗貝葉斯收縮 $\rightarrow$ COVID 年降權 $\rightarrow$ 鄰週平滑,22.6488 $\rightarrow$ 21.1487),每輪只改一項、全程同折;第 8 次實驗 以 寬窗與殘差模型雙診斷確認感測特徵連殘差都解釋不了,依協定誠實停損。

樹搜尋(第 9 次實驗)回答「結構完全主宰的地形上自動搜尋還有無價值」:重掃已手調參數只能打平,增益來自新參數 year_weights 與 JOINT 聯合移動(21.1487 $\rightarrow$ 21.0589)——幅度小於模型主導型 競賽,但正是手動「一

次一項」協定結構性拿不到的部分。逐階對照中階段 2 增益最大、逐階遞減,與「訊號早已被結構飽和」的診斷一致。

可信度方面須誠實:本場逾期提交管道已關閉,全部分數皆為 3 折 LOYO OOF、無排行榜 對照;階段 1 為代理基線,以其為基準的比較是近似值;階段 4 刻意排除對同一份 OOF 擬合 權重的 21.0332 blend 節點,採用的 21.0589 為純結構、可獨立重算驗證(根節點曾逐位吻合 第 7 次實驗)的穩健結果。

重現本實驗的最短路徑:見第 7 節。

階段 5(外部想法注入) 經快評未帶來真增益:注入機制可運作、也產生了候選(stacking),唯一數值較低者係 tier4 排除的 CV 噪音,故階段5 = 階段4——此為全 15 場一致的誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 0) 環境(uv 管理;所有 Python 執行皆透過 uv run)
uv sync

# 1) 資料(競賽已關閉,若 API 仍可下載歷史資料)
export KAGGLE_API_TOKEN=<your_token>
uv run kaggle competitions download -c playground-series-s3e20 \
    -p competitions/playground-series-s3e20/data
unzip -o competitions/playground-series-s3e20/data/playground-series-s3e20.zip \
    -d competitions/playground-series-s3e20/data

# 2) 階段 1(代理)+ 階段 2:LOYO CV + loc-week TE 入池 + 三 GBDT blend → 第 3、4 次實驗
uv run python competitions/playground-series-s3e20/scripts/train_v2.py

# 3) 階段 3 線性迭代(3.5 三段去噪;一輪一改動,同折可比)→ 第 5–8 次實驗
uv run python competitions/playground-series-s3e20/scripts/train_v3.py # +EB 收縮
uv run python competitions/playground-series-s3e20/scripts/train_v4.py # +COVID 年降權
uv run python competitions/playground-series-s3e20/scripts/train_v5.py # +鄰週平滑(階段 3 終點)
# 產出:competitions/playground-series-s3e20/submissions/sub_v5_blend_*.csv

# 4) 4.2 / 第 9 次實驗:樹搜尋工具第 2 版(best;可中斷續跑,樹狀態存 experiments_tree.json)
uv run python3 tree_search/run_s3e20_v2.py

# 報告產生(本檔)
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e20
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py \
    competitions/playground-series-s3e20/REPORT.md competitions/playground-series-s3e20/facts.json
bash .claude/skills/kaggle-report/assets/md2pdf.sh competitions/playground-series-s3e20/REPORT.md \
    competitions/playground-series-s3e20/s3e20_REPORT.pdf

# 提交至 Kaggle:本場 Late Submission 已關閉,無提交指令(所有分數皆 CV-only)

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 OOF、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s3e20
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle`。