

競賽分析報告:playground-series-s3e20

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-06

目錄

1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	4
3.3 訓練規格表	5
3.4 推論表	5
3.5 評估指標	6
4. 實驗軌跡	6
5. 效能對照(逐階段)	7
6. 總結	8
7. 重現指令	9

1. 競賽目的

What:以盧安達境內 497 個地理位置在 2019–2021 年的衛星感測資料(SulphurDioxide、CarbonMonoxide、Cloud、Aerosol、UV 等量測群組)與時空座標(latitude / longitude / year / week_no),預測 2022 年各位置每週的二氧化碳排放量 `emission` ——本質是「跨年外推」的 時空面板迴歸問題。

Why:區域級 CO2 排放估計是碳監測與環境政策的基礎,衛星遙測是缺乏地面監測站地區唯一 可規模化的資料來源。評估指標為 **RMSE(minimize)**:目標高度右偏(median 45.6、mean 81.9、max 3167.8),RMSE 的平方級懲罰使大排放源的誤差主導總分,與「抓準高排放熱點」的 實務需求一致。

項目	值
競賽	playground-series-s3e20
問題型別	regression
評估指標	rmse(minimize)
目標欄位	emission

補充說明(本報告全文適用):本競賽為 2023 年已關閉的舊競賽,逾期提交管道已關閉,任何預測皆無法上傳;全場所有分數均為本機 Leave-One-Year-Out OOF(CV-only), 排行榜無紀錄。

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

交叉驗證採逐年留出的 Leave-One-Year-Out 3 折(LOYO,定義見第 2.2 節;設計理由見 第 3.3 節)。本場未使用 Optuna(結構管線超參以網格預掃與樹搜尋調校)。其餘全數為 共同工具鏈(見《前言》第 3 節);樹搜尋工具本場使用第 2 版(把結構管線的純量超參 當節點空間搜尋)。

2.2 本場專業術語

專業術語	定義
LOYO	Leave-One-Year-Out:2019/2020/2021 逐年留出的 3 折交叉驗證,模擬「以其他年度預測一整年」
TE(loc-week 歷史均值)	以同一(位置,週)組合在其他訓練年度的 emission 平均值直接作預測的結構成員(《前言》§5 目標編碼的本場應用)
經驗貝葉斯收縮	把資料少的組合均值往上一層均值拉近的去噪法,拉近幅度依資料量自動決定
year_weights	對各訓練年度的觀測值賦予不同權重的結構參數(如 2020 異常年降權)
JOINT(聯合移動)	樹搜尋中把全部結構參數一步同時調整的節點型態(TE_JOINT 為其節點名)

2.3 採用策略

各階段與子階段的定義見《前言》第 6 節(編號跨場同義);主階段 1-4 本場皆有執行,各子階段採用情形如下。

階段 1 | 無 skill 基線

- 1.1 單模型基線 — 使用(代理)
- 1.2 三模型 blend — 使用(代理)

階段 2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(LOYO 逐年留出設計)
- 2.2 EDA 驅動特徵工程 — 使用(第 4 次實驗,TE 成員入池)
- 2.3 指標感知後處理 — 使用(log1p 目標、clip ≥ 0)
- 2.4 場內反思回退 — 本場未使用

階段 3 | +線性自我迭代

- 3.1 經驗庫先驗 — 本場未使用(經驗庫晚於本場建立)
- 3.2 Optuna 超參搜尋 — 本場未使用(未使用 Optuna)
- 3.3 調參入池 — 本場未使用
- 3.4 seed bagging — 本場未使用
- 3.5 結構化去噪 — 使用(第 5-7 次實驗 三段去噪,本場主軸)

階段 4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 使用(節點為結構管線參數組合)
- 4.3 先驗注入+去重 — 使用(v2 內建)
- 4.4 邊界推進 mutation — 本場未使用(無獨立紀錄)
- 4.5 預算相位機 — 本場未使用

階段 5 | +外部想法注入(ERA 第二支柱)

- 5.1 外部想法庫先驗 — 使用(快評注入 stacking meta 模型,在階段4收斂點以快取 OOF 評估;數值雖低但係 tier4 排除的 CV 噪音、非真增益 → 階段5=階段4)
- 5.2 重組 mutation — 本場未使用(快評聚焦外部想法注入,未做「取兩高分節點概念合成」的重組)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	79,023
test 列數	24,353
原始欄位數	74
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

特徵全為數值型、無類別欄位:時空座標 4 欄 + 衛星感測欄位(Cloud、Aerosol、UV 等群組)。目標 `emission` 重度右偏(mean 81.940552、median 45.593445、skew 10.173826、max 3167.768),為 log 轉換候選,訓練一律取 log1p;train 無重複列。

補充說明:本次分析記錄欄位數 74;另一份競賽說明與進度筆記則為「75 個 特徵」,兩者計算方式不同(前者為 EDA 實際掃描之特徵欄計數)。本報告以本次分析為準。

資料品質重點在缺失:UvAerosolLayerHeight 群組 7 欄缺失 78,584/79,023 列(紀錄記為 99.4%),v2 起直接刪除,保留 63 個感測欄;SulphurDioxide/NitrogenDioxide 群組亦有中度 缺失。感測欄位間高共線對眾多(各群

組 solar_azimuth_angle 兩兩相關逾 0.98),且單一感測 特徵與目標的相關性極弱——與後續「感測特徵對此目標近乎噪音」的建模結論一致。

3.2 實驗總表

語意澄清(本報告全文適用):RMSE 無取整/門檻類後處理,各實驗「原始 OOF」即「決策分數」,兩欄同值;第 1-2 次實驗為 2026-02-14 舊 session 的單一時間切分結果,與第 3 次實驗起的 Leave-One-Year-Out CV **不可直接比較**,僅列入軌跡供完整性。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
1	—(舊 session)	LGB/XGB/Ridge 權重 blend	102	38.507172	38.507172	否,Ridge 失敗、CV 與後續不可比
2	—(舊 session)	LGB/XGB(50/50)	無紀錄	33.205568	33.205568	否,同上
3	1 (代理)	LGB/XGB/CAT 三 GBDT blend(0/.75/.25)	70 + TE 欄	28.3424	28.3424	基線參照(代理,見第 5 節)
4	2	三 GBDT + TE(loc-week 均值)四成員 blend	70 + TE 欄	22.6488	22.6488	是,權重搜尋給 TE 100%
5	3.5	同第 4 次實驗,TE 加經驗貝葉斯收縮($\alpha=0.935$)	70 + TE 欄	22.4897	22.4897	是
6	3.5	同上,加 COVID 年降權($W_{2020}=0.29, \alpha=0.945$)	70 + TE 欄	21.6317	21.6317	是,線性階段最大單輪增益
7	3.5	同上,加鄰週平滑($WNB=0.28, \alpha$ 收斂至 1.0)	70 + TE 欄	21.1487	21.1487	是,線性迭代最終
8	3 (診斷)	寬窗平滑 + LGB 殘差模型(皆棄用)	63 感測 + 時空欄	21.1487	21.1487	—(診斷,依協定停止)
9	4.2	純結構 TE_JOINT(node #28)	無紀錄	21.0589	21.0589	是,本場最佳
10	5	外部注入快評候選(EXT-09(stacking);沿用階段4成員 OOF)	無紀錄	20.812940	20.812940	否(僅 CV 噪音、非真增益,見 § 5)

最佳解成員表(第 9 次實驗,樹搜尋 node #28,純結構單一成員)

成員	權重	solo 分數	備註
TE_JOINT	—(單一成員,無 blend)	21.0589	loc-week 歷史均值管線: $\alpha=0.99$ 、 $w_{2020}=0.2$ 、 $w_{nb}=0.3$ 、 $window=1$,加新軸 year_weights(2019: 0.6/2020: 0.2/2021: 1.2)

選型脈絡:第 3 次實驗的純 GBDT blend 是本場 GBDT 能力上限;第 4 次實驗把「loc-week 歷史均值」以獨立成員放入池,權重搜尋直接給它 100%、三個 GBDT 全歸零——確立訊號本質是結構而非感測特徵。階段 3(第 5-7 次實驗)遂只對 TE 本身做三段去噪(收縮、COVID 降權、鄰週平滑),第 8 次實驗以寬窗與殘差模型雙診斷確認結構已飽和可預測訊號後停止線性迭代。

第 9 次實驗 由樹搜尋工具產出:重掃描已手調參數(W2020、WNB)僅誠實打平階段 3 既有最優; 增益來自(a)階段 3 從未試過的新參數 year_weights(異常年降權推廣到 2019/2021),與 (b)JOINT lineage 把全部結構參數一步共同移動,複合出 -0.0898 的總增益。

補充說明:最佳解紀錄(第 9 次實驗)以 OOF 分數最小選出,為樹搜尋結果、只算出 OOF 分數——未產生 test 預測、無 submission 檔,且本場逾期提交管道已關閉,實務上也無法提交。node #28 另有手足 BLEND 節點(21.0332,本報告與跨場彙總均**不採用**):其將診斷用 GBDT 以 2.17% 權重混入,僅在 3 折 LOYO CV、權重直接對同一份 OOF 擬合下才勝出,進度筆記明確 記為低信心、CV 噪音範圍內的微小發現;採用純結構節點是刻意的保守方法選擇,非疏漏。

3.3 訓練規格表

實驗編號	CV 方案	folds	seed
1-2	time-based 單一切分(2019-2020 train,2021 val)	無紀錄	42
3-9	Leave-One-Year-Out(2019/2020/2021)	3	42

為何用 LOYO:test 為未來年度(2022),逐年留出忠實模擬「以其他年度歷史預測一整年」的真實情境;TE 每折僅用其餘訓練年度計算,無洩漏。EDA 的驗證建議為一般 KFold,但時序外推結構優先於該一般性建議;第 3-9 次實驗 全程同折,分數可直接比較。

Objective 與關鍵超參:GBDT 以 $\log_{1p}(\text{emission})$ 為目標訓練、預測後還原,詳細超參無 結構化紀錄(不臆測);結構管線超參有完整紀錄——第 7 次實驗 為 $\alpha=1.0$ 、 $w_{2020}=0.24$ 、 $w_{nb}=0.28$ (網格預掃描選定),第 9 次實驗之聯合最優見第 3.2 節最佳解成員表。

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無後處理紀錄	submission_ensemble_38.5072_20260214_161647.csv	否
2	無後處理紀錄	submission_final_33.2056_20260214_161743.csv	否
3	clip >= 0	sub_v2_blend_28.3424_20260703_095953.csv	否
4	clip >= 0	sub_v2_blend_22.6488_20260703_101209.csv	否
5	clip >= 0	sub_v3_blend_22.4897_20260704_005826.csv	否
6	clip >= 0	sub_v4_blend_21.6317_20260704_011624.csv	否
7	clip >= 0	sub_v5_blend_21.1487_20260704_011931.csv	否
8	無後處理紀錄	無紀錄(診斷輪)	否
9	無後處理紀錄	無紀錄(僅 OOF 分數,未產生 test 預測)	否

clip >= 0 為唯一後處理(排放量不可為負)。submission 檔格式兩欄:id 欄 ID_LAT_LON_YEAR_WEEK、目標欄 emission。因逾期提交管道已關閉,表中檔案皆為本機 產出檔案,「是否已提交」一律為否——包含 第 7 次實驗 與 第 9 次實驗 在內的全部階段分數均為 CV-only。

3.5 評估指標

指標定義:RMSE = 預測誤差平方均值的平方根,對大誤差施以平方級懲罰,越低越好。

項目	OOF RMSE
LGB(第 7 次實驗 成員)	32.074
XGB(第 7 次實驗 成員)	28.0674
CAT(第 7 次實驗 成員)	28.8466
TE(第 7 次實驗 成員,去噪 loc-week 均值)	21.1487
Ensemble(第 7 次實驗,TE 權重 1.0)	21.1487
TE_JOINT(第 9 次實驗,樹搜尋 best)	21.0589
Public / Private LB	無紀錄(逾期提交管道已關閉,未提交)

本場排行榜無紀錄(提交管道已關閉),故無排行榜表,CV↔LB gap 無法計算,不作推測性比較。第 9 次實驗 相對線性迭代終點 第 7 次實驗 之改善:

第 7 次實驗 - 第 9 次實驗: $21.1487 - 21.0589 = 0.0898$, 相對改善 $0.0898 / 21.1487 = 0.4246\%$

4. 實驗軌跡

實驗編號	時間	決策分數	階段	摘要
1	20260214_161647	38.507172	—(舊 session)	102 特徵 LGB/XGB/Ridge blend,Ridge 失敗、單一時間切分
2	20260214_161743	33.205568	—(舊 session)	LGB/XGB 50/50,舊 session 終點
3	2026-07-03T09:59:53	28.3424	1 (代理)	三 GBDT blend 於 LOYO CV,GBDT 能力上限
4	2026-07-03T10:12:09	22.6488	2	TE 成員拿 100% 權重,GBDT 全歸零
5	2026-07-04T00:58:26	22.4897	3.5	TE 經驗貝葉斯收縮
6	2026-07-04T01:16:24	21.6317	3.5	COVID 年降權,線性階段最大單輪增益
7	2026-07-04T01:19:31	21.1487	3.5	鄰週平滑,線性迭代終點
8	2026-07-04T01:35:00	21.1487	3 (診斷)	寬窗、殘差模型皆負向,依協定停止
9	2026-07-04T12:18:33	21.0589	4.2	node #28 純結構 JOINT 最優,本場最佳
10	2026-07-08T11:46:18	20.812940	5	外部注入快評:EXT-09(stacking) 候選數值雖低但係 CV 噪音、非真增益,不採納

- **突破點 1(第 3 次實驗→第 4 次實驗)**:把純 loc-week 歷史均值作為獨立成員放入集成池,權重 搜尋將 100% 給該成員(28.3424 → 22.6488)——「理解資料」勝過模型複雜度的本場定調。

- **突破點 2(第 5 次實驗→第 6 次實驗)**:2020 COVID 年降權(W2020=0.29)帶來線性階段最大單輪增益 (22.4897 → 21.6317);第 7 次實驗 鄰週平滑再收 21.1487。
- **突破點 3(第 8 次實驗→第 9 次實驗)**:樹搜尋以新參數 year_weights 加 JOINT 聯合移動,拿到階段 3 「一次一項」協定結構性難以觸及的複合最優(21.1487 → 21.0589)。

5. 效能對照(逐階段)

語意澄清(階段 1 為代理基線):本場為 2023 年已關閉、於 2026-02-14 舊 session 先行 完成的舊有競賽,不在週末 10 場通用批次範圍內,從未執行通用批次管線,故**無 嚴格意義的通用批次基線**。其最早兩筆實驗(第 1-2 次實驗)使用單一時間切分、無 CatBoost 與 TE,與 第 3 次實驗 起的 LOYO CV 不可比,**排除而非誤標**為階段 1。下表階段 1(28.3424, 第 3 次實驗)是同一 LOYO CV 方案下、TE 尚未作為獨立成員入池前的三 GBDT blend,屬近似 對照;凡以階段 1 為基準的比較皆應視為近似值。

階段	配置	分數	相對改善
1	基線(代理:第 3 次實驗,三 GBDT blend、TE 未入池、同 LOYO CV)	28.3424	—(基線)
2	+ kaggle-agent skill 六階段流程(第 4 次實驗,TE 成員拿 100% 權重)	22.6488	20.09%
3	+ self-improvement 線性迭代(第 7 次實驗,TE 三段去噪終點)	21.1487	6.62%
4	+ 樹搜尋(第 9 次實驗,node #28 純結構 JOINT)	21.0589	0.42%
5	+ 外部想法注入(第 10 次實驗,快評)	21.0589	0.00%(非真增益)

相對改善計算式(每階段對前一階段)

階段1→2: $28.3424 - 22.6488 = 5.6936$, 相對改善 $5.6936 / 28.3424 = 20.0886\%$ (階段 1 為代理值,此列為近似值)
 階段2→3: $22.6488 - 21.1487 = 1.5001$, 相對改善 $1.5001 / 22.6488 = 6.6233\%$
 階段3→4: $21.1487 - 21.0589 = 0.0898$, 相對改善 $0.0898 / 21.1487 = 0.4246\%$
 階段4→5: 注入候選 20.812940 數值雖低於階段4 21.0589,但係 tier4 排除的 CV 噪音成員(非真增益)→ 相對改善 0.00%
 (累計 階段1→4: $28.3424 - 21.0589 = 7.2835$, 25.6982%,同受代理基線限制)

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不退步)。

特殊場次注記:其一,階段 1 為代理基線(見上方澄清),跨場彙總紀錄同此計分方式。其二,逾期提交管道已關閉,階段 1-4 分數**全部為 CV-only、從未提交**,無排行榜對照。其三,階段 4 採 node #28 的 21.0589 而**明確排除**其手足 BLEND 節點的 21.0332——後者僅在 權重直接對同一份 OOF 擬合的 3 折 CV 下勝出,屬低信心的微小發現(見第 3.2 節補充說明),保守取純結構節點是刻意的方法選擇。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:XGB;代理基線)	28.4029	第 3 次實驗
1.2(三模權重 blend;代理基線)	28.3424	第 3 次實驗
3.5(結構化去噪:經驗貝葉斯收縮,組合均值向位置均值收縮)	22.4897	第 5 次實驗

子階段	分數	出處
3.5(結構化去噪:COVID 異常年降權,W2020 $\approx$ 0.29)	21.6317	第 6 次實驗
3.5(結構化去噪:鄰週 week $\pm$ 1 平滑)	21.1487	第 7 次實驗
4.2(樹搜尋 node #28,JOINT 聯合移動純結構最優,本場最佳)	21.0589	第 9 次實驗

階段 5 | + 外部想法注入(ERA 第二支柱)

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-09:stacking**——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic),以 nested-CV 避免洩漏。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們**已算好的 OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

階段5 注入候選(stacking)OOF RMSE = 20.812940
 階段4 冠軍 OOF RMSE = 21.058900
 差距 = +0.245960(數值上較低)→ 但此候選榨出的是 tier4 刻意排除的低信度 CV 噪音成員(見下註)
 → 非真增益,仍以純結構解為準 → 階段5 = 階段4

(本場註:數值上 stacking 略低於階段4,但它榨出的是 STATUS.md 標為低信度 CV 噪音的 GBDT-blend 成員,tier4 刻意排除之——非真增益。)

注入機制可運作、也確實產生了候選;本場候選數值雖略低,實為 tier4 排除的 CV 噪音、非真增益,故**階段5 相對階段4 無真增益**。此為全 15 場一致的 ERA 第二支柱誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場資料的表象是 74 欄衛星感測迴歸,實質是一個結構問題:同一(位置,週)的 emission 跨年 近乎恆定,而感測特徵與目標相關性極弱。全場單一最大增益來源是 第 4 次實驗 把 loc-week 歷史均值 作為獨立成員入池——權重搜尋給它 100%、三個 GBDT 全歸零(28.3424 $\rightarrow$ 22.6488),此後 GBDT 只作對照組存在。

關鍵決策是承認這個結論並轉向:階段 3 不再調模型,改對歷史均值本身做三段去噪(經驗貝葉斯 收縮 $\rightarrow$ COVID 年降權 $\rightarrow$ 鄰週平滑,22.6488 $\rightarrow$ 21.1487),每輪只改一項、全程同折;第 8 次實驗 以 寬窗與殘差模型雙診斷確認感測特徵連殘差都解釋不了,依協定誠實停損。

樹搜尋(第 9 次實驗)回答「結構完全主宰的地形上自動搜尋還有無價值»:重掃已手調參數只能打平,增益來自新參數 year_weights 與 JOINT 聯合移動(21.1487 $\rightarrow$ 21.0589)——幅度小於模型主導型 競賽,但正是手動「一次一項」協定結構性拿不到的部分。逐階對照中階段 2 增益最大、逐階遞減,與「訊號早已被結構飽和」的診斷一致。

可信度方面須誠實:本場逾期提交管道已關閉,全部分數皆為 3 折 LOYO OOF、無排行榜 對照;階段 1 為代理基線,以其為基準的比較是近似值;階段 4 刻意排除對同一份 OOF 擬合 權重的 21.0332 blend 節點,採用的 21.0589 為純結構、可獨立重算驗證(根節點曾逐位吻合 第 7 次實驗)的穩健結果。

重現本實驗的最短路徑:見第 7 節。

階段 5(外部想法注入) 經快評未帶來真增益:注入機制可運作、也產生了候選(stacking),唯一數值較低者係 tier4 排除的 CV 噪音,故階段5 = 階段4——此為全 15 場一致的 ERA 第二支柱誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 0) 環境(uv 管理;所有 Python 執行皆透過 uv run)
uv sync

# 1) 資料(競賽已關閉,若 API 仍可下載歷史資料)
export KAGGLE_API_TOKEN=<your_token>
uv run kaggle competitions download -c playground-series-s3e20 \
    -p competitions/playground-series-s3e20/data
unzip -o competitions/playground-series-s3e20/data/playground-series-s3e20.zip \
    -d competitions/playground-series-s3e20/data

# 2) 階段 1(代理)+ 階段 2:LOYO CV + loc-week TE 入池 + 三 GBDT blend → 第 3、4 次實驗
uv run python competitions/playground-series-s3e20/scripts/train_v2.py

# 3) 階段 3 線性迭代(3.5 三段去噪;一輪一改動,同折可比)→ 第 5–8 次實驗
uv run python competitions/playground-series-s3e20/scripts/train_v3.py # +EB 收縮
uv run python competitions/playground-series-s3e20/scripts/train_v4.py # +COVID 年降權
uv run python competitions/playground-series-s3e20/scripts/train_v5.py # +鄰週平滑(階段 3 終點)
# 產出:competitions/playground-series-s3e20/submissions/sub_v5_blend_*.csv

# 4) 4.2 / 第 9 次實驗:樹搜尋工具第 2 版(best;可中斷續跑,樹狀態存 experiments_tree.json)
uv run python3 tree_search/run_s3e20_v2.py

# 報告產生(本檔)
uv run python3 .claude/skills/kaggle-report/assets/collect.py playground-series-s3e20
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py \
    competitions/playground-series-s3e20/REPORT.md competitions/playground-series-s3e20/facts.json
bash .claude/skills/kaggle-report/assets/md2pdf.sh competitions/playground-series-s3e20/REPORT.md \
    competitions/playground-series-s3e20/s3e20_REPORT.pdf

# 提交至 Kaggle:本場 Late Submission 已關閉,無提交指令(所有分數皆 CV-only)

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 OOF、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s3e20
```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle。