

競賽分析報告:playground-series-s4e1

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整 | 產生日期:2026-07-07

目錄	
1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格表	5
3.4 推論表	5
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	6
5. 效能對照(逐階段)	7
6. 總結	8
7. 重現指令	9

1. 競賽目的

What:依銀行客戶的帳戶與人口屬性(信用分數、地區、性別、年齡、存款餘額、產品數、活躍度等)預測客戶是否流失(Exited ,0/1),為二元分類問題。本場是 S4 開季第一場,也是本專案「跨季泛化」驗證的第一場:檢驗由 S3 十場蒸餾出的經驗庫配方在新一季資料上 是否成立。

Why:評估指標為 **ROC-AUC(maximize)**。流失客戶佔比約兩成(不平衡),AUC 衡量「把流失者排在留存者前面」的排序能力,與門檻無關,對類別不平衡穩健,是流失預警這類「輸出風險排序供業務端取 top-N 介入」場景的合理指標。

項目	值
競賽	playground-series-s4e1
問題型別	binary_classification
評估指標	auc(maximize)
目標欄位	Exited

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第3版(預算60節點、強制探索爆發、自動停止)。交叉驗證採依 Exited 分層的 StratifiedKFold(設計理由見第3.3節)。

2.2 本場專業術語

本場無特有專業術語,所需詞彙均見《前言》第5節。

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段1 | 無 skill 基線

- 1.1 單模型基線 — 使用(第3-5次實驗)
- 1.2 三模型 blend — 使用(第6次實驗)

階段2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(依 EDA 建議分層切分,併入第7-10次實驗)
- 2.2 EDA 驅動特徵工程 — 使用(28特徵 + fold-safe surname TE 修正)
- 2.3 指標感知後處理 — 本場未使用(AUC 無後處理議題)
- 2.4 場內反思回退 — 本場未使用

階段3 | +線性自我迭代

- 3.1 經驗庫先驗 — 使用(第11次實驗 加權對照:AUC 不吃不平衡加權,跨季重驗成立)
- 3.2 Optuna 超參搜尋 — 使用(第13次實驗,只以第0折評分挑參)
- 3.3 調參入池 — 使用(第14次實驗,入池不替換)
- 3.4 seed bagging — 使用(第15、16次實驗,增益歸零)
- 3.5 結構化去噪 — 本場未使用

階段4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 本場未使用(無獨立紀錄)
- 4.3 先驗注入+去重 — 使用(v3 內建)
- 4.4 邊界推進 mutation — 使用(node #5,num_leaves 上推)

- 4.5 預算相位機 — 使用(本場最佳)

階段 5 | +外部想法注入

- 5.1 外部想法庫先驗 — 使用(快評注入 rank averaging,在階段4收斂點以快取 OOF 評估;未勝過階段4 → 階段5=階段4)
- 5.2 重組 mutation — 本場未使用(機制已建置[harness_v4 機械版 + LLM 版];跨場 pilot 實測與 mega-blend 搜尋冗餘、無增益,見 docs/recombine_findings)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	165,034
test 列數	110,023
原始欄位數	12(9 數值 + 3 類別,不含 id/target)
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

目標 Exited 為 0/1,正類(流失)比例約兩成(mean 0.211599)。資料乾淨:train/test 皆零缺失、零重複列,無高共線特徵對;數值欄 train/test 均值漂移皆在 1% 內,無明顯 分布位移。單變數相關以 Age 最強(Pearson +0.340768),NumOfProducts 次之 (-0.214554);EDA 驗證提示為分層抽樣(target 離散),與實際採用的 StratifiedKFold 一致。

特徵工程沿用二月版 28 特徵集(性別/地區 dummy、年齡衍生、餘額衍生、產品數旗標、七個交互項、surname 目標編碼),但帶一項刻意修正:二月版 surname TE 以獨立折(不同 seed) 計算 OOF,姓氏分組跨兩種折劃分共享,構成隱性洩漏路徑;本次改為 fold-safe(TE 折 == 模型訓練折)。此修正使可比分數整體下修(詳見第 3.5 節與第 6 節)。

3.2 實驗總表

語意澄清(本報告全文適用):AUC 為連續排名指標,本場無取整/後處理議題,「原始 OOF」即為決策分數,下表兩欄同值。第 1、2 次實驗 為二月首跑的舊格式紀錄,無法納入自動抽取,原文照列於第 4 節「無法解析之紀錄」,不進本表。

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
3	1.1	LGB(通用批次)	無紀錄	0.89097	0.89097	否
4	1.1	XGB(通用批次)	無紀錄	0.89068	0.89068	否
5	1.1	CAT(通用批次)	無紀錄	0.8913	0.8913	否
6	1.2	LGB+XGB+CAT blend(通用批次)	無紀錄	0.8922	0.8922	是(階段 1 基線)
7	2	LGB(skill solo)	28	0.89365	0.89365	否

實驗編號	階段	模型/成員	特徵數	原始 OOF	決策分數	是否採納
8	2	XGB(skill solo)	28	0.893965	0.893965	否
9	2	CAT(skill solo)	28	0.893913	0.893913	否
10	2	LGB+XGB+CAT blend	28	0.894302	0.894302	是(階段 2 最佳)
11	3.1	LGB is_unbalance=True(加權對照)	28	0.893235	0.893235	否(先驗成立,棄加權)
12	3.1	3-way blend(LGB 不加權)	28	0.894302	0.894302	否(與 第 10 次實驗同值)
13	3.2	LGB Optuna 調參(只在第 0 折評分挑參)	28	0.894171	0.894171	否(本場最強 solo)
14	3.3	4-way blend(+LGB_tuned)	28	0.894354	0.894354	是(階段 3 最佳)
15	3.4	LGB_tuned seed=2024(seed-bag)	28	0.894137	0.894137	否
16	3.4	5-way blend(+seed-bag)	28	0.894354	0.894354	否(增益歸零,依協定停止)
17	4.5	樹搜尋 node #44:37 成員 mega-blend	28	0.894393	0.894393	是(最終最佳)
18	5	外部注入快評候選(EXT-12(rank);沿用階段4 成員 OOF)	28	0.894359	0.894359	否(未勝過階段4,見 § 5)

最佳解成員表(第 17 次實驗,node #44 mega-blend;僅列權重 ≥ 0.01 的 18 個成員,其餘 19 個 成員權重 < 0.01)

成員	權重	solo 分數	備註
node#18(lgb)	0.1848	0.894191	調參參數族 seed 變體,權重最高
node#42(xgb)	0.1685	0.89369	深 XGB 系譜成員
node#15(lgb)	0.1254	0.894184	調參參數族 seed 變體
node#33(cat)	0.077	0.893612	深 CatBoost 系譜成員
node#23(lgb)	0.0558	0.89417	調參參數族 seed 變體
node#1(lgb)	0.0496	0.893825	淺 LGB 手調變體
node#28(lgb)	0.0481	0.893967	淺 LGB 系譜成員
node#31(cat)	0.0435	0.89354	深 CatBoost 系譜成員
node#40(xgb)	0.0424	0.89354	深 XGB 系譜成員
node#5(lgb)	0.0423	0.894171	邊界推進(num_leaves 上推)節點
node#17(lgb)	0.0268	0.89417	調參參數族 seed 變體
node#39(xgb)	0.025	0.893552	深 XGB 系譜成員
node#27(lgb)	0.0228	0.893932	淺 LGB 系譜成員
node#32(cat)	0.0224	0.893585	深 CatBoost 系譜成員
node#29(cat)	0.018	0.893563	深 CatBoost 系譜成員

成員	權重	solo 分數	備註
node#24(lgb)	0.0149	0.893934	淺 LGB 系譜成員
node#26(lgb)	0.0141	0.893947	淺 LGB 系譜成員
node#30(cat)	0.0138	0.893557	深 CatBoost 系譜成員

權重高度分散,無單一成員過半——與階段 3 各輪 blend 權重集中於 3-5 個成員形成對比,mega-blend 的增益來自大量弱異質成員的隨機波動互相抵消。

3.3 訓練規格表

全部 15 筆實驗(第 3-17 次實驗)共用同一 CV 方案,列一次:

實驗編號	CV 方案	folds	seed
3-17(全部)	5fold_stratified	5	42

正類約兩成的不平衡二元目標,以 StratifiedKFold 保各折比例一致(EDA 驗證建議同此);各階段(含樹搜尋每一節點)共用同一組折,故全報告分數逐位元可比。關鍵超參:第 13 次實驗之 Optuna 最優(num_leaves 242、max_depth 5、learning_rate 0.0123、min_child_samples 11,詳實驗紀錄之文字備註);第 17 次實驗 權重搜尋規格有完整紀錄(每節點 800 次權重抽樣、seed 42、再作逐權重微調)。

3.4 推論表

AUC 需機率輸出,全部提交檔皆為原始機率、無後處理。本場逾期提交管道已關閉(帳號未曾參賽,提交 API 回應 403;以階段 3 與階段 4 兩個實檔各實測一次),故「是否已提交」全為否。

實驗編號	後處理	submission 檔	是否已提交
6	無	sub_generic_0.89220_20260707_100440.csv	否
10	無	tier2_blend_0.89430_20260707_100641.csv	否
12	無	tier3_r1_blend_0.89430_20260707_100859.csv	否
14	無	tier3_r2_blend_0.89435_20260707_102041.csv	否
16	無	tier3_r3_blend_0.89435_20260707_102221.csv	否
17	無	sub_tree_best_0.89439_20260707_115813.csv	否(403,CV-only)

第 17 次實驗的 submission 檔由重建流程產生:37 個成員全部依樹中配置從頭重訓,逐成員 OOF 與搜尋快取逐位元一致(max|diff| = 0.0)、權重搜尋重放復原全精度權重且 blend AUC 逐位元吻合後,才以復原權重混合 test 預測(OOF 重現閘門,與 s3e16 同一作法;重建指令見第 7 節)。

3.5 評估指標 / 排行榜

指標定義:ROC-AUC = 隨機一正一負樣本對中,模型將正樣本排前的機率(排序品質,與門檻無關)。

分數總表見第 3.2 節(各 solo 與 blend 之 OOF AUC)。本場無排行榜對照:逾期提交管道關閉,各階段全部 CV-only,排行榜表從缺。

補充說明:階段間增益為 OOF 內部比較,無外部 LB 驗證;其量級(見第 5 節算式)比 同資料族二月版實測的 CV↔LB gap(~0.005)小約兩個數量級,跨階段排序在真實 LB 上未必 保持。本場 CV 的外部可信度只能借二月的實際提交對照 間接支撐(見下)。

二月首跑(不同特徵設定:TE 非 fold-safe,含 is_unbalance)曾實際提交,是本資料族僅有 的 CV↔LB 對照:

二月對照(第 2 次實驗,舊設定):CV 0.89653 → Public LB 0.88716 / Private LB 0.89179
CV↔Private gap:0.89653 - 0.89179 = 0.00474(CV 輕微樂觀,量級與 S3 各場一致)
本次 fold-safe 修正後同配方 solo 降至 0.8937 量級(洩漏修正使 CV 更保守,
gap 預期小於二月版)

4. 實驗軌跡

(下表「決策分數」= OOF AUC)

實驗編號	時間	決策分數	階段	摘要
3	07-07T10:05:28	0.89097	1.1	通用批次 LGB,原始欄位 label-encode
4	07-07T10:05:28	0.89068	1.1	通用批次 XGB
5	07-07T10:05:28	0.8913	1.1	通用批次 CAT,階段 1 最強 solo
6	07-07T10:05:28	0.8922	1.2	通用批次三模型 blend = 階段 1 基線
7	07-07T10:06:41	0.89365	2	28 特徵 + fold-safe TE,LGB
8	07-07T10:06:41	0.893965	2	同特徵 XGB,階段 2 最強 solo
9	07-07T10:06:41	0.893913	2	同特徵 CAT
10	07-07T10:06:41	0.894302	2	三模型 blend = 階段 2 最佳
11	07-07T10:08:35	0.893235	3.1	is_unbalance=True 加權對照:加權較差,經驗庫先驗跨季成立
12	07-07T10:08:59	0.894302	3.1	blend 重搜權重,與 第 10 次實驗 同值
13	07-07T10:20:23	0.894171	3.2	Optuna 只以第 0 折評分挑參、50 trials,本場最強 solo
14	07-07T10:20:42	0.894354	3.3	調參版入池不替換,4-way = 階段 3 最佳
15	07-07T10:21:52	0.894137	3.4	seed=2024 seed-bag 成員
16	07-07T10:22:21	0.894354	3.4	5-way 增益歸零,連續無改善依協定停止
17	07-07T11:58:44	0.894393	4.5	樹搜尋 60 節點滿預算,探索爆發之 mega-blend(node #44)
18	2026-07-08T11:46:18	0.894359	5	外部注入快評:EXT-12(rank) 候選 OOF 未勝過階段4,不採納

- **突破點 1(第 6→10 次實驗;增量見第 5 節算式):**本場最大單段增益來自 28 特徵集 + fold-safe surname TE(階段 2 特徵工程),遠大於其後所有調參/集成增益之和。
- **突破點 2(第 13→14 次實驗;增量見第 5 節算式):**Optuna 調參版「入池不替換」使 4-way blend 刷新階段 3 最佳——S3 驗證過的三步配方(調參→入池→seed-bag)中,前兩步跨季成立,第三步(第 15→16 次實驗)增益歸零。

- **突破點 3(第 17 次實驗;增量見第 5 節算式):**階段 4 樹搜尋後期集中在最有希望方向的 44 個節點,無一超越階段 3;全部 lineage 停滯凍結觸發強制探索爆發,全池 mega-blend(37 成員)一舉刷新 全域最佳——增益來自「把整個 solo 池混起來」,不來自任何單一 solo(探索爆發注入的 兩個單模 0.89419 / 0.893317 皆未勝出)。

無法解析之紀錄(二月首跑舊格式,原文照列):

```
{
  "id": 1, "name": "Majority Class Baseline", "model": "majority", "cv_score": 0.5,
  "cv_std": 0.0, "notes": "AUC=0.5 (random), Accuracy=0.78840"}
{"id": 2, "name": "LightGBM Baseline", "model": "lightgbm", "cv_score": 0.89653, ...
  "notes": "28 features, stratified 5-fold, surname target encoding, is_unbalance=True.
  Feb 2026 run (STATUS.md): submission lgbm_baseline_20260219_150434.csv ->
  Public LB 0.88716 / Private LB 0.89179."}
```

5. 效能對照(逐階段)

階段	配置	分數	相對改善
1	基線(通用批次,第 6 次實驗 三模型 blend)	0.8922	—(基線)
2	+ kaggle-agent skill 六階段(第 10 次實驗,28 特徵 + fold-safe TE)	0.894302	0.24%
3	+ 線性迭代(第 14 次實驗,Optuna 調參入池 4-way)	0.894354	0.01%
4	+ 樹搜尋(第 17 次實驗,node #44 mega-blend)	0.894393	0.00%
5	+ 外部想法注入(第 18 次實驗,快評)	0.894393	0.00%(未勝過)

相對改善計算式(每階段對前一階段)

```
階段1→2: 0.894302 - 0.8922 = 0.002102, 相對改善 0.002102 / 0.8922 = 0.2356%
階段2→3: 0.894354 - 0.894302 = 0.000052, 相對改善 0.000052 / 0.894302 = 0.0058%
階段3→4: 0.894393 - 0.894354 = 0.000039, 相對改善 0.000039 / 0.894354 = 0.0044%
階段4→5: 注入候選 0.894359 未勝過階段4 0.894393, 搜尋保留階段4 → 相對改善 0.00%(外部注入無增益)
```

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三(效能不 退步)。

本場為 AUC 連續指標、無特殊計分,各階段皆為同折同特徵之 OOF AUC,直接可比(唯階段 1 為 通用批次管線、直接用原始欄位,特徵不同屬逐階段設計本意)。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
1.1(最佳單模:CAT)	0.8913	第 5 次實驗
1.2(三模權重 blend)	0.8922	第 6 次實驗
2.2(特徵工程:28 特徵 + fold-safe surname TE)	0.894302	第 10 次實驗
3.1(經驗庫先驗:is_unbalance 加權對照,增益 +0)	0.894302	第 12 次實驗
3.2(Optuna 調參 LGB solo,本場最強 solo)	0.894171	第 13 次實驗

子階段	分數	出處
3.3(調參入池不替換,4-way)	0.894354	第 14 次實驗
3.4(seed bagging,增益歸零)	0.894354	第 16 次實驗
4.5(相位機 + 探索爆發,node #44 mega-blend,本場最佳)	0.894393	第 17 次實驗

階段 5 | + 外部想法注入

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-12:rank averaging**——把各成員預測先轉成排名再加權平均,對只看排序的指標(如 ROC-AUC)特別自然。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們**已算好的 OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

```
階段5 注入候選(rank averaging)OOF ROC-AUC = 0.894359
階段4 冠軍          OOF ROC-AUC = 0.894393
差距 = -0.000034 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4
```

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場資料乾淨(零缺失、零重複、無漂移),訊號集中在 Age 與 NumOfProducts 兩個特徵;正類約兩成的不平衡形態決定了兩件事:CV 用 StratifiedKfold,以及「AUC 排名指標不吃 不平衡加權」的經驗庫先驗有了跨季重驗的舞台(第 1 輪加權對照:加權 0.893235 < 不加權,先驗在 165k 大樣本上同向成立)。

本場最重要的方法決策是 surname 目標編碼的 fold-safe 修正:二月版 TE 折與模型折不同 seed,姓氏分組跨折共享形成隱性洩漏,是二月 CV 0.89653 高於本次同配方(0.8937 量級)的主因——「用不同折算 TE 看似避開洩漏,實為另一種洩漏路徑」是本場寫回經驗庫的核心教訓。修正後全部階段共用同折同特徵,報告內分數逐位元可比。

增益結構呈典型遞減階梯(逐階數字見第 5 節算式):階段 2 特徵工程為最大單段,階段 3 線性迭代次之(Optuna 調參入池有效、seed-bag 歸零、依協定停止),階段 4 增量最小——搜尋後期 集中磨最有希望的方向卻一無所獲,增益全部來自強制探索爆發的 37 成員 mega-blend,與 S3 結論一致。經驗庫配方在 S4 首場:先驗方向全部成立,增益量級隨資料放大而縮小。

工程面,本場是樹搜尋工具第 3 版續跑機制的**第一次真實復原**:前一次執行在播種中被外部中止,重新啟動後載回 5 節點狀態且分數與實驗原始紀錄逐位元一致,補種後跑滿預算;過程中並修復了「lineage 提案耗盡即空轉」的執行迴圈缺口。

最終 第 17 次實驗 通過 OOF 逐位元重現閘門(37 成員 $\max|\text{diff}| = 0.0$)後產生 test 預測,但 逾期提交管道關閉 (提交 API 回應 403 實測),本場各階段皆 CV-only,外部可信度借二月 實際提交對照(gap ~0.005)間接支撐。

重現本實驗的最短路徑:見第 7 節。

階段 5(外部想法注入) 經快評未勝過階段4:注入機制可運作、也產生了候選(rank averaging),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 資料(需有效 KAGGLE_API_TOKEN;本場資料已在磁碟)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions download -c playground-series-s4e1 \
    -p competitions/playground-series-s4e1/data && \
    unzip -o competitions/playground-series-s4e1/data/playground-series-s4e1.zip \
    -d competitions/playground-series-s4e1/data

# 階段 1:通用批次基線(第 3–6 次實驗)
uv run python3 competitions/run_competition.py playground-series-s4e1

# 階段 2:skill 六階段(28 特徵 + fold-safe TE;第 7–10 次實驗)
uv run python3 competitions/playground-series-s4e1/scripts/04_train_blend.py

# 階段 3:線性迭代三輪(第 11–16 次實驗;依序為 3.1 / 3.2+3.3 / 3.4)
uv run python3 competitions/playground-series-s4e1/scripts/05_iterate.py r1_unbalance_ablation
uv run python3 competitions/playground-series-s4e1/scripts/05_iterate.py r2_optuna_lgb
uv run python3 competitions/playground-series-s4e1/scripts/05_iterate.py r3_seed_bag

# 4.5 / 第 17 次實驗:樹搜尋工具第 3 版(可中斷續跑,狀態存 experiments_tree_v3.json)
uv run python3 tree_search/run_s4e1_v3.py

# 最佳解重建 + OOF 重現閘門 + 產生 test 預測(submission 檔)
uv run python3 competitions/playground-series-s4e1/scripts/06_rebuild_tree_best.py

# 提交(本場 Late Submission 已關閉,以下指令現況回 403,列供流程完整性)
uv run kaggle competitions submit -c playground-series-s4e1 \
    -f competitions/playground-series-s4e1/submissions/<submission.csv> -m "<msg>"

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 OOF、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s4e1
```

執行目錄為專案根目錄 /home/tjyen/ai_agents/kaggle ;所有 Python 執行皆透過 uv run 。