

競賽分析報告:playground-series-s4e1

產生方式:kaggle-report skill(數字來自 facts.json,敘述由 agent 撰寫) 素材等級:full | 產生日期:2026-07-07 本報告所有數字皆出自 facts.json,經 verify_report.py 驗證。

1. 競賽目的

What:依銀行客戶的帳戶與人口屬性(信用分數、地區、性別、年齡、存款餘額、產品數、活躍度等)預測客戶是否流失(Exited,0/1),為二元分類問題。本場是 S4 開季第一場,也是本專案「跨季泛化」驗證的第一場:檢驗由 S3 十場蒸餾出的經驗庫配方在新一季資料上 是否成立。

Why:評估指標為 **ROC-AUC(maximize)**。流失客戶佔比約兩成(不平衡),AUC 衡量「把流失者排在留存者前面」的排序能力,與門檻無關,對類別不平衡穩健,是流失預警這類「輸出風險排序供業務端取 top-N 介入」場景的合理指標。

項目	值
競賽	playground-series-s4e1
問題型別	binary_classification
評估指標	auc(maximize)
目標欄位	Exited
素材等級	full

2. 使用工具、術語與刻度定義

2.1 工具與環境

工具	用途
LightGBM / XGBoost / CatBoost	梯度提升樹基礎模型,構成各層 blend 的成員
Optuna	tier3 第 2 輪對 LGB 超參搜尋(fold-0 代理,50 trials)
自建樹搜尋 harness(v3)	tier4 結構化搜尋模型/超參/集成組合空間(預算 60 節點、強制 explore burst、自動停止)
5-fold CV 框架(scikit-learn)	StratifiedKFold 分層 5 折交叉驗證,四層共用同一折
uv	Python 套件與虛擬環境管理,所有腳本皆以 uv run 執行
Kaggle CLI	資料下載與提交通道探測(本場 Late Submission 已關閉,見第 3.4/3.5 節)

本場工具鏈組合邏輯:Claude Code(LLM)負責決策——選型、特徵修正(fold-safe 目標編碼)、經驗庫先驗的取舍、何時停損;Auto-ML 工具負責系統化執行——Optuna 超參搜尋、樹搜尋 harness 的組合空間探索與權重搜尋。

2.2 術語表

術語	定義
OOF	out-of-fold:每筆訓練樣本由「未見過它的那折模型」產生的預測;OOF 分數即本報告所有 CV 分數
solo	單一模型(單一組超參)的 5 折訓練結果
blend	多個 solo 的 OOF 加權平均;權重由搜尋決定(見權重搜尋)
權重搜尋	在權重單純形上找使 OOF 指標最優的組合(單純形網格或 Dirichlet 抽樣+座標上升精修)
seed bagging	同一組超參、只換隨機種子重訓,作為額外 blend 成員以降低變異
Optuna(fold-0 代理)	超參自動搜尋;每個 trial 只在第 0 折上評分以控制時間,優勝配置再以完整 5 折驗證
目標編碼(TE)/ fold-safe	以群組(本場為姓氏)的目標均值作特徵;fold-safe 指編碼所用之折與模型訓練折完全相同,杜絕跨折洩漏
ROC-AUC	隨機抽一正一負樣本,模型把正樣本排在前面的機率;0.5=隨機、1=完美
StratifiedKFold	各折保持正負類比例一致的 K 折切分
樹搜尋 / harness	以樹狀結構管理實驗系譜的自動搜尋框架:每節點為一個 solo/blend 配置,依 lineage 擴展
lineage	樹搜尋中由根節點某直接子節點衍生的整條系譜(一個突變方向)
plateau	lineage 連續數次未刷新全域最佳而被凍結,搜尋轉往其他 lineage
explore burst	全部 lineage 皆 plateau 後強制注入的一批長射種子(含 mega-blend)
mega-blend	把當時整個 solo 池全部納入的 kitchen-sink blend
OOF 重現閘門	提交前把最佳解全部成員從頭重訓,逐位元比對 OOF 與搜尋當時快取一致才允許產生 test 預測
CV-only	該結果僅有交叉驗證分數、無排行榜(LB)錨點

2.3 階段與刻度定義

四層 tier 定義(消融階梯,逐層疊加):

層級	定義
tier1	基線:Claude Code 直接執行 generic 批次管線(run_competition.py),無 skill、無人工特徵
tier2	+ kaggle-agent skill 六階段流程(EDA→特徵工程→建模→評估)
tier3	+ self-improvement 線性迭代(經驗庫先驗驅動的逐項改進)
tier4	+ 樹搜尋(harness v3,結構化搜尋特徵/模型/超參組合空間)

本場用到的子刻度(分類字典,僅列本場有天然紀錄者;§ 5 有對應分數表):

子刻度	定義
1.b	多模型 + OOF 權重搜尋 blend
2.b	特徵工程(本場:28 特徵 + fold-safe surname TE 修正)
3.a	經驗庫先驗(本場:is_unbalance 消融)
3.b	Optuna 超參搜尋(fold-0 代理)
3.c	調參版入池不替換
3.d	seed bagging
4.e	相位機 + explore burst + 自動停止(harness v3)

階段代號對照表(內部代號,正文出現前先定義):

代號	白話名稱	對應層級
r1 / r2 / r3	tier3 線性迭代第 1 / 2 / 3 輪	tier3
node #N	樹搜尋樹中的節點編號(見第 2.2 節)	tier4
H-1	harness v3 上線工程(resume 契約 / subprocess timeout / burst 種子健全閘)	tier4 基礎設施

3. 流程(how):五大元件

3.1 資料規格

項目	值
train 列數	165,034
test 列數	110,023
原始欄位數	12(9 數值 + 3 類別,不含 id/target)
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

目標 `Exited` 為 0/1,正類(流失)比例約兩成(mean 0.211599)。資料乾淨:train/test 皆零缺失、零重複列,無高共線特徵對;數值欄 train/test 均值漂移皆在 1% 內,無明顯 分布位移。單變數相關以 Age 最強(Pearson +0.340768),NumOfProducts 次之 (-0.214554);EDA 驗證提示為分層抽樣(target 離散),與實際採用的 StratifiedKFold 一致。

特徵工程沿用二月版 28 特徵集(性別/地區 dummy、年齡衍生、餘額衍生、產品數旗標、七個 交互項、surname 目標編碼),但帶一項刻意修正:二月版 surname TE 以獨立折(不同 seed) 計算 OOF,姓氏分組跨兩種折劃分共享,構成隱性洩漏路徑;本次改為 fold-safe(TE 折 == 模型訓練折)。此修正使可比分數整體下修(詳見第 3.5 節與第 6 節)。

3.2 實驗總表

語意澄清(本報告全文適用):AUC 為連續排名指標,本場無取整/後處理議題,「原始 OOF」即為決策分數,下表兩欄同值。
exp 1、2 為二月首跑的舊 schema 紀錄,無法由 collect.py 解析,列於第 4 節「無法解析之紀錄」,不進本表。

exp	階段	模型/成員	特徵數	原始 OOF	決策分數	採納
3	tier1	LGB(generic)	無紀錄	0.89097	0.89097	否
4	tier1	XGB(generic)	無紀錄	0.89068	0.89068	否
5	tier1	CAT(generic)	無紀錄	0.8913	0.8913	否
6	tier1	LGB+XGB+CAT blend(generic)	無紀錄	0.8922	0.8922	是(tier1 基線)
7	tier2	LGB(skill solo)	28	0.89365	0.89365	否
8	tier2	XGB(skill solo)	28	0.893965	0.893965	否
9	tier2	CAT(skill solo)	28	0.893913	0.893913	否
10	tier2	LGB+XGB+CAT blend	28	0.894302	0.894302	是(tier2 最佳)
11	tier3 r1	LGB is_unbalance=True(消融)	28	0.893235	0.893235	否(先驗成立,棄加權)
12	tier3 r1	3-way blend(LGB 不加權)	28	0.894302	0.894302	否(與 exp 10 同值)
13	tier3 r2	LGB Optuna-tuned(fold-0 代理)	28	0.894171	0.894171	否(本場最強 solo)
14	tier3 r2	4-way blend(+LGB_tuned)	28	0.894354	0.894354	是(tier3 最佳)
15	tier3 r3	LGB_tuned seed=2024(seed-bag)	28	0.894137	0.894137	否
16	tier3 r3	5-way blend(+seed-bag)	28	0.894354	0.894354	否(增益歸零,依協定停止)
17	tier4	樹搜尋 node #44:37 成員 mega-blend	28	0.894393	0.894393	是(最終最佳)

best 成員表(exp 17,node #44 mega-blend;僅列權重 ≥ 0.01 的 18 個成員,其餘 19 個 成員權重 < 0.01)

成員	權重	solo 分數	備註
node#18(lgb)	0.1848	0.894191	調參參數族 seed 變體,權重最高
node#42(xgb)	0.1685	0.89369	深 XGB 系譜成員
node#15(lgb)	0.1254	0.894184	調參參數族 seed 變體
node#33(cat)	0.077	0.893612	深 CatBoost 系譜成員
node#23(lgb)	0.0558	0.89417	調參參數族 seed 變體
node#1(lgb)	0.0496	0.893825	淺 LGB 手調變體
node#28(lgb)	0.0481	0.893967	淺 LGB 系譜成員
node#31(cat)	0.0435	0.89354	深 CatBoost 系譜成員
node#40(xgb)	0.0424	0.89354	深 XGB 系譜成員

成員	權重	solo 分數	備註
node#5(lgb)	0.0423	0.894171	邊界推進(num_leaves 上推)節點
node#17(lgb)	0.0268	0.89417	調參參數族 seed 變體
node#39(xgb)	0.025	0.893552	深 XGB 系譜成員
node#27(lgb)	0.0228	0.893932	淺 LGB 系譜成員
node#32(cat)	0.0224	0.893585	深 CatBoost 系譜成員
node#29(cat)	0.018	0.893563	深 CatBoost 系譜成員
node#24(lgb)	0.0149	0.893934	淺 LGB 系譜成員
node#26(lgb)	0.0141	0.893947	淺 LGB 系譜成員
node#30(cat)	0.0138	0.893557	深 CatBoost 系譜成員

權重高度分散,無單一成員過半——與 tier3 各輪 blend 權重集中於 3-5 個成員形成對比,mega-blend 的增益來自大量弱異質成員的方差抵消。

3.3 訓練規格表

全部 15 筆實驗(exp 3-17)共用同一 CV 方案,列一次:

exp	CV 方案	folds	seed
3-17(全部)	5fold_stratified	5	42

正類約兩成的不平衡二元目標,以 StratifiedKFold 保各折比例一致(EDA 驗證提示同此); 四層(含樹搜尋每一節點)共用 `features.py::make_folds` 產生的同一組折,故全報告分數 逐位元可比。關鍵超參:exp 13 之 Optuna 最優(num_leaves 242、max_depth 5、learning_rate 0.0123、min_child_samples 11,詳 experiments.json notes);exp 17 權重 搜尋規格見其 ensemble.method(dirichlet k=800、seed 42、座標上升精修)。

3.4 推論表

AUC 需機率輸出,全部提交檔皆為原始機率、無後處理。本場 Late Submission 已關閉 (帳號 userHasEntered=False ,CreateSubmission 403,以 tier3 與 tier4 兩個實檔各實測 一次),故「已提交」全為否。

exp	後處理	submission 檔	已提交
6	無	sub_generic_0.89220_20260707_100440.csv	否
10	無	tier2_blend_0.89430_20260707_100641.csv	否
12	無	tier3_r1_blend_0.89430_20260707_100859.csv	否
14	無	tier3_r2_blend_0.89435_20260707_102041.csv	否
16	無	tier3_r3_blend_0.89435_20260707_102221.csv	否
17	無	sub_tree_best_0.89439_20260707_115813.csv	否(403,CV-only)

exp 17 的 submission 檔由 `scripts/06_rebuild_tree_best.py` 產生:37 個成員全部依樹中 配置從頭重訓,逐成員 OOF 與搜尋快取逐位元一致($\max|\text{diff}| = 0.0$)、權重搜尋重放復原 全精度權重且 blend AUC 逐位元吻合後,才以復原權重混合 test 預測(OOF 重現閘門, s3e16 前例)。

3.5 評估指標 / 排行榜

指標定義:ROC-AUC = 隨機一正一負樣本對中,模型將正樣本排前的機率(排序品質,與 門檻無關)。

分數總表見第 3.2 節(各 solo 與 blend 之 OOF AUC)。本場無排行榜錨點:Late Submission 關閉,四層全部 CV-only,排行榜表從缺。

誠實但書:tier 間增益為 OOF 內部比較,無外部 LB 驗證;其量級(見 S 5 算式)比 同資料族二月版實測的 CV↔LB gap(~0.005)小約兩個數量級,跨層排序在真實 LB 上未必 保持。本場 CV 的外部可信度只能借二月錨點間接支撐(見下)。

二月首跑(不同特徵口徑:TE 非 fold-safe,含 is_unbalance)曾實際提交,是本資料族僅有 的 CV↔LB 錨點:

二月錨點(exp 2,舊口徑):CV 0.89653 → Public LB 0.88716 / Private LB 0.89179
CV↔Private gap:0.89653 - 0.89179 = 0.00474(CV 輕微樂觀,量級與 S3 各場一致)
本次 fold-safe 修正後同配方 solo 降至 0.8937 量級(洩漏修正使 CV 更保守,
gap 預期小於二月版)

4. 實驗軌跡

(階段代號定義見第 2.3 節;下表「決策分數」= OOF AUC)

exp	時間	決策分數	階段	一句話摘要
3	07-07T10:05:28	0.89097	tier1	generic LGB,raw 欄位 label-encode
4	07-07T10:05:28	0.89068	tier1	generic XGB
5	07-07T10:05:28	0.8913	tier1	generic CAT,tier1 最強 solo
6	07-07T10:05:28	0.8922	tier1	generic 3-model blend = tier1 基線
7	07-07T10:06:41	0.89365	tier2	28 特徵 + fold-safe TE,LGB
8	07-07T10:06:41	0.893965	tier2	同特徵 XGB,tier2 最強 solo
9	07-07T10:06:41	0.893913	tier2	同特徵 CAT
10	07-07T10:06:41	0.894302	tier2	3-model blend = tier2 最佳
11	07-07T10:08:35	0.893235	tier3 r1	is_unbalance=True 消融:加權較差,經驗庫先驗跨季成立
12	07-07T10:08:59	0.894302	tier3 r1	blend 重搜權重,與 exp 10 同值
13	07-07T10:20:23	0.894171	tier3 r2	Optuna fold-0 代理 50 trials,本場最強 solo
14	07-07T10:20:42	0.894354	tier3 r2	調參版入池不替換,4-way = tier3 最佳

exp	時間	決策分數	階段	一句話摘要
15	07-07T10:21:52	0.894137	tier3 r3	seed=2024 seed-bag 成員
16	07-07T10:22:21	0.894354	tier3 r3	5-way 增益歸零,連續無改善依協定停止
17	07-07T11:58:44	0.894393	tier4	樹搜尋 60 節點滿預算,explore burst 之 mega-blend(node #44)

- **突破點 1(exp 6→10;增量見 § 5 算式):**本場最大單段增益來自 28 特徵集 + fold-safe surname TE(tier2 特徵工程),遠大於其後所有調參/集成增益之和。
- **突破點 2(exp 13→14;增量見 § 5 算式):**Optuna 調參版「入池不替換」使 4-way blend 刷新 tier3 最佳——S3 驗證過的三步配方(調參→入池→seed-bag)中,前兩步跨季成立,第三步 (exp 15→16)增益歸零。
- **突破點 3(exp 17;增量見 § 5 算式):**tier4 樹搜尋 exploit 階段 44 節點無一超越 tier3; 全 lineage plateau 觸發強制 explore burst,kitchen-sink mega-blend(37 成員)一舉刷新 全域最佳——增益來自「把整個 solo 池混起來」,不來自任何單一新 solo(兩個 burst 長射 solo 0.89419 / 0.893317 皆未勝出)。

無法解析之紀錄(facts.unparsed,二月首跑舊 schema,原文照列):

```
{
  "id": 1,
  "name": "Majority Class Baseline",
  "model": "majority",
  "cv_score": 0.5,
  "cv_std": 0.0,
  "notes": "AUC=0.5 (random), Accuracy=0.78840"
}
{
  "id": 2,
  "name": "LightGBM Baseline",
  "model": "lightgbm",
  "cv_score": 0.89653,
  ...
  "notes": "28 features, stratified 5-fold, surname target encoding, is_unbalance=True.
  Feb 2026 run (STATUS.md): submission lgbm_baseline_20260219_150434.csv ->
  Public LB 0.88716 / Private LB 0.89179."
}
```

5. 效能對照:四層消融

層級	配置	分數	相對改善
tier1	基線(generic 批次,exp 6 三模型 blend)	0.8922	—(基線)
tier2	+ skill 六階段(exp 10,28 特徵 + fold-safe TE)	0.894302	見下方算式
tier3	+ 線性迭代(exp 14,Optuna 調參入池 4-way)	0.894354	見下方算式
tier4	+ 樹搜尋(exp 17,node #44 mega-blend)	0.894393	見下方算式

```
tier1→tier2:0.894302 - 0.8922    = 0.002102,相對改善 0.002102 / 0.8922    = 0.2356%
tier2→tier3:0.894354 - 0.894302 = 0.000052,相對改善 0.000052 / 0.894302 = 0.0058%
tier3→tier4:0.894393 - 0.894354 = 0.000039,相對改善 0.000039 / 0.894354 = 0.0044%
```

本場由導入報告功能後之版本執行,分數自 tier2 起未低於前一層——符合計畫書目標三(效能不 退步)。

本場為 AUC 連續指標、無特殊口徑,四層皆為同折同特徵之 OOF AUC,直接可比(唯 tier1 為 generic 管線之 raw 欄位口徑,特徵不同屬消融設計本意)。

子刻度分解(定義見第 2.3 節;僅列本場有天然紀錄者,分數皆引自第 3.2 節總表):

子刻度	對應紀錄	分數
1.b 多模 + 權重搜尋 blend	exp 6	0.8922
2.b 特徵工程	exp 10	0.894302
3.a 經驗庫先驗(is_unbalance 消融)	exp 12	0.894302(+0)
3.b + 3.c Optuna 調參入池	exp 14	0.894354
3.d seed bagging	exp 16	0.894354(+0)
4.e 相位機 + explore burst(v3)	exp 17	0.894393

6. 總結

本場資料乾淨(零缺失、零重複、無漂移),訊號集中在 Age 與 NumOfProducts 兩個特徵; 正類約兩成的不平衡形態決定了兩件事:CV 用 StratifiedKFold,以及「AUC 排名指標不吃 不平衡加權」的經驗庫先驗有了跨季重驗的舞台(r1 消融:加權 0.893235 < 不加權,先驗在 165k 大樣本上同向成立)。

本場最重要的方法決策是 surname 目標編碼的 fold-safe 修正:二月版 TE 折與模型折不同 seed,姓氏分組跨折共享形成隱性洩漏,是二月 CV 0.89653 高於本次同配方(0.8937 量級)的主因——「用不同折算 TE 看似避開洩漏,實為另一種洩漏路徑」是本場寫回經驗庫的核心教訓。修正後全部四層共用同折同特徵,報告內分數逐位元可比。

增益結構呈典型遞減階梯(逐層數字見 S5 算式):tier2 特徵工程為最大單段,tier3 線性 迭代次之(Optuna 調參入池有效、seed-bag 歸零、依協定停止),tier4 增量最小——exploit 階段一無所獲,增益全部來自強制 explore burst 的 37 成員 mega-blend,與 S3 結論一致。經驗庫配方在 S4 首場:先驗方向全部成立,增益量級隨資料放大而縮小。

工程面,本場是 harness v3 H-1 resume 契約的第一次真實復原:前代執行程序在播種中被 外部中止, load_search_state 載回 5 節點狀態且分數與 experiments.json 逐位元一致,補種後跑滿預算;過程中並修復了「lineage 提案耗盡即空轉」的 driver 缺口。

最終 exp 17 通過 OOF 逐位元重現閘門(37 成員 $\max|\text{diff}| = 0.0$)後產生 test 預測,但 Late Submission 關閉(403 實測),本場四層皆 CV-only,外部可信度借二月錨點 (gap ~0.005)間接支撐。

重現本實驗的最短路徑:見第 7 節。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 資料(需有效 KAGGLE_API_TOKEN;本場資料已在磁碟)
export KAGGLE_API_TOKEN=$(cat ~/.kaggle/kaggle_api_token.txt | tr -d '[:space:]')
uv run kaggle competitions download -c playground-series-s4e1 \
    -p competitions/playground-series-s4e1/data && \
    unzip -o competitions/playground-series-s4e1/data/playground-series-s4e1.zip \
    -d competitions/playground-series-s4e1/data
```

```
# tier1:generic 批次基線(exp 3-6)
uv run python3 competitions/run_competition.py playground-series-s4e1

# tier2:skill 六階段(28 特徵 + fold-safe TE;exp 7-10)
uv run python3 competitions/playground-series-s4e1/scripts/04_train_blend.py

# tier3:線性迭代三輪(exp 11-16)
uv run python3 competitions/playground-series-s4e1/scripts/05_iterate.py r1_unbalance_ablation
uv run python3 competitions/playground-series-s4e1/scripts/05_iterate.py r2_optuna_lgb
uv run python3 competitions/playground-series-s4e1/scripts/05_iterate.py r3_seed_bag

# tier4:樹搜尋 v3(exp 17;可中斷續跑,狀態存 experiments_tree_v3.json)
uv run python3 tree_search/run_s4e1_v3.py

# 最佳解重建 + OOF 重現閘門 + 產生 test 預測(submission 檔)
uv run python3 competitions/playground-series-s4e1/scripts/06_rebuild_tree_best.py

# 提交(本場 Late Submission 已關閉,以下指令現況回 403,列供流程完整性)
uv run kaggle competitions submit -c playground-series-s4e1 \
    -f competitions/playground-series-s4e1/submissions/<submission.csv> -m "<msg>"
```

執行目錄為專案根目錄 `/home/tjyen/ai_agents/kaggle` ;所有 Python 執行皆透過 `uv run` 。