

競賽分析報告:playground-series-s5e10

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整(二月基線有真實排行榜錨點,本輪 2-4 階段 CV-only,見第 3.5 節) | 產生日期:2026-07-07

目錄	
1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格	4
3.4 推論表	4
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	5
5. 效能對照(逐階段)	6
6. 總結	7
7. 重現指令	7

1. 競賽目的

What:依道路與環境欄位(曲率、速限、車道數、號誌、通報事故數、能見度、路面狀況、是否上學季等)預測每段道路的**事故風險** `accident_risk` (0-1 連續值),為迴歸問題。

Why:評估指標為 **RMSE(minimize)**——預測值與真實風險的均方根誤差,越小越好。目標落在 0-1、平均 0.352、標準差 0.166,且值域被量化在 0.01 的格點上(僅 98 個相異值); 這個「連續分數卻落在離散格點」的性質,誘使人做「把預測貼回格點」的後處理,本場實測 證明對 RMSE 反而有害(見第 4 節)。

Data:train 517,754 列、test 172,585 列。資料乾淨:無缺失、無 train/test 分布漂移 (每個特徵的均值位移都 < 0.8%);但有 10,774 列完全重複的特徵組合對到不同目標值, 這是資料本身的雜訊地板(相對 51 萬列佔比極小)。曲率與事故風險相關最強(Pearson 0.544)、速限次之(0.431)、通報事故數中等(0.214);車道數、號誌有無、上學季近乎零相關($|r| < 0.01$)。

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第3版(預算相位機)。目標為連續且獨立同分布,交叉驗證採 **KFold 5 折(shuffle,seed=42)**——不需分層或分箱,全場固定同一組折;二月既有紀錄用的是同一組折(KFold 切分只依樣本數與 seed),故本輪各階段分數與二月基線直接可比。

2.2 本場專業術語

本場無特有專業術語,所需詞彙均見《前言》第5節。

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段 1 | 無 skill 基線

- 1.1 單模型基線 — 使用(沿用二月既有紀錄,見第3.5節)
- 1.2 三模型 blend — 使用(二月加權集成)

階段 2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(連續 iid 目標,plain shuffled KFold)
- 2.2 EDA 驅動特徵工程 — 使用(沿用二月建立的 27 特徵集)
- 2.3 指標感知後處理 — 使用(檢驗「貼回 0.01 格點」,對 RMSE 否決,維持只 clip,見第4節)
- 2.4 場內反思回退 — 本場未使用

階段 3 | +線性自我迭代

- 3.1 經驗庫先驗 — 使用(兩條先驗經對照檢驗,一條確認、一條否決,見第4節)
- 3.2 Optuna 超參搜尋 — 使用(fold-0 代理目標,直接優化 clipped RMSE)
- 3.3 調參入池 — 使用(調參模型加入池,不取代)
- 3.4 seed bagging — 使用
- 3.5 結構化去噪 — 本場未使用

階段 4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 使用(節點為 blend,直接以 clipped OOF RMSE 評分)
- 4.3 先驗注入+去重 — 使用
- 4.4 邊界推進 mutation — 使用

- 4.5 預算相位機 — 使用(第 3 版,60 節點預算;爆發後耐心停於 39 個評估節點)

階段 5 | +外部想法注入

- 5.1 外部想法庫先驗 — 使用(快評注入 stacking meta 模型,在階段4收斂點以快取 OOF 評估;未勝過階段4 → 階段5=階段4)
- 5.2 重組 mutation — 本場未使用(機制已建置[harness_v4 機械版 + LLM 版];跨場 pilot 實測與 mega-blend 搜尋冗餘、無增益,見 docs/recombine_findings)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	517,754
test 列數	172,585
特徵數	原始欄位 + 二月特徵工程展開為 27
目標	accident_risk(0-1 連續,均值 0.352,落在 0.01 格點,98 相異值)
特別規則摘要	禁外部資料/禁預訓練模型/禁網路存取;每日提交上限 5 次

3.2 實驗總表

計分方式說明(全文適用):所有決策分數均為 5 折 clipped-OOF RMSE(越小越好); clip 指把預測夾回 [0,1],是唯一保留的後處理。

實驗編號	階段	模型/成員	決策分數	是否採納
4	1	二月加權集成(LGB+XGB+LGB)	0.056074	是(階段 1 冠軍)
5	2	LGB solo(27 特徵)	0.056069	否(階段 2 成員)
6	2	XGB solo(27 特徵)	0.056071	否(階段 2 成員)
7	2	CAT solo(27 特徵)	0.056061	否(階段 2 成員)
8	2	LGB+XGB+CAT blend(單純形權重搜尋)	0.056027	是(階段 2 冠軍)
9	3.1	LGB(交互項先驗檢驗,12 基礎特徵)	0.056061	是(先驗確認,見第 4 節)
10	3	第 1 輪 blend(先驗解析後)	0.056017	否(被後續超越)
11	3.2	LGB Optuna 調參(fold-0 代理,直接優化 RMSE)	0.055998	否(入池成員)
12	3	第 2 輪 blend(+調參 LGB)	0.055982	否(被後續超越)
13	3.4	調參 LGB seed=2024	0.055991	否(入池成員)
14	3	第 3 輪 blend(+seed 成員)	0.055976	是(階段 3 冠軍)
15	4.2	樹搜尋 mega-blend(node #29,14 有效成員)	0.055968	是(全場最佳)

實驗編號	階段	模型/成員	決策分數	是否採納
16	5	外部注入快評候選(EXT-09(stacking);沿用階段4成員 OOF)	0.055969	否(未勝過階段4,見 § 5)

最佳解成員表(第 15 次實驗,node #29 全池 mega-blend,14 個非零權重成員)

成員	模型	權重	solo 分數
node#15	LGB	0.3359	0.055987
node#17	LGB	0.0984	0.056007
node#6	LGB	0.0898	0.056015
node#19	LGB	0.0892	0.056007
node#0	LGB	0.0658	0.055991
node#20	XGB	0.0609	0.056058
node#4	LGB	0.0485	0.056005
node#26	CAT	0.0457	0.056082
node#23	LGB	0.0428	0.056076
node#24	LGB	0.0349	0.056076
node#28	CAT	0.0342	0.056083
node#2	XGB	0.0213	0.056066
node#14	LGB	0.0201	0.056006
node#1	LGB	0.0125	0.056077

分數最好的單一成員(node#15,0.055987)拿到最大權重,但真正壓低 blend 的是把 14 個多樣成員(含 solo 分數平庸的 CatBoost node#26、node#28)一起混起來——單一最佳成員 0.055987,合成後 0.055968。

3.3 訓練規格

項目	設定
切分	KFold 5 折(shuffle,seed=42),全場固定同一組折
超參搜尋	Optuna 40 trials(第 11 次實驗):每組參數先只在第 0 折評分(630.4 秒),目標直接為 clipped RMSE,勝出者再以完整 5 折驗證
樹搜尋	第 3 版工具:60 節點預算、評估 39 個節點、總時 3308.1 秒;停於爆發後 20 次無改善(耐心準則)。過程有失敗節點:邊界推進(4.4)把 node#5 的 min_child_samples 推到非法負值→評估失敗,連帶 4 個引用它的 blend 節點失敗;另 6 個為去重佔位(皆不影響冠軍與階梯)

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
4	clip [0,1]	(二月既有提交)	是(二月,見第 3.5 節)
15	clip [0,1]	sub_tree_best_0.05597_20260707_182744.csv	否(競賽關閉,CV-only)

`id_column = id`、`target_column = accident_risk`。第 15 次實驗 的提交檔由重建流程重新訓練 14 個成員、通過 OOF 重現閘門後產出(重建指令見第 7 節)。

3.5 評估指標 / 排行榜

- 指標:RMSE(minimize)。
- **階段 1 有真實排行榜錨點**(二月既有紀錄,非本輪產出):加權集成 CV 0.056074、Public LB 0.05558、Private LB 0.05583。兩榜皆低於(優於)CV,顯示本資料集的排行榜 分數方向性地優於本地 OOF。
- **本輪(階段 2-4)CV-only**:競賽已關閉延遲提交,重建流程通過 OOF 重現閘門並產出 提交檔後,提交遭 Kaggle 拒絕,依規記錄為 CV-only;以二月階段 1 的 LB 錨點作為 本地分數的外部參考背景。

4. 實驗軌跡

實驗編號	決策分數	階段	摘要
4	0.056074	1	二月加權集成,強起點
8	0.056027	2	27 特徵集三模型 blend(成員 第 5-7 次實驗)
9	0.056061	3.1	先驗檢驗 A:交互項先驗確認(12 基礎特徵勝 27 特徵)
10	0.056017	3	兩先驗解析後重配權重
11	0.055998	3.2	Optuna 調參 LGB(fold-0 代理,直接優化 RMSE)
12	0.055982	3	調參 LGB 入池,重配權重
14	0.055976	3	seed=2024 成員入池,3 輪迭代收尾
15	0.055968	4.2	樹搜尋 node #29,全池 mega-blend
16	0.055969	5	外部注入快評:EXT-09(stacking) 候選 OOF 未勝過階段4,不採納

- **轉折 1(第 9 次實驗,交互項先驗被確認)**:經驗庫帶來 s3e9 的先驗「顯式乘積/多項式 交互欄位對 GBDT 沒有增益(樹自己會切分)」。本場以對照檢驗:12 基礎特徵的 solo LGB (0.056061)勝過含 15 個交互欄位的 27 特徵集(0.056069),先驗**確認**,交互欄位自 LGB 家族剔除。這一條**推翻了二月自己 STATUS 宣稱「交互項是關鍵」的說法**——同一資料、換一套決策紀律,結論相反,已寫回經驗庫。
- **轉折 2(貼格點先驗被否決)**:目標落在 0.01 格點,誘使人套用 s3e14 的先驗「把預測貼回 最近的訓練觀測格點」。本場檢驗:貼格點後 RMSE 升到 0.056095,劣於只 clip 的 0.056027。原因是 RMSE(平方誤差)要的是條件期望(連續均值),不是格點值——把連續預測硬拉到格點 只會增加誤差。先驗**否決**,後處理維持只 clip;此為「離散外觀的目標不代表該做離散化」的一條反例。
- **轉折 3(第 11-14 次實驗,線性迭代穩步推進)**:Optuna 直接以 clipped RMSE 為目標調參 (0.055998)、再換 seed=2024 重訓入池,blend 由 0.056027 一路推到 0.055976,每步小而確實。
- **轉折 4(第 15 次實驗,mega-blend 這次贏了)**:60 節點預算的樹搜尋中,把全池 21 個 solo 一次混起來、由 Dirichlet 權重搜尋定權的 kitchen-sink mega-blend(node #29)得 0.055968,勝過線性階段的最佳 blend(0.055976)與最強單一 solo(0.055991)。值得一提的是 **這與 s4e11 恰成對比**:同一套搜尋機制、同樣的強制探索爆發,s4e11 的 mega-blend 輸給了 系譜內逐步長成的血統 blend,本場卻是 mega-blend 直接奪冠——搜尋在不同資料上找到不同 形狀的贏家,這正是用搜尋取代固定配方的價值。

- **收尾(關門與提交)**:最佳解 14 個非零權重成員全部從頭重訓,逐位比對 OOF 與搜尋當時 快取一致,通過 OOF 重現關門後產出提交檔;提交遭拒(競賽關閉),記 CV-only。

5. 效能對照(逐階段)

階段	配置	分數(RMSE)	相對改善
1	未用 skill,二月加權集成(第 4 次實驗)	0.056074	—(基準)
2	+ kaggle-agent skill 六階段(第 8 次實驗)	0.056027	0.08%
3	+ 線性自我迭代(第 14 次實驗)	0.055976	0.09%
4	+ 樹搜尋(第 15 次實驗)	0.055968	0.01%
5	+ 外部想法注入(第 16 次實驗,快評)	0.055968	0.00%(未勝過)

相對改善計算式(每階段對前一階段;RMSE 越小越好,改善=(前-後)/ 前)

階段1→2: $0.056074 - 0.056027 = +0.000047$, 相對改善 $0.000047 / 0.056074 = 0.0838\%$
 階段2→3: $0.056027 - 0.055976 = +0.000051$, 相對改善 $0.000051 / 0.056027 = 0.0910\%$
 階段3→4: $0.055976 - 0.055968 = +0.000008$, 相對改善 $0.000008 / 0.055976 = 0.0143\%$
 階段1→4: $0.056074 - 0.055968 = +0.000106$, 相對改善 $0.000106 / 0.056074 = 0.1891\%$
 階段4→5: 注入候選 0.055969 未勝過階段4 0.055968, 搜尋保留階段4 → 相對改善 0.00%(外部注入無增益)

四個階段單調下降(RMSE 越小越好),階段 1→4 累計壓低約 0.19%。增幅集中在前兩步(skill 與線性迭代各約 0.08–0.09%),樹搜尋這一步只再擠出 0.01%——與 s4e11 一致的 跨季型態:遞增階梯在新季度仍成立、但可壓縮空間明顯縮小,尾段每一步都是「最後一哩」的精細競爭。

階段 5 | + 外部想法注入

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 **EXT-09:stacking**——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic),以 nested-CV 避免洩漏。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們**已算好的 OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

階段5 注入候選(stackings)OOF RMSE = 0.055969
 階段4 冠軍 OOF RMSE = 0.055968
 差距 = -0.000001 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場是跨季驗證的第三場(前兩場見 playground-series-s4e1、s4e11 報告)。三個要點:

第一,**經驗庫先驗必須連同適用條件一起檢驗**。本場一次驗了兩條先驗:交互項先驗(s3e9)被**確認**、貼格點先驗(s3e14)被**否決**。尤其交互項這條,結論直接推翻二月自己對同一 資料集的宣稱——先驗不是照抄舊結論,而是帶著假設當場對照,確認與否決都寫回經驗庫。

第二,**離散外觀不等於該離散化**。目標落在 0.01 格點很容易誘導人做貼格點後處理,但 RMSE 要的是條件均值;實測貼格點反而升高誤差(0.056095 對 0.056027)。這與 s3e16(取整 MAE 場)恰成互補:指標決定後處理,不是目標的外觀決定後處理。

第三,**樹搜尋的贏家形狀因資料而異**。本場 mega-blend 奪冠、s4e11 mega-blend 落敗,兩場用的是同一套搜尋機制——這正是「用搜尋取代固定配方」的理由:固定套路會賭錯形狀,搜尋 會就地找到對的那個。整體看,遞增配置的階梯在跨季資料上第三度成立(0.056074→0.055968,精確數字見第 5 節算式),增幅隨階段遞減;本輪 CV-only,以二月階段 1 的 LB 錨點 (Public 0.05558 / Private 0.05583,皆優於其 CV 0.056074)提示本資料集排行榜方向性優於本地分數。

階段 5(外部想法注入) 經快評未勝過階段4:注入機制可運作、也產生了候選(stacking),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 階段 1:二月加權集成基線(既有紀錄;full_pipeline.py 為二月完整管線,含基線集成)
uv run python3 competitions/playground-series-s5e10/scripts/full_pipeline.py

# 階段 2:skill 六階段管線(27 特徵集,三模型 + 權重搜尋)
uv run python3 competitions/playground-series-s5e10/scripts/04_train_blend.py

# 階段 3:線性自我迭代(兩先驗檢驗 → Optuna → seed bagging,3 輪)
uv run python3 competitions/playground-series-s5e10/scripts/05_iterate.py

# 階段 4:樹搜尋(第 3 版工具,60 節點預算)
uv run python3 tree_search/run_s5e10_v3.py

# 重現最佳解(00F 重現閘門 + 產出提交檔)
uv run python3 competitions/playground-series-s5e10/scripts/06_rebuild_tree_best.py

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 00F、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s5e10
```