

競賽分析報告:playground-series-s6e1

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整(二月基線有真實排行榜錨點但為 RMSE 計分,與本輪 R2 不同指標;本輪 2-4 階段 CV-only,見第 3.5 節) | 產生日期: 2026-07-07

目錄	
1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格	4
3.4 推論表	4
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	5
5. 效能對照(逐階段)	6
6. 總結	7
7. 重現指令	7

1. 競賽目的

What:依學習習慣與人口統計欄位(每日讀書時數、出席率、睡眠時數與品質、主修、讀書方式、設施評分、考試難度、性別、年齡、有無網路)預測每位學生的**考試分數** `exam_score` (19.6-100 連續值),為迴歸問題。

Why:本跨季單元依 `config.yaml` 以 **R2(maximize)**為評估指標——決定係數,越大越好。目標落在 19.6-100、平均 62.51、標準差 18.92、共 805 個相異值。單一最強預測子非常突出: 每日讀書時數與分數的 Pearson 相關達 0.762267,遠勝第二名的出席率(0.360954);這個「一個主導特徵 + 一票弱特徵」的結構,誘使人替它手工造大量顯式交互欄(讀書時數 × 出席率、× 睡眠品質、× 設施……),本場正面檢驗了這些交互欄對 GBDT 是否真有增益(見第 4 節)。

Data:train 630,000 列、test 270,000 列。資料極乾淨:無缺失、無特徵重複列、無 train/test 分布漂移(每個數值特徵的均值位移都 < 0.04%)。年齡近乎與分數無關 (Pearson 0.010472)。

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第3版(預算相位機)。目標為連續且獨立同分布,交叉驗證採 **KFold 5 折(shuffle,seed=42)**——不需分層或分箱,全場固定同一組折;二月既有紀錄用的是同一組折(KFold 切分只依樣本數與 seed),故本輪各階段分數與二月基線直接可比。本場所有訓練皆設為跨行程逐位可重現(LightGBM `deterministic=True + force_row_wise=True`、三模型統一 `num_threads=16`),這是第4階段 OOF 重現閘門能逐位通過的前提(見第4節轉折4)。

2.2 本場專業術語

本場無特有專業術語,所需詞彙均見《前言》第5節。

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段 1 | 無 skill 基線

- 1.1 單模型基線 — 使用(沿用二月既有紀錄,見第3.5節)
- 1.2 三模型 blend — 使用(二月加權集成)

階段 2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(連續 iid 目標,plain shuffled KFold)
- 2.2 EDA 驅動特徵工程 — 使用(沿用二月建立的 22 特徵集)
- 2.3 指標感知後處理 — 使用(clip 到 [0,100],經階段3先驗檢驗 B 確認為安全網)
- 2.4 場內反思回退 — 本場未使用

階段 3 | +線性自我迭代

- 3.1 經驗庫先驗 — 使用(兩條先驗經對照檢驗,交互項先驗被否決、clip 先驗被確認,見第4節)
- 3.2 Optuna 超參搜尋 — 使用(fold-0 代理目標,直接優化 clipped R2)
- 3.3 調參入池 — 使用(調參模型加入池,不取代)
- 3.4 seed bagging — 使用
- 3.5 結構化去噪 — 本場未使用

階段 4 | +樹搜尋

- 4.1 單模型節點樹 — 本場未使用
- 4.2 ensemble 節點樹 — 使用(節點為 blend,直接以 clipped OOF R2 評分)

- 4.3 先驗注入+去重 — 使用(4 次去重前置攔截)
- 4.4 邊界推進 mutation — 本場未使用(root 調參後的參數皆位於搜尋盒內部,無邊界候選可推)
- 4.5 預算相位機 — 使用(第 3 版,60 節點預算;爆發後耐心停於 46 個評估節點)

階段 5 | +外部想法注入(ERA 第二支柱)

- 5.1 外部想法庫先驗 — 使用(快評注入 stacking meta 模型,在階段4收斂點以快取 OOF 評估;未勝過階段4 → 階段5=階段4)
- 5.2 重組 mutation — 本場未使用(快評聚焦外部想法注入,未做「取兩高分節點概念合成」的重組)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	630,000
test 列數	270,000
特徵數	原始 11 欄 + 二月特徵工程展開為 22
目標	exam_score(19.6–100 連續,均值 62.51、標準差 18.92、相異值 805、無缺失)
特別規則摘要	允許外部資料/預訓練模型/網路存取;每日提交上限 5 次

3.2 實驗總表

計分方式說明(全文適用):所有決策分數均為 5 折 clipped-OOF R2(越大越好); clip 指把預測夾回 [0,100],是唯一保留的後處理。

實驗編號	階段	模型/成員	決策分數	是否採納
4	1	二月加權集成(LGB+XGB+LGB)	0.786414	是(階段 1 冠軍)
5	2	LGB solo(22 特徵)	0.785938	否(階段 2 成員)
6	2	XGB solo(22 特徵)	0.786026	否(階段 2 成員)
7	2	CAT solo(22 特徵)	0.785979	否(階段 2 成員)
8	2	LGB+XGB+CAT blend(單純形權重搜尋)	0.786793	是(階段 2 冠軍)
9	3.1	LGB(交互項先驗檢驗,11 基礎特徵)	0.785844	否(先驗否決,見第 4 節)
10	3	第 1 輪 blend(先驗解析後)	0.786794	否(被後續超越)
11	3.2	LGB Optuna 調參(fold-0 代理,直接優化 R2)	0.786647	否(入池成員)
12	3	第 2 輪 blend(+調參 LGB)	0.786998	否(被後續超越)
13	3.4	調參 LGB seed=2024	0.786613	否(入池成員)

實驗編號	階段	模型/成員	決策分數	是否採納
14	3	第 3 輪 blend(+seed 成員)	0.787060	是(階段 3 冠軍)
15	4.2	樹搜尋 mega-blend(node #27,17 有效成員)	0.787183	是(全場最佳)
16	5	外部注入快評候選(EXT-09(stacking);沿用階段4成員 OOF)	0.787156	否(未勝過階段4,見 § 5)

最佳解成員表(第 15 次實驗,node #27 全池 mega-blend,17 個非零權重成員,依權重排序前 10)

成員	模型	權重	solo 分數
node#16	LGB	0.1126	0.786584
node#5	LGB	0.0998	0.786492
node#12	LGB	0.0983	0.786656
node#23	XGB	0.0817	0.785704
node#13	LGB	0.0696	0.786684
node#25	CAT	0.0635	0.785771
node#19	LGB	0.0633	0.786359
node#17	LGB	0.0615	0.786553
node#18	LGB	0.0593	0.786330
node#4	LGB	0.0588	0.786613

分數最好的單一成員是 node#13(0.786684),但它只拿到 0.0696 權重;真正壓出增益的是把 17 個多樣成員(含 solo 分數平庸的 XGB node#23、CatBoost node#25)一起混起來——單一最佳成員 0.786684,合成後 0.787183。

3.3 訓練規格

項目	設定
切分	KFold 5 折(shuffle,seed=42),全場固定同一組折
超參搜尋	Optuna 40 trials(第 11 次實驗):每組參數先只令第 0 折評分(715.9 秒),目標直接為 clipped R2,勝出者再以完整 5 折驗證
樹搜尋	第 3 版工具:60 節點預算、評估 46 個節點、總時 4592.9 秒;停於爆發後 20 次無改善(耐心準則),4 次去重前置攔截,無失敗節點

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
4	clip [0,100]	(二月既有提交)	是(二月,見第 3.5 節)
15	clip [0,100]	sub_tree_best_0.78718_20260707_221451.csv	否(競賽關閉,CV-only)

`id_column = id`、`target_column = exam_score`。第 15 次實驗的提交檔由重建流程重新訓練 21 個成員、通過 OOF 重現閘門後產出(重建指令見第 7 節)。

3.5 評估指標 / 排行榜

- 指標(本單元,依 config.yaml):R2(maximize)。
- 二月有真實排行榜,但為不同指標:**二月既有提交在 Kaggle 上以 **RMSE** 計分 (Public 8.70380、Private 8.72876,考分尺度),與本輪的 R2 不是同一指標,故無法為 R2 階梯提供數值錨點——它只證明二月管線能產出有效且可排序的 test 預測。
- 本輪(階段 1-4)CV-only:**R2 階梯全為本地 5 折 OOF;重建流程通過 OOF 重現閘門並產出提交檔後,提交遭 Kaggle 拒絕(競賽已關閉延遲提交,回傳 403),依規記錄為 CV-only。

4. 實驗軌跡

實驗編號	決策分數	階段	摘要
4	0.786414	1	二月加權集成,強起點
8	0.786793	2	22 特徵集三模型 blend(成員 第 5-7 次實驗)
9	0.785844	3.1	先驗檢驗 A:交互項先驗被否決(11 基礎特徵輸給 22 特徵)
10	0.786794	3	兩先驗解析後重配權重
11	0.786647	3.2	Optuna 調參 LGB(fold-0 代理,直接優化 R2)
12	0.786998	3	調參 LGB 入池,重配權重
14	0.787060	3	seed=2024 成員入池,3 輪迭代收尾
15	0.787183	4.2	樹搜尋 node #27,全池 mega-blend
16	0.787156	5	外部注入快評:EXT-09(stacking) 候選 OOF 未勝過階段4,不採納

- 轉折 1(第 9 次實驗,交互項先驗被否決):**經驗庫帶來 s3e9 的先驗「顯式乘積/多項式 交互欄位對 GBDT 沒有增益(樹自己會切分)」,以及 s3e7/s3e14「特徵過多反而退步、精簡是 常規武器」。本場以對照檢驗:11 基礎特徵的 solo LGB(0.785844)反而輸給含 11 個交互 欄位的 22 特徵集(0.785938),差 0.000094。先驗**否決**——本資料上顯式交互欄確實帶來 增益,22 特徵集保留。這一條與 **s5e10 恰成對比**:同一條 s3e9 先驗在 s5e10 被確認 (交互欄無用),在本場卻被否決(交互欄有用),也**印證了二月自己 STATUS 宣稱「交互項是關鍵」的說法**——同一條先驗、換一套資料,結論相反,確認與否決都寫回經驗庫。
- 轉折 2(clip 先驗被確認):**目標物理值域為 [0,100],套用 s3e1/s3e11 的先驗「clip 到 訓練目標值域作安全網」。本場檢驗:對階段 2 blend OOF 做 clip,R2 由 0.786792 微升到 0.786793(+0.000000 量級),幾乎不動——因為 GBDT 預測本就極少超出 [0,100]。先驗 **確認為無害安全網**,後處理維持只 clip;誠實註記其效果微小。
- 轉折 3(第 11-14 次實驗,線性迭代穩步推進):**Optuna 直接以 clipped R2 為目標調參 (0.786647,較未調參 LGB +0.000709,為本輪單模最大增益)、再換 seed=2024 重訓入池,blend 由 0.786793 一路推到 0.787060,每步小而確實。

- **轉折 4(第 15 次實驗, mega-blend 這次贏了; 開門的前提是可重現):**60 節點預算的樹 搜尋中, 把全池 21 個 solo 一次混起來、由 Dirichlet 權重搜尋定權的 kitchen-sink mega-blend(node #27, 17 個非零權重)得 0.787183, 勝過線性階段的最佳 blend(0.787060) 與最強單一 solo(0.786684)。這與 s5e10 一致(mega-blend 奪冠)、與 s4e11 相反(該場 血統 blend 勝出)。**收尾開門遇到一個真實工程坑並解決:**LightGBM 預設會依當下計時 在 row-wise/col-wise 直方圖之間自動選擇, 這使得同一組參數跨行程訓練不可逐位重現 (root 重訓與快取 OOF 一度相差達每樣本 0.87); 改為固定 `force_row_wise + num_threads` 後 降為 0.0, OOF 重現開門才能逐位通過。
- **收尾(開門與提交):**最佳解 21 個成員全部從頭重訓, 逐位比對 OOF 與搜尋當時快取一致 ($\max|dOOF| = 0$), 通過 OOF 重現開門後產出提交檔; 提交遭拒(競賽關閉, 403), 記 CV-only。

5. 效能對照(逐階段)

階段	配置	分數(R2)	相對改善
1	未用 skill, 二月加權集成(第 4 次實驗)	0.786414	—(基準)
2	+ kaggle-agent skill 六階段(第 8 次實驗)	0.786793	0.0482%
3	+ 線性自我迭代(第 14 次實驗)	0.787060	0.0339%
4	+ 樹搜尋(第 15 次實驗)	0.787183	0.0156%
5	+ 外部想法注入(第 16 次實驗, 快評)	0.787183	0.00%(未勝過)

相對改善計算式(每階段對前一階段; R2 越大越好, 改善 = (後-前) / |前|)

階段1→2: $0.786793 - 0.786414 = +0.000379$, 相對改善 $0.000379 / 0.786414 = 0.0482\%$
 階段2→3: $0.787060 - 0.786793 = +0.000267$, 相對改善 $0.000267 / 0.786793 = 0.0339\%$
 階段3→4: $0.787183 - 0.787060 = +0.000123$, 相對改善 $0.000123 / 0.787060 = 0.0156\%$
 階段1→4: $0.787183 - 0.786414 = +0.000769$, 相對改善 $0.000769 / 0.786414 = 0.0978\%$
 階段4→5: 注入候選 0.787156 未勝過階段4 0.787183, 搜尋保留階段4 → 相對改善 0.00%(外部注入無增益)

四個階段單調上升(R2 越大越好), 階段 1→4 累計提升約 0.0978%。增幅集中在前兩步 (skill 與線性迭代各約 0.03-0.05%), 樹搜尋這一步再擠出 0.0156%——與 s4e11、s5e10 一致的 跨季型態: 遞增階梯在新季度仍成立、但可壓縮空間明顯縮小, 尾段每一步都是「最後一哩」的精細競爭。本場目標的可預測性上限本就高(單一特徵 study_hours 就吃掉大半訊號), 四階段 都落在 0.786-0.787 的窄帶內。

階段 5 | + 外部想法注入(ERA 第二支柱)

階段5 讓 agent 在搜尋停滯時, 從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成一個新候選解丟進搜尋, 看能否突破階段4。本場注入的點子是 **EXT-09:stacking**——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic), 以 nested-CV 避免洩漏。

「快評」是什麼: 不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們**已算好的 OOF 預測(快取)**, 在這組成員上套用注入的點子、算出新組合的 OOF 分數, 再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

```
階段5 注入候選(stacking)00F R2 = 0.787156
階段4 冠軍          00F R2 = 0.787183
差距 = -0.000027 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4
```

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的 ERA 第二支柱誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場是跨季驗證的第四場(前三場見 playground-series-s4e1、s4e11、s5e10 報告)。三個要點:

第一,**同一條經驗庫先驗可以在不同場得到相反的驗證結果**。s3e9 的「顯式交互欄對 GBDT 無用」先驗,在 s5e10 被**確認**(該場交互欄確實無用),在本場卻被**否決**(本場交互欄帶來 0.000094 的 R2 增益,22 特徵集勝 11 基礎特徵),而這正好印證了二月自己對同一資料的宣稱。先驗不是照抄舊結論,而是帶著假設當場對照——確認與否決都寫回經驗庫,兩場相反的結論恰恰是「先驗必連同適用條件一起檢驗」最有力的示範。

第二,**逐位重現的閘門會逼出真實的工程問題**。樹搜尋的 OOF 增益要能轉成可提交的 test 預測,前提是每個成員都能被逐位重訓;LightGBM 的自動 row/col-wise 選擇讓這件事在跨行程時悄悄失敗(每樣本差達 0.87),固定直方圖方法與執行緒數後才降為 0。閘門不是形式——它抓出了一個沒有它就會靜默污染提交檔的 bug。

第三,**樹搜尋的贏家形狀因資料而異但本場回到 mega-blend**。本場 mega-blend 奪冠(與 s5e10 同、與 s4e11 反),用的是同一套搜尋機制——這正是「用搜尋取代固定配方」的理由:固定套路會賭錯形狀,搜尋會就地找到對的那個。整體看,遞增配置的階梯在跨季資料上第四度成立(0.786414→0.787183,精確數字見第 5 節算式),增幅隨階段遞減;本輪 R2 階梯 CV-only,二月雖有真實排行榜但為 RMSE 計分(Public 8.70380 / Private 8.72876),與本輪 R2 非同一指標,故不作數值錨點。

階段 5(外部想法注入) 經快評未勝過階段4:注入機制可運作、也產生了候選(stacking),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的 ERA 第二支柱誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 階段 1:二月加權集成基線(既有紀錄;full_pipeline.py 為二月完整管線,含基線集成)
uv run python3 competitions/playground-series-s6e1/scripts/full_pipeline.py

# 階段 2:skill 六階段管線(22 特徵集,三模型 + 權重搜尋)
uv run python3 competitions/playground-series-s6e1/scripts/04_train_blend.py

# 階段 3:線性自我迭代(兩先驗檢驗 → Optuna → seed bagging,3 輪)
uv run python3 competitions/playground-series-s6e1/scripts/05_iterate.py r1_interaction_prior
uv run python3 competitions/playground-series-s6e1/scripts/05_iterate.py r2_optuna_lgb
uv run python3 competitions/playground-series-s6e1/scripts/05_iterate.py r3_seed_bag
```

階段 4: 樹搜尋 (第 3 版工具, 60 節點預算)

```
uv run python3 tree_search/run_s6e1_v3.py
```

重現最佳解 (00F 重現閘門 + 產出提交檔)

```
uv run python3 competitions/playground-series-s6e1/scripts/06_rebuild_tree_best.py
```

階段 5: 外部想法注入快評 (注入候選 vs 階段4, 用快取 00F、不重訓)

```
uv run python3 docs/scripts/stage5_sweep.py s6e1
```