

競賽分析報告:playground-series-s6e2

本報告由自動化報告流程產生:所有數字直接取自實驗原始紀錄並經自動一致性驗證,敘述由 AI 彙整。紀錄完整度:完整(二月有真實排行榜錨點且同為 AUC 計分,但採多 seed 平均之非同折 CV 方案,故僅為背景參照;本輪 1-4 階段 CV-only,見第 3.5 節) | 產生日期:2026-07-08

目錄	
1. 競賽目的	1
2. 本場工具、專業術語與採用策略	2
2.1 本場工具	2
2.2 本場專業術語	2
2.3 採用策略	2
3. 實驗方法	3
3.1 資料規格	3
3.2 實驗總表	3
3.3 訓練規格	4
3.4 推論表	4
3.5 評估指標 / 排行榜	5
4. 實驗軌跡	5
5. 效能對照(逐階段)	6
6. 總結	7
7. 重現指令	8

1. 競賽目的

What:依 13 個臨床欄位(年齡、性別、胸痛類型、血壓、膽固醇、空腹血糖是否過高、心電圖結果、最大心率、運動誘發心絞痛、ST 段壓低、ST 段斜率、螢光透視血管數、鉀顯影) 預測每位受檢者是否罹患心臟病 (Presence/Absence),為二元分類問題。

Why:本跨季單元依 config.yaml 以 **AUC-ROC(maximize)**為評估指標——這是一個排名 指標,只看正類機率把樣本排序得多好、與門檻無關,對近乎均衡(不平衡比 1.230452)的二元 醫療篩檢很合適;因此提交必須交原始正類機率,而非硬性 0/1 標籤(交標籤會摧毀 AUC 賴以 計分的排序)。與上一場 s6e1 「單一特徵獨大」不同,本場訊號分散在多個中等強度預測子: 鉀顯影與目標的相關最高(0.605776),其後是胸痛類型(0.460684)、運動誘發心絞痛 (0.441864)、最大心率(-0.440985)、螢光透視血管數(0.438604)、ST 段壓低(0.430641); 血壓幾乎無關 (-0.005181)。

Data:train 630,000 列、test 270,000 列。資料極乾淨:無缺失、無特徵重複列;正例 (Presence)282,454 列、負例(Absence)347,546 列,正例佔比 0.44834。

2. 本場工具、專業術語與採用策略

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf);本節僅列本場特有的部分。

2.1 本場工具

全數為共同工具鏈(見《前言》第3節),無本場特有工具;樹搜尋工具本場使用第3版(預算相位機)。目標為二元類別,交叉驗證採 **StratifiedKFold 5 折(shuffle,seed=42)**——對類別標籤分層以免折內某類過少,全場固定同一組折;二月 v1 基線用的是同一組折(StratifiedKFold 切分只依目標向量與 seed),故本輪各階段分數與二月 v1 基線直接可比。本場所有訓練皆設為跨行程逐位可重現(LightGBM `deterministic=True + force_row_wise=True`、三模型統一 `num_threads=16`),且**從第一次訓練就固定**(沿用 s6e1 硬賺到的修正),這是第4階段 OOF 重現關門能逐位通過的前提(見第4節轉折4)。

2.2 本場專業術語

本場無特有專業術語,所需詞彙均見《前言》第5節。

2.3 採用策略

各階段與子階段的定義見《前言》第6節(編號跨場同義);主階段1-4本場皆有執行,各子階段採用情形如下。

階段1 | 無 skill 基線

- 1.1 單模型基線 — 使用(沿用二月既有紀錄,見第3.5節)
- 1.2 三模型 blend — 使用(二月 v1 加權集成 LGB+XGB)

階段2 | kaggle-agent skill

- 2.1 EDA 驅動 CV 設計 — 使用(二元目標,對標籤分層的 StratifiedKFold)
- 2.2 EDA 驅動特徵工程 — 使用(沿用二月 v3 認定最佳的 33 特徵集)
- 2.3 指標感知後處理 — 使用(AUC 為排名指標,無後處理:交原始機率)
- 2.4 場內反思回退 — 本場未使用

階段3 | +線性自我迭代

- 3.1 經驗庫先驗 — 使用(兩條先驗經對照檢驗,交互項先驗被確認、不平衡加權先驗被確認,見第4節)
- 3.2 Optuna 超參搜尋 — 使用(fold-0 代理目標,直接優化 AUC)
- 3.3 調參入池 — 使用(調參模型加入池,不取代)
- 3.4 seed bagging — 使用
- 3.5 結構化去噪 — 本場未使用

階段4 | +樹搜尋

- 4.1 單模型節點樹 — 使用(六條 solo 血統,含 SEEDBAG/FEATPRUNE/BOUNDARYPUSH)

- 4.2 ensemble 節點樹 — 使用(節點為 blend,直接以 OOF AUC 評分)
- 4.3 先驗注入+去重 — 使用(本場 0 次去重攔截)
- 4.4 邊界推進 mutation — 使用(root 調參後 max_depth=4 落在搜尋盒下緣,推進到 3,成為最佳解成員之一)
- 4.5 預算相位機 — 使用(第 3 版,60 節點預算;爆發後停於 60 節點硬上限)

階段 5 | +外部想法注入

- 5.1 外部想法庫先驗 — 使用(快評注入 stacking meta 模型,在階段4收斂點以快取 OOF 評估;未勝過階段4 → 階段5=階段4)
- 5.2 重組 mutation — 本場未使用(機制已建置[harness_v4 機械版 + LLM 版];跨場 pilot 實測與 mega-blend 搜尋冗餘、無增益,見 docs/recombine_findings)

3. 實驗方法

3.1 資料規格

項目	值
train 列數	630,000
test 列數	270,000
特徵數	原始 13 欄;二月特徵工程展開為 33,經階段 3 先驗檢驗後 LGB 回退到 13 原始欄
目標	Heart Disease(Presence 282,454 / Absence 347,546,正例佔比 0.44834,無缺失)
特別規則摘要	允許外部資料/預訓練模型/網路存取;每日提交上限 5 次

3.2 實驗總表

計分方式說明(全文適用):所有決策分數均為 5 折 OOF AUC(越大越好);AUC 為排名 指標,無後處理,提交原始正類機 率。

實驗編號	階段	模型/成員	決策分數	是否採納
1	1	二月 v1 加權集成(LGB+XGB)	0.95498	是(階段 1 冠軍)
6	2	LGB solo(33 特徵)	0.955009	否(階段 2 成員)
7	2	XGB solo(33 特徵)	0.955048	否(階段 2 成員)
8	2	CAT solo(33 特徵)	0.955151	否(階段 2 成員)
9	2	LGB+XGB+CAT blend(單純形權重搜尋)	0.955197	是(階段 2 冠軍)
10	3.1	LGB(交互項先驗檢驗,13 原始特徵)	0.955238	是(先驗確認,base13 入池)
11	3	第 1 輪 blend(兩先驗解析後)	0.955310	否(被後續超越)
12	3.2	LGB Optuna 調參(fold-0 代理,直接優化 AUC)	0.955501	否(入池成員)

實驗編號	階段	模型/成員	決策分數	是否採納
13	3	第 2 輪 blend(+調參 LGB)	0.955501	否(被後續超越)
14	3.4	調參 LGB seed=2024	0.955501	否(入池成員)
15	3	第 3 輪 blend(+seed 成員)	0.955510	是(階段 3 冠軍)
16	4.2	樹搜尋 mega-blend(node #43,8 個非零成員)	0.955529	是(全場最佳)
17	5	外部注入快評候選(EXT-09(stacking);沿用階段4成員 OOF)	0.955474	否(未勝過階段4,見 § 5)

最佳解成員表(第 16 次實驗,node #43 全池 mega-blend,37 成員中 8 個非零權重,依權重排序)

成員	模型	權重	solo 分數
node#14	LGB	0.3523	0.955512
node#13	LGB	0.1647	0.955504
node#27	LGB	0.1458	0.955421
node#4	LGB	0.1118	0.955499
node#23	LGB	0.0879	0.955421
node#0	LGB	0.0772	0.955501
node#20	LGB	0.0397	0.955454
node#16	LGB	0.0206	0.955497

八個非零成員全是 LGB 家族變體(調參 base13 LGB 的 seed 變體、特徵剪枝版、邊界推進版與 root 本身);37 個成員裡的 XGB 與 CatBoost 全被權重搜尋歸零。分數最好的單一成員是 node#14(0.955512),合成後 0.955529——mega-blend 對同族的多個強 solo 取平均,再擠出 0.000017 的變異縮減增益。

3.3 訓練規格

項目	設定
切分	StratifiedKFold 5 折(shuffle,seed=42),對類別標籤分層,全場固定同一組折
超參搜尋	Optuna 40 trials(第 12 次實驗):每組參數先只在第 0 折評分(515.1 秒),目標直接為 OOF AUC,勝出者再以完整 5 折驗證(調出淺樹 max_depth=4、強正則)
樹搜尋	第 3 版工具:60 節點預算、評估 60 個節點、總時 7958.9 秒;停於 60 節點硬上限,0 次去重前置攔截,無失敗節點

3.4 推論表

實驗編號	後處理	submission 檔	是否已提交
1	無(原始機率)	(二月既有提交)	是(二月,見第 3.5 節)
16	無(原始機率)	sub_tree_best_0.95553_*.csv	否(競賽關閉,CV-only)

`id_column = id`、`target_column = Heart Disease`。第 16 次實驗的提交檔由重建流程重新訓練 37 個成員、通過 OOF 重現閘門後產出(重建指令見第 7 節);AUC 為排名指標,提交原始正類機率,無門檻或取整。

3.5 評估指標 / 排行榜

- 指標(本單元,依 config.yaml):AUC-ROC(maximize)。
- **二月有真實排行榜,且同為 AUC 計分**:二月最佳提交是 v3(Public LB AUC 0.95332),但它採 5-seed $\times$ 5-fold 平均這種**非同折**的 CV 方案(交叉驗證 OOF AUC 0.95526),與本輪的單一 StratifiedKFold 折不可位元級相比,故只作背景參照、不作本輪 AUC 階梯的數值錨點(絕不跨 CV 方案比較分數);它證明二月管線能產出有效且可排序的 test 預測。
- **本輪(階段 1-4)CV-only**:AUC 階梯全為本地 5 折 OOF;重建流程通過 OOF 重現閘門並產出提交檔後,提交遭 Kaggle 拒絕(競賽已關閉延遲提交,回傳 403),依規記錄為 CV-only。

4. 實驗軌跡

實驗編號	決策分數	階段	摘要
1	0.95498	1	二月 v1 加權集成,同折可比的強起點
9	0.955197	2	33 特徵集三模型 blend(成員 第 6-8 次實驗)
10	0.955238	3.1	先驗檢驗 A:交互項先驗被確認(13 原始特徵勝 33 特徵)
11	0.955310	3	兩先驗解析後重配權重
12	0.955501	3.2	Optuna 調參 LGB(fold-0 代理,直接優化 AUC,淺樹強正則)
14	0.955501	3.4	seed=2024 成員入池
15	0.955510	3	3 輪迭代收尾
16	0.955529	4.2	樹搜尋 node #43,全池 mega-blend
17	0.955474	5	外部注入快評:EXT-09(stacking) 候選 OOF 未勝過階段4,不採納

- **轉折 1(第 10 次實驗,交互項先驗被確認)**:經驗庫帶來 s3e9 的先驗「顯式乘積/門檻 欄位對 GBDT 沒有增益(樹自己會切分)」,以及 s3e7/s3e14「特徵過多反而退步、精簡是常規 武器」。本場以對照檢驗:13 個原始 UCI 特徵的 solo LGB(0.955238)反而**勝過**含 20 個 工程欄位的 33 特徵集(0.955009),差 +0.000229。先驗**確認**——本資料上工程欄確實無用, LGB 池成員改用 13 原始特徵。這一條與 **s6e1 恰成對比**(該場交互欄有用、先驗被否決)、與 **s5e10 一致**(該場先驗被確認);同一條先驗換一套資料,結論相反,確認與否決都寫回經驗庫。
- **轉折 2(第 10 次實驗,不平衡加權先驗被確認)**:AUC 是排名指標,經驗庫先驗「對不平衡 加權(is_unbalance) 反而擾動排序、對 AUC 不利」(s3e3 小樣本、s4e1 大樣本兩度驗證)。本場檢驗:LGB 開 is_unbalance=True 得 0.954993,較預設不加權 0.955009 低 0.000016。先驗**確認**——加權微幅拖累 AUC(資料近均衡故效應很小),維持不加權;這是繼 s3e3、s4e1 後第三個大樣本佐證。
- **轉折 3(第 12-15 次實驗,線性迭代穩步推進)**:Optuna 直接以 OOF AUC 為目標調參,調出 淺樹 (max_depth=4)強正則的 LGB(0.955501,較未調參 base13 LGB +0.000262,為本輪單模 最大增益)、再換 seed=2024 重訓入池,blend 由 0.955310 一路推到 0.955510,每步小而確實。
- **轉折 4(第 16 次實驗,mega-blend 這次贏了;閘門逐位通過)**:60 節點預算的樹搜尋中,把全池 37 個 solo 一次混起來、由 Dirichlet 權重搜尋定權的 kitchen-sink mega-blend (node #43,8 個非零權重全為 LGB 家族變體)得 0.955529,勝過線性階段最佳 blend (0.955510)與最強單一 solo(node#14 的 0.955512)。這與

s5e10、s6e1 一致(mega-blend 奪冠)。因為 determinism 從一開始就固定,收尾關門一次通過:37 個成員全部重訓,逐位 比對 OOF 與搜尋當時快取一致(max|dOOF| = 0),通過後產出提交檔;提交遭拒(競賽關閉, 403),記 CV-only。

5. 效能對照(逐階段)

階段	配置	分數(AUC)	相對改善
1	未用 skill,二月 v1 加權集成(第 1 次實驗)	0.95498	—(基準)
2	+ kaggle-agent skill 六階段(第 9 次實驗)	0.955197	0.0227%
3	+ 線性自我迭代(第 15 次實驗)	0.955510	0.0328%
4	+ 樹搜尋(第 16 次實驗)	0.955529	0.0020%
5	+ 外部想法注入(第 17 次實驗,快評)	0.955529	0.00%(未勝過)

相對改善計算式(每階段對前一階段;AUC 越大越好,改善 =(後-前)/ 前)

階段1→2:0.955197 - 0.95498 = +0.000217,相對改善 0.000217 / 0.95498 = 0.0227%
階段2→3:0.955510 - 0.955197 = +0.000313,相對改善 0.000313 / 0.955197 = 0.0328%
階段3→4:0.955529 - 0.955510 = +0.000019,相對改善 0.000019 / 0.955510 = 0.0020%
階段1→4:0.955529 - 0.95498 = +0.000549,相對改善 0.000549 / 0.95498 = 0.0575%
階段4→5:注入候選 0.955474 未勝過階段4 0.955529,搜尋保留階段4 → 相對改善 0.00%(外部注入無增益)

本場由導入報告功能後之版本執行,分數自階段 2 起未低於前一階段——符合計畫書目標三 (效能不退步)。

四個階段單調上升(AUC 越大越好),階段 1→4 累計提升約 0.0575%。增幅集中在前兩步 (skill 與線性迭代各約 0.02-0.03%),樹搜尋這一步再擠出 0.0020%——與 s4e11、s5e10、s6e1 一致的跨季型態:遞增階梯在新季度仍成立、但可壓縮空間明顯縮小,尾段每一步都是「最後一哩」的精細競爭。本場四階段都落在 0.95498-0.95553 的窄帶內(全距 0.000549,見第 5 節算式),模型高度相關、訊號早已飽和。

子階段分數表(定義見第 2.3 節;僅列本場有既有紀錄者)

子階段	分數	出處
3.1 經驗庫先驗(交互項,13 原始特徵)	0.955238	第 10 次實驗
3.2 Optuna 調參 LGB	0.955501	第 12 次實驗
3.4 seed bagging(調參 LGB seed=2024)	0.955501	第 14 次實驗

階段 5 | + 外部想法注入

階段5 讓 agent 在搜尋停滯時,從外部想法庫(對應文獻與跨賽經驗)取一條新點子、翻成 一個新候選解丟進搜尋,看能否突破階段4。本場注入的點子是 EXT-09:stacking——對各成員的 OOF 預測再疊一層 meta 模型(迴歸用 Ridge、分類用 Logistic),以 nested-CV 避免洩漏。

「快評」是什麼:不必重跑整個樹搜尋——直接取**階段4冠軍集成的成員**與它們已算好的 **OOF 預測(快取)**,在這組成員上套用注入的點子、算出新組合的 OOF 分數,再與階段4 冠軍比。這是「這條外部點子到底能不能勝過階段4」的**快速且有效代理**(省去重訓):

```
階段5 注入候選(stacking)OOF ROC-AUC = 0.955474
階段4 冠軍          OOF ROC-AUC = 0.955529
差距 = -0.000055 → 注入候選並沒有更好 → 搜尋保留階段4 → 階段5 = 階段4
```

注入機制可運作、也確實產生了候選,但候選贏不過已近最優的階段4集成,故**階段5 相對 階段4 無增益(持平)**。此為全 15 場一致的誠實負面結論;「為何贏不過」的完整解釋見《總結報告》第 7 節與 docs/phase_j_j3_findings,本場快評可重現(見第 7 節 指令)。

6. 總結

本場是跨季驗證的第五場、也是最後一場(前四場見 playground-series-s4e1、s4e11、s5e10、s6e1 報告)。三個要點:

第一,**同一條經驗庫先驗在本場得到與上一場相反的驗證結果**。s3e9 的「顯式交互欄對 GBDT 無用」先驗,在 s6e1 被**否決**(該場交互欄有用),在本場卻被**確認**(13 原始特徵以 0.955238 勝過 33 特徵的 0.955009,差 0.000229),與 s5e10 同向。二月自己造了 20 個工程欄 並認定它們是關鍵,乾淨的同折對照卻顯示原始欄單獨就分數更高。先驗不是照抄舊結論,而是 帶著假設當場對照——同一條先驗、換一套資料,結論可以相反,確認與否決都寫回經驗庫。同一輪 還確認了 AUC 的第二條先驗:對近均衡資料開不平衡加權,反而讓 AUC 掉 0.000016(s3e3/s4e1 之後第三個大樣本佐證)。

第二,**這場的 mega-blend 贏家其實是 LGB 家族內部的變異縮減**。樹搜尋把 37 個 solo 一次 混起來,權重搜尋卻只給 8 個 LGB 變體非零權重、把所有 XGB 與 CatBoost 歸零——本資料上 LGB 家族獨強,真正的增益來自對調參 base13 LGB 的多個 seed/剪枝/邊界變體取加權平均(最強單成員 node#14 0.955512 → 合成 0.955529)。這與「用搜尋取代固定配方」的精神一致:固定套路會硬塞三模型多樣性,搜尋則就地判定該場只有 LGB 有用。

第三,**逐位重現的閘門一次通過,因為 determinism 從第一次訓練就固定**。上一場 s6e1 是在 收尾才發現 LightGBM 的自動 row/col-wise 直方圖選擇讓跨行程訓練不可重現、臨時補救;本場 把該修正 (force_row_wise + 固定 num_threads)從頭就設好,37 個成員全部逐位重訓與快取 一致($\max|dOOF| = 0$),閘門一次過關。整體看,遞增配置的階梯在跨季資料上第五度成立 (0.95498→0.955529,精確數字見第 5 節算式),增幅隨階段遞減;本輪 AUC 階梯 CV-only,二月 雖有同指標的真實排行榜(v3 Public 0.95332)但採非同折的多 seed 平均方案,故不作數值錨點。

重現本實驗的最短路徑見第 7 節:依序跑階段 2、階段 3 三輪、階段 4 樹搜尋與重建閘門即可 複現 0.95498→0.955529 的完整階梯。

階段 5(外部想法注入)經快評未勝過階段4:注入機制可運作、也產生了候選(stacking),但贏不過已近最優的階段4集成,故階段5 = 階段4——此為全 15 場一致的誠實負面結論(見第 5 節「階段 5」段與《總結報告》第 7 節)。

7. 重現指令

```
cd /home/tjyen/ai_agents/kaggle

# 階段 2:skill 六階段管線(33 特徵集,三模型 + 權重搜尋)
uv run python3 competitions/playground-series-s6e2/scripts/04_train_blend.py

# 階段 3:線性自我迭代(兩先驗檢驗 → Optuna → seed bagging,3 輪)
uv run python3 competitions/playground-series-s6e2/scripts/05_iterate.py r1_prior_check
uv run python3 competitions/playground-series-s6e2/scripts/05_iterate.py r2_optuna_lgb
uv run python3 competitions/playground-series-s6e2/scripts/05_iterate.py r3_seed_bag

# 階段 4:樹搜尋(第 3 版工具,60 節點預算)
uv run python3 tree_search/run_s6e2_v3.py

# 重現最佳解(00F 重現閘門 + 產出提交檔)
uv run python3 competitions/playground-series-s6e2/scripts/06_rebuild_tree_best.py

# 階段 5:外部想法注入快評(注入候選 vs 階段4,用快取 00F、不重訓)
uv run python3 docs/scripts/stage5_sweep.py s6e2
```