

與 Aygün 等人 ERA 系統的方法對照

本文把本專案的 Kaggle 混合式 agent,與 Eser Aygün 等人(2026,Nature;預印本 arXiv:2509.06503v3,78 頁) 的 ERA(Empirical Research Assistant,Google DeepMind) 系統做逐項對照:方法、benchmark、結果、嚴謹度,並誠實標出本專案「不是」什麼、以及哪裡反而更嚴謹。

引用標記:ERA 側標 [ERA p.N] 為預印本頁碼;本專案側標 檔案:行 為 repo 內位置。所有數字均可回溯。

目錄

1. 一句話定位

2. 方法對照

2.1 搜尋引擎

2.2 外部想法注入(第二支柱)——最關鍵的對照

3. Benchmark 對照

4. 結果對照

5. 消融與統計嚴謹度對照

6. 誠實差距與定位總結

附錄:待接線後可真正對齊 ERA 第二支柱的路徑

1

2

2

2

3

4

4

5

5

1. 一句話定位

- ERA 是一套**自動化系統**:給定可機器評分的任務,LLM 直接寫 Python 程式碼,在沙盒執行評分,再由**樹搜尋**在「程式碼空間」爬坡;外部研究想法透過**注入 prompt** 引導 LLM 寫出特定做法。[ERA p.2, p.13]
- 本專案 是一套 Claude Code Skill + 人在迴圈的競賽流程,外加一支**自建樹搜尋**;搜尋是在「**固定 GBDT 家族(LGB/XGB/CAT)的組態空間**」做手寫組合搜尋,LLM 不在變異迴圈內。 docs/TECH_REPORT.md:28-34 、 docs/PREFACE.md:94-101

兩者共用同一組「兩支柱」語言(LLM + 樹搜尋;第二支柱=外部想法整合),本專案的階段 4/5 正是照這兩支柱設計來做**受控消融**。但如下所述,兩者在「LLM 扮演什麼角色」上有本質差異,對照時必須講清楚,不能暗示等價。

2. 方法對照

2.1 搜尋引擎

面向	ERA	本專案
搜尋型態	PUCT 樹搜尋(作者自稱更接近 Flat-UCB 而非 AlphaZero;無 rollout,從全樹節點取樣展開)[ERA p.13]	候選樹 + 回溯的組合搜尋(harness_v2/v3/v4);breadth-then-depth 預算 相位機 + explore burst + auto-stop docs/PREFACE.md:131-137
一個節點是	一段被執行並評分的 LLM 產生程式碼 [ERA p.13]	一個組態:solo(單模型+單超參,完整 K-fold)或 blend docs/PREFACE.md:94-96
變異算子	LLM 依父節點 code+score 生成一個新的子程式碼;隨機性來自 LLM 取樣 [ERA p.13-14]	propose_child / select_next_parent 走 SOLO_SEEDS 種子集 + mutation 佇列;boundary-push 把調參範圍邊界外推一格 docs/phase_j_j3_findings.md:37-39
集成	由 LLM 在程式碼內自行決定	OOF 權重搜尋 (blend = solo 的 OOF 加權平均,dirichlet 權重)、mega-blend(全 solo 集成) docs/PREFACE.md:86,101
用的 LLM	全實驗 Gemini 2.5 Flash (換 Pro 提升有限)[ERA p.13]	Claude Code(但 僅 在流程外做 EDA/特徵/決策與 手寫種子 ,不在搜尋迴圈內產生程式碼)
調參常數	c_puct = 1,在 Kaggle benchmark 上調出 [ERA p.13]	無對應超參;預算以節點/相位控制

核心差異(必須明說):ERA 的樹搜尋是在由 LLM 生成的任意程式碼上爬坡——變異算子就是「LLM 重寫程式」。本專案的樹搜尋是在**人預先定義好的模型家族與調參空間**上做組合/權重搜尋——變異算子是手寫的 propose_child。因此本專案階段 4 對齊的是 ERA 的「**以樹搜尋取代線性單路徑**」這個**結構性想法**,不是「LLM 自動寫程式」的能力。這點在報告與對外說明時不可含糊。

2.2 外部想法注入(第二支柱)——最關鍵的對照

面向	ERA	本專案
注入點	prepend 到「LLM 產生程式碼」的 prompt ;LLM 隨即寫出遵循該想法的程式碼 [ERA p.14]	併入 suggest_priors 回傳的 tree['priors'] (harness_v4 的 suggest_priors_v4) docs/phase_j_j3_findings.md:15-22
想法來源	專家建議、高被引論文/教科書的 LLM 摘要 、Deep Research、AI co-scientist [ERA p.3,5,14]	外部想法庫 knowledge/idea_bank.md ([EXT]);內部經驗庫 knowledge/experience.md ([INT]) README.md:48-51
是否真的被消費	是 ——注入點就是變異算子的輸入,直接左右每次生成的程式碼 [ERA p.12,14]	否 —— tree['priors'] 是 write-only ,只供列印/記錄; SOLO_SEEDS / mutation 佇列/ propose_child / select_next_parent /評估器全部不讀它 docs/phase_j_j3_findings.md:5-42
實證	文獻引導的 ERA 產出 BBKNN(TS),較最佳已發表法 +14% ;44%(24/55)重組解勝過雙親 [ERA p.5]	單變數 A/B(s3e3): off ([INT]) vs ext ([INT]+2 條淨新 [EXT])→ 全域最佳同為節點 #11、AUC 0.841442 完全相同 、22 節點 逐位元相同 ($\Delta=+0.00000000$) docs/phase_j_j3_findings.md:5-42

面向	ERA	本專案
想法重組	LLM 把兩個父方法的原理口語化後生成新 prompt(概念空間重組) [ERA p.15]	harness_v4 有重組 mutation(合成兩高分節點核心概念),但因上述消費端未接線,對搜尋同樣無效

結論:ERA 的第二支柱是**負重的**——注入的文字直接是變異算子(LLM prompt)的輸入。本專案的第二支柱在**現行架構下是「構造型 no-op」**:注入機制(池合併/去重/閘門)本身正確,但**消費端沒接線**。經驗庫知識**確實**引導了搜尋,但是**透過作者手寫種子**(作者讀 experience.md、把先驗手寫進 seed 組態; [PRIOR Pk] 是手寫字串常數, prior_usage_summary 只 regex 解析、不回溯 tree['priors'])。這是本專案與 ERA 最大的方法落差,已誠實記錄於 docs/phase_j_j3_findings.md 與 docs/TECH_REPORT.md:90-96。 **根因:**本專案搜尋迴圈裡沒有「LLM 產生程式碼」這個算子,自然沒有可供注入的 prompt;要讓注入負重,得先把 tree['priors'] 接進 propose_child /種子邏輯,或引入 LLM-in-loop 的程式碼變異。

3. Benchmark 對照

面向	ERA	本專案
Kaggle 場次	2023 賽季(S3)16 場 Playground(迴歸+分類)[ERA p.4, Table S2 p.57]	15 場: 10 場同季 S3 + 5 場跨季 S4-S6 docs/benchmark_facts.json:4-7
評分方式	直接提交 Kaggle 真實排行榜 ,指標=公開榜人類百分位 [ERA p.4]	幾乎全為 本地 OOF(5-fold) ;僅 s3e16 有真實 LB ,其餘 14 場已關榜 (403)只有 CV docs/TECH_REPORT.md:52-55、docs/SUMMARY_REPORT.md:68-71
對照基準	Single(1 次呼叫)、Best-of-1000、AIDE、TS、TS+Expert、TS+BDT [ERA p.3]	階段 1(無 skill 基線)→2→3→4→5 的自身消融階梯 docs/PREFACE.md:104-143
Kaggle 以外	scRNA-seq、COVID 預測、GIFT-Eval、geospatial、ZAPBench、數值積分 6 個科學領域 [ERA p.5-9]	無(僅表格競賽)

強對齊點:本專案的 10 場 S3(s3e1/3/5/7/9/11/14/16/19/20)**全部落在 ERA 的 16 場名單內**;本專案拿不到的 6 場(s3e2/4/8/10/12/17,帳號無法接受已關閉競賽規則、下載 403)**正好是 ERA 有、本專案缺**的那幾場。因此本專案的 Kaggle benchmark 可視為 **ERA 完全相同 benchmark 的 10/16 子集**,只是評分改為本地 CV。

關鍵落差:ERA 用**真實榜的人類百分位**衡量「達到專家水準」;本專案除 s3e16 外**沒有真實榜、也沒有人類百分位校準**。因此本專案能誠實宣稱的是「**每加一項能力,受控 CV 分數階梯式改善**」,不能宣稱「達到人類第 N 百分位」。

4. 結果對照

	ERA	本專案
Kaggle 主結果	16 場平均公開榜百分位:Single $\approx$ 34% $\rightarrow$ Best-of-1000 $\approx$ 49% $\rightarrow$ AIDE $\approx$ 56% $\rightarrow$ TS$\approx$64% $\rightarrow$ TS+Expert$\approx$68% $\rightarrow$ TS+BDT$\approx$71% (讀自 Fig.1b,無數值表)[ERA p.3-4]	15 場 階段 1$\rightarrow$4 階梯場場成立 (9 升 1 平,無任一階整體倒退) docs/TECH_REPORT.md:59-60
增幅型態	TS 明顯優於單次與 best-of-1000,亦勝 AIDE [ERA p.4]	增幅集中在 結構性洞見 場(s3e20 +25.7% 、s3e5 +19.2%),接近天花板的場 <1% docs/SUMMARY_REPORT.md:131
真實榜證據	全 benchmark 真榜;scRNA 40 個 方法勝過人類榜首、COVID 14 個 模型勝過 CDC 集成 [ERA p.1,5,7]	僅 s3e16 :樹搜尋版兩榜同向勝過線性冠軍(Public 1.34356 $\rightarrow$ 1.34315、Private 1.34075 $\rightarrow$ 1.33859) docs/SUMMARY_REPORT.md:68-85
泛化	跨 6 科學領域皆達專家水準 [ERA p.5-9]	跨季 5 場(5 種指標)階梯仍成立,增幅收斂 docs/TECH_REPORT.md:68

量級誠實話:ERA 的成果是「在真實榜上勝過人類/官方集成」的**跨領域、大規模**結果;本專案的成果是「在 10/16 相同 benchmark 的子集上,以受控消融證明每項自主能力的邊際貢獻」,增幅多為 0.0x%(僅結構性場顯著),且第五支柱貢獻**恰為零(構造性)**。兩者是**不同量級、不同宣稱**的工作——本專案的價值在**方法論的乾淨與可回溯**,不在絕對戰績。

5. 消融與統計嚴謹度對照

面向	ERA	本專案
核心消融	TS vs Best-of-N(N=1000/128):5 個 LLM 中 4 個、兩問題上 TS 勝(唯 GPT-5 在 batch integration 已飽和)[ERA p.9,15]	5 階段階梯 + 每階子階段;跨場 tier1 $\rightarrow$ tier4 對照 15 場 docs/SUMMARY_REPORT.md
注入消融	44%(24/55)重組勝雙親;無建議只到 ComBat 水準、文獻引導達 BBKNN 榜首 [ERA p.5,29]	第五階段單變數 A/B = 逐位元相同 (構造性 no-op) docs/phase_j_j3_findings.md
顯著性檢定	無 ;主結果以長條圖與名次呈現,未報信賴區間	paired bootstrap(B=5000) :整條 2 $\rightarrow$ 4 階梯 5 場全部 CI 排除 0;樹搜尋單步僅在大樣本(n $\approx$ 52-63 萬)顯著,小樣本落在 OOF 噪音內 docs/statistical_rigor.md:66-82
重現閘門	有沙盒重跑;採遵性人工稽核(幾乎全「遵循」注入算法)[ERA p.34]	OOF 逐位重現閘門 :最佳解成員從頭重訓、逐位比對 OOF 才產提交;部分達 $\max \Delta\text{OOF} =0$ 位元級 docs/TECH_REPORT.md:45-48

本專案反而更嚴謹之處(可對老師說的亮點):ERA 的 Kaggle 主結果只給長條圖、**沒有信賴區間**;本專案對每一階轉換做了 **paired bootstrap 顯著性**,而且誠實把「階梯場場成立」校準成「信累積增益、別過度宣稱單一 0.0x% 步」(docs/statistical_rigor.md)。這種「小步是否只是噪音」的自問自答,是本專案方法論上的獨立

貢獻。但範圍限制:bootstrap 目前只涵蓋 5 場跨季(有 OOF 快取),10 場 S3 缺快取尚未納入;且 CI 只量 OOF 抽樣變異,不含重跑搜尋(seed/fold/Optuna)變異,是下限。

6. 誠實差距與定位總結

本專案「不是」什麼(避免對外暗示等價): 1. **不是**「LLM 自動寫程式」系統——搜尋在固定 GBDT 組態空間,LLM 不在變異迴圈內。 2. 第二支柱(外部注入)**在現行架構下不負重**——ERA 的注入是核心機制,本專案的是 no-op(靠手寫種子引導)。 3. **不是**真實榜/人類百分位驗證——除 s3e16 外全為本地 CV,無「達到專家水準」的外部尺標。 4. 規模與領域遠小於 ERA(單一表格領域、單一 driver、手寫先驗種子)。

本專案的真實價值: 1. 在 **ERA 完全相同 benchmark 的 10/16 子集上**,以**受控消融**逐段隔離「skill 化流程 / 線性自我迭代 / 樹搜尋」各自的邊際貢獻——這是 ERA 論文沒做到的細粒度歸因。 2. **統計嚴謹度**(paired bootstrap + 位元級 OOF 重現閘門)在方法論上**比 ERA 主結果更保守可信**。 3. 對第二支柱做出並誠實記錄了一個**構造性負面發現**(注入 no-op),把「知識有引導」與「自動 plumbing 被消費」兩種宣稱清楚切開——這正是科學誠信的展現。

一句話:本專案不是 ERA 的復刻或縮小版戰績挑戰,而是**借用 ERA 的兩支柱框架**,在其相同 **benchmark 的子集上**,做一次乾淨、可回溯、統計誠實的能力歸因研究;並在過程中誠實界定了自建系統與 ERA 的本質差距。

附錄:待接線後可真正對齊 ERA 第二支柱的路徑

若要把「外部想法注入」從 no-op 變成負重(真正對齊 ERA pillar 2),最小改動有二選一: 1. **接線既有先驗**:把 `tree['priors']` 實際接進 `propose_child / SOLO_SEEDS`,讓注入的 [EXT] 想法改變候選生成(仍在 GBDT 組態空間內,量得到邊際值但不等於 ERA 的 code-mutation)。 2. **引入 LLM-in-loop 程式碼變異**:在搜尋迴圈內讓 LLM 依 prompt(含注入想法)生成/改寫特徵或建模程式碼——這才是與 ERA 同構的做法,但工程量與算力顯著較大,且 arm64 環境有套件風險。

方向題(接線 vs 接受誠實負面結果)留待決定,見 `docs/phase_j_j3_findings.md` 結語。