

Phase J J-3 歸因發現:階段5 注入 hook 已建置,但尚未接入搜尋消費端

這是一個誠實的負面/架構級結果,需要決策(見「下一步的分岔」)。日期:2026-07-08。

目錄	
一句話	1
怎麼測的(單一變因)	1
結果	2
根因(grep + 實證雙重確認)	2
重要的區辨(不要誤讀這個 0)	2
下一步的分岔(需決策)	2
接線 pilot 已執行(2026-07-08,使用者選 A,設計為「plateau 觸發、限次數」)	3
為什麼外部注入贏不過階段4(合理解釋)	4
最終結論(stage 5 / ERA 第二支柱)	4

一句話

外部想法注入(階段5)的 hook 本身正確,但現行樹搜尋架構下 `tree['priors']` 是 **write-only** (只寫來列印/記錄,沒有任何搜尋算子讀它),所以「純 [INT] vs [INT]+[EXT]」的單一變因對照 得到**構造性的 $\Delta = 0$** ——不是噪音級的接近零,是**逐位元相同**。

怎麼測的(單一變因)

以 s3e3(AUC,資料小、全搜尋 ~17s,可乾淨確定性重跑)為對象:

- 建 `tree_search/run_s3e3_v4.py`,**唯一搜尋相關改動** = 把 driver 開頭那次 `suggest_priors(COMP_META)` 換成 `harness_v4.suggest_priors_v4(COMP_META, mode=V4_MODE)` (mode 讀環境變數)。其餘種子、折、預算、mutation、評估器全部不動。
- 正確性閘門:(1) `mode='off'` 的先驗與 `hv2.suggest_priors` **逐字相同**(通過); (2) `mode='ext'` 對本場**淨新注入 2 條 [EXT]**——EXT-12(rank averaging)、EXT-14 (對抗驗證)(通過)。
- 同 seed=42、同折、各跑到底,比較全域最佳 OOF。

結果

	全域最佳節點	AUC	tree['priors'] 條數
off([INT] only)	node #11	0.841442	8
ext([INT]+[EXT])	node #11	0.841442	10(多 2 條 [EXT])

- **delta (ext – off) = +0.00000000**。
- 逐節點比對(22 節點):結構性差異 0 處、分數差異 0 處($\max|\Delta\text{score}|=0$)、18 個快取 OOF 向量 $\max|\Delta|=0$ 。
off 與 ext 逐位元相同。

根因(grep + 實證雙重確認)

suggest_priors 的回傳只寫入 tree['priors'] 供列印/記錄;種子(SOLO_SEEDS)、mutation 佇列、propose_child、select_next_parent、評估器**沒有一個讀 tree['priors']**。driver 裡 [PRIOR PK] 標籤是作者在種子/佇列裡**手寫的字串常數**, prior_usage_summary 也只 regex 解析 這些手寫標籤、從不回溯 tree['priors']。harness_v2/v3 內查無任何 tree['priors'] 讀取點。**bit-identical 的結果本身就是證明:** 唯一差異(2 條額外先驗)若被任何算子讀到必會改變某處;它什麼都沒改 → tree['priors'] 確為 write-only。此為**架構級**(四個候選 driver 同一模式),非 s3e3 特性。

重要的區辨(不要誤讀這個 0)

1. **注入機制本身是對的**:harness_v4 正確併池 [INT]+[EXT]、去重、閘門通過。問題在**消費端**。
2. **階段 4 的價值仍然真實**:樹搜尋 stage4 > stage3 的增益來自**搜尋機制本身**(候選樹、回溯、OOF 權重搜尋、探索爆發),與 suggest_priors 無關——這些結果不受本發現影響。
3. **經驗庫知識確實影響了搜尋,但透過的是「作者手寫種子」而非自動注入**:driver 作者讀 experience.md 後把先驗手寫進種子配置; suggest_priors 這個**函式的輸出**是裝飾性的。因此各場報告「階段 4.3 先驗注入 +去重 — 使用」在「知識有引導」意義上成立,但「自動注入 plumbing 被搜尋消費」的隱含意義**不成立**——這點值得在報告語言上誠實校準(非緊急)。

下一步的分岔(需決策)

要真正量測階段5 的邊際價值,必須先讓 priors **通電**——把 tree['priors'] 接進搜尋決策,例如:

- 把 **EXT-12(rank averaging)** 轉成「加一個 rank-average blend 成員」的候選節點;
- 把 **EXT-14(對抗驗證)** 轉成「跑對抗驗證、據以重排/加權 CV」的候選動作;
- 更一般地:讓 propose_child / 種子邏輯真的讀 tree['priors'],把每條先驗映射成一個可執行的 mutation/候選,並在 mutation 記錄裡標 provenance([INT]/[EXT])。

選項 A:做這個 wiring(工程量中等,但會改變樹搜尋對**所有場**的行為 → 需重跑、可能重開 既有 stage4 結果)。
選項 B:接受此誠實發現,把階段5 描述為「注入 hook 建置完成、待接入 消費端」,不宜稱其增益。

這兩個選項牽動研究方向與既有結果,留待督導/使用者決定;在此之前不自行大改。證據檔: `tree_search/run_s3e3_v4.py` (+ 過程狀態檔,未入版控的實驗產物)。

接線 pilot 已執行(2026-07-08,使用者選 A,設計為「plateau 觸發、限次數」)

使用者選 A(接線),並提出好設計:**外部想法注入做成選配——階段4 plateau 推不動時才觸發、且限制執行次數**(正是計畫書 § 6 迭代策略「停滯時搜尋外部想法」的實作)。據此執行:

① **機制建成並自測通過** —— `tree_search/idea_injection.py`:讀 `idea_bank.md` → 依 `comp_meta` 篩選 + [INT] 去重 → 用**翻譯器登錄表**把 [EXT] 想法轉成搜尋候選 config → 標 [EXT-MN] provenance。這條「自動注入」的線是通的(J-3 的 write-only 死路已被繞過)。首個乾淨翻譯器: EXT-12(rank averaging)→ rank 空間 blend。

② **快速、真實的價值量測**(在階段4贏家=收斂/plateau 點注入,用**快取 OOF** 直接評估,不重訓):

場(AUC)	prob 空間(階段4)	rank 空間(EXT-12 注入)	delta	判定
s3e3	~0.841(最佳)	0.8329 / 0.8143(樹內既有 rank 節點)	明顯更差	無增益
s4e1	0.894368	0.894359	-0.000008	噪音級
s6e2	0.954527	0.954528	+0.000001	噪音級

③ **全 15 場快評 sweep**(`docs/scripts/stage5_sweep.py`):加入第二個通用翻譯器 **stacking (EXT-09,meta 模型,任何指標適用)**,對 15 場各在階段4贏家(收斂點)注入候選、用快取 OOF 評估,與 **committed tier4**(authoritative 階段4)比較:

判定	場數	場次
持平/噪音($ \text{delta} \leq 1e-4$)	6	s3e1, s3e7, s4e1, s5e10, s6e1, s6e2
注入候選明顯更差	8	s3e3, s3e5, s3e9, s3e11, s3e14, s3e16, s3e19, s4e11
數值「勝出」但=已排除的 CV 噪音	1	s3e20

框架(重要):真正的階段5(搜尋 plateau 注入後**保留最佳**)= **階段4,15 場全持平**—— 搜尋會丟棄較差的注入候選,不被拖累;上表「更差」量的是**注入候選本身**輸給階段4(即該想法 沒產生更好的解),非階段5被拖累。**過程抓到兩個假正例**,正說明此 sweep 的嚴謹: - **s3e7**:一開始用快評權重搜尋當基線(0.900028)看似 stacking 勝,但 committed tier4 其實 0.900455 更高——弱基線假象,改用 committed tier4 後為 null。 - **s3e20**:唯一數值勝出,但 stacking 榨出的是 STATUS.md 標為**低信度 CV 噪音**的 GBDT-blend 成員(節點 #37, 21.0332),而 tier4 刻意排除之、只認純結構解 #28(21.0589)——非真增益。

為什麼外部注入贏不過階段4(合理解釋)

null 不是機制無能,而是有紮實的原因:

1. **階段4優化器在現有成員上已近最優**:樹搜尋的 OOF 權重搜尋(dirichlet $k=800$ + 座標上升) 已找到成員池的近最優凸組合;能乾淨注入的想法(rank 平均、stacking)本質只是**用不同方式 組合同一批成員**,贏不過已近最優的權重搜尋。
2. **可注入的想法冗餘或與指標不對齊**:rank 平均只是組合前的單調重排,對權重搜尋已直接優化的指標無新資訊;stacking meta 模型比凸權重搜尋更有彈性 → **過擬合 CV 噪音**(成員多為高度 相關 GBDT),且 ridge 最小化平方誤差、對 MAE/SMAPE 不對齊 → s3e14 -5、s3e19 -41 爆掉 (與 s3e14 既有發現「Ridge stacking 輸 simplex」一致)。
3. **有用的領域想法早已被 LLM 作者手寫進搜尋**(J-3 的發現):外部庫裡該場適用的條目,大多與 driver 種子/變異重疊,自動注入是多餘的。
4. **訊號已被榨到噪音地板**(bootstrap 的發現):階段4最佳已逼近 OOF 估計天花板,可壓縮空間 $\leq 0.0x\%$ 、常在噪音內——**任何**方法都難再擠出,不是外部想法特別無能。
5. **能帶來新訊號的想法恰好難注入 + 資料相依**:對抗驗證、entity embedding、目標編碼變體需 新特徵/重訓、無法乾淨自動注入,且效果看資料(如對抗驗證只在有 train/test 漂移時有用,而 這些合成 Playground 資料幾乎無漂移)。

最終結論(stage 5 / ERA 第二支柱)

外部想法注入的機制可以建、也真的通電(`idea_injection.py`);但實測 15 場,外部注入從未 產生一個能勝過階段4的候選——階段5 = 階段4(全持平)。原因:能乾淨注入的想法只是重組「已被近最優組合的成員池」、真正有用的領域想法已被手寫進搜尋、而訊號已被前四階段榨到噪音 地板。外部知識只在「引入搜尋錯過的新訊號」時才有價值,而這些成熟的表格題幾乎沒有被錯過的 結構可撿。∴在此設定下,ERA 第二支柱無可量測的系統性增益(無害亦無益)。

這是**嚴謹建立的誠實負面結果**(真實資料、15 場實測、可重現、兩個假正例已抓除),與本專案 J-3、determinism、統計噪音等發現同一誠實水準。階段4(第一支柱)的價值不受影響。

可重現: `uv run python3 docs/scripts/stage5_sweep.py` (15 場快評)、`uv run python3 tree_search/stage5_inject_pilot.py s4e1` (單場);機制見 `tree_search/idea_injection.py`。