

前言:全案共同方法、工具與專業術語

本文件是整個競賽實驗系列的共同總覽:研究設計、實驗流程、工具鏈、專業術語與階段定義 集中在此,各場競賽報告不再重複。本文件為方法說明,不含任何實驗數字;各場數據見 各場競賽報告,跨場彙總見總結報告 (SUMMARY_REPORT)。

閱讀方式:先讀本前言,再讀任一場競賽報告,最後讀總結報告。各場報告的第 2 節 只列「本場特有」的工具與專業術語,以及本場各階段的採用情形;在報告正文遇到不認識的 詞,先查該報告第 2.2 節,再查本前言第 5 節專業術語表。

目錄	
1. 研究目的	1
2. 共同實驗流程	1
3. 共同工具鏈	2
4. 評估與分數的通用約定	2
5. 全案專業術語表	2
6. 階段與子階段定義(全案字典)	3
7. 各場報告的結構	4

1. 研究目的

本專案評估 AI agent(Claude Code)自主參加 Kaggle 表格資料競賽的能力。做法很直接:**同一場競賽解五次,一次比一次多給一項方法**——從沒有任何輔助的 基線開始,依序加入競賽流程 skill、線性自我迭代、樹搜尋(取代線性迭代)、外部想法注入——再比較五次的分數,就能看出每一項方法各帶來多少改善。每場報告的第 5 節「效能對照」列出該場五次的分數;總結報告彙整跨場結論。

五個配置即「階段 1-5」,完整定義見本前言第 6 節。

2. 共同實驗流程

每場競賽都走同一條流程:

- 資料理解(EDA):**欄位型態、目標分布、缺失與異常、洩漏風險。
- CV 設計:**依資料性質選擇切分方式(分層/分箱/時序),此後全場固定同一組折,確保跨實驗分數可比。本系列各場皆採 5 折。
- 特徵工程:**由 EDA 發現引導的衍生特徵。
- 建模與集成:**多個模型各自完成 K 折訓練(solo),再以 OOF 權重搜尋合成 blend。
- 評估與決策:**一律以 OOF 分數決策,不看單折、不看訓練分數;可提交的場次 再以排行榜複核本地驗證是否可信。

6. 提交(開放場次):先通過 OOF 重現閘門,才產生 test 預測並提交; 競賽已關閉提交者標記 CV-only。

紀錄與報告:所有實驗寫入統一格式的原始紀錄;報告中的數字由程式直接從原始紀錄 抽取,並經自動一致性驗證,敘述由 AI 彙整。

3. 共同工具鏈

工具	用途
Claude Code(LLM agent)	全流程決策:模型選型、特徵工程、停損判斷、報告敘述
kaggle-agent skill	競賽流程操作手冊:EDA→CV 設計→特徵→建模→評估→提交 六階段
self-improvement skill	線性自我迭代與跨競賽經驗庫的操作手冊
kaggle-report skill	報告自動產生:事實抽取、數字一致性驗證、PDF 輸出
LightGBM / XGBoost / CatBoost	三個梯度提升樹模型,所有集成的基礎成員
scikit-learn	交叉驗證切分與評估指標計算
Optuna	超參數自動搜尋(階段 3 起使用)
自建樹搜尋工具	階段 4 的候選樹搜尋:第 1 版節點為單一模型、第 2 版節點為 blend、第 3 版加入預算相位機與自動停止
uv	Python 套件與環境管理,所有腳本以 <code>uv run</code> 執行

分工原則:LLM 負責判斷與決策(選什麼方向、何時停),AutoML 工具(Optuna、樹搜尋) 負責系統化的搜尋執行,兩者互補。

4. 評估與分數的通用約定

- 每場競賽用該場官方指定的評估指標(MAE、RMSE、ROC-AUC 等),於各場報告 第 3 節說明;指標的優化方向(越小越好或越大越好)以該場報告為準。
- 本地分數一律指 OOF 分數;排行榜分數一律標明 Public 或 Private。
- 同場所有實驗共用同一組折,分數才可直接比較;跨場分數不互比(指標與資料不同)。

5. 全案專業術語表

正文常用詞,依主題分組。

實驗與驗證

專業術語	定義
exp N	該場報告中第 N 筆實驗紀錄的編號(場內編號,跨場不互通)
CV / 折(fold)	交叉驗證:訓練資料切成 K 份輪流當驗證集,以平均分數評估模型

專業術語	定義
StratifiedKFold(分層 K 折)	各折保持指定類別(或分箱)比例一致的切分方式
OOF	out-of-fold:每筆訓練樣本由「未見過它的那折模型」預測,拼回全訓練集後計算的分數;全案所有本地決策的依據
CV↔LB gap	本地 OOF 分數與排行榜分數的差距,用於檢查本地驗證是否可信
CV-only	該結果僅有交叉驗證分數、沒有排行榜分數可對照(競賽已關閉提交等原因)
Public / Private LB	Kaggle 排行榜:Public 為賽中可見的部分測試集分數,Private 為決定最終名次的另一部分
OOF 重現閘門	提交前把最佳解的全部成員從頭重訓,逐位比對 OOF 與搜尋當時的快取一致,才允許產生 test 預測
巢狀驗證	把「選擇」這個動作(選特徵、調權重)也放進驗證:在部分折上做選擇,用沒參與選擇的折驗分數,避免選擇本身造成過度樂觀

建模與集成

專業術語	定義
solo	單一模型(單一組超參數)的完整 K 折訓練結果
blend / 權重搜尋	多個 solo 的 OOF 加權平均;權重由演算法在 OOF 上搜尋而得
seed bagging	同一組超參數換隨機種子重訓,加入集成以降低隨機波動
目標編碼(TE)/ fold-safe	以群組的目標平均值作特徵;fold-safe 指編碼所用的折與模型訓練折完全一致,杜絕跨折洩漏
rank-average	各模型的預測值先轉成名次(排名)再加權平均;對輸出大小尺度不同的模型更穩
經驗庫	跨競賽累積的「什麼有效/什麼無效」條目,供後續場次作先驗

樹搜尋(階段 4)

專業術語	定義
節點	樹搜尋中的一個候選配置(一個 solo 或一個 blend)
lineage(系譜)	由根節點某直接子節點衍生的整條後代鏈,代表一個優化方向
plateau	某 lineage 連續數次未刷新全域最佳而被凍結,搜尋轉往其他方向
explore burst(探索爆發)	全部 lineage 皆凍結後,強制注入的一批新起點
mega-blend	把當時全部 solo 成員都納入的大集成
邊界推進	調參搜尋範圍的邊緣值再往外推一步的嘗試(如把學習率壓到搜尋下限之外)

6. 階段與子階段定義(全案字典)

實驗依「使用的方法架構」分為五個階段,階段內的具體優化辦法以子階段(如 1.1)表示。編號與簡稱在所有競賽報告中意義相同,可跨場直接對照;各場報告第 2.3 節只列「編號、簡稱、本場是否使用」,定義以本表為唯一出處。

編號	簡稱	定義
1	無 skill 基線	未使用 kaggle-agent skill: Claude Code 直接執行通用 AutoML 腳本
1.1	單模型基線	單一模型、預設參數、原始特徵
1.2	三模型 blend	三個梯度提升樹模型 + OOF 權重搜尋 blend
2	kaggle-agent skill	依 skill 的六階段流程作業: EDA→CV 設計→特徵工程→建模→後處理→提交
2.1	EDA 驅動 CV 設計	依資料性質設計切分(分層/分箱/時序)
2.2	EDA 驅動特徵工程	由 EDA 發現引導的衍生特徵
2.3	指標感知後處理	依評估指標調整目標與輸出(取整、objective 對齊等)
2.4	場內反思回退	單輪反思(reflexion): 嘗試失敗即回退上一版
3	+線性自我迭代	階段 2 加上「一次改一件事、固定停止準則」的逐輪優化
3.1	經驗庫先驗	以跨競賽經驗庫引導迭代方向
3.2	Optuna 超參搜尋	自動調參, 調參後模型納入集成池
3.3	調參入池	調參模型「加入」集成池而非取代原成員
3.4	seed bagging	調參模型換隨機種子重訓再入池
3.5	結構化去噪	EB 收縮/異常期降權/鄰域平滑等訊號去噪
4	+樹搜尋	階段 2 加上候選樹+回溯機制的組合空間搜尋(取代線性迭代)
4.1	單模型節點樹	節點=單一模型配置(工具第 1 版)
4.2	ensemble 節點樹	節點=blend 配置, 直接以最終計分方式的分數評分(如取整後計分)(工具第 2 版)
4.3	先驗注入+去重	經驗庫先驗引導擴展方向, 子節點去重
4.4	邊界推進 mutation	以邊界推進產生新節點的擴展方式
4.5	預算相位機	把運算預算分成幾個時期(先廣後深)排程, 加上探索爆發與自動停止(工具第 3 版)
5	+外部想法注入	階段 4 加上外部文獻想法庫(全案規劃中)
5.1	外部想法庫先驗	文獻與冠軍方案的想法注入搜尋先驗
5.2	重組 mutation	取兩個高分節點的核心概念合成新解

對照原始紀錄用: 歷史紀錄文字中的舊代號 Phase B 即階段 3、Phase E-3 即階段 4、tier1-4 即階段 1-4; 所有報告正文一律不使用舊代號。

7. 各場報告的結構

每份競賽報告固定 7 節:

節	內容
1 競賽目的	這場比什麼、評估指標與資料概要
2 本場工具、專業術語與採用策略	僅本場特有的工具與專業術語; 2.3 為本場各階段採用情形表

節	內容
3 實驗方法	資料規格與實驗總表(所有數字的出處)
4 實驗軌跡	按時間順序的決策敘事:為何這樣做、結果如何
5 效能對照	逐階段分數對照:每一階段比前一階段改善多少
6 總結	本場學到什麼、哪些作法有效
7 重現指令	從原始資料重現最佳解的完整指令

報告 2.3 節「本場是否使用」欄的意義:**使用** = 該階段/子階段在本場有實際執行; **本場未使用** = 全案字典中有此項但本場未執行(或無獨立紀錄);規劃中的階段 標「本場未執行」。