

成果簡報:AI Agent 自主參加 Kaggle 表格競賽

本簡報濃縮整個暑期專案的成果,供口頭報告與快速檢視使用;完整方法見《前言》(PREFACE),逐場與跨場數據見《總結報告》(SUMMARY_REPORT)與各場競賽報告。所有數字均取自可重現的原始紀錄並經自動一致性驗證。

目錄

1. 一句話目標	1
2. 做了什麼(交付物)	1
3. 核心方法:五階段消融	2
4. 主要結果	2
5. 跨場學到的可遷移洞見	2
6. 對齊 Aygün 等人 ERA(計畫書 4.1)	3
7. 對照計畫書五大目標	3
8. 下一步	3

1. 一句話目標

評估「Claude Code(LLM agent)+ AutoML 工具」的混合式 AI agent,能否**自主**走完 Kaggle 表格競賽的完整資料科學流程(理解題目 → EDA → CV 設計 → 特徵 → 建模 → 集成 → 提交),並用**受控消融**量化「每加一項自主能力,分數多改善多少」。方法對齊 Aygün 等人(2026, Nature)的 ERA 系統核心主張。

2. 做了什麼(交付物)

交付物	內容
kaggle-agent skill	競賽流程操作手冊:六階段 EDA→CV→特徵→建模→評估→提交
self-improvement skill	線性自我迭代 + 跨競賽經驗庫(什麼有效/無效的累積條目)
自建樹搜尋工具(3 版)	候選樹 + 回溯 + 預算相位機,取代線性單路徑優化
外部想法庫 + 注入鉤	24 條有真實出處的文獻技法([EXT]),v4 harness 把它與經驗庫併池注入樹搜尋
kaggle-report skill	報告自動產生:事實抽取 → 數字一致性驗證 → 目錄/頁碼 PDF
15 場競賽 + 3 份總覽	各場報告 + 前言 + 總結報告 + 本簡報,全部自動化產生並驗證

3. 核心方法:五階段消融

同一場競賽解多次,一次比一次多給一項能力,再比較分數,就能逐段隔離每項能力的貢獻:

- **階段 1:**無 skill 基線(直接跑通用 AutoML)
- **階段 2:**+ kaggle-agent skill(結構化六階段流程)
- **階段 3:**+ 線性自我迭代(經驗庫先驗、Optuna、seed bagging)
- **階段 4:**+ 樹搜尋(候選樹取代線性單路徑 → 對應 ERA 第一支柱)
- **階段 5:**+ 外部想法注入(文獻想法庫 → 對應 ERA 第二支柱;注入機制已建置並實測——外部 注入在測試場無可量測系統性增益(誠實 null),見 § 8)

4. 主要結果

(1) 遞增階梯場成立:15 場競賽(10 場同季 S3 主 benchmark + 5 場跨季 S4–S6), 每一場的階段 1→4 都是正向或持平,**沒有一場在任一階整體倒退**——這是「導入自主能力 確實有用」的跨場證據(計畫書目標三:效能不退步)。

(2) 增幅分布本身是資訊:大改善集中在「資料藏著結構性洞見」的場次(如 s3e20 +25.7%、s3e5 +19.2%),已被基線逼近天花板的場次增量普遍 <1%。這說明 agent 的價值在「找到並利用 結構」,而非無差別地堆疊模型。

(3) 真實排行榜驗證:s3e16 是唯一有真實 Kaggle LB 對照者,樹搜尋版(階段 4)對線性版(階段 2)在 Public 與 Private **兩榜同方向改善**,CV↔LB 落差兩次提交一致——這是本套方法 第一個外部(非本地)信度證據。

(4) 跨季泛化:把 S3 驗證過的四階段配方原封搬到第 4–6 季五場競賽(五種不同指標: AUC、accuracy、RMSE、R2),階梯**仍場場成立**,只是增幅收斂——配方能泛化到新季度與新指標。

5. 跨場學到的可遷移洞見

- **經驗庫先驗必須逐場檢驗——同一先驗可得相反結論:**交互項先驗在 s5e10/s6e2 被確認、卻在 s6e1 被否決;類別不平衡加權在不同指標場各有適用邊界。先驗要連同適用條件一起搬。
- **指標決定後處理,不是目標外觀決定:**整數目標配取整(s3e16)、序數配 OptimizedRounder (s3e5);但 s5e10 目標雖落格點,對 RMSE 貼格點反而有害——外觀離散 ≠ 該離散化。
- **樹搜尋的贏家形狀因資料而異:**有場 mega-blend 奪冠、有場血統 blend 勝出、有場單一模型 勝出——固定套路會賭錯形狀,搜尋會就地找到對的那個。
- **可重現性紀律:**跨季場的階段 4 最佳解全數通過 OOF 逐位重現閘門;並修掉 LightGBM 跨進程非決定性,達 $\max|d_{\text{OOF}}|=0$ 的位元級重現——這是消融方法論可信度的根。

6. 對齊 Aygün 等人 ERA(計畫書 4.1)

ERA 支柱	本專案對應	狀態
第一支柱:候選樹取代線性單路徑	階段 4 樹搜尋(3 版工具)	已完成、15 場驗證
第二支柱:外部知識注入	階段 5 外部想法庫 + v4 注入鉤 + plateau 注入	想法庫 24 條 + 併池去重 + 注入機制(idea_injection.py)建置並實測完成。誠實結論:機制可行,但外部注入在測試場 無可量測系統性增益(null) ——能乾淨翻譯的想法搜尋已覆蓋、有用的想法已手寫(見 phase_j_j3_findings)

7. 對照計畫書五大目標

目標	狀態
一:報告自動生成	kaggle-report skill,15 場全自動產出
二:報告品質(可讀、無自創術語)	前言抽共同內容、白話化、目錄頁碼
三:效能不退步	15 場階梯場場成立
四:決策可追溯	數字一致性驗證閘門 + OOF 逐位重現閘門
五:可重現與可部署	重現已達位元級;封裝/容器化進行中

8. 下一步

- **階段 5(外部注入)已收尾**:J-3 發現 `tree['priors']` 為 write-only → 已接線 (idea_injection.py,plateau 觸發、限次數)並實測。誠實答案:**外部注入在測試場無可量測系統性增益(null)**——能乾淨翻譯的想法(rank averaging)搜尋已覆蓋,有用的想法已手寫或 難自動翻譯。ERA 第二支柱定位為「機制可行、邊際價值 null」的嚴謹負面結果(見 docs/phase_j_j3_findings.md)。若要續探,方向是「需重訓/新特徵」的想法(對抗驗證等),但從一致型態看報酬遞減。
- 交付層收尾:Skill 封裝、使用說明、容器化(本機為 arm64,套件建置為變數)。
- 統計嚴謹度升級:多種子重跑 + 信賴區間,把「階段 N > 階段 N-1」由點估計變為統計顯著。