

Playground-Series 逐階段效能總報告(10 場 S3 + 跨季 5 場 S4-S6)

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf)。本報告由自動化報告流程產生:主表數字取自跨場彙總的原始紀錄並經自動一致性驗證,敘述由 AI 彙整。範圍:週末批次 10 場第三季(S3)競賽的完整階段 1-4 軌跡(主 benchmark),另加跨季 5 場(s4e1、s4e11、s5e10、s6e1、s6e2)的泛化驗證。

目錄	
1. 這份報告在看什麼	1
2. 十場逐階段總表	1
3. 逐場關鍵招式與一句結論	2
4. 跨場反覆驗證的四個配方	3
5. 真實排行榜驗證(僅 s3e16)	3
6. 跨季泛化(第 4-6 季:5 場,5 種指標)	4
7. 階段5(外部想法注入):機制可行、邊際價值 null	4
8. 總結	5
重現方式	5

1. 這份報告在看什麼

同一場競賽用四種遞增配置各解一次——階段 1(無 skill)→ 2(kaggle-agent skill 流程)→ 3(+線性自我迭代)→ 4(+樹搜尋)——比較分數,就能逐段隔離出每一項方法各帶來多少貢獻 (階段定義見《前言》第 6 節,不在此重複)。主 benchmark 為 10 場 S3;另用五場第 4-6 季 競賽檢驗同一套配方跨季、跨指標是否仍成立。

2. 十場逐階段總表

競賽	指標	階段 1	階段 2	階段 3	階段 4	階段1→4 相對變化
s3e1(加州房價)	rmse(↓)	0.56166	0.558768	0.557088	0.556329	+0.95%
s3e3(離職預測)	roc_auc(↑)	0.81624	0.832925	0.83814	0.845051	+3.53%
s3e5(酒質,QWK)	quadratic_weighted_kappa(↑)	0.47871	0.52687	0.56769	0.57066	+19.21%
s3e7(訂房取消)	roc_auc(↑)	0.89882	0.899395	0.899893	0.900455	+0.18%

競賽	指標	階段 1	階段 2	階段 3	階段 4	階段1→4 相對變化
s3e9(混凝土強度)	rmse(↓)	12.54287	12.073474	12.070034	12.070034 (平手)	+3.77%
s3e11(媒體成本)	rmsle(↓)	0.29723	0.296143	0.295648	0.29528	+0.66%
s3e14(藍莓產量)	mae(↓)	341.40782	340.711795	340.59891	340.35572	+0.31%
s3e16(蟹齡, 取整 MAE)*	mae(取整, ↓)	1.35441	1.33812	1.33812	1.33563	+1.39%
s3e19(銷量預測, SMAPE)*	smape(↓)	無可比分數*	10.175397	10.019463	9.75707	+4.11%(階段2→4)
s3e20(盧安達 CO2)*	rmse(↓)	28.3424(代理)*	22.6488	21.1487	21.0589	+25.70%

計分方式註記(僅這四場需要,其餘六場為乾淨對照):

- **s3e19**:階段 1(隨機 KFold)與階段 2-4(TimeSeriesSplit)CV 方案不同、不可比較——test 為嚴格未來期,隨機 KFold 是內插式樂觀估計;本列「階段 1」故標「無可比分數」,相對變化改報 階段2→4。
- **s3e16**:階段 2-4 皆為取整計分(非原始分數);階段 2=階段 3(線性迭代兩輪未過取整門檻,依協定誠實停止)。
- **s3e20**:此賽 2023 已關閉,階段 1 為同 CV 方案下的代理基線(非嚴格通用批次);全部階段皆 CV-only。
- **s3e9**:階段 4=階段 3(精確平手,非缺漏)——樹搜尋追平而非打敗線性最佳,顯示該場資料噪音上限已被線性迭代摸到頂。

十場中,階段 4 相對階段 3 全數未退步(9 場改善、1 場精確持平)——計畫書目標三(效能不退步)的跨場證據。

3. 逐場關鍵招式與一句結論

競賽	關鍵招式	一句結論
s3e1	地理密度/最近距離特徵 + Optuna 入池 + seed bagging	樹能自行切分座標,原始幾何度量才是真增益,粗粒度地理目標編碼反而冗餘
s3e3	移除類別不平衡加權、收緊正則化,Optuna 直接優化完整 CV 的 ROC-AUC	排名指標下,擾動損失面的不平衡加權是壞交易,直接優化最終指標才對
s3e5	OptimizedRounder 取代直接四捨五入,Optuna 目標直接設為後處理後的 QWK	離散化指標必須用指標本身驗證增益,不能靠代理 loss 再套後處理
s3e7	剪除無關日期特徵,Optuna 調參後加入池(不取代)	特徵不是越多越好;同一調參配方重複套用反而傷 blend 多樣性
s3e9	正則化與特徵工程對抗重複列標籤噪音,seed bagging 是停滯後唯一持續生效者	噪音天花板下,樹搜尋精確追平而非打敗線性最佳,是誠實的天花板驗證
s3e11		

競賽	關鍵招式	一句結論
	fold-safe 門市目標編碼為最大單一增益,CatBoost 深度推過搜尋邊界	邊界推進是本場單一最大增益來源,值得成為標準變異型別
s3e14	剪除近完美共線特徵,調參 LGB 入池,樹搜尋探索爆發 mega-blend 收尾	solo 分數普通的成員能拿最大 blend 權重,探索爆發是後期突破唯一來源
s3e16	目標取整為最大增益,樹搜尋延續原始/取整反轉並實際提交取得雙榜改善	決策指標必須是取整後分數;本場是十場中唯一有真實 LB 對照者
s3e19	log1p 目標 + 日曆特徵,TimeSeriesSplit 下對最後一折 Optuna 調參 + seed bagging	時序外推必須用 TimeSeriesSplit;比例分解在總量難外推時輸給 GBDT
s3e20	發現目標跨年近乎恆定,純 location-week 歷史均值完勝 GBDT,再三段去噪疊加	結構訊號飽和到連殘差層都榨不出可預測性,GBDT 全程權重歸零

4. 跨場反覆驗證的四個配方

- Optuna → 入池(不取代)→ seed bagging:**在 s3e1、s3e3、s3e7、s3e9、s3e11、s3e14、s3e19 共七場一致有效,是目前樣本量最大的耐用配方。已知邊界是 s3e16——目標需取整時,原始 OOF 上的增益可能穿不過四捨五入的離散邊界,必須以取整分數決策。
- 指標感知後處理:**整數目標直接取整(s3e16)、序數目標配 OptimizedRounder 調切點(s3e5)、離散格點目標貼齊最近訓練觀測值(s3e14);三者都勝過「不做後處理/僅 clip」,且都必須用指標本身(而非代理 loss)驗證增益。
- 探索爆發 + mega-blend(樹搜尋機制):**強制觸發的探索爆發在 s3e3、s3e7、s3e14 皆為後期突破的唯一貢獻來源;共通模式是「solo 分數不亮眼卻拿最大 blend 權重」的成員。
- 邊界推進:**Optuna 調參卡在搜尋邊界時,把「推過邊界」當成標準變異型別,在 s3e11、s3e5、s3e16 各自被驗證為單一最大增益來源之一;s3e7 的第 3 版工具自動邊界偵測提供第四個獨立確認。

5. 真實排行榜驗證(僅 s3e16)

十場中僅 **s3e16** 有真實 Kaggle 排行榜對照,且是唯一同時具備階段 2「與」階段 4 兩筆真實提交者(其餘九場的階段 4 皆為僅有 OOF 分數的搜尋產物,未提交)。

提交	對應階段	日期	Public	Private
#1	2/3(第 1 次實驗,線性冠軍)	2026-07-03	1.34356	1.34075
#2	4(第 5 次實驗,樹搜尋)	2026-07-06	1.34315	1.33859

雙榜改善(提交#2 相對提交#1):

Public : 1.34356 - 1.34315 = 0.00041

Private: 1.34075 - 1.33859 = 0.00216

兩榜皆對提交#1 改善、方向一致——是這套樹搜尋配方第一次獲得的外部(真實排行榜)驗證,而非僅本地比較。決策指標全程為取整後 OOF MAE(算式與 CV↔LB gap 一致性檢查見該場競賽報告第 3.5 節)。

6. 跨季泛化(第 4–6 季:5 場,5 種指標)

把 S3 驗證過的四階段配方(階段 1→4)原封搬到第 4–6 季的五場競賽——橫跨三個季度、五種不同指標——檢驗這套遞增階梯是否只在同季 S3 成立,還是能泛化到新季度與新指標。

競賽	指標	階段 1	階段 2	階段 3	階段 4	階段1→4 相對變化
s4e1(信用違約)	roc_auc(↑)	0.8922	0.894302	0.894354	0.894393	+0.25%
s4e11(憂鬱傾向)	accuracy(↑)	0.93955	0.939488	0.9399	0.940235	+0.07%
s5e10(道路事故風險)	rmse(↓)	0.056074	0.056027	0.055976	0.055968	+0.19%
s6e1(考試成績)	r2(↑)	0.786414	0.786793	0.78706	0.787183	+0.10%
s6e2(心臟病)	roc_auc(↑)	0.95498	0.955197	0.95551	0.955529	+0.06%

五場全 CV-only(競賽關榜,提交遭 403;階段 4 最佳解仍先通過 OOF 逐位重現閘門才嘗試提交)。四個跨季發現:

- 階梯場場成立,但增幅收斂:**五場的階段 1→4 全數正向(見上表相對變化欄),幅度普遍小於多數 S3 場——遞增配置在跨季、跨指標下仍不整體退步,只是可壓縮空間更小。s4e11 的階段 2 曾出現微退(28 特徵集起步略遜通用 blend),後續階段追回,如實保留。
- 經驗庫先驗必須逐場檢驗——同一先驗可得相反結論:**交互項先驗(「顯式交互欄對 GBDT 無益」)在 s5e10、s6e2 被對照檢驗**確認**、卻在 s6e1 被**否決**(該場交互欄確實有用);類別不平衡加權先驗在 accuracy(s4e11)與 AUC(s6e2)場也各自檢驗其適用邊界。先驗要連同適用條件一起搬、當場檢驗後才用——這些正反案例都寫回了經驗庫。
- 樹搜尋的贏家形狀因資料而異:**s5e10、s6e1、s6e2 的階段 4 由 mega-blend(全池成員)奪冠, s6e2 更收斂成單一模型家族內部變異;而 s4e11 由系譜逐步長成的血統 blend 勝出、mega-blend 落敗。同一套搜尋機制在不同資料上找到不同形狀的最優解,正是用搜尋取代固定配方的價值。
- 可重現性紀律:**五場的階段 4 最佳解皆通過 OOF 逐位重現閘門;s6e1、s6e2 更把 LightGBM 的跨進程非決定性固定(deterministic 旗標),達到 $\max|dOOF|=0$ 的位元級重現。

統計顯著性校準(詳見 docs/statistical_rigor.md):對五場的階段 OOF 做 paired bootstrap 信賴區間分析——**端到端階梯(base blend → 樹搜尋贏家)的總改善,五場全部超出 OOF 估計 噪音、統計顯著**;但個別階段(尤其樹搜尋那一步)在兩個較小樣本的場次(s4e1、s4e11)落在噪音內,s4e11 更是每個單步都不個別顯著、只有累積才顯著。誠實結論:信「累積的階梯」,不過度宣稱任何單一 0.0x% 步(此 CI 僅量 OOF 估計的抽樣變異、非重跑搜尋的變異,為下界)。

逐場完整軌跡見各場競賽報告(competitions/playground-series-{s4e1,s4e11,s5e10,s6e1,s6e2})。

7. 階段5(外部想法注入):機制可行、邊際價值 null

第五階段(ERA 第二支柱)把外部文獻想法**自動注入**樹搜尋。我們把它做成計畫書 § 6 迭代策略所述的「停滯(plateau)時搜尋外部想法」的機制(tree/idea_injection.py :讀外部想法庫 → 依競賽篩選 + 與內部經驗去重 → 翻譯成搜尋候選 → 標來源),並對 **15 場**在階段4收斂點注入 候選、用快取 OOF 快評(docs/scripts/stage5_sweep.py)。

結果:15 場中,外部注入從未產生一個能勝過階段4的候選——階段5 = 階段4(全持平)。 (過程還抓除兩個假正例:s3e7 的弱基線、s3e20 榨出的已排除 CV 噪音——見 docs/phase_j_j3_findings。)

為什麼 null(合理解釋):(1) 階段4的 OOF 權重搜尋已在成員池上近最優,能乾淨注入的想法 (rank 平均、stacking) 只是重組同一批成員、贏不過它;(2) 更有彈性的 stacking 反而過擬合 CV 噪音、且對非平方誤差指標不對齊(故 MAE/SMAPE 場明顯更差);(3) 真正有用的領域想法早已被 作者手寫進搜尋(見前言階段定義);(4) 訊號已被前四階段榨到噪音地板;(5) 能帶來新訊號的想法 (對抗驗證等)需新特徵/重訓、難自動注入且資料相依。**外部知識只在「引入搜尋錯過的新訊號」時才有價值,而這些成熟表格題幾乎沒有被錯過的結構可撿。**

這是**嚴謹的誠實負面結果**(機制通電、15 場實測、可重現、假正例已抓除),與本報告其他發現 同一誠實水準;階段4(第一支柱)的價值不受影響。詳見 docs/phase_j_j3_findings.md。

8. 總結

逐階段對照把「導入 skill 有沒有用」拆成三個可獨立檢驗的問題:階段1→2 隔離 kaggle-agent skill 流程本身、階段2→3 隔離線性自我迭代與經驗庫、階段3→4 隔離樹搜尋(對應 Aygün 等人 ERA 「候選樹取代線性單路徑」的核心主張)。十場 S3 加五場跨季(S4-S6、五種指標)的結果一致——三段隔離都拿到正向或持平訊號,沒有一場在任一階整體倒退。

增幅不均本身是資訊:大增益集中在「資料藏著結構性洞見」的場次(s3e20 +25.7%、s3e5 +19.2%),已被基線逼近天花板的場次增量普遍 <1%;跨季後增幅進一步縮小,但階梯仍成立。唯一有真實 LB 對照的 s3e16 同時驗證了階段 2 與階段 4,CV↔LB gap 兩次提交同方向同量級,是目前最強的外部 信度證據。

這個階梯尚未走到終點:階段 5(樹搜尋 + 外部想法注入,ERA 第二支柱)已定義並執行中,待收官後 本報告將擴為五階對照,並回答關鍵問題——外部文獻想法注入,能否在已被經驗庫與樹搜尋兩層榨過的 競賽上再擠出系統性(而非噪音級)的增益。

重現方式

```
uv run python3 docs/scripts/build_benchmark_table.py
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py docs/SUMMARY_REPORT.md docs/benchmark
bash .claude/skills/kaggle-report/assets/md2pdf.sh docs/SUMMARY_REPORT.md docs/SUMMARY_REPORT.pdf
```