

Playground-Series 逐階段效能總報告(10 場 S3 + 跨季 S4)

全案共同的研究設計、實驗流程、工具鏈、專業術語與五階段定義,見《前言》(docs/PREFACE.pdf)。本報告由自動化報告流程產生:主表數字取自跨場彙總的原始紀錄並經自動一致性驗證,敘述由 AI 彙整。範圍:週末批次 10 場第三季(S3)競賽的完整階段 1–4 軌跡(主 benchmark),另加跨季 s4e1、s4e11 兩場的泛化驗證。

目錄	
1. 這份報告在看什麼	1
2. 十場逐階段總表	1
3. 逐場關鍵招式與一句結論	2
4. 跨場反覆驗證的四個配方	3
5. 真實排行榜驗證(僅 s3e16)	3
6. 跨季泛化(第四季:s4e1、s4e11)	4
7. 總結	4
重現方式	4

1. 這份報告在看什麼

同一場競賽用四種遞增配置各解一次——階段 1(無 skill)→ 2(kaggle-agent skill 流程)→ 3(+線性自我迭代)→ 4(+樹搜尋)——比較分數,就能逐段隔離出每一項方法各帶來多少貢獻 (階段定義見《前言》第 6 節,不在此重複)。主 benchmark 為 10 場 S3;另用兩場第四季(S4) 競賽檢驗同一套配方跨季是否仍成立。

2. 十場逐階段總表

競賽	指標	階段 1	階段 2	階段 3	階段 4	階段1→4 相對變化
s3e1(加州房價)	rmse(↓)	0.56166	0.558768	0.557088	0.556329	+0.95%
s3e3(離職預測)	roc_auc(↑)	0.81624	0.832925	0.83814	0.845051	+3.53%
s3e5(酒質,QWK)	quadratic_weighted_kappa(↑)	0.47871	0.52687	0.56769	0.57066	+19.21%
s3e7(訂房取消)	roc_auc(↑)	0.89882	0.899395	0.899893	0.900455	+0.18%
	rmse(↓)	12.54287	12.073474	12.070034		+3.77%

競賽	指標	階段 1	階段 2	階段 3	階段 4	階段1→4 相對變化
s3e9(混凝土強度)					12.070034 (平手)	
s3e11(媒體成本)	rmsle(↓)	0.29723	0.296143	0.295648	0.29528	+0.66%
s3e14(藍莓產量)	mae(↓)	341.40782	340.711795	340.59891	340.35572	+0.31%
s3e16(蟹齡, 取整 MAE)*	mae(取整, ↓)	1.35441	1.33812	1.33812	1.33563	+1.39%
s3e19(銷量預測, SMAPE)*	smape(↓)	無可比分數*	10.175397	10.019463	9.75707	+4.11%(階段2→4)
s3e20(盧安達 CO2)*	rmse(↓)	28.3424(代理)*	22.6488	21.1487	21.0589	+25.70%

計分方式注記(僅這四場需要,其餘六場為乾淨對照):

- **s3e19**:階段 1(隨機 KFold)與階段 2-4(TimeSeriesSplit)CV 方案不同、不可比較——test 為嚴格未來期,隨機 KFold 是內插式樂觀估計;本列「階段 1」故標「無可比分數」,相對變化改報 階段2→4。
- **s3e16**:階段 2-4 皆為取整計分(非原始分數);階段 2=階段 3(線性迭代兩輪未過取整門檻,依協定誠實停止)。
- **s3e20**:此賽 2023 已關閉,階段 1 為同 CV 方案下的代理基線(非嚴格通用批次);全部階段皆 CV-only。
- **s3e9**:階段 4=階段 3(精確平手,非缺漏)——樹搜尋追平而非打敗線性最佳,顯示該場資料噪音上限已被線性迭代摸到頂。

十場中,階段 4 相對階段 3 全數未退步(9 場改善、1 場精確持平)——計畫書目標三(效能不退步)的跨場證據。

3. 逐場關鍵招式與一句結論

競賽	關鍵招式	一句結論
s3e1	地理密度/最近距離特徵 + Optuna 入池 + seed bagging	樹能自行切分座標,原始幾何度量才是真增益,粗粒度地理目標編碼反而冗餘
s3e3	移除類別不平衡加權、收緊正則化,Optuna 直接優化完整 CV 的 ROC-AUC	排名指標下,擾動損失面的不平衡加權是壞交易,直接優化最終指標才對
s3e5	OptimizedRounder 取代直接四捨五入,Optuna 目標直接設為後處理後的 QWK	離散化指標必須用指標本身驗證增益,不能靠代理 loss 再套後處理
s3e7	剪除無關日期特徵,Optuna 調參後加入池(不取代)	特徵不是越多越好;同一調參配方重複套用反而傷 blend 多樣性
s3e9	正則化與特徵工程對抗重複列標籤噪音,seed bagging 是停滯後唯一持續生效者	噪音天花板下,樹搜尋精確追平而非打敗線性最佳,是誠實的天花板驗證
s3e11		

競賽	關鍵招式	一句結論
	fold-safe 門市目標編碼為最大單一增益,CatBoost 深度推過搜尋邊界	邊界推進是本場單一最大增益來源,值得成為標準變異型別
s3e14	剪除近完美共線特徵,調參 LGB 入池,樹搜尋探索爆發 mega-blend 收尾	solo 分數普通的成員能拿最大 blend 權重,探索爆發是後期突破唯一來源
s3e16	目標取整為最大增益,樹搜尋延續原始/取整反轉並實際提交取得雙榜改善	決策指標必須是取整後分數;本場是十場中唯一有真實 LB 對照者
s3e19	log1p 目標 + 日曆特徵,TimeSeriesSplit 下對最後一折 Optuna 調參 + seed bagging	時序外推必須用 TimeSeriesSplit;比例分解在總量難外推時輸給 GBDT
s3e20	發現目標跨年近乎恆定,純 location-week 歷史均值完勝 GBDT,再三段去噪疊加	結構訊號飽和到連殘差層都榨不出可預測性,GBDT 全程權重歸零

4. 跨場反覆驗證的四個配方

- Optuna → 入池(不取代)→ seed bagging:**在 s3e1、s3e3、s3e7、s3e9、s3e11、s3e14、s3e19 共七場一致有效,是目前樣本量最大的耐用配方。已知邊界是 s3e16——目標需取整時,原始 OOF 上的增益可能穿不過四捨五入的離散邊界,必須以取整分數決策。
- 指標感知後處理:**整數目標直接取整(s3e16)、序數目標配 OptimizedRounder 調切點(s3e5)、離散格點目標貼齊最近訓練觀測值(s3e14);三者都勝過「不做後處理/僅 clip」,且都必須用指標本身(而非代理 loss)驗證增益。
- 探索爆發 + mega-blend(樹搜尋機制):**強制觸發的探索爆發在 s3e3、s3e7、s3e14 皆為後期突破的唯一貢獻來源;共通模式是「solo 分數不亮眼卻拿最大 blend 權重」的成員。
- 邊界推進:**Optuna 調參卡在搜尋邊界時,把「推過邊界」當成標準變異型別,在 s3e11、s3e5、s3e16 各自被驗證為單一最大增益來源之一;s3e7 的第 3 版工具自動邊界偵測提供第四個獨立確認。

5. 真實排行榜驗證(僅 s3e16)

十場中僅 **s3e16** 有真實 Kaggle 排行榜對照,且是唯一同時具備階段 2「與」階段 4 兩筆真實提交者(其餘九場的階段 4 皆為僅有 OOF 分數的搜尋產物,未提交)。

提交	對應階段	日期	Public	Private
#1	2/3(第 1 次實驗,線性冠軍)	2026-07-03	1.34356	1.34075
#2	4(第 5 次實驗,樹搜尋)	2026-07-06	1.34315	1.33859

雙榜改善(提交#2 相對提交#1):

Public : $1.34356 - 1.34315 = 0.00041$

Private: $1.34075 - 1.33859 = 0.00216$

兩榜皆對提交#1 改善、方向一致——是這套樹搜尋配方第一次獲得的外部(真實排行榜)驗證,而非僅本地比較。決策指標全程為取整後 OOF MAE(算式與 CV↔LB gap 一致性檢查見該場競賽報告第 3.5 節)。

6. 跨季泛化(第四季:s4e1、s4e11)

把 S3 驗證過的整套配方(階段 1→4)原封搬到第四季兩場競賽:

```
s4e1 (ROC-AUC,越大越好): 0.8922 → 0.894302 → 0.894354 → 0.894393 (階段1→4 +0.24%)
s4e11(accuracy,越大越好):0.93955 → 0.939488 → 0.9399 → 0.940235 (階段1→4 +0.07%;階段2 微退 -0.01%,如實列)
```

三個跨季發現:

1. **配方成立,但增幅明顯縮小**:兩場的階段 1→4 總改善(+0.24%、+0.07%,見上方階梯)都小於多數 S3 場——遞增階梯在新季度仍不退步,但可壓縮空間更小。s4e11 的階段 2 甚至出現 -0.01% 的微幅退步 (28 特徵集起步 blend 略遜於通用 blend),如實保留、後續階段追回。
2. **經驗庫先驗不能照搬**:s4e11 把 S3 學到的 `is_unbalance` 先驗(來自排名類指標場次)搬到 accuracy 指標上,對照檢驗反而退步、當場否決——證實先驗必須連同適用條件一起搬、檢驗後才用。這條負面結果已寫回經驗庫。
3. **兩場皆 CV-only**:S4 競賽已關榜(提交遭拒),僅有本地分數;s4e1 另發現二月舊紀錄有一處 目標編碼跨折洩漏,已在該場報告誠實標注並修正。

逐場完整軌跡見各場競賽報告(competitions/playground-series-s4e1、s4e11)。

7. 總結

逐階段對照把「導入 skill 有沒有用」拆成三個可獨立檢驗的問題:階段1→2 隔離 kaggle-agent skill 流程本身、階段2→3 隔離線性自我迭代與經驗庫、階段3→4 隔離樹搜尋(對應 Aygün 等人 ERA 「候選樹取代線性單路徑」的核心主張)。十場 S3 加兩場 S4 的結果一致——三段隔離都拿到正向或持平訊號,沒有一場在任一階整體倒退。

增幅不均本身是資訊:大增益集中在「資料藏著結構性洞見」的場次(s3e20 +25.7%、s3e5 +19.2%),已被基線逼近天花板的場次增量普遍 <1%;跨季後增幅進一步縮小,但階梯仍成立。唯一有真實 LB 對照的 s3e16 同時驗證了階段 2 與階段 4,CV↔LB gap 兩次提交同方向同量級,是目前最強的外部 信度證據。

這個階梯尚未走到終點:階段 5(樹搜尋 + 外部想法注入,ERA 第二支柱)已定義並執行中,待收官後 本報告將擴為五階對照,並回答關鍵問題——外部文獻想法注入,能否在已被經驗庫與樹搜尋兩層榨過的 競賽上再擠出系統性(而非噪音級)的增益。

重現方式

```
uv run python3 docs/scripts/build_benchmark_table.py
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py docs/SUMMARY_REPORT.md docs/benchmark
bash .claude/skills/kaggle-report/assets/md2pdf.sh docs/SUMMARY_REPORT.md docs/SUMMARY_REPORT.pdf
```