

十場競賽四層消融總報告(playground-series 週末批次)

產生方式:數字逐字取自 docs/benchmark_facts.json (由 docs/scripts/build_benchmark_table.py 決定性抽取自各競賽 experiments.json),敘述由 agent 撰寫。 素材範圍:本週末批次 10 場 playground-series 競賽的完整消融軌跡(tier1-4)。 本報告所有數字皆出自 docs/benchmark_facts.json ,經 verify_report.py 驗證。 定位:本報告是讀者友善的敘事版總結,供督導一次比較十場全貌; docs/benchmark_summary.md 是同一份數字的精簡資料附錄,兩者互補、不重複維護。

1. 總覽

本報告把本週末批次 10 場 playground-series 競賽的「generic baseline → kaggle-agent skill 流程 → self-improvement 線性迭代 → 樹搜尋」四層消融(ablation)結果,整理成單一份可一次讀完 的總報告。四層構成一組對照實驗,逐層隔離出一種價值來源:

層級	定義	隔離出的價值
tier 1	generic baseline——Claude Code 直接執行、 未引入 kaggle-agent skill(run_competition.py 固定 LGB+XGB+CAT blend,無 EDA、無特徵工程、無逐場決策)	基線(無 skill)
tier 2	完整 skill 六階段流程最佳分數(Phase A,Phase B 自我改進迭代之前)	skill 流程本身
tier 3	線性迭代最終最佳分數(Phase A + Phase B 自我改進迭代後, 不含 樹搜尋)	自我改進迭代 + 跨競賽經驗庫
tier 4	樹搜尋(tree-search,Phase D-G)後之最佳分數,即 tier3 之上再疊加樹搜尋結果	搜尋式設計(對應 Aygün 等人 ERA 的樹搜尋主張)

tier5 預告:樹搜尋 + 外部想法注入(idea injection,ERA 第二支柱、計畫書 4.1)已於 Phase J 定義並執行中——本報告暫僅涵蓋 tier1-4,tier5 待收官後另行併入本表。

2. 使用工具與環境

工具	用途
LightGBM / XGBoost / CatBoost	三個梯度提升樹基礎模型,十場皆用於 blend 主體
Optuna	Phase B 超參搜尋(fold-proxy 或直接優化最終指標,依資料規模擇一)
自建樹搜尋 harness(v1/v2/v3)	Phase D-G 對全部 10 場搜尋特徵集/模型組合/超參空間

工具	用途
OptimizedRounder 等指標特化後處理	整數取整(s3e16)、序數切點優化(s3e5)、離散格點 snap(s3e14)
5-fold CV / StratifiedKFold / TimeSeriesSplit / Leave-One-Year-Out	依資料型態擇一,見各競賽 REPORT.md 第 3.3 節
uv	Python 套件與虛擬環境管理,所有腳本皆以 uv run 執行

十場的共通分工邏輯:Claude Code(LLM)負責問題理解、驗證策略、特徵工程與何時停損等 決策;Auto-ML 工具 (Optuna、樹搜尋 harness)負責系統化執行超參搜尋、集成與組合空間探索。

3. 十場四層總表

競賽	指標	tier1	tier2	tier3	tier4	tier1→tier4 相對變化
s3e1(加州房價)	rmse(↓)	0.56166	0.558768	0.557088	0.556329	+0.95%
s3e3(離職預測)	roc_auc(↑)	0.81624	0.832925	0.83814	0.845051	+3.53%
s3e5(酒質,QWK)	quadratic_weighted_kappa(↑)	0.47871	0.52687	0.56769	0.57066	+19.21%
s3e7(訂房取消)	roc_auc(↑)	0.89882	0.899395	0.899893	0.900455	+0.18%
s3e9(混凝土強度)	rmse(↓)	12.54287	12.073474	12.070034	12.070034 (平手)	+3.77%
s3e11(媒體成本)	rmsle(↓)	0.29723	0.296143	0.295648	0.29528	+0.66%
s3e14(藍莓產量)	mae(↓)	341.40782	340.711795	340.59891	340.35572	+0.31%
s3e16(蟹齡,取整 MAE)*	mae(取整,↓)	1.35441	1.33812	1.33812	1.33563	+1.39%
s3e19(銷量預測,SMAPE)*	smape(↓)	無可比 generic*	10.175397	10.019463	9.75707	+4.11% (tier2→tier4)
s3e20(盧安達 CO2)*	rmse(↓)	28.3424(proxy)*	22.6488	21.1487	21.0589	+25.70%

口徑 call-out(僅四場需要,其餘六場為乾淨對照) - s3e19:tier1(5.31891,plain KFold)與 tier2/3/4(TimeSeriesSplit)CV 方案不同、不可比較——test 為嚴格未來期,隨機 KFold 是內插式樂觀估計。本列「tier1」故標「無可比 generic」,相對

變化欄改報 tier2→tier4。- **s3e16**:tier2-tier4 皆為「取整(rounded)」口徑,非 collect.py 一般 adapter 輸出的 原始 blend_oof_mae;tier2=tier3(Phase B 兩輪未通過取整門檻,依協定誠實停止)。- **s3e20**:此賽 2023 已關閉,不在本週末批次的 run_competition.py 範圍內,tier1 為同 CV 方案下的 proxy 基線(加入 location-week target encoding 之前的 GBDT blend),非嚴格 generic-batch 對照;Late Submission 已關閉,全部四層皆 CV-only。- **s3e9**:tier4 = tier3(12.070034,精確平手,非缺漏)——樹搜尋精確追平(而非打敗)線性 最佳,顯示該場資料噪音上限已被線性迭代摸到頂,是誠實記錄而非搜尋失敗。

十場中,tier4 相對於 tier3 全數未退步(9 場改善、1 場精確持平,s3e9)——符合計畫書目標三 (效能不退步)的跨場證據。

4. 逐場一行摘要表

競賽	關鍵招式	一句結論
s3e1	地理密度/最近距離特徵 + Optuna(fold-proxy)入池 + seed bagging	樹能自行切分座標,粗粒度地理 target encoding 反而冗餘,原始幾何度量才是真增益
s3e3	移除類別不平衡加權、收緊正則化,再以 Optuna 直接優化完整 CV 上的 ROC-AUC	排名指標下,擾動損失面的不平衡加權是壞交易,直接優化最終指標才是正解
s3e5	OptimizedRounder 取代 naive rounding,Optuna 目標函式直接設為後處理後的 QWK	離散化指標必須用指標本身驗證增益,不能靠代理 loss 再套後處理
s3e7	剪除與目標無關的日期欄位特徵,Optuna fold-proxy 調參後加入池(不取代)	特徵不是越多越好,調參配方對第二個模型重複套用反而傷 blend 多樣性
s3e9	正則化與特徵工程合力對抗重複列標籤噪音,seed bagging 是調參停滯後唯一持續生效的槓桿	資料噪音天花板下,樹搜尋精確追平而非打敗線性最佳,是誠實的天花板驗證
s3e11	fold-safe store target encoding 為最大單一增益,CatBoost 深度推過 Optuna 搜尋邊界	邊界推進(boundary-push)是本場單一最大槓桿,值得成為標準變異型別
s3e14	剪除近完美共線特徵,Optuna 調參 LGB 加入池,樹搜尋 explore-burst mega-blend 收尾	solo 分數普通的長射成員能拿到最大 blend 權重,burst 機制是後期突破的唯一來源
s3e16	目標取整為最大槓桿,樹搜尋節點延續 raw/rounded 反轉並實際提交取得雙榜改善	決策指標必須是取整後分數;本場是十場中唯一同時擁有 tier2 與 tier4 真實 LB 錨點的競賽
s3e19	log1p 目標 + 日曆特徵,TimeSeriesSplit 下對最後一折做 Optuna 代理調參 + 兩輪 seed bagging	時序外推情境必須用 TimeSeriesSplit;比例分解結構化方法在總量本身難外推時輸給 GBDT
s3e20	發現目標跨年近乎恆定,純 location-week 歷史均值完勝所有 GBDT,再以三段去噪疊加增益	結構訊號已飽和到連殘差層都榨不出更多可預測性,GBDT 全程權重歸零

5. 真實排行榜驗證

十場中僅 **s3e16** 擁有真實 Kaggle 排行榜錨點,且是唯一同時具備 tier2「與」tier4 兩筆 真實提交的競賽,其餘九場的 tier4 皆為 OOF-only(見第 7 節)。

提交	對應層級	日期	Public	Private
#1	tier2/tier3(exp1,線性迭代冠軍)	2026-07-03	1.34356	1.34075
#2	tier4(exp5,樹搜尋 node #15)	2026-07-06	1.34315	1.33859

雙榜改善 (提交#2 相對提交#1) :

Public : 1.34356 - 1.34315 = 0.00041

Private: 1.34075 - 1.33859 = 0.00216

兩榜皆對提交#1 改善、方向一致——是這套樹搜尋配方第一次獲得的外部(真實排行榜)驗證,而非僅 OOF 內部比較。決策指標全程為取整(rounded)後 OOF MAE(1.33812→1.33563),而非 collect.py 一般 adapter 輸出的原始 blend_oof_mae(完整算式與 CV↔LB gap 一致性檢查見 [competitions/playground-series-s3e16/REPORT.md](#) § 3.5)。

6. 跨場驗證的配方

- Optuna(fold-proxy 或直接優化最終指標)→入池(不取代原成員)→seed bagging:**在 s3e1、s3e3、s3e7、s3e9、s3e11、s3e14、s3e19 共七場一致驗證有效,是目前樣本量最大的 耐用配方;已知邊界是 s3e16——目標需取整時,同一配方在 raw OOF 上的增益可能無法穿越 四捨五入的離散邊界,必須以 rounded 分數而非 raw 分數做決策。
- 指標感知後處理(metric-aware post-processing)三寶:**整數目標直接四捨五入 (s3e16)、序數目標配 OptimizedRounder 對 OOF 指標調切點(s3e5,遠勝 naive rounding)、離散格點目標 snap 到最近訓練集觀測值(s3e14);三者都比「不做後處理」或「僅 clip」穩定勝出,且都必須用指標本身(而非代理 loss)驗證增益是否成立。
- explore-burst + mega-blend(樹搜尋 tier4 機制):**harness 強制觸發的探索性爆發,在 s3e3(規模曲線驗證跑)、s3e7(v3 驗證跑)、s3e14(v1 與 v3 驗證跑)皆為後期突破的唯一 貢獻來源;共通模式是「solo 分數不特別亮眼、卻拿到最大 blend 權重」的長射成員——s3e14 的 EXPL_CATDEEP/EXPL_REGDEEP、s3e19 的 CALSUBSET、s3e1 的 CEILING 混合分類器皆屬此類。
- boundary-push(邊界推進):**當 Optuna 調參結果卡在搜尋空間邊界上時,把「推過邊界」當成標準 mutation 型別,在 s3e11(CatBoost max_depth 推過上界)、s3e5(LGBBOUND 成員)、s3e16(learning_rate 推過邊界)三場各自被驗證為單一最大槓桿之一;s3e7 的 harness v3 自動邊界偵測提供第四個獨立確認資料點。

7. 誠實但書

- 全數 CV-only,除 s3e16 外(tier2「與」tier4 皆已 LB 驗證):**其餘九場的 tier4 皆為 Phase G-1a/G-1b 以 `log_experiment_v2` 入帳的樹搜尋(tree-search)結果,全數為 OOF-only 搜尋產物——未產生任何 test 預測、未提交 Kaggle,對應 experiments.json 筆記皆無 `submission` 欄位。
- s3e19 的 CV 方案差異:**generic baseline 使用隨機 shuffle KFold,而 skill 流程 (tier2/tier3)與樹搜尋(tier4)皆使用 TimeSeriesSplit,兩者不可直接比較,故 tier1 標「無可比 generic」。tier4 額外帶有 fold-5 double-dip 與

scale/seed 皆為 OOF-fitted 的警語,真實預期的 SMAPE 應讀作「明顯低於 10.02」而非字面上的 9.76。

- **s3e16 的取整口徑**:tier2-tier4 皆為「四捨五入到整數後」的 OOF MAE,非 collect.py 一般 adapter 輸出的原始 blend_oof_mae;tier4 是本場第二起 raw/rounded 反轉案例——其原始 OOF 比線性冠軍的原始分數更差,取整後卻更優,決策必須以取整分數為準。
- **s3e20 無真正的 generic 基線**:此賽 2023 已關閉,非本週末批次 run_competition.py 範圍內的競賽,tier1 是同 CV 方案下的 proxy 基線,非嚴格意義的 generic-batch 對照;Late Submission 已關閉,tier1-tier4 全數無法實際提交。tier4 明確排除低信心的 GBDT-blend 手足節點(21.0332,3 折 CV 下的邊際發現),採用穩健的純結構節點(21.0589)。
- **s3e9 的 tier4 = tier3(平手,非缺漏)**:樹搜尋精確追平(而非打敗)線性迭代最佳,顯示該場資料噪音上限已被線性迭代摸到頂; build_benchmark_table.py 的 is_tree_entry() 偵測到 s3e9 的 experiments.json 中並無任何樹搜尋筆記錄,tier4 機械式地等於 tier3,如實反映此一平手結果。

8. 總結敘事

四層消融的設計初衷,是把「導入 skill 有沒有用」拆成三個可獨立檢驗的問題:tier1→tier2 隔離出 kaggle-agent skill 六階段流程本身的價值(EDA、特徵工程、CV 設計、建模一次到位地取代 generic baseline 的無腦 blend);tier2→tier3 隔離出自我改進迭代與跨競賽經驗庫的價值(把單場驗證過的配方系統化地套用到後續競賽);tier3→tier4 隔離出樹搜尋這種搜尋式設計本身的價值,對應 Aygün 等人 ERA 論文「候選樹取代線性單路徑迭代」的核心主張。十場的結果顯示三層隔離都拿到正向訊號——沒有一場在任何一層出現整體倒退。

三層的增益量級並不均勻,而這種不均勻本身就是資訊:tier1→tier3 的最大增益來自「資料本身藏著一個結構性洞見」的競賽——s3e20 發現目標跨年近乎恆定(+25.70% 至 tier4)、s3e5 發現離散化指標需要指標感知的後處理(+19.21% 至 tier4);而已經被 generic baseline 逼近天花板的競賽(s3e7、s3e9、s3e11、s3e14)增量普遍落在 1% 以內,說明 skill 流程與迭代的邊際報酬會隨資料本身的可壓縮空間縮小而遞減。tier3→tier4 的樹搜尋則在九場拿到額外正向增益、一場(s3e9)誠實追平,證實搜尋式設計即使疊加在已充分線性迭代過的結果之上,仍能靠 explore-burst mega-blend 與 boundary-push 兩種機制系統性地擠出殘餘空間。

誠實但書是這整個階梯設計的一部分,而非事後補救:s3e9 的平手被如實記錄而非美化成勝利, s3e16 的 raw/rounded 反轉兩次出現且每次都以取整分數而非原始分數做決策,s3e19 的 CV 方案差異與雙重擬合警語被逐層攜帶而非在推進到下一層時悄悄丟棄,s3e20 的 tier1 proxy 身份與低信心節點排除都被明確標注。十場中僅 s3e16 有真實 Kaggle LB 錨點,而它恰好同時驗證了 tier2 與 tier4 兩層——CV↔LB gap 在兩次獨立提交間維持同一量級同方向,是這整套四層消融方法論目前最強的外部信度證據。

這個階梯本身尚未走到終點:tier5(樹搜尋 + 外部想法注入)已於 Phase J 定義並執行中,是 ERA 論文第二支柱(想法注入)在本專案的具體實作,控制變因為與 tier4 同 folds、同評估器,唯一差異是 idea_bank 注入與重組(recombination)mutation。待其收官後,本報告將擴充為五層對照,並補上尚待驗證的問題:外部文獻想法注入能否在已被本專案經驗庫與樹搜尋兩層榨過的競賽上,再擠出系統性而非噪音級的增益。

重現方式

```
uv run python3 docs/scripts/build_benchmark_table.py
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py docs/SUMMARY_REPORT.md docs/benc
bash .claude/skills/kaggle-report/assets/md2pdf.sh docs/SUMMARY_REPORT.md docs/SUMMARY_REPORT.pdf
```