

十場競賽逐階段效能總報告(playground-series 週末批次)

全案共同的研究設計、實驗流程、工具鏈、術語與五階段定義,見《前言》(docs/PREFACE.pdf)。本報告由自動化報告流程產生:所有數字直接取自跨場彙總的原始紀錄並經自動一致性驗證,敘述由 AI 彙整。素材範圍:本週末批次 10 場 playground-series 競賽的完整逐階段軌跡(階段 1-4)。定位:本報告是讀者友善的敘事版總結,供督導一次比較十場全貌;另有同一份數字的精簡 資料附錄,兩者互補、不重複維護。

目錄

1. 總覽

2. 使用工具與環境

3. 十場逐階段總表

4. 逐場一行摘要表

5. 真實排行榜驗證

6. 跨場驗證的配方

7. 可信度與補充說明

8. 總結敘事

重現方式

1

2

2

3

4

4

4

5

6

1. 總覽

本報告把本週末批次 10 場 playground-series 競賽的「無 skill 基線 → kaggle-agent skill 流程 → self-improvement 線性迭代 → 樹搜尋」逐階段對照結果,整理成單一份可一次讀完的總報告。各階段構成一組對照實驗,逐階隔離出一種價值來源(完整定義見《前言》第 6 節):

階段	定義	隔離出的價值
1	無 skill 基線——Claude Code 直接執行通用批次管線(固定 LGB+XGB+CAT blend,無 EDA、無特徵工程、無逐場決策)	基線(無 skill)
2	完整 kaggle-agent skill 六階段流程最佳分數(線性自我迭代之前)	skill 流程本身
3	線性迭代最終最佳分數(線性自我迭代後,不含樹搜尋)	自我改進迭代 + 跨競賽經驗庫
4	樹搜尋後之最佳分數,即階段 3 之上再疊加樹搜尋結果	搜尋式設計(對應 Aygün 等人 ERA 的樹搜尋主張)

階段 5 預告:樹搜尋 + 外部想法注入(ERA 第二支柱、計畫書 4.1)已定義並執行中—— 本報告暫僅涵蓋階段 1-4, 階段 5 待收官後另行併入本表。

2. 使用工具與環境

工具	用途
LightGBM / XGBoost / CatBoost	三個梯度提升樹基礎模型,十場皆用於 blend 主體
Optuna	階段 3 超參搜尋(代理折或直接優化最終指標,依資料規模擇一)
自建樹搜尋工具(v1/v2/v3)	階段 4 對全部 10 場搜尋特徵集/模型組合/超參空間
OptimizedRounder 等指標特化後處理	整數取整(s3e16)、序數切點優化(s3e5)、離散格點貼齊(s3e14)
5-fold CV / StratifiedKFold / TimeSeriesSplit / Leave-One-Year-Out	依資料型態擇一,見各競賽報告第 3.3 節
uv	Python 套件與虛擬環境管理,所有腳本皆以 uv run 執行

十場的共通分工邏輯:Claude Code(LLM)負責問題理解、驗證策略、特徵工程與何時停損等 決策;Auto-ML 工具(Optuna、樹搜尋工具)負責系統化執行超參搜尋、集成與組合空間探索。

3. 十場逐階段總表

競賽	指標	階段 1	階段 2	階段 3	階段 4	階段1→4 相對變化
s3e1(加州房價)	rmse(↓)	0.56166	0.558768	0.557088	0.556329	+0.95%
s3e3(離職預測)	roc_auc(↑)	0.81624	0.832925	0.83814	0.845051	+3.53%
s3e5(酒質,QWK)	quadratic_weighted_kappa(↑)	0.47871	0.52687	0.56769	0.57066	+19.21%
s3e7(訂房取消)	roc_auc(↑)	0.89882	0.899395	0.899893	0.900455	+0.18%
s3e9(混凝土強度)	rmse(↓)	12.54287	12.073474	12.070034	12.070034(平手)	+3.77%
s3e11(媒體成本)	rmsle(↓)	0.29723	0.296143	0.295648	0.29528	+0.66%
s3e14(藍莓產量)	mae(↓)	341.40782	340.711795	340.59891	340.35572	+0.31%
s3e16(蟹齡,取整 MAE)*	mae(取整,↓)	1.35441	1.33812	1.33812	1.33563	+1.39%
s3e19(銷量預測,SMAPE)*	smape(↓)	無可比分數*	10.175397	10.019463	9.75707	+4.11%(階段2→4)

競賽	指標	階段 1	階段 2	階段 3	階段 4	階段1→4 相對變化
s3e20(盧安達 CO2)*	rmse(↓)	28.3424(代理)*	22.6488	21.1487	21.0589	+25.70%

計分方式注記(僅四場需要,其餘六場為乾淨對照) - s3e19:階段 1(5.31891,隨機 KFold)與階段 2/3/4(TimeSeriesSplit)CV 方案不同、不可比較——test 為嚴格未來期,隨機 KFold 是內插式樂觀估計。本列「階段 1」故標「無可比分數」,相對變化欄改報 階段2→4。 - **s3e16:**階段 2-4 皆為取整計分,非一般流程輸出的原始分數;階段 2=階段 3(線性迭代兩輪未通過取整門檻,依協定誠實停止)。 - **s3e20:**此賽 2023 已關閉,不在本週末批次的通用批次範圍內,階段 1 為同 CV 方案下的代理基線(加入 loc-week 目標編碼之前的 GBDT blend),非嚴格通用批次對照;逾期提交已關閉,全部階段皆 CV-only。 - **s3e9:**階段 4 = 階段 3(12.070034,精確平手,非缺漏)——樹搜尋精確追平(而非打敗)線性最佳,顯示該場資料噪音上限已被線性迭代摸到頂,是誠實記錄而非搜尋失敗。

十場中,階段 4 相對於階段 3 全數未退步(9 場改善、1 場精確持平,s3e9)——符合計畫書目標三 (效能不退步)的跨場證據。

4. 逐場一行摘要表

競賽	關鍵招式	一句結論
s3e1	地理密度/最近距離特徵 + Optuna(代理折)入池 + seed bagging	樹能自行切分座標,粗粒度地理 target encoding 反而冗餘,原始幾何度量才是真增益
s3e3	移除類別不平衡加權、收緊正則化,再以 Optuna 直接優化完整 CV 上的 ROC-AUC	排名指標下,擾動損失面的不平衡加權是壞交易,直接優化最終指標才是正解
s3e5	OptimizedRounder 取代直接四捨五入,Optuna 目標函式直接設為後處理後的 QWK	離散化指標必須用指標本身驗證增益,不能靠代理 loss 再套後處理
s3e7	剪除與目標無關的日期欄位特徵,Optuna 代理折調參後加入池(不取代)	特徵不是越多越好,調參配方對第二個模型重複套用反而傷 blend 多樣性
s3e9	正則化與特徵工程合力對抗重複列標籤噪音,seed bagging 是調參停滯後唯一持續生效的作法	資料噪音天花板下,樹搜尋精確追平而非打敗線性最佳,是誠實的天花板驗證
s3e11	fold-safe 門市目標編碼為最大單一增益,CatBoost 深度推過 Optuna 搜尋邊界	邊界推進是本場單一最大增益來源,值得成為標準變異型別
s3e14	剪除近完美共線特徵,Optuna 調參 LGB 加入池,樹搜尋探索爆發 mega-blend 收尾	solo 分數普通的成員能拿到最大 blend 權重,探索爆發機制是後期突破的唯一來源
s3e16	目標取整為最大增益來源,樹搜尋節點延續原始/取整反轉並實際提交取得雙榜改善	決策指標必須是取整後分數;本場是十場中唯一同時擁有階段 2 與階段 4 真實 LB 對照的競賽
s3e19	log1p 目標 + 日曆特徵,TimeSeriesSplit 下對最後一折做 Optuna 代理調參 + 兩輪 seed bagging	时序外推情境必須用 TimeSeriesSplit;比例分解結構化方法在總量本身難外推時輸給 GBDT
s3e20	發現目標跨年近乎恆定,純 location-week 歷史均值完勝所有 GBDT,再以三段去噪疊加增益	結構訊號已飽和到連殘差層都榨不出更多可預測性,GBDT 全程權重歸零

5. 真實排行榜驗證

十場中僅 **s3e16** 擁有真實 Kaggle 排行榜對照,且是唯一同時具備階段 2「與」階段 4 兩筆 真實提交的競賽,其餘九場的階段 4 皆為 OOF-only(見第 7 節)。

提交	對應階段	日期	Public	Private
#1	2/3 (第 1 次實驗,線性迭代冠軍)	2026-07-03	1.34356	1.34075
#2	4 (第 5 次實驗,樹搜尋 node #15)	2026-07-06	1.34315	1.33859

雙榜改善 (提交#2 相對提交#1):

Public : $1.34356 - 1.34315 = 0.00041$

Private: $1.34075 - 1.33859 = 0.00216$

兩榜皆對提交#1 改善、方向一致——是這套樹搜尋配方第一次獲得的外部(真實排行榜)驗證,而非僅 OOF 內部比較。決策指標全程為取整後 OOF MAE(1.33812→1.33563),而非一般流程輸出的原始分數(完整算式與 CV↔LB gap 一致性檢查見該場競賽報告第 3.5 節)。

6. 跨場驗證的配方

- Optuna(代理折或直接優化最終指標)→入池(不取代原成員)→seed bagging:**在 s3e1、s3e3、s3e7、s3e9、s3e11、s3e14、s3e19 共七場一致驗證有效,是目前樣本量最大的 耐用配方;已知邊界是 s3e16——目標需取整時,同一配方在原始 OOF 上的增益可能無法穿越 四捨五入的離散邊界,必須以取整分數而非原始分數做決策。
- 指標感知後處理三式:**整數目標直接四捨五入 (s3e16)、序數目標配 OptimizedRounder 對 OOF 指標調切點(s3e5,遠勝直接 四捨五入)、離散格點目標貼齊最近的訓練集觀測值(s3e14);三者都比「不做後處理」或「僅 clip」穩定勝出,且都必須用指標本身(而非代理 loss)驗證增益是否成立。
- 探索爆發 + mega-blend(樹搜尋階段 4 機制):**樹搜尋工具強制觸發的探索爆發,在 s3e3(規模曲線驗證跑)、s3e7(v3 驗證跑)、s3e14(v1 與 v3 驗證跑)皆為後期突破的唯一 貢獻來源;共通模式是「solo 分數不特別亮眼、卻拿到最大 blend 權重」的成員——s3e14 的 EXPL_CATDEEP/EXPL_REGDEEP、s3e19 的 CALSUBSET、s3e1 的 CEILING 組合成員皆屬此類。
- 邊界推進:**當 Optuna 調參結果卡在搜尋空間邊界上時,把「推過邊界」當成標準 mutation 型別,在 s3e11(CatBoost max_depth 推過上界)、s3e5(LGBBOUND 成員)、s3e16(learning_rate 推過邊界)三場各自被驗證為單一最大增益來源之一;s3e7 的樹搜尋 工具第 3 版自動邊界偵測提供第四個獨立確認資料點。

7. 可信度與補充說明

- **全數 CV-only,除 s3e16 外(階段 2「與」階段 4 皆已 LB 驗證):**其餘九場的階段 4 皆為 樹搜尋結果,全數為 OOF-only 搜尋產物——未產生任何 test 預測、未提交 Kaggle,對應實驗紀錄皆無 提交欄位。

- **s3e19 的 CV 方案差異**:通用批次基線使用隨機 shuffle KFold,而 skill 流程 (階段 2/3)與樹搜尋(階段 4)皆使用 TimeSeriesSplit,兩者不可直接比較,故階段 1 標「無可比分數」。階段 4 額外帶有 fold 5 雙重使用與 scale/seed 皆對 OOF 擬合的警語,真實預期的 SMAPE 應讀作「明顯低於 10.02」而非字面上的 9.76。
- **s3e16 的取整計分**:階段 2-4 皆為「四捨五入到整數後」的 OOF MAE,非一般流程輸出的原始分數;階段 4 是本場第二起原始/取整反轉案例——其原始 OOF 比線性冠軍的原始分數更差,取整後卻更優,決策必須以取整分數為準。
- **s3e20 無真正的通用批次基線**:此賽 2023 已關閉,非本週末批次通用批次範圍內的競賽,階段 1 是同 CV 方案下的代理基線,非嚴格意義的通用批次對照;逾期提交已關閉,階段 1-4 全數無法實際提交。階段 4 明確排除低信心的 GBDT-blend 手足節點(21.0332,3 折 CV 下的微小發現),採用穩健的純結構節點(21.0589)。
- **s3e9 的階段 4 = 階段 3(平手,非缺漏)**:樹搜尋精確追平(而非打敗)線性迭代最佳,顯示該場資料噪音上限已被線性迭代摸到頂;跨場彙總流程偵測到 s3e9 的實驗紀錄中並無任何樹搜尋筆數,階段 4 機械式地等於階段 3,如實反映此一平手結果。

8. 總結敘事

逐階段對照的設計初衷,是把「導入 skill 有沒有用」拆成三個可獨立檢驗的問題:階段1→2 隔離出 kaggle-agent skill 六階段流程本身的價值(EDA、特徵工程、CV 設計、建模一次到位地取代通用批次基線的固定 blend);階段2→3 隔離出自我改進迭代與跨競賽經驗庫的價值(把單場驗證過的配方系統化地套用到後續競賽);階段3→4 隔離出樹搜尋這種搜尋式設計本身的價值,對應 Aygün 等人 ERA 論文「候選樹取代線性單路徑迭代」的核心主張。十場的結果顯示三段隔離都拿到正向訊號——沒有一場在任何一階出現整體倒退。

三段的增益量級並不均勻,而這種不均勻本身就是資訊:階段1→3 的最大增益來自「資料本身藏著一個結構性洞見」的競賽——s3e20 發現目標跨年近乎恆定(+25.70%至階段 4)、s3e5 發現離散化指標需要指標感知的後處理(+19.21%至階段 4);而已經被通用批次基線逼近天花板的競賽(s3e7、s3e9、s3e11、s3e14)增量普遍落在 1% 以內,說明 skill 流程與迭代的增益幅度會隨資料本身的可壓縮空間縮小而遞減。階段3→4 的樹搜尋則在九場拿到額外正向增益、一場(s3e9)誠實追平,證實搜尋式設計即使疊加在已充分線性迭代過的結果之上,仍能靠探索爆發 mega-blend 與邊界推進兩種機制系統性地擠出殘餘空間。

如實揭露是這整個階梯設計的一部分,而非事後補救:s3e9 的平手被如實記錄而非美化成勝利, s3e16 的原始/取整反轉兩次出現且每次都以取整分數而非原始分數做決策,s3e19 的 CV 方案差異與雙重擬合警語被逐階攜帶而非在推進到下一階時悄悄丟棄,s3e20 的階段 1 代理身份與低信心節點排除都被明確標注。十場中僅 s3e16 有真實 Kaggle LB 對照,而它恰好同時驗證了階段 2 與階段 4 兩階——CV↔LB gap 在兩次獨立提交間維持同一量級同方向,是這整套逐階段對照方法目前最強的外部信度證據。

這個階梯本身尚未走到終點:階段 5(樹搜尋 + 外部想法注入)已定義並執行中,是 ERA 論文第二支柱(想法注入)在本專案的具體實作,控制變因為與階段 4 同折、同評估器,唯一差異是外部想法庫注入與重組 mutation。待其收官後,本報告將擴充為五階對照,並補上尚待驗證的問題:外部文獻想法注入能否在已被本專案經驗庫與樹搜尋兩層榨過的競賽上,再擠出系統性而非噪音級的增益。

重現方式

```
uv run python3 docs/scripts/build_benchmark_table.py
uv run python3 .claude/skills/kaggle-report/assets/verify_report.py docs/SUMMARY_REPORT.md docs/benchmark
bash .claude/skills/kaggle-report/assets/md2pdf.sh docs/SUMMARY_REPORT.md docs/SUMMARY_REPORT.pdf
```