

混合式 LLM+AutoML agent 於 Kaggle 表格競賽的受控 消融研究(技術報告草稿)

草稿:本文把整個專案綜合成研究溝通用的技術報告,供後續精修為正式報告/論文草稿。所有量化結果取自可重現的原始紀錄,並經自動一致性驗證(見各引用檔)。

目錄	
摘要	1
1. 引言	1
2. 對齊 Aygün 等人 ERA	2
3. 方法	2
4. 實驗設定	2
5. 結果	2
6. 分析與跨場發現	3
7. 限制	3
8. 結論與未來工作	4

摘要

我們評估「Claude Code(大型語言模型 agent)+ 梯度提升樹 AutoML(LightGBM/XGBoost/ CatBoost)」的混合式 agent,能否自主完成 Kaggle 表格競賽的完整資料科學流程,並用**受控 消融**量化每項自主能力的邊際貢獻。做法是同一場競賽以遞增配置各解一次——(1)無 skill 基線、(2)加結構化競賽流程 skill、(3)加線性自我迭代與跨競賽經驗庫、(4)加樹搜尋(候選樹 取代線性單路徑)、(5)加外部文獻想法注入——再比較分數。在 15 場競賽(10 場同季第三季主 benchmark + 5 場跨第 4–6 季、五種指標)上,遞增階梯**場場成立、無一場在任一階整體倒退**;增益集中於「資料藏有結構性洞見」的場次。跨季配方仍成立但增幅收斂。對五場跨季做 paired bootstrap 顯示端到端階梯的總改善**統計顯著**,但個別階段在較小樣本場次可落入 OOF 估計噪音內。關於 ERA 第二支柱(外部想法注入),我們誠實報告:先驗原為 write-only(構造成性 no-op),我們**建置了真正的注入機制並實測**,結論為「機制可行,但外部注入在測試場無可量測系統性 增益(null)」——一個嚴謹的負面結果。本工作對應 Aygün 等人(2026)ERA 系統的兩大支柱。

1. 引言

Kaggle 表格競賽是評估自主資料科學 agent 的實務基準。既有工作多報告「end-to-end 能不能拿到好分數」,少有**逐能力的受控歸因**。本文的研究問題是:**每加一項自主能力,分數各改善多少、是否統計顯著、在什麼條件下失效?** 貢獻有四:(a)一套五階段消融協定 + 全自動、數字可追溯的報告產生管線;(b)15 場、五種指標

的跨競賽證據;(c) 跨季泛化與統計顯著性的 誠實校準;(d) ERA 第二支柱(外部知識注入)的機制建置,與「機制可行、邊際價值 null」的嚴謹負面結果。

2. 對齊 Aygün 等人 ERA

Aygün 等人(2026,Nature)的 ERA 系統有兩大支柱:以**候選樹搜尋**取代線性單路徑優化,以及注入**外部知識**引導搜尋。本工作的階段 4(自建樹搜尋:候選樹 + 回溯 + 預算相位機)對應第一支柱;階段 5(文獻想法庫 + 注入鉤 + plateau 注入)瞄準第二支柱。第 6 節報告:第二支柱先驗原為 write-only(J-3),我們接線並實測後,誠實結論為「機制可行、邊際價值 null」——這是與 ERA 對齊上最誠實的一筆。

3. 方法

五階段消融:階段 1 無 skill 基線 → 2 kaggle-agent skill 的結構化六階段(EDA→CV 設計→特徵→建模→指標感知後處理→提交)→ 3 線性自我迭代(經驗庫先驗、Optuna、seed bagging) → 4 樹搜尋(候選樹取代線性單路徑)→ 5 外部想法注入。同場所有階段共用同一組折,分數 才可直接比較。

樹搜尋(自建,三版演進):節點為候選配置(solo 或 blend),以 OOF 分數評分;lineage plateau 後回溯、探索爆發(kitchen-sink mega-blend),預算相位機先廣後深排程並自動停止。

報告產生與雙閘門:報告數字由程式從原始紀錄抽取,經**數字可追溯性閘門**(報告中每個數字必須能追溯到事實表)驗證;可提交場次另設**OOF 逐位重現閘門**(最佳解成員全部從頭重訓、逐位比對 OOF 與搜尋快取一致,才產生 test 預測)。全流程以 uv 管理、可重現。

4. 實驗設定

15 場 Kaggle Playground:10 場第三季(S3,同季週末批次,主 benchmark)+ 5 場跨第 4–6 季 (S4–S6)。五種官方指標:RMSE、ROC-AUC、accuracy、QWK、 R^2 。交叉驗證一律 5 折(依資料選分層/分箱/時序/隨機)。本地分數一律為 OOF;可提交場次以排行榜複核。逐場資料規格、實驗總表與重現指令見各場競賽報告第 3、7 節;跨場彙總見 docs/SUMMARY_REPORT。

5. 結果

(R1)遞增階梯場成立:15 場的階段 1→4 全為正向或持平,無一場在任一階整體倒退 (計畫書目標三:效能不退步的跨場證據)。

(R2)增益分布反映結構:大增益集中於結構性洞見場(s3e20 +25.7%、s3e5 +19.2%);已被基線逼近天花板的場次增量普遍 <1%。agent 的價值在「找到並利用結構」,非無差別堆疊。

(R3)真實排行榜驗證:s3e16 是唯一有真實 LB 對照者;樹搜尋版對線性版於 Public 與 Private **兩榜同方向改善**,CV↔LB 落差兩次提交一致——外部信度證據。

(R4)跨季泛化:五場跨季(五種指標)階梯仍場場成立,增幅較 S3 收斂。

(R5)統計顯著性(paired bootstrap):五場跨季的端到端階梯(base blend→ 樹搜尋贏家)總改善全部超出 OOF 估計噪音、統計顯著;但個別階段(尤其樹搜尋那一步)在兩個較小樣本場次(s4e1、s4e11)落在噪音內——其可解析度隨驗證列數 n 增加。誠實結論:信「累積的階梯」,不過度宣稱任何單一 0.0x% 步(詳見 docs/statistical_rigor)。

6. 分析與跨場發現

(F1)經驗庫先驗必須逐場檢驗——同一先驗可得相反結論:交互項先驗在 s5e10、s6e2 被對照檢驗確認、卻在 s6e1 被否決;類別不平衡加權先驗在不同指標場各有適用邊界。先驗要連同適用條件一起搬。

(F2)指標決定後處理,不是目標外觀決定:整數目標配取整(s3e16)、序數配切點優化(s3e5);但 s5e10 目標雖落 0.01 格點,對 RMSE 貼格點反而有害(平方誤差要條件均值)。

(F3)樹搜尋的贏家形狀因資料而異:mega-blend、系譜血統 blend、單一模型各有奪冠場次——固定套路會賭錯形狀,搜尋會就地找對的那個。

(F4)可重現性紀律:跨場最佳解全數通過 OOF 逐位重現閘門;修掉 LightGBM 跨進程非決定性後達 $\max|dOOF|=0$ 的位元級重現。

(F5,負面/架構)外部注入:機制可建,但邊際價值為 null:先以單一變因對照(harness_v4 只切注入 mode)發現 off 與 ext 的搜尋樹逐位元相同(構造性 0)——根因是 suggest_priors 的回傳只寫入 tree['priors'] 供記錄、沒有任何搜尋算子讀它,經驗庫知識實際是透過 driver 手寫種子引導而非自動 plumbing。隨後建置了真正的注入機制(idea_injection.py:讀 idea_bank → 篩選去重 → 翻譯成搜尋候選 → 標 provenance,plateau 觸發、限次數)並在階段4 收斂點以快取 OOF 對 15 場實測(rank averaging + 通用的 stacking 翻譯器涵蓋非 AUC 場):外部注入從未產生勝過階段4 的候選——階段5 = 階段4(全 15 場持平);過程抓除兩個假正例(s3e7 弱基線、s3e20 榨出的已排除 CV 噪音)。為什麼 null:(1) 階段4 的 OOF 權重搜尋已在成員池近最優,可乾淨注入的想法(rank/stacking)只是重組同批成員、贏不過它;(2) stacking 更有彈性 → 過擬合 CV 噪音、且對非平方誤差指標不對齊(MAE/SMAPE 場明顯更差);(3) 有用的領域想法早已被作者手寫進搜尋;(4) 訊號已被前四階段榨到噪音地板;(5) 能帶來新訊號的想法(對抗驗證等)需新特徵/重訓且資料相依。外部知識只在引入搜尋錯過的新訊號時才有價值,而這些成熟表格題幾無被錯過的結構可撿。這不否定階段 4 樹搜尋的價值(其增益來自搜尋機制本身)。可重現: docs/scripts/stage5_sweep.py ;詳見 docs/phase_j_j3_findings。

7. 限制

- **CV-only**:多數場次(尤其跨季)競賽已關榜,除 s3e16 外僅有本地 OOF(+ 部分前季 LB 錨點),缺當前真實 LB 對照。
- **統計範圍**:R5 的 bootstrap 只量 OOF 估計的抽樣變異,非重跑搜尋(換 seed/折/Optuna) 的變異——後者需重訓、本文未做;故 CI 為不確定性下界,個別「顯著」可能仍 seed-fragile。
- **第二支柱邊際價值 null**(F5):注入機制已建置並實測,但外部注入在測試場無可量測系統性增益;此為嚴謹負面結果,非機制缺陷。

- **單一 agent、單一 driver 模式**:各場 driver 的先驗種子為手寫,未系統化自動生成。

8. 結論與未來工作

遞增自主能力在 15 場、五種指標上帶來一致(場場不退步)、且**端到端統計顯著**的增益, 增益大小反映資料的結構可利用性;跨季仍成立但收斂。ERA 第二支柱(外部注入)的機制已建置 並實測,誠實結論為「機制可行、邊際價值 null」(F5)。未竟工作:多種子/多折的搜尋變異 研究(把「顯著」由 OOF 下界升級為重跑穩健)、開放場次的真實 LB 驗證、跨出表格題的評估 拓寬;以及若要續探第二支柱,需實作「需重訓/新特徵」類的外部想法(對抗驗證、頻率編碼), 但從目前一致型態看報酬遞減。

可重現與出處:各場競賽報告(competitions/playground-series-*/REPORT.md)、跨場彙總 (docs/SUMMARY_REPORT)、成果簡報(docs/PROJECT_BRIEF)、統計嚴謹度(docs/statistical_rigor + docs/scripts/bootstrap_ci.py)、J-3 發現(docs/phase_j_j3_findings)、benchmark 事實表 (docs/benchmark_facts.json + docs/scripts/build_benchmark_table.py)。方法與術語見 docs/PREFACE。