

週末自主執行總結(2026-07-03 五晚 → 07-04 六午)

使用者下班前授權自主執行 2-3 天有意義的專案工作。實際上以約 19 小時連續自主運行完成了原定計畫(Phase A-C)並超前擴展(Phase D-H)。本文為總覽;所有數字之權威出處為各競賽 experiments.json / experiments_tree*.json 與 docs/ 下各報告(皆經 verify_report.py 驗證)。

一句話總結

8 場基線題補齊完整 skill 流程並全數擊敗通用基線;10 場自我改進迭代蒸餾出 52+ 條證據型經驗庫;樹搜尋原型從 v1 迭代到 v3,對線性迭代取得 9 勝 1 精確平,並正式接入 kaggle-agent skill 成為 Stage 4 預設迴圈。

各 Phase 完成內容

Phase	內容	關鍵成果
A(8 單元)	8 場批次題完整 skill 六階段 + 報告	8/8 勝 generic 基線;每場 REPORT.md/PDF 過 verify
B(11 單元)	經驗庫 + 10 場自我改進迭代	knowledge/experience.md(52 條證據型);9/10 場再改善
C(4 單元)	benchmark 彙總 + 樹搜尋 v1 原型(3 場)	v1:1 勝 1 平 1 負 → 找到 ensemble 節點空間缺口
D(7 單元)	harness v2(4 升級) + 5 場掃描	5/5 勝;「先驗定下限、在地洞見定上限」模式
E(5 單元)	v2 補完(復仇/平反/酸性/結構)+ 規模實驗	s3e9 精確追平;s3e5 平轉勝;s3e16 穿越取整邊界;80 節點曲線 → 預算規則
F(3 單元)	harness v3(預算相位機等 6 特性)+ 驗證 + 最終報告	v3 兩場再刷新紀錄;burst+mega-blend 3 戰 3 勝
G(2 單元)	收割:樹最佳入帳 experiments.json + 全報告更新 + benchmark tier-4	四層對照表;一切成果可從正式紀錄回溯
H(2 單元)	v3 上線三需求(resume/timeout/sanity gate)+ skill 接入	82 測試全綠;references/07_tree_search.md;Stage 4 正式升級

Benchmark 四層對照(tier1 generic → tier4 樹搜尋後,相對改善)

s3e20 +25.70%、s3e5 +19.21%、s3e19 +4.11%(t2→t4)、s3e9 +3.77%(t4=t3 精確平)、s3e3 +3.53%、s3e16 +1.39%、s3e1 +0.95%、s3e11 +0.66%、s3e14 +0.31%、s3e7 +0.18%。詳表與口徑注意事項見 docs/benchmark_summary.md (+PDF)。

三個可重現的研究發現(詳見 docs/tree_search_prototype.md)

1. **先驗定下限、在地洞見定上限**:經驗庫先驗讓搜尋不走死路(多場 informed 勝率顯著高於 uninformed),但每場最大的單筆增益幾乎都來自該場自己的未驗證假設(冗餘欄剪枝、top-code clip、auto_scale、深度邊界推)。
2. **強制 explore burst + mega-blend**:三次觸發三次貢獻 100% 的後期增益(E-5、F-2×2)——探索爆發不是選配。
3. **邊界推(boundary-push)**:Optuna 最優卡在搜尋盒邊緣是常態而非例外(≥ 3 場),把「推過邊界」做成標準 mutation 有實質回報。

誠實但書(重要)

- 除 s3e16 有真實 LB 錨點(Public 1.34356/Private 1.34075,提交於樹搜尋之前)外,全部分數皆為本地 CV/OOF,未提交 Kaggle(未動任何憑證)。樹搜尋 blend 未產出測試集預測,報告中皆標「未提交/CV-only」。
- s3e19 的 9.757 帶 fold-5 double-dip 與 OOF 上擬合縮放之樂觀偏差(紀錄在案);s3e20 的 21.03 blend 為低信度未入帳(入帳的是穩健的 21.0589 純結構節點)。
- v3 的自動停止在實戰兩跑皆由硬上限收場(burst 持續改善屬正確行為),耐心路徑僅在小預算煙霧驗證過。
- Phase B 曾將 s3e20 的 experiments.json 就地遷移 v2(偏離「舊紀錄不改」原則;已驗證無資料損失)。

主要交付物索引

- docs/benchmark_summary.md/.pdf — 十場四層對照
- docs/tree_search_prototype.md/.pdf — 樹搜尋 v1→v3 全弧(15 次執行)
- docs/scaling_experiment.md/.pdf — 80 節點規模曲線與預算規則
- knowledge/experience.md — 跨競賽經驗庫(證據型)
- tree_search/harness_v3.py + 82 綠測試 — 可上線的樹搜尋引擎
- .claude/skills/*/references/07_tree_search.md — Stage 4 操作手冊(兩 skill 同步)
- 各競賽資料夾:更新後的 REPORT.md/PDF、STATUS.md、experiments.json(樹最佳已入帳)

給下週的建議

1. **給老師看的順序**:benchmark_summary(成果)→ tree_search_prototype(研究)→ 任一場 REPORT.pdf(流程品質)。這直接對應計畫書目標一/二/三/四的證據。
2. 若要拿 LB 驗證樹搜尋增益:挑 s3e16(Late Submission 開放、有歷史錨點),為樹最佳 blend 產測試預測後提交一次即可對照。
3. v3 後續(非急):auto-stop 耐心路徑的實戰驗證;經驗庫 prior 的自動化注入(ERA 想法注入完整版);跨場樹遷移。

4. 計畫書第 4-5 週(報告模組)與第 6-7 週(樹搜尋)的核心工作已於本週末提前完成,時程可重新配置(例如轉向論文 16 場 benchmark 的其餘場次、或報告 rubric 的人工驗收輪)。